

华南理工大学

South China University of Technology

博士学位论文

面向多智能体合作与共识的分布式进化算法研究

作者姓名	陈泰佑
学科专业	计算机科学与技术
指导教师	陈伟能教授
所在学院	计算机科学与工程学院
论文提交日期	2026 年 3 月 15 日

Doctoral Dissertation

Research on Distributed Evolutionary Computation for Multi-Agent Cooperation and Consensus

Candidate：Tai-You Chen

Supervisor：Prof. Wei-Neng Chen

South China University of Technology

Guangzhou, China

分类号：TP391 **学校代号：10561**

学　号：202210188291

华南理工大学博士学位论文

面向多智能体合作与共识的分布式进化算法研究

作者姓名：陈泰佑　　指导教师姓名、职称：　陈伟能　教授

申请学位级别：工学博士　　学科专业名称：计算机科学与技术

研究方向：人工智能

论文提交日期：　2026 年　3　月　15　日　　论文答辩日期：2026 年　5　月　30　日

学位授予单位：华南理工大学　　学位授予日期：　　年　　月　　日

答辩委员会成员：

主席：_____

委员：_____

华南理工大学
学位论文原创性声明

本人郑重声明：所呈交的论文是本人在导师的指导下独立进行研究所取得的研究成果。除了文中特别加以标注引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写的成果作品。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律后果由本人承担。

作者签名：　　日期：　　年　　月　　日

学位论文版权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，即：研究生在校攻读学位期间论文工作的知识产权单位属华南理工大学。学校有权保存并向国家有关部门或机构送交论文的复印件和电子版，允许学位论文被查阅（除在保密期内的保密论文外）；学校可以公布学位论文的全部或部分内容，可以允许采用影印、缩印或其它复制手段保存、汇编学位论文。本人电子文档的内容和纸质论文的内容相一致。

本学位论文属于：

□保密（校保密委员会审定为涉密学位论文时间：___年__月__日），于___年__月__日解密后适用本授权书。

□不保密,同意在校园网上发布，供校内师生和与学校有共享协议的单位浏览；同意将本人学位论文编入有关数据库进行检索，传播学位论文的全部或部分内容。

（请在以上相应方框内打“ √ ”）

作者签名：　　日期：

指导教师签名：　　日期：

作者联系电话：　　电子邮箱：

联系地址(含邮编)：

摘　要

随着人工智能与复杂网络系统的快速发展，群体智能与自主协同系统逐渐成为国际科技竞争的重要方向，国务院发布的《新一代人工智能发展规划》将群体智能与自主智能系统列为重点研究内容。多智能体系统通过多个具有感知、计算与执行能力的个体协同完成复杂任务，在无人系统集群、智能电网、无线传感器网络等领域具有广阔应用前景。尽管近年来分布式优化与多智能体协同控制取得了大量研究成果，但在面向真实复杂系统时仍面临若干关键挑战：（1）黑箱去中心场景全局共识难，当各节点无法获取全局目标函数或梯度信息时，如何在仅依赖局部函数值与邻域通信的条件下实现全局共识优化仍然困难。（2）分布式合作优化采样协调难，在多智能体协同搜索过程中，各节点的采样方向与采样步长可能存在显著差异，如何在保持个体探索能力的同时实现有效协同与稳定收敛仍有待解决。（3）局部利益冲突协同优化难，当各节点往往具有不同甚至相互冲突的局部目标函数，在局部利益驱动下实现全局目标协同优化同样具有较大挑战。

针对上述问题，本文以进化计算与多智能体共识理论为基础，围绕黑箱分布式优化问题，按照“群体演化协同–采样搜索协同–目标激励协同”的研究思路，构建适用于去中心化多智能体系统的协同进化优化框架。通过将进化计算的全局搜索能力与多智能体共识机制相结合，实现系统共识、搜索自适应性以及目标协调性的统一，从而为复杂分布式系统中的黑箱优化问题提供新的理论方法与算法框架。本文的主要研究工作与贡献包括：

第一，针对黑箱去中心化场景下全局共识难以保证的问题，本文提出一种基于内外部协同学习机制的多智能体共识优化算法。该方法将粒子群优化思想扩展至分布式环境，通过内部学习与外部学习两个阶段实现多智能体种群协同演化。在内部学习阶段，各智能体通过局部粒子群优化其局部目标函数；在外部学习阶段，各智能体通过邻域通信学习邻居种群信息，从而推动系统向全局共识解演化。同时，本文设计了基于惯性速度继承的协同更新策略以及自适应通信机制，在保证系统共识的同时降低通信开销。理论分析与实验结果表明，该算法在黑箱分布式优化问题上具有良好的收敛性能与通信效率。

第二，针对分布式进化优化过程中采样步长难以协同调节的问题，本文提出一种基于协同步长自适应机制的多智能体共识优化算法。该算法通过分析智能体搜索路径之间

的协同关系，提出协作与累积步长自适应机制，使步长能够根据邻域搜索方向的一致性或冲突程度进行动态调整。当多个智能体搜索方向一致时增大步长以增强全局探索能力；当搜索方向冲突时减小步长以提高收敛稳定性。基于该机制构建的多智能体进化策略能够在保持局部搜索能力的同时促进系统共识，并在多种黑箱分布式优化基准函数上取得具有竞争力的优化性能。

第三，针对多智能体系统中局部目标冲突导致协同优化困难的问题，本文提出一种基于适应性目标激励机制的多智能体共识优化算法。该方法通过在局部目标函数中引入可调节惩罚项，引导各智能体在保持局部自治性的同时逐步向全局共识解靠近。同时，设计冲突检测机制，仅在变量存在冲突时引入惩罚项，从而提高惩罚策略的针对性与效率。此外，本文重构了共享变量的协商过程，通过评估、竞争与共享三个步骤实现邻居智能体之间的协同决策。实验结果表明，该方法在复杂分布式优化问题上能够有效缓解局部目标冲突，提高系统整体优化性能。

第四，在现实应用层面，针对无线传感器网络中的多目标协同定位追踪问题中连续变量与离散数据关联变量耦合、搜索空间随目标数量指数增长的挑战，提出一种基于贡献度协作的多智能体粒子群优化算法。通过将原问题重构为双层分布式优化模型，将离散数据关联问题转化为局部确定性求解，从而显著降低分布式协商复杂度。同时，引入基于预测信息的种群注入策略以提升跟踪实时性与共识收敛速度。实验结果表明，该方法在多目标动态场景中能够有效提高定位精度与跟踪效率。

最后，本文研究智能电网中的分布式能源管理问题。针对电动汽车参与下供需动态变化与个体自主决策带来的优化挑战，提出一种改进的多智能体粒子群优化方法。在内部学习阶段，引入自适应定价的演化博弈策略，根据供需偏差动态调整价格信号；在外部学习阶段，设计具有可变邻居权重的协作机制，使智能体根据邻居性能动态分配学习权重。实验结果表明，该方法在不同典型场景下均能稳定系统运行并提高整体收益。

关键词：多智能体系统；去中心化系统；分布式优化；进化计算；共识理论；无线传感器网络；智能电网

Abstract

With the rapid development of artificial intelligence and complex networked systems, swarm intelligence and autonomous cooperative systems have gradually become important directions in international technological competition. Many countries and regions have successively released national strategies for artificial intelligence, in which swarm intelligence, multi-agent systems, and distributed intelligence are identified as key research topics. Multi-agent systems enable multiple agents with sensing, computing, and execution capabilities to collaboratively accomplish complex tasks, showing broad application prospects in unmanned system swarms, smart grids, wireless sensor networks, and other domains. Although significant progress has been made in distributed optimization and multi-agent cooperative control in recent years, several key challenges remain when addressing real-world complex systems: (1) global consensus in black-box decentralized scenarios is difficult; when agents cannot access the global objective function or gradient information, achieving globally consistent optimization using only local function evaluations and neighborhood communication remains challenging. (2) coordinated regulation of sampling exploration step sizes is difficult; during collaborative search, different agents may exhibit significantly different exploration directions and step sizes, and how to maintain individual exploration capability while ensuring effective cooperation and stable convergence is still an open problem. (3) cooperative optimization under conflicting local interests is difficult; when agents possess different or even conflicting local objective functions, achieving global objective optimization under locally driven behaviors becomes highly challenging.

In response to the above challenges, this dissertation is grounded in evolutionary computation and multi-agent consensus theory, and focuses on black-box distributed optimization problems. Following the research paradigm of "population evolutionary collaboration–sampling search collaboration–objective incentive collaboration," a collaborative evolutionary optimization framework suitable for decentralized multi-agent systems is constructed. By integrating the global search capability of evolutionary computation with multi-agent consensus mechanisms, the proposed framework achieves a unified balance among system consensus, search adaptability, and objective coordination, thereby providing new theoretical methods and algorithmic

frameworks for addressing black-box optimization problems in complex distributed systems. The main research contributions of this dissertation are summarized as follows.

First, to address the difficulty of achieving global consistency in black-box decentralized environments, a multi-agent consensus optimization algorithm based on an internal–external collaborative learning mechanism is proposed. This method extends the particle swarm optimization paradigm to distributed environments by introducing two evolutionary stages: internal learning and external learning. In the internal learning stage, each agent optimizes its local objective function through its local particle swarm. In the external learning stage, agents exchange information with their neighbors and learn from neighboring swarms, thereby driving the system toward a globally consistent solution. In addition, a collaborative update strategy based on inertia velocity inheritance and an adaptive communication mechanism are designed to reduce communication overhead while maintaining system consistency. Theoretical analysis and experimental results demonstrate that the proposed algorithm achieves favorable convergence performance and communication efficiency in black-box distributed optimization problems.

Second, to address the difficulty of coordinating sampling step-size adaptation in distributed evolutionary optimization, a multi-agent consensus optimization algorithm with a collaborative step-size adaptation mechanism is proposed. By analyzing the relationships among the search trajectories of different agents, a cooperative and cumulative step-size adaptation mechanism is developed, allowing step sizes to dynamically adjust according to the consistency or conflict among neighboring search directions. When multiple agents move in consistent directions, the step size increases to enhance global exploration capability; when directions conflict, the step size decreases to improve convergence stability. The resulting multi-agent evolutionary strategy promotes system consensus while preserving local exploration capability, and achieves competitive optimization performance on various black-box distributed optimization benchmark problems.

Third, to address the challenge of cooperative optimization under conflicting local objectives, a multi-agent consensus optimization algorithm based on an adaptive objective incentive mechanism is proposed. This method introduces adjustable penalty terms into local objective functions to guide agents toward globally consistent solutions while maintaining local autonomy. A conflict detection mechanism is also designed so that penalty terms are introduced

only when conflicts occur in specific decision variables, thereby improving the efficiency and specificity of the penalty strategy. Furthermore, the negotiation process of shared variables is reconstructed through three stages—evaluation, competition, and sharing—to facilitate cooperative decision-making among neighboring agents. Experimental results show that the proposed method effectively mitigates conflicts among local objectives and improves the overall optimization performance of the system in complex distributed optimization problems.

Fourth, at the application level, to address the challenges in multi-target cooperative localization and tracking in wireless sensor networks—namely the coupling between continuous variables and discrete data association variables, as well as the exponential growth of the search space with the number of targets—a contribution-based cooperative multi-agent population optimization method is proposed. By reformulating the original problem into a bi-level distributed optimization model, the discrete data association is transformed into a locally solvable deterministic problem, thereby significantly reducing the complexity of distributed negotiation. Furthermore, a prediction-based population injection strategy is introduced to improve real-time tracking performance and accelerate consensus convergence. Experimental results demonstrate that the proposed method effectively improves localization accuracy and tracking efficiency in dynamic multi-target scenarios.

Finally, this dissertation investigates the distributed energy management problem in smart grids. To address the optimization challenges caused by dynamic supply–demand variations and autonomous decision-making of electric vehicles, an improved multi-agent particle swarm optimization method is proposed. In the internal learning phase, an adaptive pricing mechanism based on evolutionary game theory is introduced, where price signals are dynamically adjusted according to supply–demand imbalance; in the external learning phase, a collaboration mechanism with adaptive neighbor weighting is designed, enabling agents to dynamically assign learning weights based on neighbor performance. Experimental results show that the proposed method can ensure stable system operation and improve overall benefits across various representative scenarios.

Keywords: multi-agent systems; decentralized systems; distributed optimization; evolutionary computation; consensus theory; wireless sensor networks; smart grids

目　录

摘　要 I

Abstract III

插图目录 X

表格目录 XII

主要名词索引 XIII

第一章　绪论 1

1.1　研究背景与意义 1

1.2　研究难点与挑战 3

1.3　研究内容与创新点 4

1.4　论文结构与章节安排 8

第二章　背景知识与研究现状 10

2.1　系统模型与问题定义 10

2.1.1　多智能体系统 10

2.1.2　分布式共识优化问题 10

2.1.3　部分重叠的分布式共识优化问题 12

2.2　分布式优化研究现状 12

2.2.1　共识理论 13

2.2.2　基于梯度的分布式优化方法 13

2.2.3　无梯度的分布式优化方法 14

2.3　进化计算研究现状 14

2.3.1　集中式进化优化算法 15

2.3.2　并行进化计算 17

2.3.3　分布式进化计算 17

2.4　本章小结 18

第三章　基于内外部协同学习的多智能体共识优化算法 19

3.1　引言 19

3.2　基于内外部协同学习的多智能体共识优化算法 20

3.2.1　算法框架 20

3.2.2 内部学习机制 ····· 22
3.2.3 外部学习机制 ····· 23
3.2.4 内外部学习频率调控机制 ····· 24
3.3 内外部协同学习算法的共识证明 ····· 26
3.4 实验 ····· 33
3.4.1 测试基准函数 ····· 33
3.4.2 自适应通信机制的效果验证 ····· 35
3.4.3 与现有算法的比较与分析 ····· 39
3.4.4 算法在不同网络规模与结构上的性能验证 ····· 42
3.5 本章小结 ····· 45
第四章 基于协同步长自适应机制的多智能体共识优化算法 ····· 46
4.1 引言 ····· 46
4.2 分布式优化中演化路径的案例研究 ····· 47
4.2.1 现有的步长自适应方法 ····· 47
4.2.2 现有方法在分布式优化中的表现与分析 ····· 48
4.3 基于协同步长自适应机制的多智能体共识优化算法 ····· 50
4.3.1 算法框架 ····· 51
4.3.2 协同累积步长自适应 ····· 53
4.3.3 CCSA 的工作原理分析 ····· 54
4.3.4 CCSA 的共识分析 ····· 57
4.4 实验 ····· 59
4.4.1 实验设置与基准函数 ····· 60
4.4.2 参数调研 ····· 61
4.4.3 消融实验 ····· 65
4.4.4 与现有算法的对比分析 ····· 66
4.4.5 现实应用问题验证 ····· 70
4.5 本章小结 ····· 71
第五章 基于适应性目标激励的多智能体共识优化算法 ····· 72
5.1 引言 ····· 72

5.2 基于适应性目标激励的多智能体共识优化算法 73
5.2.1 算法框架 74
5.2.2 基于目标激励的局部优化机制 75
5.2.3 多智能体协商机制 76
5.2.4 多智能体冲突检测机制 78
5.3 实验 80
5.3.1 实验设置 80
5.3.2 冲突检测机制的效果验证 81
5.3.3 与分而治之算法的比较与分析 81
5.3.4 与整体式算法的比较分析 84
5.3.5 参数调研 89
5.4 本章小结 91
第六章 基于多智能体共识优化的多目标协同定位追踪方法 93
6.1 引言 93
6.2 问题建模与相关工作 95
6.2.1 系统模型 95
6.2.2 多目标协同定位的问题定义 97
6.2.3 多目标协同定位的相关工作 98
6.2.4 Kuhn-Munkres 算法 98
6.3 多目标协同定位问题的等价转换与复杂度简化 99
6.4 单一时刻的分布式多目标协同定位方法 100
6.4.1 算法框架 101
6.4.2 单传感器局部优化阶段 102
6.4.3 多传感器协作阶段 104
6.4.4 计算复杂度分析 105
6.5 连续运动环境下的分布式多目标协同追踪方法 106
6.5.1 数据关联 106
6.5.2 目标数量动态变化的处理 108
6.5.3 轨迹预测与种群注入 109

6.6 实验 ····· 109
6.6.1 实验设置 ····· 109
6.6.2 自适应通信的效果验证 ····· 110
6.6.3 与现有算法的比较与分析 ····· 112
6.6.4 多目标协同追踪效果验证 ····· 115
6.7 本章小结 ····· 118
第七章 基于多智能体共识优化的分布式能源博弈与管理方法 ····· 119
7.1 引言 ····· 119
7.2 分布式能源博弈与管理问题定义 ····· 120
7.2.1 分布式能源系统 ····· 121
7.2.2 电力节点的损失函数 ····· 121
7.2.3 全局优化问题定义 ····· 123
7.3 基于多智能体共识优化的分布式能源博弈与管理方法 ····· 124
7.3.1 算法框架 ····· 124
7.3.2 基于演化博弈的内部学习 ····· 125
7.3.3 基于可变邻居权重的外部学习 ····· 126
7.4 实验 ····· 127
7.4.1 实验设置 ····· 127
7.4.2 对比算法 ····· 128
7.4.3 优化性能比较与分析 ····· 129
7.5 本章小结 ····· 131
总结与展望 ····· 132
攻读博士学位期间取得的研究成果 ····· 150

插图目录

图 1-1 本文主要研究内容与创新点 5
图 2-1 分布式共识优化的特征示意图 11
图 3-1 MASOIE 的学习机制与流程图 21
图 3-2 MASOIE 的算法时序图 21
图 3-3 当算法采用不同大小的静态间隔时取得的收敛性能 36
图 3-4 当算法采用不同大小的静态间隔时取得的优化性能 37
图 3-5 当算法应用动态间隔机制时，设置不同初始间隔时取得的收敛性能 . . 38
图 3-6 MASOIE 与四种现有算法 GFPDO、RGF、DPSO 和 DA-PSO 的比较 . 40
图 3-7 确定性-MASOIE 在 20、40、60 节点的系统下的收敛表现 42
图 3-8 MASOIE 在 20、40、60 节点的系统下的收敛表现 43
图 3-9 实验测试的四类网络拓扑 44
图 3-10 MASOIE 在不同网络拓扑下的共识表现 44
图 4-1 分布式优化中演化路径的案例研究 48
图 4-2 CCSA-DES 的系统结构与流程 50
图 4-3 提出的 CCSA 在代表案例中的表现 56
图 4-4 针对历史权重 β 的参数调研 61
图 4-5 针对通信间隔的参数调研 63
图 4-6 算法采用衰减角阈值与固定角阈值时的表现 64
图 4-7 所提出算法与当前先进算法的共识性能比较 66
图 4-8 提出的算法与 SOTA 算法在求解质量上的对比 69
图 4-9 CCSA-DES 与对比算法在多目标定位问题上的性能 71
图 5-1 MACPO 算法框架示意图 74
图 5-2 冲突检测示例图 79
图 5-3 MACPO 在优化过程中检测到的共享变量冲突概率 82
图 5-4 局部优化阶段种群与共识解的平均距离变化图 83
图 5-5 MACPO 与 MS-LLSO 的计算时间比率 88
图 5-6 不同网络规模下 MACPO 与 MS-LLSO 的时间开销 89
图 5-7 不同 λ 值下 MACPO 的性能比较 90

图 6-1 多目标协同追踪问题场景与算法框架 101
图 6-2 多目标协同追踪的基本流程 106
图 6-3 采用固定或自适应通信间隔时 MASTER 的分歧度曲线 110
图 6-4 MASTER 及其固定通信间隔变体 MASTER-FC 的时间开销对比 112
图 6-5 MASTER 与对比算法在不同数量的目标和不同的测量技术下的表现 . . 113
图 6-6 MASTER 与对比算法在不同数量的传感器和不同的测量技术下的表现 114
图 6-7 MASTER 与对比算法的分歧度曲线 115
图 6-8 提出的追踪算法与现有算法在估计精度和效率方面的性能比较 115
图 6-9 多目标协同追踪方法的连续追踪效果 116
图 6-10 多目标协同追踪方法的消融实验 117
图 7-1 MASOIE-G 算法框架 123
图 7-2 IEEE-39 节点系统示意图 129
图 7-3 MASOIE-G 与对比算法的整体性能 130

表格目录

表 3-1 当自适应通信机制采用不同初始间隔时 MASOIE 的性能表现 39
表 3-2 MASOIE 与对比算法的比较结果 41
表 4-1 CCSA-DES 中的符号说明 50
表 4-2 基准函数配置 60
表 4-3 提出的步长自适应方法 CCSA 的消融实验 67
表 4-4 CCSA-DES 与 SOTA 算法的比较结果 68
表 5-1 与变种算法及现有算法的比较结果 85
表 5-2 MACPO 与整体式算法的在不同评估预算下的效果 86
表 5-3 算法在参数 λ 的不同取值下的表现 91
表 5-4 扰动变量的参数调研 92
表 6-1 MASTER 相关符号说明 96
表 6-2 多目标协同定位相关工作的对比 98
表 6-3 MASTER 计算复杂度 106
表 6-4 MASTER 在不同的通信间隔 t_m^0 下的表现 111
表 7-1 MASOIE-G 相关符号说明 120
表 7-2 MASOIE-G 实验参数设置 128

主要名词索引

A

ACO	Ant Colony Optimization	蚁群优化算法
ADMM	Alternating Direction Method of Multipliers	交替方向乘子法
AOA	Angle-of-Arrival Measurement	到达角度测距

B

BL	Base Load	电力基础负载

C

CSA	Cumulative Step Adaptation	累积步长自适应机制
CCSA	Cooperative and Cumulative Step Adaptation	协同的累积步长自适应机制
CCSA-DES	Dencentralized Evolution Strategies with CCSA	基于 CCSA 的无中心演化策略
CMA-ES	Covariance Matrix Adaptation-based Evolution Strategy	基于协方差矩阵自适应的演化策略
CPU	Central Processing Unit	中央处理器
CSO	Competitive Swarm Optimizer	竞争粒子群优化
CG	Conventional Generator	常规发电机组

D

DEC	Distributed Evolutionary Computation	分布式进化计算
DGD	Distributed Gradient Descent	分布式梯度下降
DPSO	Distributed Particle Swarm Optimization	分布式粒子群优化
DA-PSO	Distributed particle swarm optimization algorithm using the strategies of diffusion adaptation	基于扩散方法的分布式粒子群优化算法
DM2M	Distributed Multi-target localization problem with measurement-to-measurement association	带有测量-测量关联的分布式多目标定位问题
DBM2M	Distributed Bi-level Multi-target localization problem with measurement-to-measurement association	带有测量-测量关联的分布式双层多目标定位问题

DER	Distributed Energy Resource	去中心化能源资源
DER-EV	Distributed Energy Resource Management considering Electric Vehicles	考虑 EV 充电行为的去中心化能源管理方法

E

EC	Evolutionary Computation	进化计算
ES	Evolution Strategies	演化策略
EXTRA	Exact First-Order Algorithm	精确一阶分布式优化算法
ESS	Energy Storage System	储能系统
EV	Electric Vehicle	电动汽车
EVS	Electric Vehicle Charging Station	电动汽车充电站

F

FC	Fully Connected	全连接

G

GA	Genetic Algorithm	遗传算法
GP	Genetic Programming	遗传规划
GFPDO	General Framework for Population-based Distributed Optimization	基于种群的分布式优化算法框架

L

LLSO	Level-Based Learning Swarm Optimizer	基于层级学习的粒子群优化

M

MAS	Multi-Agent Systems	多智能体系统
MASOIE	Multi-Agent Swarm Optimization With Adaptive Internal and External Learning	基于自适应内外部学习的多智能体粒子群优化算法
MASOIE-G	MASOIE considering game behaviors	考虑群体博弈行为的多智能体粒子群优化算法

MACPO	Multiagent Co-Evolutionary Algorithm With Penalty-Based Objective	基于惩罚目标激励的多智能体协同演化算法
MASTER	Multi-Agent Swarm Optimization with Contribution-Based Cooperation	基于贡献度合作的多智能体粒子群优化算法
MASTER-T	MASTER-based Tracking Algorithm	基于 MASTER 定位算法的连续多目标追踪算法
MPI	Message Passing Interface	消息传递接口开发框架

N

NP	Nondeterministic Polynomial-time	非确定性多项式时间
NDO	Network-based Distributed Optimization	网络型分布式优化

P

PSO	Particle Swarm Optimization	粒子群优化

R

RGF	Randomized Gradient-Free Methods	随机无梯度方法
RSS	Received Signal Strength Measurement	基于接收信号强度的测距技术
RTT	Round Trip Time Measurement	基于往返时延的测距技术

S

SDNO	Zeroth-order algorithms for stochastic distributed non-convex optimization	面向分布式随机非凸优化的零阶优化算法

T

TDOA	Time Difference of Arrival Measurement	基于到达时间差的测距技术

W

WSN	Wireless Sensor Network	无线传感器网络

第一章　绪论

1.1　研究背景与意义

近年来，人工智能技术不断发展，成为国际竞争的新焦点、经济发展的新引擎，为社会建设带来了新的机遇。2017 年，国务院发布《新一代人工智能发展规划》，其中“群体智能”与“自主智能系统”被列为亟需发展的新一代人工智能理论和技术方向，成为构建新一代人工智能体系的重要研究任务。群体智能强调多个智能个体通过协作与交互形成整体智能行为，其理论基础与实现机制已成为当前人工智能研究的重要前沿[1]。多智能体系统（Multi-Agent System，MAS）通过多个具备一定感知、计算与执行能力的个体之间的协同与博弈，实现复杂任务的自主完成[2]，是群体智能的重要技术载体，也是支撑多机自主智能系统的核心基础。当前，多智能体系统已在机器人集群控制[3]、任务分配与调度[4-5]、博弈与社会行为建模[6-8]、分布式智能电网[9-10]、无人系统协同控制[11]等领域展现出广阔的应用前景。

除了政策层面的引导与支持，产业与工程领域同样对多智能体技术产生了迫切需求。一方面，随着物联网、大数据与云边协同计算的发展，数据规模呈指数级增长，且数据往往分布在不同节点或机构之中，受限于隐私保护、通信带宽与数据主权等因素，难以集中存储与统一处理[12-13]。另一方面，新一代复杂系统（如无人系统集群、车联网系统、分布式能源系统等）具有高度动态性与去中心化特征，系统中各节点具备一定自治能力但缺乏全局信息[14-15]。在此背景下，传统的集中式计算范式由于其对全局信息、中心服务器与高通信开销的依赖，逐渐难以满足高实时性、高可靠性与隐私保护的需求。因此，研究去中心化、多主体协同的优化与决策方法，已成为适应未来复杂网络系统发展的必然趋势。

面对上述需求，大量学者投入到多智能体系统相关研究中。目前，相关研究主要集中于两个方向：多智能体优化[16-17]与多智能体强化学习[18-19]。二者分别从数值优化与决策学习角度出发，适用于不同类型的问题场景。多智能体优化主要关注在给定目标函数与约束条件下，通过多个智能体协同迭代，求解全局最优或近似最优解。该类方法通常具有明确的数学建模基础与收敛性分析框架，适用于参数优化、资源分配、网络控制等结构明确的优化问题。多智能体强化学习则强调在未知或部分可观测环境中，通过与环境交互进行策略学习，具备较强的环境适应能力与策略泛化能力，适用于博弈决策、协同控制与复杂策略生成问题。

在多智能体优化框架中，分布式优化是一种解决网络化系统问题的主流技术，其中每个智能体仅能访问自身的局部目标函数，而全局目标函数通常定义为所有局部目标函数之和[20]。分布式优化的核心问题在于如何通过局部信息交互实现全局目标的协同优化与共识收敛。共识理论[21]为此提供了重要理论基础，给出了在初始值不同的情况下，多智能体系统实现状态共识的充分条件。在现有文献中，基于共识理论提出了大量分布式优化算法[22-24]。例如，分布式梯度下降（Distributed Gradient Descent, DGD）[25]通过交替执行梯度更新与邻居加权平均实现协同优化；Lei *et al.*[26]提出带投影算子的分布式原始-对偶算法，在凸条件下可实现次线性收敛。上述方法主要依赖一阶或二阶导数信息，在凸或强凸假设下可获得良好的理论收敛保证。此外，随机无梯度分布式优化方法（Randomized Gradient-Free Methods, RGF）[27-28]通过构造差分估计替代真实梯度，用于求解黑盒分布式优化问题。这类方法继承了 DGD 的共识框架，在一定程度上拓展了分布式优化的适用范围。

尽管现有分布式优化方法取得了显著进展，但在面向真实复杂系统时仍面临若干关键挑战。第一，模型假设与现实场景之间存在显著差距。现有研究多建立在理想化假设之上，例如目标函数为凸或光滑、通信拓扑固定且连通、节点间同步更新、可获得精确梯度信息等。然而，在实际工程问题中，如软件仿真优化[29-30]、超参数自动调节[31]、双层优化[32]以及复杂系统控制等场景[33-34]，目标函数往往不具备显式表达式，仅能通过仿真或实验获得函数值，呈现明显的黑箱特性。第二，非凸性问题普遍存在。在神经网络训练、组合优化与复杂系统设计等问题中，目标函数通常高度非凸，存在大量局部极值与鞍点[35-36]。基于梯度的信息方法容易陷入局部最优或对初始值高度敏感，在分布式环境下这种问题会进一步放大。因此，如何在非凸、黑箱与去中心化条件下实现稳定高效的全局优化，是当前分布式多智能体优化研究的重要难题。

针对上述困难，进化计算（Evolutionary Computation, EC）在求解复杂分布式优化问题方面展现出巨大潜力。EC 是一类基于群体搜索与自然选择机制的全局优化方法，包括粒子群优化[37]、遗传算法[38]、蚁群优化[39]等。其基本思想是通过种群演化、变异与选择等机制，在无需梯度信息的条件下对搜索空间进行全局探索，从而提高跳出局部极值的能力。近年来，EC 已成功应用于多种黑盒和非凸分布式优化问题，例如无线传感器网络[40-41]、智能电网[42-43]以及多无人机系统[5,44]。基于不同计算模型，已有大量分布式与并行进化算法被提出[45]，例如主从模型[46-47]、池模型[48-49]、岛模型[50]和细胞模型[51]。这些方法通过多节点协同演化提升搜索效率与解的质量，例如分解子问题并协

同整合[52-53]，或通过子种群间精英个体交换增强多样性[48]。然而，大多数现有分布式进化算法仍基于集中式或弱分布式假设，即每个节点可以访问全局数据或共享完整种群信息，或依赖中心节点进行协调。在大数据与物联网背景下，工业数据呈现出分布式存储趋势，局部数据的独立性与隐私性日益突出。各节点仅掌握自身局部目标函数与有限邻居信息，缺乏全局视图。在这种去中心化多智能体系统中，如何设计仅基于局部信息交互、无需中心节点、能够在黑箱与非凸条件下稳定收敛的分布式进化算法，成为一个具有理论挑战与工程价值的重要研究问题。

因此，围绕去中心化多智能体系统下的黑箱分布式优化问题，构建兼具全局搜索能力与分布式共识机制的进化计算框架，不仅有助于弥补现有分布式优化理论在复杂场景下的不足，也对无人系统协同控制、分布式智能制造、能源互联网以及大规模机器学习等领域具有重要的理论意义与应用价值。

1.2 研究难点与挑战

多智能体系统在实际部署与应用过程中通常具有以下典型特征：**（1）数据分散性。**每个智能体通常在其邻近物理或逻辑范围内感知并采集数据，并将数据独立存储于本地节点。例如，在车联网系统中，每辆车仅能获取自身传感器数据[54]；在分布式能源系统中，每个发电或用电节点仅掌握自身运行状态数据[55]。受限于通信带宽、隐私保护、数据安全与数据主权等约束，这些数据往往无法集中共享或统一处理，从而导致全局信息不可得。**（2）目标分散性。**在多数分布式系统中，各节点通常拥有自身独立的优化目标，且局部目标与系统整体目标并不完全一致。例如，在智能电网中，每个发电或用电节点希望最大化自身收益或最小化自身成本，而系统整体目标则是最小化全局运行开销或提高系统稳定性[9]。由于数据分散与隐私限制，节点无法直接获知其他节点的局部目标函数形式与参数，从而使全局协同优化问题更加复杂。**（3）通信受限性。**多智能体系统通常部署在物理分散、拓扑受限的网络环境中，如无线传感器网络、无人机集群、边缘计算网络等。这类系统一般由非全连接的稀疏通信拓扑构成，每个节点仅能与其邻居节点进行点对点通信[56]。此外，在硬件资源受限的嵌入式设备或低功耗节点上，通信频率与通信数据量同样受到严格限制[57]。因此，如何在有限通信条件下实现高效协同，是算法设计中的关键问题。

尽管进化计算为黑箱优化问题提供了有效的全局搜索能力，但在上述“数据分散—目标分散—通信受限”的多智能体场景下，仍面临如下关键挑战：

（1）黑箱去中心场景下全局共识难。在黑箱优化条件下，节点无法获得显式梯度或全局函数表达式；在去中心化网络中，又不存在全局协调者或中心节点。如何在仅依赖局部函数值与邻居通信的前提下，使各智能体在搜索过程中逐步逼近共识解，并保证系统稳定收敛，是理论与算法设计上的核心难题。尤其是在非凸情形下，个体搜索方向可能存在显著差异，容易导致系统震荡或分裂。

（2）分布式合作优化过程中采样协调难。进化计算依赖采样分布与步长控制实现探索与开发的平衡。然而，在多智能体分布式环境中，各节点的搜索轨迹可能彼此冲突或方向不一致。若步长过大，系统可能难以达成共识；若步长过小，则可能陷入局部最优。如何设计既能保持个体探索能力，又能兼顾邻域协同共识的步长自适应机制，是分布式进化算法面临的重要挑战。

（3）局部利益冲突下协同优化难。当各节点拥有不同甚至相互冲突的局部目标函数时，单纯的信息共享难以保证全局目标的优化。若缺乏有效的协调或激励机制，个体可能偏向优化自身利益而偏离全局共识解。因此，需要构建能够在保持节点自治性的同时，引导其向全局共识方向演化的协同机制，从而在局部目标冲突条件下实现整体优化。

1.3 研究内容与创新点

针对上述挑战，本文从“群体演化协同—采样搜索协同—目标激励协同”三个层次展开研究，结合进化计算与多智能体共识理论，构建面向黑箱分布式优化问题的去中心化协同进化框架，实现系统共识、搜索自适应性与目标协调性的统一。具体而言，本文的创新思路与研究内容如下。

（1）通过多智能体种群协同演化实现无梯度共识机制

针对黑箱去中心场景下全局共识难的问题，本文首先研究一般分布式优化问题下的分布式进化算法，使多个智能体中的种群在高效通信与系统共识保障的前提下实现协同演化。为此，提出了一种用于黑盒与非凸分布式优化的自适应内外学习多智能体群体优化算法（Multi-Agent Swarm Optimization With Adaptive Internal and External Learning, MASOIE）。MASOIE 基于粒子群优化的基本思想，并将其转化为适用于分布式优化的两阶段学习机制。在该算法中，每个智能体独立演化一个粒子群，并通过邻域通信实现跨节点协作。主要创新包括：

- 提出由“内部学习”与“外部学习”构成的多智能体协同演化框架。在内部学习阶段，同一智能体内的粒子协同优化局部目标；在外部学习阶段，粒子通过邻域

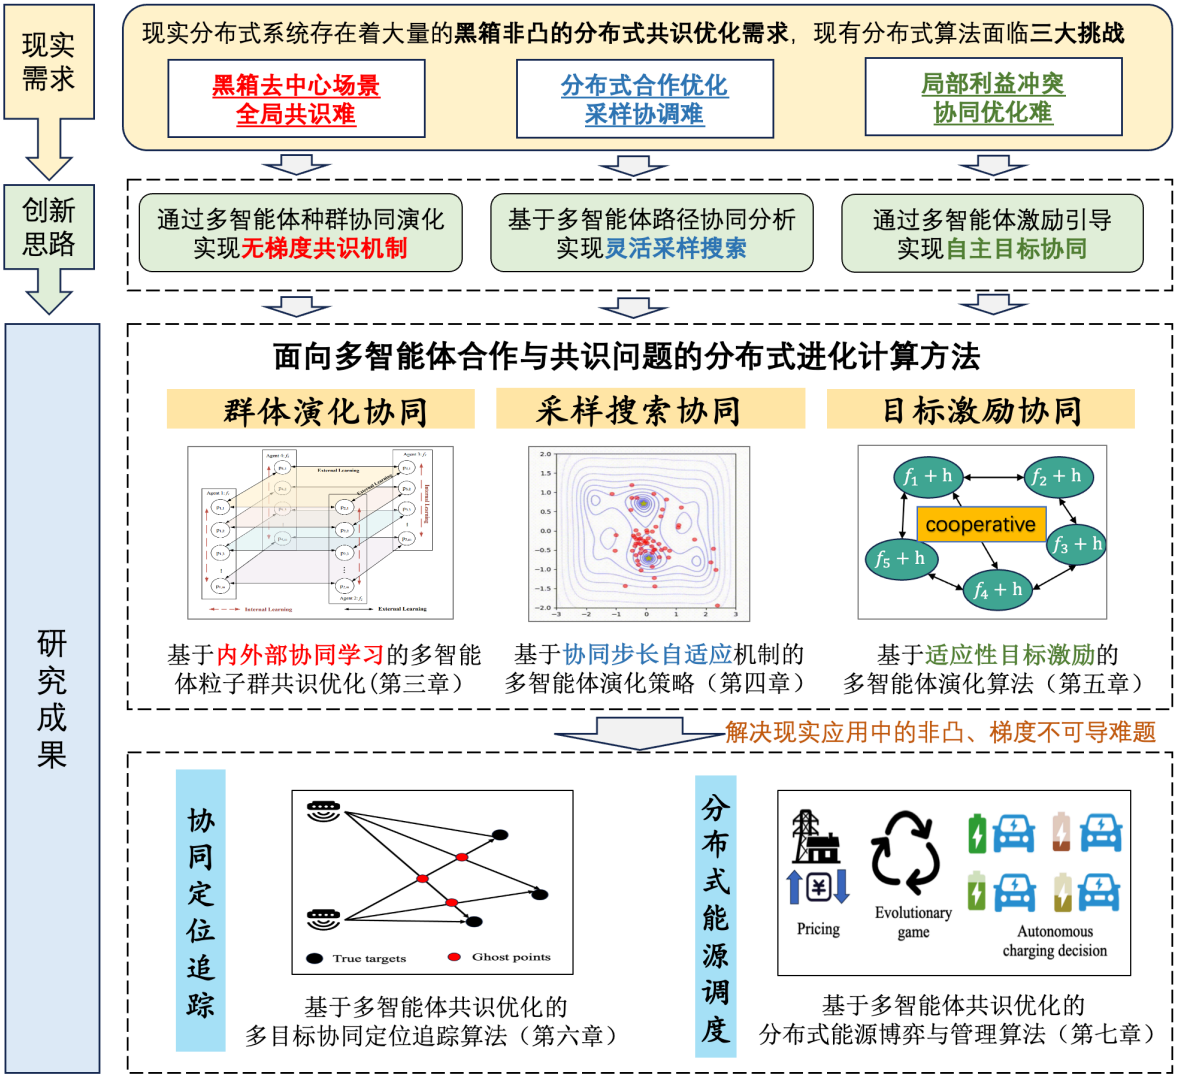


图 1-1 本文主要研究内容与创新点

通信学习邻居智能体的优秀信息，从而推动系统向全局共识解演化。为增强算法共识能力，设计特殊的惯性速度继承机制。考虑到外部学习具有更强的全局意义，其惯性项来源于上一轮外部学习阶段的速度，从而强化跨节点演化方向的延续性。消融实验验证了该机制对系统共识的提升效果。

- 设计自适应通信机制以降低通信开销。在优化初期采用较大通信间隔以增强探索能力；随着适应度变化减缓，逐步缩短通信间隔以促进共识。通过引入广播机制估计全局适应度变化，使通信调度更加合理。基于共识理论与离散动力系统理论，对 MASOIE 的确定性实现进行共识分析，给出系统收敛条件。实验表明，该算法在保持稳定共识的同时，获得具有竞争力的解质量与更低的通信成本。

（2）基于多智能体搜索路径协同分析实现灵活采样搜索

针对协同采样与步长自适应难的问题，本文进一步研究分布式进化过程中多智能体如何实现协作式步长调节，提出具有协作与累积步长自适应机制的多智能体进化策略（Dencentralized Evolution Strategies with Cooperative and Cumulative Step Adaptation, CCSA-DES）。CCSA-DES 在局部优化阶段与邻域协作阶段之间交替运行：首先，各智能体独立执行进化策略以优化局部目标；随后，通过邻域通信更新解与步长参数。其主要创新包括：

- 提出协作与累积步长自适应机制（Cooperative and Cumulative Step Adaptation, CCSA），包括内部自适应与外部自适应两个层次。通过分析智能体搜索路径方向与邻居之间的一致性或冲突程度，当方向一致时放大步长以增强协同探索，当方向冲突时缩小步长以避免震荡。本文对 CCSA 的稳定性与收敛特性进行理论分析，并通过实验验证其有效性。
- 在 CCSA 基础上构建 CCSA-DES 算法框架，并从共识表现与解质量两个方面进行系统评估。理论分析与实验结果表明，该算法在黑箱分布式优化问题上具有优于现有方法的共识表现与有竞争力的优化性能。

（3）通过多智能体激励引导实现自主目标协同

针对局部利益冲突下协同优化难的问题，本文提出多智能体协同进化算法与基于惩罚的目标函数（Multiagent Co-Evolutionary Algorithm With Penalty-Based Objective, MACPO）以求解分布式优化问题。在 MACPO 中，每个智能体控制一个子种群，个体编码包含私有变量与边上共享变量。算法包括局部优化阶段与协商阶段：前者演化子种群优化局部目标，后者通过邻域通信对共享变量进行协商。主要贡献如下：

- 设计基于惩罚的目标函数以实现局部可观测条件下的全局协同优化。在局部目标中加入与共享变量冲突相关的惩罚项，将子种群解约束在接近共识解的可控范围内，从而引导邻居智能体逐步达成共识。同时提出冲突检测机制，仅在变量存在冲突时引入对应惩罚项，提高惩罚的针对性与效率。
- 重构共享变量的协商过程，包括评估、竞争与共享三个步骤，使邻居智能体在共享变量空间内逐步达成共识，提高协商稳定性与收敛效率。所提出框架可嵌入大多数基于种群的进化算法。实验结果表明，在基准问题上与分而治之算法相比，该方法在引导子种群协同演化方面更为有效；与整体式算法相比，在保持解质量

竞争力的同时，具备更高的计算效率与可扩展性。在可计算梯度问题上，其性能接近梯度方法；在不可计算梯度的真实与基准问题上，则优于现有无梯度分布式方法。

基于上述理论成果，本文进一步在无线传感器网络系统与智能电网系统中开展应用验证，以检验所提出多智能体共识优化框架在真实复杂场景下的有效性与可扩展性。

（4）基于多智能体共识优化的多目标协同定位追踪算法

随着终端硬件通信与计算能力的提升，将分布式优化方法应用于无线传感器网络以增强传感器自主协作能力成为可能。然而，以分布式方式求解带有测量-测量关联的多目标定位问题面临显著挑战。随着目标数量增加，数据关联的组合数量呈指数增长。在去中心化分布式框架下，传感器需在指数级搜索空间中就离散变量进行协商，计算与通信压力巨大。针对上述问题，本文提出一种基于贡献度协作的多智能体群体优化方法（Multi-Agent Swarm Optimization with Contribution-Based Cooperation, MASTER），主要贡献包括：

- 针对离散变量搜索空间指数增长的问题，将多目标定位问题重构为一个双层分布式优化问题。在该重构中，局部目标函数的下层为线性指派问题，可由确定性算法高效求解；上层为连续变量优化问题。对于每一个上层候选解，都可通过下层问题获得对应最优数据关联结果。该重构将原本需要协商的离散变量转化为局部确定性计算，从而显著降低分布式协商的复杂度。
- 为在仅能访问局部测量数据的条件下促进全局优化，提出基于贡献度的协作机制。在通信前，每个传感器根据局部优化阶段中粒子群适应度提升幅度与搜索方向一致性计算其贡献度，并将粒子群连同贡献度一并发送给邻居。通信后，通过新的速度更新规则使粒子优先学习高贡献度邻居的信息。消融实验表明，该机制显著提升了全局定位精度。

（5）基于多智能体共识优化的分布式能源博弈与管理算法

在智能电网系统中，电动汽车（EV）的自主决策行为为去中心化电力分配带来新的挑战。首先，EV 的自主充电行为会对供需平衡造成显著冲击。不同于传统工业或居民负载，EV 充电行为难以由电网直接调度或集中控制。其次，在去中心化电网架构中，各节点仅掌握局部发电或用电信息，且通信网络为无中心节点的稀疏拓扑结构，使得传统集中式优化方法难以适用。针对上述挑战，本文提出改进的多智能体粒子群优化方法

（MASOIE considering game behaviors, MASOIE-G）以求解去中心化能源管理问题。主要贡献如下：

- 在内部学习阶段，引入自适应定价的演化博弈策略，实现 EV 参与下的供需平衡调节。价格信号根据系统供需偏差动态调整：当供给紧张时提高价格以抑制需求，当供给过剩时降低价格以鼓励充电。实验结果表明，该机制能够稳定系统负载波动并提高整体收益。
- 在外部学习阶段，设计具有可变邻居权重的协作机制。各智能体根据邻居适应度改善幅度动态分配学习权重，使高质量邻居信息获得更高影响力。该机制在有限通信条件下增强了有效信息传播效率。消融实验验证了该方法在不同负载与 EV 渗透率场景下均具有更优性能。

综上，本文围绕多智能体黑箱分布式优化问题，从演化协同机制、步长协同机制与目标协调机制三个层面构建系统化理论与算法框架，为去中心化复杂系统中的协同进化优化提供新的研究思路与方法支撑。通过在无线传感器网络与智能电网两类典型复杂系统中的应用验证，证明所提出多智能体共识进化优化框架不仅具备理论共识性与收敛性优势，同时在实际工程场景中具有良好的鲁棒性、可扩展性与应用潜力。

1.4 论文结构与章节安排

本文围绕去中心化多智能体系统中的黑箱分布式优化问题展开研究，从理论方法到实际应用逐步深入。全文按照“理论研究—方法扩展—应用验证”的逻辑结构组织，共分为七章，各章节内容安排如下。

第一章：绪论。本章介绍论文的研究背景与意义，分析多智能体分布式优化在复杂网络系统中的研究价值与现实需求，总结当前研究面临的主要挑战，并给出本文的研究思路、研究内容与创新点，最后对全文结构进行总体说明。

第二章：背景知识与研究现状。本章系统介绍论文所涉及的基础理论与相关研究进展。首先，在第 2.1 节中给出多智能体系统的基本模型以及本文研究的分布式优化问题定义；其次，第 2.2 节综述分布式优化领域的主要研究进展与典型方法，并分析现有方法在黑箱与去中心化场景中的局限性；最后，第 2.3 节介绍进化计算的基本原理及其在分布式与并行优化中的研究现状，为后续章节的算法设计奠定理论基础。

第三章：基于内外部协同学习的多智能体共识优化算法。针对黑箱去中心化场景下“全局共识难”的挑战，提出通过多智能体种群协同演化实现无梯度共识机制的创新思

路。基于此思想，设计一种基于内外部协同学习的多智能体共识优化算法，通过内部学习与外部学习两个阶段交替实现局部搜索与邻域协作，在无需梯度信息的条件下推动系统向全局共识解演化。本章从理论角度对算法的共识性性质进行分析，并通过实验验证算法的有效性。相关研究成果发表于 *IEEE Transactions on Evolutionary Computation*。

第四章：基于协同步长自适应机制的多智能体共识优化算法。针对多智能体协同优化过程中“采样协调难”的问题，提出基于多智能体搜索路径协同分析实现灵活采样搜索的创新思路。通过分析不同智能体搜索方向之间的一致性或冲突关系，设计协同累积步长自适应机制，使系统在保持探索能力的同时逐步增强协同共识性。在此基础上构建多智能体进化策略算法，并从共识性与优化性能两个方面进行理论与实验分析。相关成果发表于 *IEEE Transactions on Evolutionary Computation*。

第五章：基于适应性目标激励的多智能体共识优化算法。针对多智能体系统中局部利益冲突导致“协同优化难”的问题，提出通过多智能体激励引导实现自主目标协同的创新思路。通过在局部目标函数中引入适应性惩罚机制，并结合冲突检测与协商策略，引导各智能体在保持局部自治的同时逐步逼近全局共识解。在此基础上设计基于适应性目标激励的多智能体共识优化算法，并验证其在分布式优化问题中的有效性。相关成果发表于 *IEEE Transactions on Systems, Man, and Cybernetics: Systems*。

第六章：基于多智能体共识优化的多目标协同定位追踪方法。基于前述理论成果，针对无线传感器网络中的多目标定位与追踪问题开展应用研究。考虑到该问题具有非凸、离散—连续变量耦合以及数据关联复杂等特点，提出基于多智能体共识优化的分布式协同定位方法。通过将原始问题重构为双层优化问题并结合群体进化搜索机制，实现多传感器之间的协同定位与共识优化。相关研究成果发表于 *IEEE/CAA Journal of Automatica Sinica* 与 *IEEE Conference on Computer Communications 2025 (INFOCOM)*。

第七章：基于多智能体共识优化的分布式能源博弈与管理方法。针对智能电网中电动汽车参与下的分布式能源管理问题开展研究。考虑电网系统中存在非凸优化结构与不可导目标函数的特点，提出基于多智能体共识优化的分布式能源博弈与管理方法。通过构建自适应定价机制与邻域协同优化策略，实现去中心化条件下的供需平衡与系统整体收益优化。相关成果发表于 *GECCO ’25: Proceedings of the Genetic and Evolutionary Computation Conference*。

总结与展望: 该章节总结全文，并进行未来研究工作展望。

第二章　背景知识与研究现状

2.1　系统模型与问题定义

本节对本文所研究的多智能体分布式优化问题进行统一建模与形式化定义。首先给出多智能体系统的图模型描述与基本数学工具；随后定义标准分布式共识优化问题；最后介绍本文重点关注的部分重叠分布式共识优化问题，并阐明其与传统模型的区别与联系。

2.1.1　多智能体系统

多智能体系统（Multi-Agent Systems, MAS）是由多个具备感知、计算与通信能力的智能体通过通信网络相互连接所构成的网络化系统[2], 典型应用包括无线传感器网络、分布式电力系统、多无人机编队以及车联网系统等[3-4]。

在数学上，多智能体系统通常建模为一个图结构。设网络拓扑表示为无向图 $G=(V,E)$，其中顶点集合 $V=\{1,2,\ldots,n\}$ 表示 n 个智能体，边集合 $E\subseteq V\times V$ 表示智能体之间的通信连接关系。若 $(i,j)\in E$，则智能体 i 与 j 可直接交换信息。智能体 i 的邻居集合定义为

$$\mathcal{N}_i=\{j\in V\setminus\{i\}:(i,j)\in E\}. \tag{2-1}$$

通常假设图 G 是连通的，即任意两个节点之间至少存在一条路径，从而保证信息能够在网络中传播。

为刻画网络结构，引入邻接矩阵 $A=[a_{ij}]\in\mathbb{R}^{n\times n}$，当 $(i,j)\in E$ 时，$a_{ij}=1$, 否则，$a_{ij}=0$。定义度矩阵 $D=\mathrm{diag}(d_1,\ldots,d_n)$，其中 $d_i=\sum_{j=1}^{n}a_{ij}$ 为节点 i 的度。进一步定义图拉普拉斯矩阵 $L=D-A$. 当图 G 连通时，L 为半正定矩阵，且其零特征值唯一，对应特征向量 $\mathbf{1}=[1,\ldots,1]^T$。该性质是分布式共识分析的重要理论基础。

2.1.2　分布式共识优化问题

在由 n 个智能体通过通信网络连接构成的多智能体系统中，分布式优化问题[16]的一般形式如下：

$$\min F(x)=\sum_{i=1}^{n}f_i(x) \tag{2-2}$$

其中，$x \in \mathbb{R}^N$ 为 N 维决策变量，$f_i(*)$ 表示智能体 i 的本地目标函数，$F(*)$ 表示系统的全局目标函数。当本地目标函数 f_i 的数学表达式未知或其梯度不可计算时，该问题称为黑盒分布式优化问题。需要注意的是，由于各 f_i 通常来源于不同数据、感知范围或物理约束，其最优解一般并不共识，因此不存在同时最小化所有 f_i 的解。分布式优化的目标是在通信受限条件下，使系统整体达到全局最优或近似最优解。

从结构上看，问题 (2-2) 可等价转化为带共识约束的形式：

$$\begin{aligned} \min_{x_1,\ldots,x_n} \quad & \sum_{i=1}^{n} f_i(x_i) \\ \text{s.t.} \quad & x_i = x_j, \quad \forall (i,j) \in E. \end{aligned} \tag{2-3}$$

其中 x_i 为智能体 i 的局部变量副本。该形式显式地揭示了“局部优化 + 全局共识”的结构，是多数分布式算法设计的出发点。

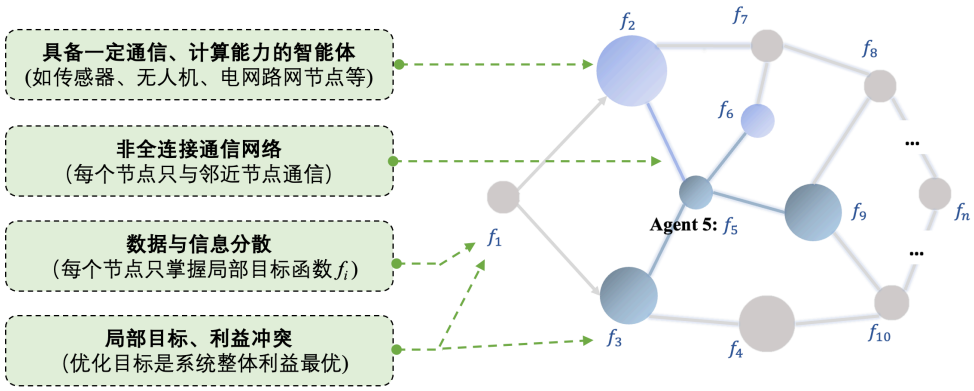


图 2-1 分布式共识优化的特征示意图

在分布式优化中最小化全局目标函数面临两个主要挑战。第一，由于本地数据、感知范围限制或隐私因素，每个智能体 i 仅能访问自身本地目标函数 f_i，因此单个智能体无法独立解决全局问题。第二，不同智能体的本地目标函数通常存在冲突，其最优解各不相同，因此不存在同时最小化所有本地目标的解。为了最小化全局目标函数 F，智能体必须协作，在多个本地目标之间取得平衡。总之，分布式优化问题是不可分的，智能体需要协作而非独立优化。

分布式优化问题广泛存在于现实多智能体系统中，例如无线传感器网络中的协同目标定位、智能电网中的预测控制与经济调度、多无人机系统中的路径规划与任务分配[9,11]。以协同定位问题为例，n 个传感器构成多智能体系统，以目标位置作为优化变量 x。智能体 i 的本地目标函数 $f_i(*)$ 表示其估计误差，全局目标函数 $F(*)$ 则最小化所有传感器估计误差之和。类似地，在包含 n 个电站的分布式电力系统中，优化变量 x 表

示功率分配策略，本地目标函数 $f_i(*)$ 表示电站的能量损耗，而全局目标 $F(*)$ 则最小化整个系统的能量损耗。

2.1.3 部分重叠的分布式共识优化问题

在许多实际网络系统中，决策变量并非完全全局共享，也并非完全私有，而是呈现“部分重叠”结构。例如在交通网络与电力系统的网络流优化问题中，节点变量（如存储容量、功率输出）为私有变量，而边变量（如流量、电压差）则为相邻节点共享变量。

为刻画此类结构，考虑无向图 $G=(V,E)$。设全局变量为

$$X=[x^1,x^2,\ldots,x^D]\in\mathbb{R}^D. \tag{2-4}$$

对于智能体 i，定义其私有变量索引集合为 $\mathcal{I}_i\subseteq\{1,\ldots,D\}$，边 (i,j) 上的共享变量索引集合为 $\mathcal{I}_{i,j}\subseteq\{1,\ldots,D\}$。则智能体 i 的局部变量索引集合为 $\Theta_i=\mathcal{I}_i\cup\bigcup_{j\in\mathcal{N}_i}\mathcal{I}_{i,j}$, 对应的局部变量为 $X_i=\mathrm{col}\{x^d\}_{d\in\Theta_i}$。

部分重叠分布式共识优化问题定义为：

$$\min_{X\in\mathbb{R}^D} F(X)=\sum_{i=1}^{n} f_i(X_i), \tag{2-5}$$

其中 $f_i:\mathbb{R}^{\|X_i\|}\to\mathbb{R}$。

在分布式实现中，可引入变量副本，将问题改写为：

$$\begin{aligned}\min_{X_1,\ldots,X_n}\quad & \sum_{i=1}^{n} f_i(X_i)\\ \text{s.t.}\quad & x_i^d=x_j^d,\quad \forall d\in\mathcal{I}_{i,j},\ \forall(i,j)\in E.\end{aligned} \tag{2-6}$$

与传统分布式优化相比，该模型具有以下特点：（1）决策变量呈现图结构分布，而非完全全局共享；（2）局部目标函数依赖于私有变量与共享变量的耦合；（3）全局共识性仅在共享变量子空间上成立。由于变量耦合与拓扑传递性，整个网络必须协同求解该优化问题，单个智能体无法独立完成优化。这类模型更贴近复杂工程系统中的实际分布式决策问题，也为后续分布式进化计算方法的设计提供了理论基础。

2.2 分布式优化研究现状

分布式优化的发展源于共识控制、凸优化理论与网络系统理论的交叉融合。随着大规模网络系统与分布式数据结构的广泛出现，如何在通信受限、信息局部可得的条件下实现全局最优，成为该领域的核心问题。本节围绕共识理论、基于梯度的方法以及无梯

度方法，对分布式优化研究的主要进展进行系统梳理。

2.2.1 共识理论

共识理论（consensus theory）是分布式优化算法设计的基础[21]。其核心问题是：在仅允许邻居间局部通信的条件下，如何使网络中所有节点的状态渐近趋于共识。

考虑一个具有 n 个节点的强连通图 G，设权重矩阵为 $W=[w_{ij}]\in\mathbb{R}^{n\times n}$，满足与图结构一致的稀疏性条件，并具有行随机性或双随机性。系统采用如下离散时间更新模型：

$$x(t)=Wx(t-1), \tag{2-7}$$

其中 $x(t)=[x_1(t),\dots,x_n(t)]^T$ 为第 t 次迭代时所有节点的状态向量。

当且仅当图 G 连通（或者对于有向图是强连通且平衡的），可以证明

$$\lim_{t\to\infty} x_i(t)=\frac{1}{n}\sum_{i=1}^{n}x_i(0),\quad \forall i\in V. \tag{2-8}$$

即所有节点的状态收敛到初始值的平均值，实现平均共识。该收敛性结论通常通过谱分析或拉普拉斯矩阵的特征值性质得到。

共识算法的本质在于利用图拉普拉斯矩阵所刻画的网络耦合结构，使局部信息逐步扩散至整个网络。在分布式优化中，共识机制通常与局部优化步骤耦合，使各节点在执行梯度更新的同时逐步消除变量差异。因此，多数分布式优化算法都可视为共识动力学与优化动力学的组合系统。

2.2.2 基于梯度的分布式优化方法

在共识理论基础上，分布式优化研究首先集中于可微凸函数情形。Nedić 和 Ozdaglar[25] 提出了经典的分布式梯度下降（Distributed Gradient Descent, DGD）算法，其基本形式为

$$x_i(k+1)=\sum_{j=1}^{n}w_{ij}(k)x_j(k)-\alpha(k)\nabla f_i(x_i(k)), \tag{2-9}$$

其中 $\alpha(k)$ 为步长序列，$\nabla f_i(x_i(k))$ 为局部梯度。

该算法在结构上体现为“加权平均 + 局部梯度下降”。在递减步长条件下，DGD 可收敛至全局最优解；但在固定步长下，通常只能收敛至最优解邻域。为实现固定步长下的精确收敛，研究者提出了多种改进方法。EXTRA 算法[24] 通过引入历史迭代修正项，消除了稳态偏差，使算法在固定步长条件下实现精确收敛。随后提出的 DIGing 方法[22]

引入梯度跟踪机制，通过构造辅助变量估计全局梯度和，从而在强凸条件下获得线性收敛速度。分布式 Newton-Raphson 方法[23] 则利用二阶信息加速收敛，提高了算法的局部收敛速率。

除了离散时间算法外，连续时间分布式优化也得到广泛研究。在连续时间框架下，优化问题通常被建模为耦合微分方程系统。例如，基于控制理论设计的分布式比例-积分算法[58] 将共识误差视为积分反馈项；零梯度和算法[59] 则构造满足梯度和为零的不变流形，实现渐近收敛。连续时间方法在理论分析上更易借助李雅普诺夫方法建立稳定性结论，但在实际实现中仍需离散化。

总体而言，基于梯度的分布式方法在凸优化框架下具有较为完善的收敛理论，并在机器学习与网络控制中得到广泛应用。然而，这类方法通常依赖于目标函数可微或梯度可获得的假设，对黑盒问题或复杂非凸问题的适用性受到限制。

2.2.3 无梯度的分布式优化方法

当目标函数缺乏解析表达式、不可微或仅能通过函数值查询获得时，需要采用无梯度方法。近年来，随机方向搜索与随机近似技术被引入分布式框架[27-28]。

典型的随机差分梯度估计形式为

$$\hat{g}_i(x) = \frac{f_i(x+\mu\xi) - f_i(x)}{\mu}\xi, \tag{2-10}$$

其中 $\mu > 0$ 为差分步长，ξ 为满足零均值与单位协方差的随机向量。在光滑性假设下，可以证明 $\mathbb{E}[\hat{g}_i(x)]$ 逼近真实梯度，从而构造类似于 DGD 的分布式更新结构。

无梯度方法的优势在于不依赖梯度信息，适用于黑盒优化与仿真驱动系统。然而，其梯度估计方差通常较大，在高维空间中容易受到维度灾难影响，收敛速度一般慢于一阶梯度方法。此外，多数现有无梯度分布式算法仍建立在凸或强凸假设之上，对非凸大规模问题的理论支持仍相对有限。

综上，现有分布式优化研究在凸、可微问题上已形成较为成熟的理论体系，但在黑盒、非凸以及变量结构复杂的场景中仍存在显著挑战。这一研究空缺为基于进化计算的分布式优化方法提供了重要的理论动机与发展空间。

2.3 进化计算研究现状

进化计算（Evolutionary Computation, EC）是一类受生物进化机制启发的随机优化方法[60]，其理论基础可追溯至达尔文自然选择理论与遗传学机制。与基于梯度的优化

方法不同，进化计算不依赖于目标函数的可微性或解析表达式，而是通过种群演化、随机变异与选择机制在搜索空间中进行全局探索。因此，EC 在非凸、不可微、噪声干扰或黑盒优化问题中具有天然优势。

从方法类别上看，进化计算主要包括遗传算法（Genetic Algorithm, GA）[38]、演化策略（Evolution Strategies, ES）[61]、遗传规划（Genetic Programming, GP）以及群体智能算法, 如粒子群优化（Particle Swarm Optimization, PSO）[37]、蚁群优化（Ant Colony Optimization, ACO）[39]等。这些方法的共同特征在于采用种群（population）作为基本搜索单元，通过“选择—变异—重组（或更新）”机制迭代生成新解。其搜索过程兼具全局探索（exploration）与局部开发（exploitation）能力，在复杂高维空间中表现出较强的鲁棒性。在理论层面，进化算法通常可建模为随机动态系统，其收敛性分析依赖马尔可夫链、随机逼近理论或动力系统方法[62-63]，实际复杂工程问题中具有广泛应用价值。

2.3.1 集中式进化优化算法

集中式进化优化算法假设所有个体处于统一计算环境中，能够访问全局适应度函数。本文重点涉及两类典型算法：粒子群优化与演化策略。

2.3.1.1 粒子群优化

粒子群优化是一种基于群体协作搜索机制的优化算法[37]，其思想源于对鸟群觅食行为的模拟，通过粒子之间的信息共享实现协同搜索。每个粒子表示一个候选解，具有位置 x_i 与速度 v_i 两个状态变量。

标准 PSO 中，粒子速度通常由惯性项、个体认知项与群体社会项共同决定。速度更新公式一般写为

$$v_i(t+1) = \omega v_i(t) + c_1 r_1 (p_i - x_i(t)) + c_2 r_2 (g - x_i(t)), \tag{2-11}$$

其中 p_i 为粒子历史最优位置，g 为全局最优位置，ω、c_1、c_2 为控制参数。随后位置更新为:

$$x_i(t+1) = x_i(t) + v_i(t+1). \tag{2-12}$$

参数设计直接影响算法的收敛速度与稳定性，因此成为 PSO 研究的重要方向。

竞争粒子群优化（Competitive Swarm Optimizer, CSO）[64]是针对大规模优化问题提出的改进算法。CSO 取消了个体历史最优与全局最优的显式存储机制，而采用竞争机

制更新粒子。每次从种群中随机无放回地选取两个粒子，比较其适应度值，适应度较优者记为胜者 x_w，另一粒子记为败者 x_l。随后仅更新败者的速度与位置：

$$\begin{aligned} v_l(t+1) =& r_1 v_l(t) + r_2(x_w(t) - x_l(t)) + \phi r_3(\overline{x}(t) - x_l(t)), \\ x_l(t+1) =& x_l(t) + v_l(t+1), \end{aligned} \tag{2-13}$$

其中 $r_1, r_2, r_3 \sim U(0,1)$，$\overline{x}(t)$ 为种群平均位置，ϕ 为调节参数。该竞争机制增强了种群多样性，避免了过早收敛问题，在高维优化中表现出较好的扩展性。

另一类针对大规模优化问题提出的粒子群变体是基于层级学习机制的粒子群优化（Level-Based Learning Swarm Optimizer, LLSO）[65]。该方法受到教育学中“分层教学”思想的启发，根据粒子的适应度值将种群划分为多个层级，并对不同层级的粒子采用差异化的学习策略。

具体而言，算法首先按照适应度对粒子排序，并将其划分为若干层级。处于较低层级的粒子在更新时从更高层级中随机选择两个示例粒子进行学习，其中较优粒子主要引导开发（exploitation），而相对较差的粒子则有助于保持探索（exploration）能力。粒子速度更新通常可表示为

$$v_i(t+1) = r_1 v_i(t) + r_2(x_{r_1} - x_i(t)) + \phi r_3(x_{r_2} - x_i(t)), \tag{2-14}$$

其中 x_{r_1} 与 x_{r_2} 为从更高层级中选取的两个示例粒子，$r_1, r_2, r_3 \sim U(0,1)$，$\phi$ 为调节参数。更新后的位置仍由 $x_i(t+1) = x_i(t) + v_i(t+1)$ 给出。

通过层级划分与多示例学习机制，LLSO 能够在种群层面实现探索与开发的有效权衡：较低层级粒子倾向于探索搜索空间，而较高层级粒子更专注于局部开发，从而在高维优化问题中保持较好的搜索多样性与收敛性能。

2.3.1.2 演化策略

演化策略（Evolution Strategies, ES）[61]起源于德国学派的工程优化研究，其核心思想是通过高斯变异进行连续空间搜索。最经典形式为 (μ, λ)-ES 或 $(\mu + \lambda)$-ES，其中 μ 为父代个体数量，λ 为子代数量。

在基本 ES 框架下，第 t 代父代个体 $x_i^{(t)}$ 通过高斯扰动生成子代：

$$x_i^{(t+1)} = x_i^{(t)} + \sigma^{(t)} \mathcal{N}(0, I), \tag{2-15}$$

其中 $\sigma^{(t)}$ 为步长参数。步长自适应是 ES 的关键机制，例如 1/5 成功法则或累计路径步

长控制（Cumulative Step Adaptation, CSA），均用于动态调整搜索尺度。

进一步发展的协方差矩阵自适应演化策略（Covariance Matrix Adaptation-based Evolution Strategy, CMA-ES）[66]通过学习协方差矩阵来刻画搜索方向分布，从而提高在非凸函数上的收敛效率。相比 PSO，ES 更强调统计搜索机制与步长控制理论，在连续优化问题中具有较强理论基础。

2.3.2 并行进化计算

随着计算规模的扩大，进化计算逐渐向并行化方向发展[45]。根据计算结构不同，并行进化计算主要包括主从模型[46-47]、池模型[48-49]、岛模型[50] 和细胞模型[51]等。

主从模型通常由主节点负责种群管理与选择操作，从节点负责个体适应度评估。该结构实现简单，但存在中心节点瓶颈。池模型采用共享存储结构，多个处理单元从公共池中读取与写入个体，实现异步演化。岛模型将种群划分为多个子种群，周期性进行迁移操作，通过精英个体交换提升多样性。细胞模型则将个体分布在网格结构上，仅与局部邻域交互，增强空间多样性。

上述并行模型的核心目标是提升计算效率与解质量。然而，大多数研究仍假设各节点可访问全局适应度函数或共享完整问题信息。随着工业数据分布式存储与隐私保护需求的提升，这一假设在实际系统中逐渐受到挑战[67]。

2.3.3 分布式进化计算

分布式进化计算（Distributed Evolutionary Computation, DEC）强调在信息局部可得、通信受限的网络环境下进行协同优化。与传统并行进化计算不同，DEC 中每个智能体通常仅能访问自身局部目标函数，无法计算全局适应度。

现有研究多集中于具体应用场景，例如无线传感器网络[40-41]、智能电网[42-43] 以及多无人机系统[5,44]。这些方法通常在局部种群基础上，通过邻居通信实现协同。

在算法结构上，每个智能体维护一个子种群，并执行独立演化操作，同时周期性地与邻居交换信息。关键问题在于通信信息的设计与利用方式。一类方法传递子种群最优解或精英个体，通过信息扩散增强协同能力；另一类方法传递适应度值或辅助变量，以辅助局部决策。在信息利用机制方面，有研究将邻居最优解的平均值引入粒子更新规则，也有方法通过加权融合辅助变量估计全局信息。

总体来看，分布式进化计算在工程应用中表现出较强适应性，但在理论收敛性、通信复杂度控制以及变量耦合结构处理方面仍存在不足。尤其是在部分重叠变量结构或复

杂非凸黑盒问题中，如何设计高效协同机制仍是亟待解决的关键问题。

2.4 本章小结

本章围绕分布式优化与进化计算两个研究方向，梳理了相关理论基础与发展现状，并分析了当前方法在真实分布式环境下面临的关键挑战。

首先，在分布式优化领域，大量研究基于共识理论与分布式迭代框架展开，形成了以分布式梯度法、交替方向乘子法及共识优化为代表的主流方法。这类方法在凸优化问题上具有较完善的理论收敛性分析，并广泛应用于传感器网络、智能电网与多智能体系统等场景。然而，分布式优化方法通常依赖梯度信息或问题的结构化分解，对目标函数的可微性、凸性或解析形式有较强假设。当问题为非凸、高维或黑箱形式时，其适用性与性能将显著受限。

其次，在进化计算领域，粒子群优化、演化策略等群体智能方法因其无需梯度信息、适用于非凸与复杂黑箱优化问题而得到广泛研究。针对大规模优化问题，研究者提出了多种改进机制以增强算法的搜索能力与收敛性能。同时，并行进化计算框架（如主从模型、岛模型、细胞模型等）通过多子种群协同演化提升了计算效率。然而，这类方法大多建立在集中式适应度评估或可访问全局信息的假设之上，本质上仍属于“集中式问题的并行求解”，并未真正解决信息分散条件下的协同优化问题。

在分布式进化计算方向，已有研究尝试将进化算法与多智能体分布式架构相结合，通过子种群独立演化与邻域通信实现协同优化。这类方法在特定应用场景中取得了一定成果，但仍普遍存在以下不足：一是通信信息设计依赖较强的全局适应度假设；二是通信开销与算法性能之间的权衡缺乏系统分析；三是在高维、大规模及数据异构环境下的稳定性与收敛机制尚不清晰。

综合来看，进化计算在复杂黑箱优化方面具有显著优势，而分布式优化在多智能体协同与共识控制方面具有成熟理论基础，但两者之间仍存在明显鸿沟：前者多基于集中式框架，后者多依赖梯度与结构假设。在真实的分布式数据环境中，优化问题往往同时具备信息分散、隐私受限、目标非凸、不可显式建模等特征，现有方法难以直接满足实际需求。

第三章　基于内外部协同学习的多智能体共识优化算法

3.1　引言

分布式优化是一种解决网络化系统问题的主流技术，其中每个智能体仅能访问自身的局部目标函数，而全局目标函数通常定义为所有局部目标函数之和。分布式优化的研究重点在于如何使多个智能体协同优化全局目标函数并达成共识。在将 EC 算法应用于分布式优化时，局部目标函数的去中心化以及局部通信范围限制是主要困难。为解决这一问题，已有研究工作展开探索，根据智能体协作方式不同，大致可分为两类。第一类方法中，智能体通过间接方式协作计算解的全局适应度[68-70]。当评估一个解时，每个智能体计算该解的局部适应度，并通过智能体之间的通信获得全局适应度。因此，由于全局适应度可得，这类算法可以采用集中式优化方法。现有研究中的通信拓扑包括链式结构[68]、树结构[69] 和连通图结构[70]。例如，在文献 Ai et al.[70] 中，在连通图中反复执行加权平均直至系统达到相同的适应度值，即全局适应度；在文献 Choudhury et al.[69] 中，网络组织为树结构，适应度值由叶节点逐步传递至根节点。第二类方法中，智能体协作整合不同智能体的解[40,42,71-72]。在这类算法中，每个智能体维护一个子种群，通过整合各自种群中的解信息来协同优化全局目标函数。例如，在文献 Jalloul et al.[71] 中，智能体记录邻居最优解的平均值，并通过改进的速度更新策略演化粒子群；在文献 Wang et al.[40] 中，智能体将接收到的邻居最优解与本地最优解比较，并采用更优者更新本地解。

然而，上述 EC 算法未能同时兼顾通信效率与系统共识。第一类算法具有良好的共识性能，因为每个智能体都可以无冲突地获得全局适应度；但每次计算解的全局适应度都需要信息扩散至整个网络，通信开销较大。第二类算法通信成本较低，因为每代仅需与邻居通信一次；但它们主要面向低维问题或特定场景，且大多数未对系统共识性提供理论分析。因此，有必要进一步研究面向一般分布式优化问题的分布式进化算法，使多个智能体中的种群在高效通信与系统共识保障的前提下有效协同进化。

本章提出了一种用于黑盒和非凸分布式优化的自适应内外学习多智能体群体优化算法（Multi-Agent Swarm Optimization With Adaptive Internal and External Learning, MASOIE）。我们基于 PSO 的基本思想，并将其转化为适用于分布式优化的两阶段学习机制。这是因为 PSO 及其变体在连续问题上已展现出强大的全局优化能力。在 MASOIE 中，每个智能体演化一个粒子群，并通过通信与邻居智能体协作。本章的主要贡献体现在以下四个方面：

1) 本算法是少数在局部目标去中心化与局部通信范围条件下研究分布式进化算法共识性问题的工作之一。我们基于共识理论与动力系统理论，对 MASOIE 的确定性实现进行了系统共识的理论分析。与现有基准函数上的算法相比，MASOIE 在保持稳定共识性能的同时，获得了具有竞争力的解质量和更低的通信成本。
2) 为了在每个智能体仅能访问自身局部目标函数的情况下实现全局目标优化，提出了一种由内部学习与外部学习组成的多智能体协同进化框架。在该框架中，粒子可以从两个层面学习：首先，在内部学习阶段，同一智能体内的粒子相互学习并优化局部目标函数；其次，在外部学习阶段，粒子从邻居智能体中的粒子学习，协同实现对全局目标的共识优化。
3) 为提升 MASOIE 的共识能力，设计了一种特殊的粒子群惯性速度使用方式。具体而言，考虑到外部学习具有更强的全局意义，其惯性速度来源于上一轮外部学习阶段的速度。消融实验表明，该策略有效提升了 MASOIE 的共识性能。
4) 为提高 MASOIE 的通信效率，设计了一种自适应通信机制。在优化初期，MASOIE 采用较大的通信间隔以增强种群探索能力；随着优化推进，根据适应度变化逐步缩短通信间隔，使系统在后期实现全局共识。为使通信间隔调整更加合理，我们引入广播机制，使局部智能体能够估计全局适应度变化。

我们在包含十个分布式黑盒与非凸优化问题的基准测试上，将 MASOIE 与四种现有算法进行比较。同时，通过消融实验验证 MASOIE 中各特殊设计（包括自适应通信机制与速度设置）的有效性。我们还通过实验展示 MASOIE 在不同规模与不同拓扑网络下的性能表现。

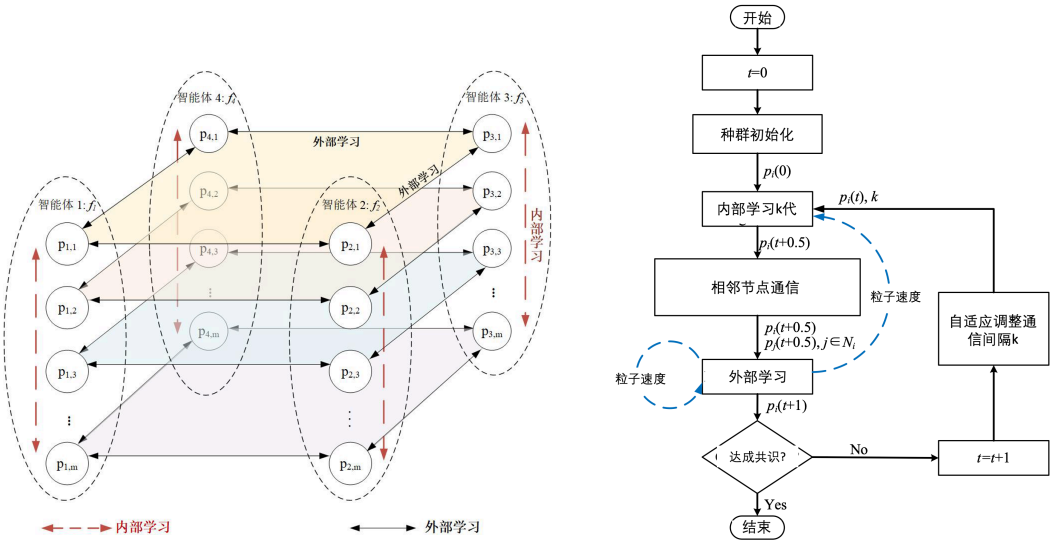
本章其余部分结构如下。第 3.2 节介绍所提出的 MASOIE；第 3.3 节给出 MASOIE 系统共识的理论分析；第 3.4 节进行实验验证；最后，第 3.5 节对本章进行小结。

3.2 基于内外部协同学习的多智能体共识优化算法

本节首先阐述 MASOIE 的整体框架。随后，依次介绍 MASOIE 的三个核心组成部分：内部学习、外部学习以及自适应通信机制。

3.2.1 算法框架

在 MASOIE 中，每个智能体维护一个规模相同的粒子群。我们设计了一个双层学习框架，使粒子可以从两个层面改进解。首先，粒子可以从同一智能体内的其他粒子中学习，称为内部学习。其次，粒子可以从邻接智能体中的粒子中学习，称为外部学习。



a) 学习机制　　b) 智能体流程图

图 3-1 MASOIE 的学习机制与流程图。(a) 为 MASOIE 在一个 4 节点系统中的学习机制示意图，各节点以环形结构连接。智能体 1 的粒子群表示为 $\{p_{1,1}, p_{1,2}, p_{1,3}, ..., p_{1,m}\}$，其他智能体类似。红色虚线箭头表示内部学习，发生在单个智能体内部。内部学习指同一智能体内的粒子相互学习，以优化其本地目标函数。黑色实线箭头表示外部学习，发生在不同智能体之间。外部学习指粒子从相邻智能体的粒子中学习，以协作优化全局目标函数。(b) 智能体的流程图。蓝色箭头表示惯性速度的传递方向。具体而言，粒子在内部学习阶段的惯性速度为上一次外部学习的速度；粒子在外部学习阶段的惯性速度同样为上一次外部学习的速度。

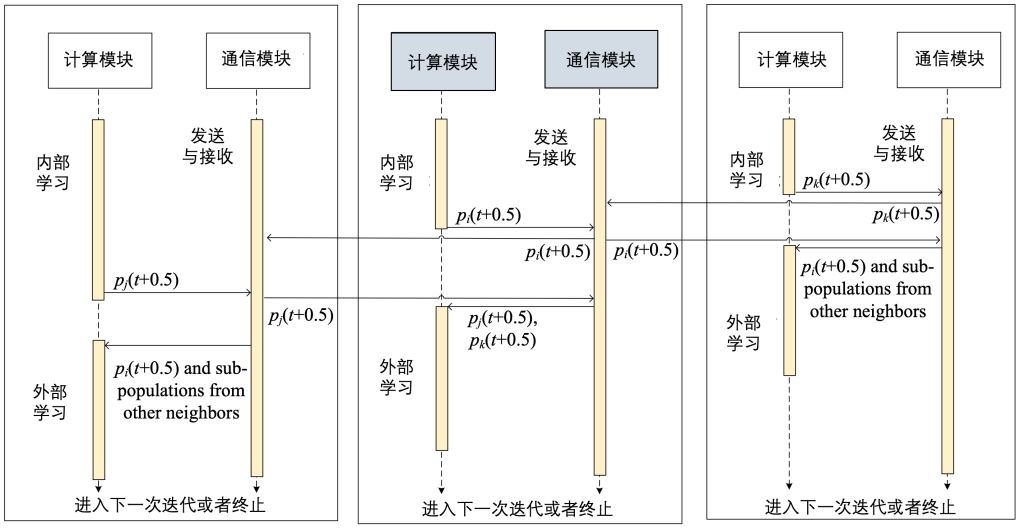


图 3-2 MASOIE 的算法时序图。每个智能体包含计算模块与通信模块。图中假设智能体 j 的计算速度快于智能体 i，而智能体 k 的计算速度慢于智能体 i。

内部学习与外部学习的结合，使得在仅已知各自本地目标函数的情况下，多个智能体能够协同优化全局目标函数。图 3-1a 展示了 MASOIE 在一个 4 智能体系统中的示意图，其中红色虚线箭头与黑色实线箭头分别表示内部学习与外部学习。

在 MASOIE 的每次迭代中主要包括四个步骤：内部学习、通信、外部学习以及自适应间隔调整。图 3-1b 展示了网络系统中智能体 i 的流程图。初始化阶段，智能体 i 初始化其种群 $p_i(0)$，即一个粒子群。在内部学习阶段，智能体对种群 $p_i(t)$ 演化 k 代。为便于表示，将内部学习后的中间状态记为 $p_i(t+0.5)$。随后，智能体 i 与其邻居集合 $\mathcal{N}_i$ 进行通信并交换种群信息。在外部学习阶段，每个智能体利用来自邻居 $\mathcal{N}_i$ 的种群 $p_j(t+0.5)$，对每个粒子执行一次外部学习，得到 $p_i(t+1)$。若系统尚未收敛，智能体 i 将自适应调整通信间隔 k，并进入下一次迭代。MASOIE 在每个智能体上的伪代码如算法 3-1 所示。

智能体的邻居由系统的网络拓扑结构决定。若两个智能体在网络拓扑中相连，则它们互为邻居并可以进行通信。本章考虑静态通信网络。当某智能体完成内部学习后，即向其邻居发送信息；当其接收到所有邻居的信息后，开始执行外部学习。图 3-2 给出了 MASOIE 的一个示例时序图。在该示例中，假设智能体 j 的计算速度快于智能体 i，而智能体 k 的计算速度慢于智能体 i。以智能体 i 为例，当其完成内部学习后，计算模块将种群 $p_i(t+0.5)$ 发送至通信模块；随后通信模块将 $p_i(t+0.5)$ 传输给邻居智能体 j 与 k。之后，智能体 i 等待来自所有邻居的消息。由于智能体 j 较早完成内部学习，其通信模块已提前收到 $p_j(t+0.5)$；智能体 k 在稍后完成并发送 $p_k(t+0.5)$ 至智能体 i。当智能体 i 接收到该消息后，通信模块将 $p_j(t+0.5), p_k(t+0.5)$ 返回至计算模块，随后计算模块开始执行外部学习。

3.2.2 内部学习机制

内部学习是指同一智能体内的粒子相互学习的过程。在该过程中，智能体对其本地目标函数进行探索。

在许多现有 PSO 算法中，例如原始 PSO[73] 和标准 PSO[74]，通常记录粒子的个体历史最优或全局历史最优解，并以此指导粒子的运动。然而，历史最优解机制并不适用于分布式优化问题。在分布式优化中，每个智能体仅能访问自身的本地目标函数，并据此计算粒子的局部适应度，因此所记录的历史最优解是基于本地目标函数的。由于本地目标函数的最优解通常不同于全局目标函数的最优解，系统难以通过历史最优解实现共识收敛。假设在优化过程中某智能体的粒子群位于全局目标函数的最优区域，由于当前位置通常不同于其本地历史最优位置，粒子群难以在该位置保持稳定，从而无法实现全局

共识。

因此，在 MASOIE 的内部学习中，粒子不再基于历史最优解，而是向当前种群中的精英粒子学习。内部学习阶段包含 k 代演化。在内部学习第 g 代时，第 i 个智能体中第 a 个粒子的更新规则为：

$$\begin{aligned} v_{i,a}^{t+\frac{g}{2k}} &= r_1 v_{i,a}^{t+\frac{g-1}{2k}} + r_2(x_{i,b}^{t+\frac{g-1}{2k}} - x_{i,a}^{t+\frac{g-1}{2k}}) + \phi r_3(x_{i,c}^{t+\frac{g-1}{2k}} - x_{i,a}^{t+\frac{g-1}{2k}}) \\ x_{i,a}^{t+\frac{g}{2k}} &= x_{i,a}^{t+\frac{g-1}{2k}} + v_{i,a}^{t+\frac{g}{2k}} \end{aligned} \tag{3-1}$$

其中，$x_{i,a}$ 和 $v_{i,a}$ 分别表示该粒子的位置与惯性速度；$x_{i,b}$ 和 $x_{i,c}$ 为当前种群 p_i 中选取的两个精英粒子；r_1, r_2, r_3 为 $(0,1)$ 区间内的随机权重；ϕ 为常数参数。第 g 代的迭代索引表示为 $t+\frac{g}{2k}$。经过 k 代内部学习后，粒子状态记为 $x_{i,a}^{t+0.5}$，种群记为 $p_i(t+0.5)$。

本章采用基于层级的选择机制[65] 来选择内部学习中的精英粒子 $x_{i,b}$ 与 $x_{i,c}$。在每一代中，每个粒子从同一智能体中选择两个适应度优于自身的学习目标，即满足 $f_i(x_{i,b}^{t+\frac{g-1}{2k}}) < f_i(x_{i,a}^{t+\frac{g-1}{2k}})$ 且 $f_i(x_{i,c}^{t+\frac{g-1}{2k}}) < f_i(x_{i,a}^{t+\frac{g-1}{2k}})$。该层级选择机制根据适应度将种群划分为多个层级 $\{1,2,..,L\}$。对于第 $\{3,4,...,L\}$ 层的粒子，首先随机选择两个低于自身层级的层级，然后在每个层级中随机选择一个粒子；第 2 层粒子从第 1 层中随机选择两个粒子；第 1 层粒子在该代不更新位置。

3.2.3 外部学习机制

外部学习是粒子从邻接智能体的粒子中学习的过程。在该过程中，各智能体协同优化全局目标函数。通常，粒子的惯性速度为其上一次运动的速度，而在外部学习之前，粒子的最近一次运动为内部学习。然而，内部学习得到的速度 $v_{i,a}^{t+0.5}$ 并不适合作为外部学习的惯性速度，因为内部学习的惯性速度（式 3-1）仅反映本地目标函数的优化趋势，缺乏全局意义。相比之下，外部学习的惯性速度（式 3-2）融合了邻接智能体的优化趋势，具有更强的全局意义。因此，外部学习阶段的惯性速度采用上一次外部学习的速度 $v_{i,a}^{t}$。图 3-1b 展示了 MASOIE 中的速度传递关系。

因此，第 i 个智能体中第 a 个粒子在外部学习阶段的位置更新规则为：

$$\begin{aligned} v_{i,a}^{t+1} &= \varphi r_4 v_{i,a}^{t} + \sum_{j \in \mathcal{N}_i} \omega_{ij}(x_{j,a}^{t+0.5} - x_{i,a}^{t+0.5}) \\ x_{i,a}^{t+1} &= x_{i,a}^{t+0.5} + v_{i,a}^{t+1} \end{aligned} \tag{3-2}$$

其中，r_4 为 $(0,1)$ 区间内的随机权重，φ 为常数参数，$v_{i,a}^{t}$ 为上一次外部学习的速度，$x_{j,a}^{t+0.5}$ 表示第 j 个智能体中的第 a 个粒子。

学习权重 $\omega_{i,j}$ 在整个优化过程中保持不变。权重矩阵 $W = [\omega_{i,j}] \in \mathbb{R}^{n\times n}$ 为预设的随机矩阵，满足 $\sum_{j=1}^{n} \omega_{i,j} = 1,\ \forall i = \{1, 2, ..., n\}$。该矩阵基于共识理论进行设计，不同于大多数 PSO 中的随机权重。

在外部学习阶段，一个粒子可能向多个学习目标学习，其数量取决于邻居的数量。通过通信，智能体接收来自邻居的解，这些解代表其他本地目标函数的偏好位置。因此，从其他智能体学习有助于优化全局目标函数并实现共识收敛。

3.2.4 内外部学习频率调控机制

在分布式优化中，智能体的行为包括通信与计算两个方面。通信用于交换信息并实现系统共识，计算用于探索本地目标函数并寻找更优解。因此，需要在通信与计算之间取得平衡，即合理设置通信间隔。为实现系统在早期充分探索、后期精细开发，并最终在不同智能体之间达成共识，本章提出了一种自适应通信机制。

该自适应通信机制通过调整内部学习的代数 k 来改变通信间隔。在优化初期，MASOIE 采用较大的内部学习代数（即较大的通信间隔），以增强种群的探索能力；随着优化过程的推进，根据适应度变化逐步减少内部学习代数（即缩短通信间隔），从而促进系统在后期实现共识收敛。

自适应通信机制的核心思想是在一段时间内种群平均适应度无明显改进时降低通信间隔。由于优化目标为最小化全局目标函数，从理论上讲应采用全局适应度作为判断种群是否进步的指标。然而，在分布式系统中单个智能体无法直接获得全局适应度。因此，引入路由协议在网络中广播本地适应度，使各智能体能够估计全局适应度。

算法 3-1 描述了 MASOIE 的自适应通信机制。在算法开始时，各智能体通过泛洪机制构建路由表。第 i 个智能体的路由表 $R_i = \{(u, v) : \text{send the fitness of agent } u \text{ to neighbor } v\}$ 决定其应向不同邻居转发哪些智能体的适应度信息，从而避免信息冗余传播与旧信息覆盖。在演化过程中，每个智能体维护一个列表 $D_i \in \mathbb{R}^{1\times n}$，记录系统中各智能体的本地适应度（第 2 行）。每次通信时，智能体根据路由表向每个邻居发送 D_i 的一个子集（第 18 行）。该子集因邻居不同而不同。当接收到邻居的适应度信息后，智能体更新其适应度列表 D_i（第 20–22 行）。随后，通过比较当前列表的平均值与历史最优值（第 24 行），判断种群是否取得全局进展。若当前适应度低于记录的最优值，则更新最优值（第 25–26 行）；若连续十代未取得进展，则将通信间隔减一（第 28–31 行）。此外，当通信间隔已达到最小值 $minInv$ 时，将不再继续减小。

Algorithm 3-1 MASOIE 在每个智能体 i 上的执行流程

输入: 局部目标函数 f_i，邻居集合 $\mathcal{N}_i$

在本地优化器中初始化种群 $p_i(0)$，通过洪泛（flooding）构建路由表 R_i
通信间隔 $k = k_0$，适应度列表 $D_i = \mathbf{0}_{1\times n}$，迭代索引 $t = 0$
$c = 0,\ threshold = 10, bestfit = \text{inf}$
while 未收敛 **do**
    for $g = 1$ to k **do**
        for $a = 1$ to m **do**
            选择粒子 b 和 c，并根据式 (3-1) 更新 $v_{i,a}^{t+\frac{g}{2k}}$ 和 $x_{i,a}^{t+\frac{g}{2k}}$
        end for
    end for
    向邻居发送 $p_i(t+0.5)$，并从 $\mathcal{N}_i$ 中的邻居接收 $p_j(t+0.5)$
    for $a = 1$ to m **do**
        根据式 (3-2) 更新 $v_{i,a}^{t+1}$ 和 $x_{i,a}^{t+1}$
    end for
    使用本地目标函数 f_i 更新粒子的适应度
    $D_i(i) = \frac{1}{m}\sum_{a=1}^{m} f_i(x_{i,a}^{t+1})$
    for 每个邻居 $v \in \mathcal{N}_i$ **do**
        向智能体 v 发送 $P_{i,v} = \{(u, D_i(u)) : (u, v) \in R_i\}$，并从邻居 v 接收 $P_{v,i}$
        for $(u, f) \in P_{v,i}$ **do**
            $D_i(u) = f$
        end for
    end for
    if $\frac{1}{n}\sum_{j=1}^{n} D_i(j) < bestfit$ **then**
        $bestfit = \frac{1}{n}\sum_{j=1}^{n} D_i(j)$
        $c = 0$
    else
        $c = c + 1$
        if $c > threshold$ 且 $k > minInv$ **then**
            $k = k - 1, c = 0$
        end if
    end if
    $t = t + 1$
end while

输出: p_i

3.3 内外部协同学习算法的共识证明

在本节中，我们对 MASOIE 的系统共识进行理论分析。在分布式优化中，多智能体系统在解上达成共识是重要且必要的。因此，一个基于种群的分布式优化算法不仅要求每个智能体内部的种群收敛（即 $x^*_{i,a} = x^*_{i,b}\ \forall 1 \leq a, b \leq \|\mathcal{P}\|$），还要求所有智能体最终具有相同的解（即 $x^*_{i,a} = x^*_{j,a}\ \forall 1 \leq i, j \leq n$）。在以下分析中，我们讨论 MASOIE 的确定性实现形式，其中 r_1, r_2, r_3 和 r_4 均取其期望值 $\frac{1}{2}$。此外，ϕ 和 φ 设为 1。

情形 1

给定一个连通图 $G =< V, E >$ 和一个随机矩阵 W，其中当 $(i, j) \in E$ 或 $i = j$ 时，$W_{i,j} > 0$。在 MASOIE 的确定性实现中，当每次迭代执行一次内部学习时，分布式系统最终可以在解上达成共识。

证明: 分布式系统中的总体种群可表示为 $X(t) = \{X_1(t), X_2(t), ..., X_m(t)\}$，其中 t 为迭代索引，m 为每个节点中的种群规模。为方便证明，我们将所有 n 个智能体中的第 i 个粒子组成一个集合，对应于图 3-1a 中的第 i 条横层。其位置和速度分别表示为 $X_i(t)$ 和 $V_i(t)$：

$$
\begin{aligned}
X_i(t) &= \begin{pmatrix} - & x_{1,i}(t)^T & - \\ - & x_{2,i}(t)^T & - \\ & \vdots & \\ - & x_{n,i}(t)^T & - \end{pmatrix} \in \mathbb{R}^{n \times d} \\
V_i(t) &= \begin{pmatrix} - & v_{1,i}(t)^T & - \\ - & v_{2,i}(t)^T & - \\ & \vdots & \\ - & v_{n,i}(t)^T & - \end{pmatrix} \in \mathbb{R}^{n \times d}
\end{aligned}
\tag{3-3}
$$

我们将迭代索引记为 t。由于每次迭代包含一次内部学习和一次外部学习，我们将内部学习后的中间系统状态记为 $X(t + \frac{1}{2})$。

从系统视角看，内部学习过程可表示为：

$$
\begin{aligned}
V_i(t + \frac{1}{2}) &= r_1 V_i(t) + r_2(M_i(t) - X_i(t)) + r_3(N_i(t) - X_i(t)) \\
X_i(t + \frac{1}{2}) &= X_i(t) + V_i(t + \frac{1}{2})
\end{aligned}
\tag{3-4}
$$

其中

$$M_i(t) = \begin{pmatrix} - & x_{1,b_{i,1}}(t)^T & - \\ - & x_{2,b_{i,2}}(t)^T & - \\ & \vdots & \\ - & x_{n,b_{i,n}}(t)^T & - \end{pmatrix} \in \mathbb{R}^{n\times d} \tag{3-5}$$

以及

$$N_i(t) = \begin{pmatrix} - & x_{1,c_{i,1}}(t)^T & - \\ - & x_{2,c_{i,2}}(t)^T & - \\ & \vdots & \\ - & x_{n,c_{i,n}}(t)^T & - \end{pmatrix} \in \mathbb{R}^{n\times d} \tag{3-6}$$

这里，$M_i(t)$ 和 $N_i(t)$ 是各智能体中第 i 个粒子的学习目标。例如，智能体 1 中的第 i 个粒子在式 (3-1) 中选择该智能体中的第 $b_{i,1}$ 个和第 $c_{i,1}$ 个粒子作为其学习目标。

内部学习之后，外部学习过程可表示为：

$$\begin{aligned} V_i(t+1) &= r_4 V_i(t) + (W-I)X_i(t+\frac{1}{2}) \\ X_i(t+1) &= X_i(t+\frac{1}{2}) + V_i(t+1) \end{aligned} \tag{3-7}$$

这里我们考虑 MASOIE 的确定性实现，因此 r_1, r_2, r_3 和 r_4 均取其期望值 $\frac{1}{2}$。则完整一次迭代过程可表示为：

$$\begin{aligned} V_i(t+1) &= \frac{1}{2}WV_i(t) + \frac{1}{2}(W-I)(M_i(t)+N_i(t)) \\ X_i(t+1) &= \frac{1}{2}(W+I)V_i(t) + \frac{1}{2}W(M_i(t)+N_i(t)) \end{aligned} \tag{3-8}$$

假设 M_i 和 N_i 为外生信号，则根据动力系统理论，V_i 的收敛性取决于矩阵 $\frac{1}{2}W$。（可能会认为 V_i 和 X_i 相互影响。实际上，$X_i(t+1)$ 依赖于 $V_i(t)$，但 $V_i(t+1)$ 不依赖于 $X_i(t)$。详细分析见章节3.3.0.1。）由于 W 是随机矩阵，其特征值满足 $|\lambda_i| \leq 1$，$i \in \{1, 2, ..., n\}$。因此矩阵 $\frac{1}{2}W$ 的特征值小于或等于 $\frac{1}{2}$。矩阵收敛的充要条件是其特征值模小于 1。因此，V_i 最终可以收敛，即 $\lim_{t\to\infty} V_i(t) = V_i^*$。其收敛状态为：

$$\begin{aligned} V_i^* &= \frac{1}{2}WV_i^* + \frac{1}{2}(W-I)(M_i(t)+N_i(t)) \\ (I-\frac{1}{2}W)V_i^* &= \frac{1}{2}(W-I)(M_i(t)+N_i(t)) \end{aligned} \tag{3-9}$$

假设 V_i^* 收敛到一个非零向量，则粒子仍在运动，因此 $M_i(t)$ 和 $N_i(t)$ 会持续变化。

这将导致方程左端为静态，而右端为动态的矛盾。因此，最终 $V_i^* = \mathbf{0}$。于是有：

$$\frac{1}{2}(W - I)(M_i(t) + N_i(t)) = 0 \tag{3-10}$$

即：

$$W(M_i(t) + N_i(t)) = I(M_i(t) + N_i(t)) \tag{3-11}$$

随后，根据式 (3-8) 在 $V_i(t)$ 收敛之后，有：

$$X_i(t+1) = \frac{1}{2}W(M_i(t) + N_i(t)) \tag{3-12}$$

根据式 (3-11)，等价于：

$$X_i(t+1) = \frac{1}{2}(M_i(t) + N_i(t)) \tag{3-13}$$

由于 MASOIE 中的学习目标是随机选择的，$M_i(t)$ 和 $N_i(t)$ 在进化过程中不断变化。若 $x_{i,a}^* \neq x_{i,b}^*$, $\exists 1 \leq a, b \leq \|\mathcal{P}\|$，则收敛后该等式不恒成立。（可能会认为当 $M_i(t) \neq N_i(t)$ 时该等式成立。对此情况的详细解释见章节3.3.0.2。）因此，有：

$$x_{i,a}^* = x_{i,b}^* \ \forall 1 \leq a, b \leq \|\mathcal{P}\| \tag{3-14}$$

该结果表明每个节点内种群收敛。进一步，有：

$$X_i^* = \frac{1}{2}W(M_i(t) + N_i(t)) = WX_i^* \tag{3-15}$$

根据共识理论，可得共识条件：

$$x_{i,a}^* = x_{j,a}^* \ \forall 1 \leq i, j \leq n \tag{3-16}$$

情形 2

给定一个连通图 $G =< V, E >$ 和一个随机矩阵 W，其中当 $(i,j) \in E$ 时，$W_{i,j} > 0$。在 MASOIE 的确定性实现中，当每次迭代执行两次内部学习时，分布式系统最终可以在解上达成共识。

证明: 类似于定理 1，我们将分布式系统中粒子的位置和速度分别表示为 $X(t) = \{X_1(t), X_2(t), ..., X_m(t)\}$ 和 $V(t) = \{V_1(t), V_2(t), ..., V_m(t)\}$。

由于每次迭代包含两次内部学习和一次外部学习，我们将第一次内部学习后的中间系统状态记为 $X(t + \frac{1}{3})$，第二次内部学习后的中间状态记为 $X(t + \frac{2}{3})$。从系统视角看，

第一次内部学习过程可表示为：

$$V_i(t+\frac{1}{3}) = r_1 V_i(t) + r_2(M_i^1(t) - X_i(t)) + r_3(N_i^1(t) - X_i(t))$$

$$X_i(t+\frac{1}{3}) = X_i(t) + V_i(t+\frac{1}{3}) \tag{3-17}$$

随后，第二次内部学习过程可表示为：

$$\begin{aligned} V_i(t+\frac{2}{3}) =& r_1 V_i(t+\frac{1}{3}) + r_2(M_i^2(t+\frac{1}{3}) - X_i(t+\frac{1}{3})) + r_3(N_i^1(t+\frac{1}{3}) - X_i(t+\frac{1}{3})) \\ X_i(t+\frac{2}{3}) =& X_i(t+\frac{1}{3}) + V_i(t+\frac{2}{3}) \end{aligned} \tag{3-18}$$

接着，外部学习过程可表示为：

$$\begin{aligned} V_i(t+1) &= r_4 V_i(t) + (W-I)X_i(t+\frac{2}{3}) \\ X_i(t+1) &= X_i(t+\frac{2}{3}) + V_i(t+1) \end{aligned} \tag{3-19}$$

这里我们考虑 MASOIE 的确定性实现，因此 r_1, r_2, r_3 和 r_4 均取其期望值 $\frac{1}{2}$。则完整一次迭代过程可表示为：

$$\begin{aligned} V_i(t+1) =& \frac{1}{4}(W+I)V_i(t) - \frac{1}{2}(W-I)X_i(t) + (W-I)A \\ X_i(t+1) =& (\frac{1}{2}I + \frac{1}{4}W)V_i(t) - \frac{1}{2}WX_i(t) + WA \end{aligned} \tag{3-20}$$

其中

$$A = \frac{1}{4}(M_i^1(t) + N_i^1(t)) + \frac{1}{2}(M_i^2(t+\frac{1}{3}) + N_i^2(t+\frac{1}{3})) \tag{3-21}$$

该动态过程等价于：

$$\begin{bmatrix} V_i(t+1) \\ X_i(t+1) \end{bmatrix} = \begin{bmatrix} \frac{1}{4}(W+I) & -\frac{1}{2}(W-I) \\ \frac{1}{2}I + \frac{1}{4}W & -\frac{1}{2}W \end{bmatrix} \begin{bmatrix} V_i(t) \\ X_i(t) \end{bmatrix} + \begin{bmatrix} (W-I)A \\ A \end{bmatrix} \tag{3-22}$$

假设 M_i^1, M_i^2, N_i^1 和 N_i^2 为外生信号，则 $\begin{bmatrix} V_i(t) \\ X_i(t) \end{bmatrix}$ 的收敛性取决于矩阵 $\begin{bmatrix} \frac{1}{4}(W+I) & -\frac{1}{2}(W-I) \\ \frac{1}{2}I + \frac{1}{4}W & -\frac{1}{2}W \end{bmatrix}$。该动力系统矩阵的特征值小于 1。证明见章节3.3.0.3。

根据动力系统理论，矩阵特征值模小于 1 是收敛的充要条件。因此，$\begin{bmatrix} V_i \\ X_i \end{bmatrix}$ 最终可

以收敛。其收敛状态为：

$$\begin{bmatrix} V_i^* \\ X_i^* \end{bmatrix} = \begin{bmatrix} \frac{1}{4}(W+I) & -\frac{1}{2}(W-I) \\ \frac{1}{2}I+\frac{1}{4}W & -\frac{1}{2}W \end{bmatrix} \begin{bmatrix} V_i^* \\ X_i^* \end{bmatrix} + \begin{bmatrix} (W-I)A \\ A \end{bmatrix} \tag{3-23}$$

其等价形式为：

$$\begin{bmatrix} V_i^* \\ X_i^* \end{bmatrix} - \begin{bmatrix} \frac{1}{4}(W+I) & -\frac{1}{2}(W-I) \\ \frac{1}{2}I+\frac{1}{4}W & -\frac{1}{2}W \end{bmatrix} \begin{bmatrix} V_i^* \\ X_i^* \end{bmatrix} = \begin{bmatrix} (W-I)A \\ A \end{bmatrix} \tag{3-24}$$

由于 MASOIE 中的学习目标是随机选择的，即使 $X_i(t)$ 收敛到 X_i^*，M_i^1, N_i^1, M_i^2 和 N_i^2 仍然会变化。若 $x_{i,a}^* \neq x_{i,b}^*, \exists 1 \leq a, b \leq \|\mathcal{P}\|$，则方程右端在演化过程中将持续变化。然而，当 X_i 收敛到 X_i^* 后，方程左端保持不变。因此，有：

$$x_{i,a}^* = x_{i,b}^* \ \forall 1 \leq a, b \leq \|\mathcal{P}\| \tag{3-25}$$

且

$$A = \frac{3}{2}X_i^* \tag{3-26}$$

该结果表明每个节点内的种群收敛。随后有：

$$\begin{cases} V_i^* = \frac{1}{4}(W+I)V_i^* - 2(W-I)X_i^* \\ X_i^* = (\frac{1}{2}I+\frac{1}{4}W)V_i^* + WX_i^* \end{cases} \tag{3-27}$$

进一步得到：

$$\begin{cases} V_i^* = \mathbf{0} \\ X_i^* = WX_i^* \end{cases} \tag{3-28}$$

根据共识理论，可得共识条件：

$$x_{i,a}^* = x_{j,a}^* \ \forall 1 \leq i, j \leq n \tag{3-29}$$

综上，我们证明了在两种基本条件下，所提出的算法能够实现全局共识。这表明 MASOIE 的基本框架是有效的。除了共识能力之外，还应考虑算法的优化性能。为了进一步提升 MASOIE 的优化性能，我们引入了更为复杂的机制，这增加了理论分析的难度。例如，我们设计了自适应通信机制，并将系数 r_1, r_2, r_3, r_4 设置为随机值。因此，粒子群的动力系统变得高维且复杂，难以用显式的动力学方程表示。基于此，我们将在下

一节通过实验验证 MASOIE 的共识能力。

补充说明

3.3.0.1 对式 (3-8) 中 V_i 动力学矩阵的分析

我们首先列出原文中的两个方程：

$$V_i(t+1) = \frac{1}{2}WV_i(t) + \frac{1}{2}(W-I)(M_i(t)+N_i(t)) \tag{3-30}$$

$$X_i(t+1) = \frac{1}{2}(W+I)V_i(t) + \frac{1}{2}W(M_i(t)+N_i(t)) \tag{3-31}$$

由式 (3-31) 可以导出一个反馈关系：

$$X_i(t+1) - \frac{1}{2}(W+I)V_i(t) = \frac{1}{2}W(M_i(t)+N_i(t)) \tag{3-32}$$

然而，通过进一步运算，我们可以得到：

$$\begin{aligned}
\frac{1}{2}(W+I)V_i(t) &= X_i(t+1) - \frac{1}{2}W(M_i(t)+N_i(t)) \\
&= X_i(t+\frac{1}{2}) + V_i(t+1) - \frac{1}{2}W(M_i(t)+N_i(t)) \\
&= X_i(t) + V_i(t+\frac{1}{2}) + V_i(t+1) - \frac{1}{2}W(M_i(t)+N_i(t)) \\
&= X_i(t) + \frac{1}{2}V_i(t) + \frac{1}{2}(M_i(t)-X_i(t)) + \frac{1}{2}(N_i(t)-X_i(t)) + V_i(t+1) \\
&\quad - \frac{1}{2}W(M_i(t)+N_i(t)) \\
&= \frac{1}{2}V_i(t) + V_i(t+1) + \frac{1}{2}(I-W)(M_i(t)+N_i(t)) \\
\Rightarrow V_i(t+1) &= \frac{1}{2}WV_i(t) + \frac{1}{2}(W-I)(M_i(t)+N_i(t))
\end{aligned} \tag{3-33}$$

该结果与式 (3-30) 等价。

因此，$V_i(t+1)$ 仅取决于 $V_i(t)$ 和外源信号。这就是我们称 V_i 的动力学矩阵为 $\frac{W}{2}$ 的原因。

3.3.0.2 对式 (3-13) 的详细解释

有人可能认为，如果 $M_i(t) = -N_i(t) \neq 0$，则式 (16) 不成立。然而，如果 $M_i(t) = -N_i(t) \neq 0$，则 $M_i(t)$ 和 $N_i(t)$ 并非收敛状态。在这种情况下，$V_i(t)$ 也不是收敛状态。这与 MASOIE 的粒子选择机制有关，该机制在第 III-B 节中介绍。在内部学习阶段，一个粒子在每一代中都会在同一个智能体内随机选择两个优于自身的其他粒子。对于一个粒

子来说，始终满足它所选择的两个粒子互为相反数且不为零是不可能的。

下面，我们采用反证法进行说明。具体而言，我们考虑第 a 个智能体的种群，记作 $\mathcal{P}_a = \{x_{a,1}, x_{a,2}, ..., x_{a,m}\}$。在时间 t，第 a 个智能体的第 i 个粒子选择了第 j 个粒子和第 k 个粒子，那么 $M_i(t)$ 的第 a 行是 $x_{a,j}$，$N_i(t)$ 的第 a 行是 $x_{a,k}$。假设在时间 t 满足 $M_i(t) = -N_i(t) \neq 0$，即 $x_{a,j} = -x_{a,k} \neq 0$。那么，我们总能找到两个不满足该条件的粒子。具体来说，考虑一个粒子 $x_{a,l}$ $(l \neq i, j, k)$，以下两个条件不能同时满足：$x_{a,j} = -x_{a,l} \neq 0$ 且 $x_{a,k} = -x_{a,l} \neq 0$。因此，一旦粒子 (j, l) 或 (k, l) 在后续时间步被粒子 i 选中，$M_i(t) = -N_i(t) \neq 0$ 就不再成立。

因此，在这种情况下，$M_i(t)$ 和 $N_i(t)$ 不是收敛状态。综上所述，当 $M_i(t) = -N_i(t) \neq 0$ 时，$M_i(t)$、$N_i(t)$ 和 $V_i(t)$ 均不是收敛状态。只要 $V_i(t)$ 收敛，就会满足 $x^*_{i,a} = x^*_{i,b}$ $\forall 1 \leq a, b \leq \|\mathcal{P}\|$。

3.3.0.3 对式 (3-22) 中动力学矩阵特征值上界的证明

假设 λ 是该矩阵的一个特征值，而 $x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$ 是对应的单位特征向量（即 $x_1^T x_1 + x_2^T x_2 = 1$）。我们有：

$$\begin{bmatrix} \frac{1}{4}(W+I) & -\frac{1}{2}(W-I) \\ \frac{1}{2}I + \frac{1}{4}W & -\frac{1}{2}W \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \lambda \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \tag{3-34}$$

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}^T \begin{bmatrix} \frac{1}{4}(W+I) & -\frac{1}{2}(W-I) \\ \frac{1}{2}I + \frac{1}{4}W & -\frac{1}{2}W \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \lambda \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}^T \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \lambda \tag{3-35}$$

进而:

$$\begin{aligned} \lambda &= \frac{1}{4}[x_1^T(W+I)x_1 - 2x_1^T(W-I)x_2 + x_2^T(W+2I)x_1 - 2x_2^T W x_2] \\ &= \frac{1}{4}[(x_1+x_2)^T W(x_1 - 2x_2) + x_1^T x_1 + 4x_1^T x_2] \end{aligned} \tag{3-36}$$

因为随机矩阵的最大特征值为 1，所以 W 的 2-范数为 1（$\|W\|_2 = 1$）。根据 Holder 不等式和范数相容性，我们有 $(x_1+x_2)^T W(x_1 - 2x_2) \leq \|x_1 + x_2\| * \|W(x_1 - 2x_2)\| \leq$

$\|x_1+x_2\|*1*\|x_1-2x_2\|$。进而:

$$\begin{aligned}
\lambda \leq & \frac{1}{4}[\|x_1+x_2\|*\|x_1-2x_2\|+x_1^Tx_1+4x_1^Tx_2] \\
= & \frac{1}{4}[\sqrt{x1^Tx1+x_2^Tx_2+2x_1^Tx_2}*\sqrt{x_1^Tx_1+4x_2^Tx_2-4x_1^Tx_2}+x_1^Tx_1+4x_1^Tx_2] \\
= & \frac{1}{4}[\sqrt{1+2x_1^Tx_2}*\sqrt{1+3x_2^Tx_2-4x_1^Tx_2}+x_1^Tx_1+4x_1^Tx_2] \\
= & \frac{1}{4}[\sqrt{1+3x_2^Tx_2-2x_1^Tx_2+6(x_1^Tx_2)(x_2^Tx_2)-8(x_1^Tx_2)^2}+x_1^Tx_1+4x_1^Tx_2] \\
= & \frac{1}{4}[\sqrt{1+3\|x_2\|^2-2\|x_1\|\|x_2\|cos\alpha+6(\|x_1\|\|x_2\|cos\alpha)(\|x_2\|^2)-8\|x_2\|^2\|x_1\|^2cos^2\alpha} \\
& +\|x_1\|^2+4\|x_1\|\|x_2\|cos\alpha] \\
= & \frac{1}{4}[\sqrt{-8\|x_2\|^2\|x_1\|^2cos^2\alpha+(-2+6\|x_2\|^2)\|x_1\|\|x_2\|cos\alpha+1+3\|x_2\|^2} \\
& +\|x_1\|^2+4\|x_1\|\|x_2\|cos\alpha]
\end{aligned} \tag{3-37}$$

其中 α 是 x_1 和 x_2 之间的夹角，$\alpha \in [0,\pi]$。因为 $x_1^Tx_1+x_2^Tx_2=1$，令 $cos\theta=\|x_1\|$ 且 $sin\theta=\|x_2\|$，其中 $\theta \in [0,\frac{\pi}{2}]$。

$$\begin{aligned}
\lambda \leq & \frac{1}{4}[\sqrt{-8sin^2\theta cos^2\theta cos^2\alpha+(-2+6sin^2\theta)cos\theta sin\theta cos\alpha+1+3sin^2\theta} \\
& +cos^2\theta+4cos\theta sin\theta cos\alpha]
\end{aligned} \tag{3-38}$$

where $\theta \in [0,\frac{\pi}{2}]$.

不等式的右侧是关于两个变量 θ 和 α 的函数。当 $\alpha=0$ 且 $\theta \approx 0.9757$ 时达到最大值。最大值约为 0.9231。因此，$\lambda<1$。

3.4 实验

本节首先介绍基准函数与实验设置。其次，通过实验验证所提出的自适应通信机制、惯性速度设置以及嵌入算法的效果。第三，将 MASOIE 与四种现有算法进行比较。最后，测试 MASOIE 在不同网络拓扑结构下的性能。

3.4.1 测试基准函数

为了测试分布式优化算法的有效性，我们构建了一组分布式优化基准函数。在该基准上测试算法时，每个智能体 i 只能访问其本地目标函数 f_i。需要注意的是，全局目标函数 $F=\frac{1}{n}\sum_{i=1}^{n}f_i(x)$ 仅用于评估算法效果，在优化过程中任何智能体都无法访问该全局目标函数。

所提出的分布式优化基准函数具有如下特征：

- F1-F4：同质、平移、不可分，包含单峰与多峰基础函数
- F5-F10：异质、平移、不可分，包含单峰与多峰基础函数
- F11-F12：同质、最优解位于边界、不可分，包含单峰与多峰基础函数
- F13-F14：同质、平移、部分可分，包含单峰与多峰基础函数
- F15：同质、真实应用问题

3.4.1.1 合成函数

智能体 i 的本地目标函数如式 (3-39) 所示，由一个非凸基础函数和一个线性项构成，因此本地目标函数是非凸的。

$$\begin{aligned} f_i(x) &= f^i_{elementary}(z) + \sum_{j=1}^{D}[A]_{ij}x_j \\ \text{其中}\ \ z &= T^{0.2}_{asy}(T_{osz}(R_i(x - x_{opt}))) \\ \text{且}\ \ \sum_{i=1}^{n}[A]_{ij} &= 0, j = 1, 2, ..., D \end{aligned} \tag{3-39}$$

其中 D 为决策变量个数，n 为智能体数量。基础函数 $f^i_{elementary}$ 可以选用 Elliptic、Schwefel、Rosenbrock 或 Griewank 函数。

全局目标函数为所有本地目标函数的平均值。由于各子问题中的线性项相互抵消，因此全局目标函数等于所有基础函数的平均值，即 $F(x) = \frac{1}{n}\sum_{i=1}^{n} f_i(x) = \frac{1}{n}\sum_{i=1}^{n} f^i_{elementary}$。

式 (3-39) 中的本地目标函数通过以下四个步骤构造：

- 将基础函数的最优解从 $\vec{0}$ 平移至 x_i^{opt}。在 F1-F10 和 F13-F14 中，x_i^{opt} 在搜索范围内随机生成；在 F11-F12 中，x_i^{opt} 的一半变量被设置在搜索边界上。
- 使用随机生成的正交矩阵 R 对向量进行旋转。在 F1-F12 中，对全部变量向量进行旋转，使本地目标函数不可分；在 F13-F14 中，仅对部分变量进行旋转，使本地目标函数部分可分。
- 将向量输入变换函数 T_{osz}，以构造平滑的局部不规则性。
- 将向量输入变换函数 T_{asy}，以破坏对称函数的对称性。

3.4.1.2 真实应用

F15 为带噪声测量的分布式多目标定位问题，其构造如下：

$$\begin{aligned} F(x) &= \frac{1}{n}\sum_{i=1}^{n} f_i(x) \\ \text{其中}\quad f_i(x) &= \sum_{t=1}^{N_t}(\phi_{it} - \|x_{[t*3,t*3+2]} - \omega_i\|^2)^2 \end{aligned} \tag{3-40}$$

其中 N_t 为目标数量，ω_i 为传感器 i 的位置，ϕ_{it} 为传感器 i 到目标 t 的带噪距离测量值。ω_i 为三维向量，$x_{[t*3,t*3+2]}$ 表示第 t 个目标位置的估计值。

3.4.1.3 实验设置

我们在 10 个基准函数 F1-F10 上测试 MASOIE 及其他算法。F1-F4 为同质函数，F5-F10 为异质函数。每个函数包含 100 个决策变量和 20 个节点。种群规模设为 300。根据文献[65] 中的分层机制，层数候选集合设为 $\{4, 6, 8, 10, 20, 50\}$。通信间隔在 3.4.2 中进行研究。根据实验结果，在后续实验中初始通信间隔 k_0 设为 4，最小间隔 $minInv$ 设为 2。

每个实验重复 25 次。实验在由 Intel(R) Xeon(R) CPU E5-2699 v3@2.30GHz 36 核处理器和 CentOS 7.5 x64 系统组成的集群上进行。

3.4.2 自适应通信机制的效果验证

3.4.2.1 静态通信间隔的性能验证

我们首先测试采用静态通信间隔（即内部学习次数 k）的 MASOIE 性能。通信间隔分别设置为 1 至 8，并测试其表现。共识能力与解质量分别见图3-3 和图 3-4。在图 3-4 中，纵坐标为智能体平均解的全局适应值，计算方式为 $\frac{1}{n}\sum_{i=1}^{n} f_i(\frac{1}{n}\sum_{j=1}^{n} x_{j,0})$。根据解质量结果，在 F1、F2、F5、F7、F8 和 F10 上，当通信间隔设为 4 时，MASOIE 取得最低适应值。因此，通信间隔为 4 时解质量优于其他取值。然而，根据图3-3 的收敛结果，当通信间隔大于 3 时，MASOIE 无法收敛。

该实验结果的原因在于通信间隔会影响系统多样性。内部学习会增加系统多样性，因为每个智能体探索自身本地目标；相反，外部学习会降低系统多样性，因为智能体之间融合种群。因此，通信间隔实际上是在探索能力与共识能力之间的权衡。较小通信间隔的 MASOIE 具有更强的共识能力但较弱的探索能力；较大通信间隔的 MASOIE 具有更强的探索能力但较弱的共识能力。因此，当通信间隔为静态时，很难在探索能力与共

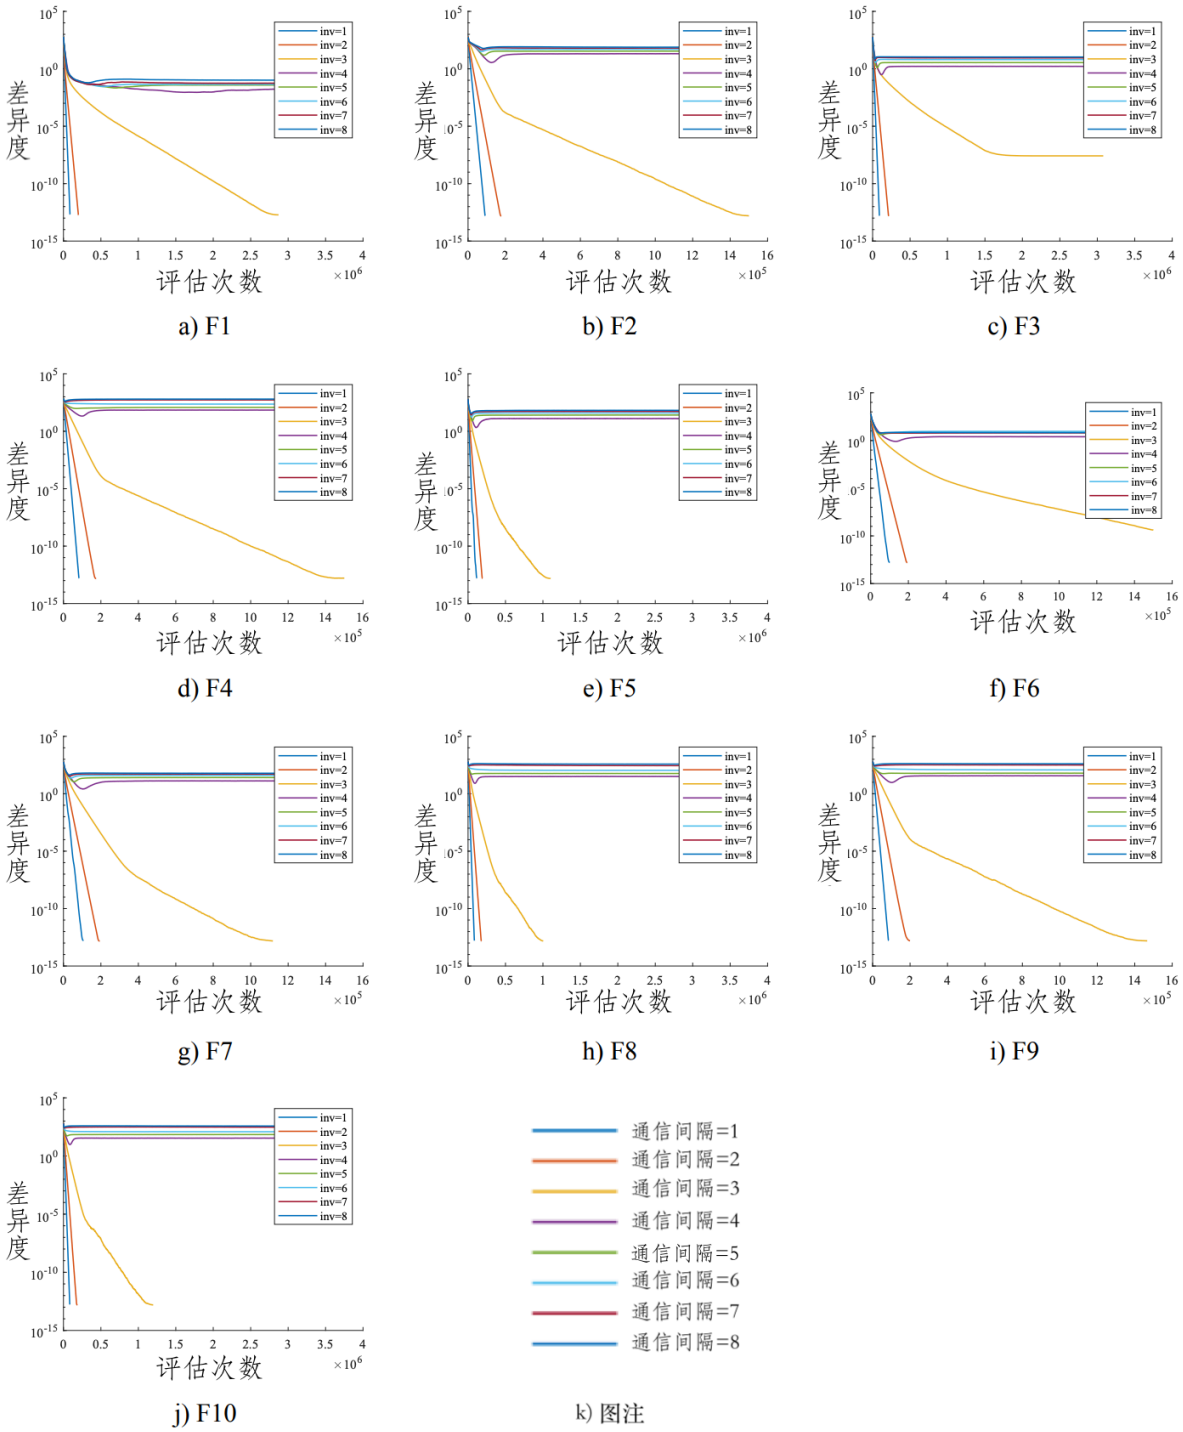


图 3-3 当算法采用不同大小的静态间隔时取得的收敛性能

识能力之间取得平衡。这促使我们研究自适应通信间隔机制，在不同优化阶段采用不同的通信间隔。

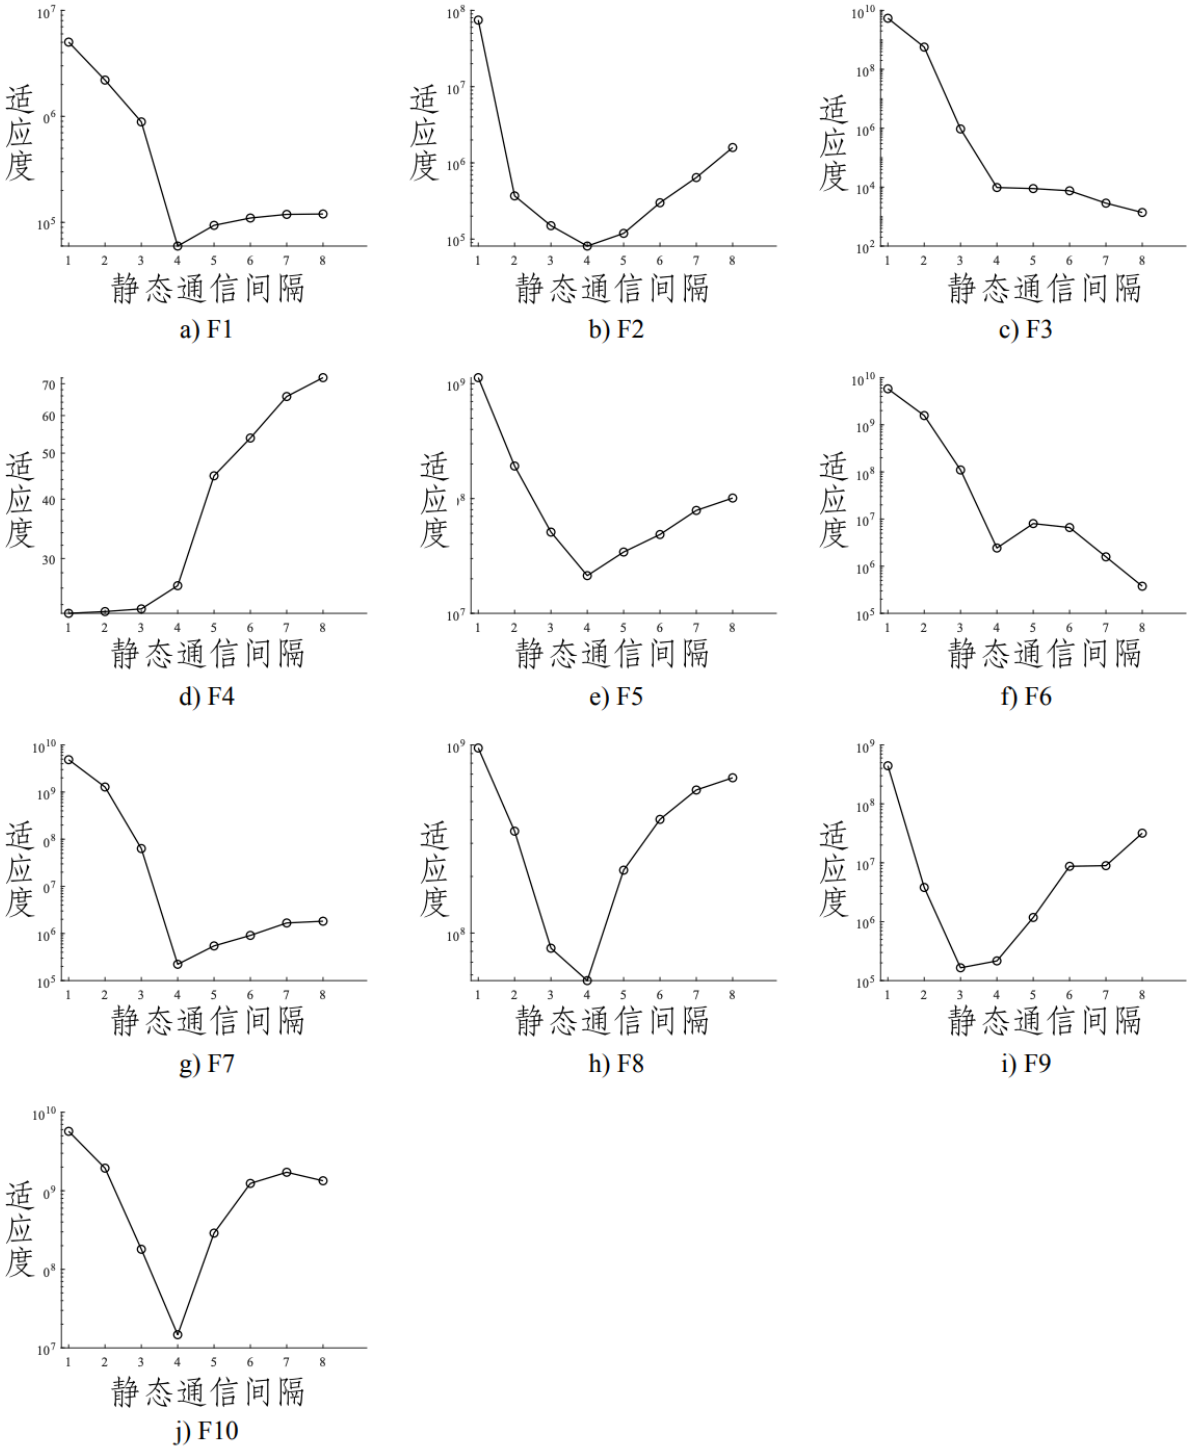


图 3-4 当算法采用不同大小的静态间隔时取得的优化性能

3.4.2.2 自适应通信间隔的性能验证

针对上述静态通信间隔的困难，本章提出的自适应通信间隔方法可以同时兼顾探索与共识。类似地，我们测试了采用自适应通信间隔的 MASOIE 性能。初始通信间隔分别设置为 2 至 8。本实验中最小间隔设为 2，原因有二：第一，根据章节 3.3，MASOIE

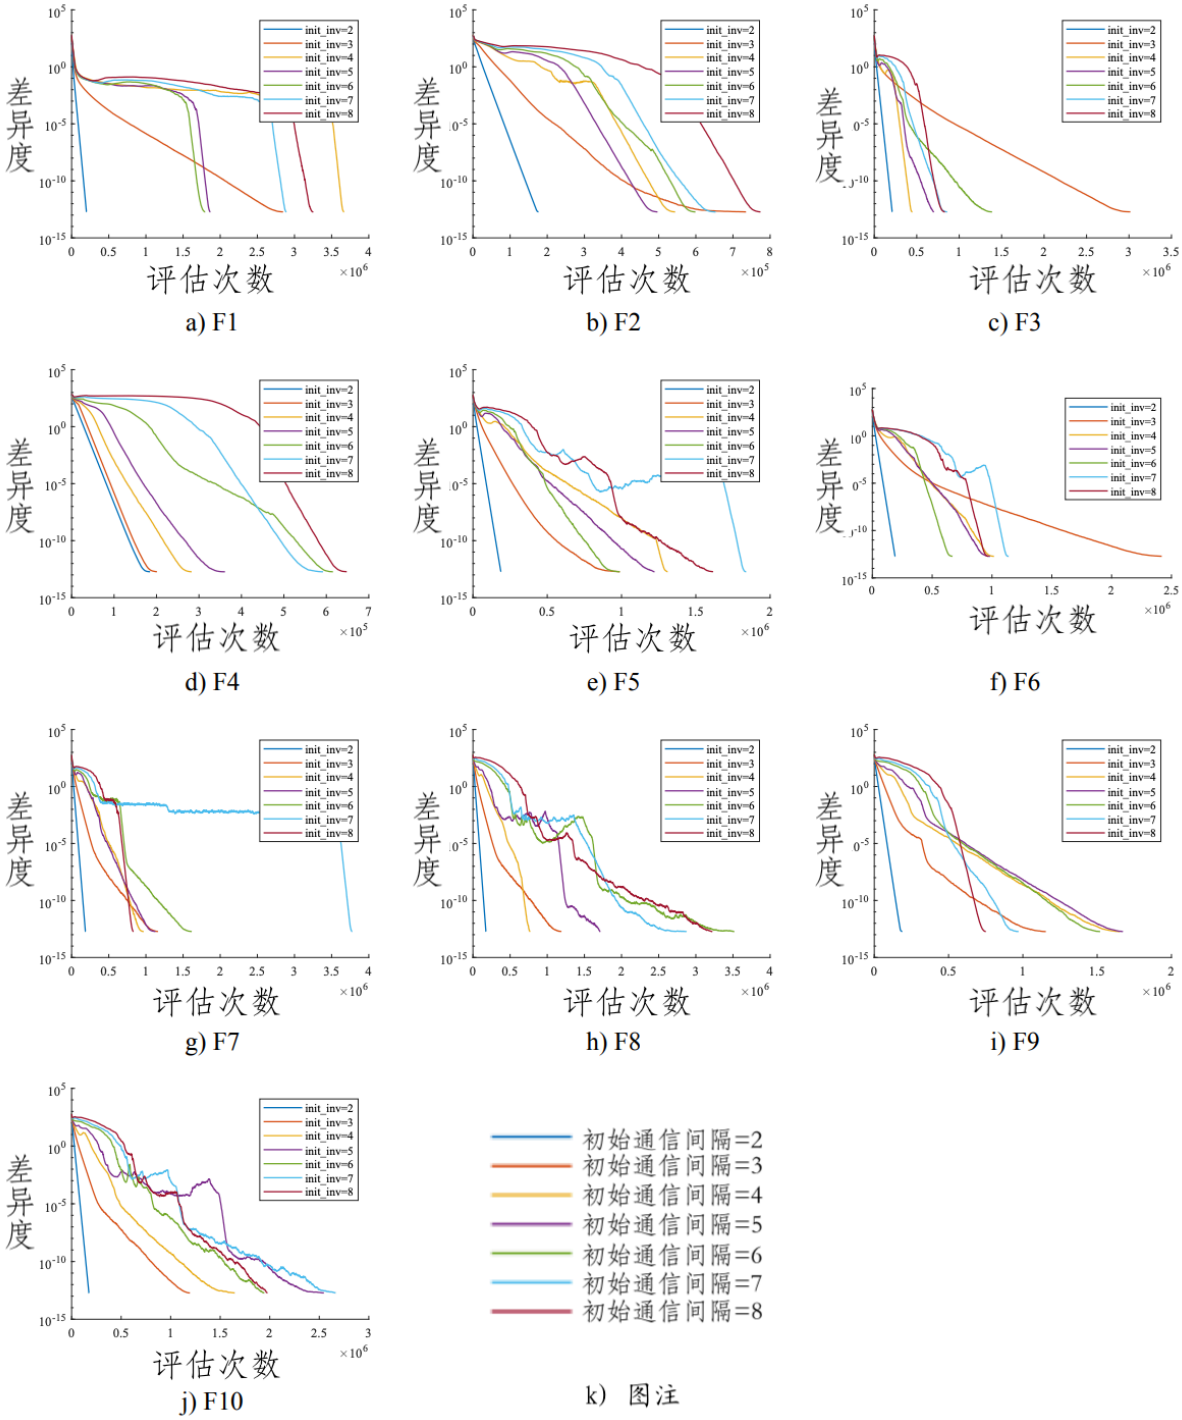


图 3-5 当算法应用动态间隔机制时，设置不同初始间隔时取得的收敛性能

的确定性实现当间隔为 2 时可证明达到共识；第二，根据章节3.4.2.2，当静态间隔设为 2 时，MASOIE 在测试函数上能够达到共识。共识能力与解质量分别见图3-5 和表 3-1。

根据图3-5，当自适应通信机制的初始间隔设为 2-8 时，MASOIE 在十个测试函数上均可达到共识。这表明自适应通信机制可以提升 MASOIE 的共识能力。根据表 3-1 的解质量结果，当初始间隔设为 4 时，MASOIE 在十个函数中的六个上优于其他取值。采用

自适应间隔机制时，最优间隔选择与前述实验结果相似。在该表中，我们还比较了自适应间隔与静态间隔的最优结果。结果显示，在 F2、F5、F6、F8 和 F10 上，自适应间隔显著优于静态间隔。相反，在 F3 上，当间隔设为 8 时，静态间隔显著优于自适应间隔。然而，当间隔为 8 时，静态间隔下的 MASOIE 无法达到共识。在其余四个函数上，两者无显著差异。综上，所提出的自适应间隔机制有利于提升算法的共识能力，且解质量具有竞争力。后续实验中初始间隔设为 4。

表 3-1 当自适应通信机制采用不同初始间隔时 MASOIE 的性能表现

	2	3	4	5	6	7	8	动态间隔（最佳）	静态间隔（最佳）	p-value
F1	2.18E+06	8.83E+05	**6.23E+04**	9.16E+04	1.15E+05	1.16E+05	1.03E+05	6.23E+04	**5.98E+04**	1.76E-01
F2	3.76E+05	1.49E+05	**6.49E+04**	7.42E+04	8.46E+04	9.42E+04	1.19E+05	**6.49E+04**	8.11E+04	1.14E-04#
F3	5.81E+08	9.72E+05	9.70E+03	8.94E+03	5.93E+03	**3.52E+03**	5.70E+03	3.52E+03	**1.38E+03**	7.08E-10*
F4	**2.31E+01**	2.36E+01	2.42E+01	2.54E+01	3.37E+01	3.89E+01	5.92E+01	2.31E+01	**2.30E+01**	1.30E-01
F5	1.92E+08	5.06E+07	**1.98E+07**	2.52E+07	2.99E+07	2.96E+07	2.81E+07	**1.98E+07**	2.13E+07	1.72E-02#
F6	1.57E+09	1.06E+08	2.09E+06	6.50E+06	5.30E+06	1.34E+06	**1.72E+05**	**1.72E+05**	3.76E+05	2.05E-07#
F7	1.26E+09	6.23E+07	**1.83E+05**	2.91E+05	3.50E+05	3.55E+05	4.46E+05	**1.83E+05**	2.22E+05	1.61E-01
F8	3.52E+08	8.30E+07	**4.50E+07**	9.50E+07	1.37E+08	1.68E+08	2.18E+08	**4.50E+07**	5.59E+07	2.81E-06#
F9	3.40E+06	**1.70E+05**	2.02E+05	2.94E+05	1.41E+06	9.06E+05	9.64E+06	1.70E+05	**1.65E+05**	1.81E-01
F10	1.93E+09	1.89E+08	**1.02E+07**	1.22E+08	2.74E+08	3.61E+08	5.27E+08	**1.02E+07**	1.47E+07	4.23E-04#

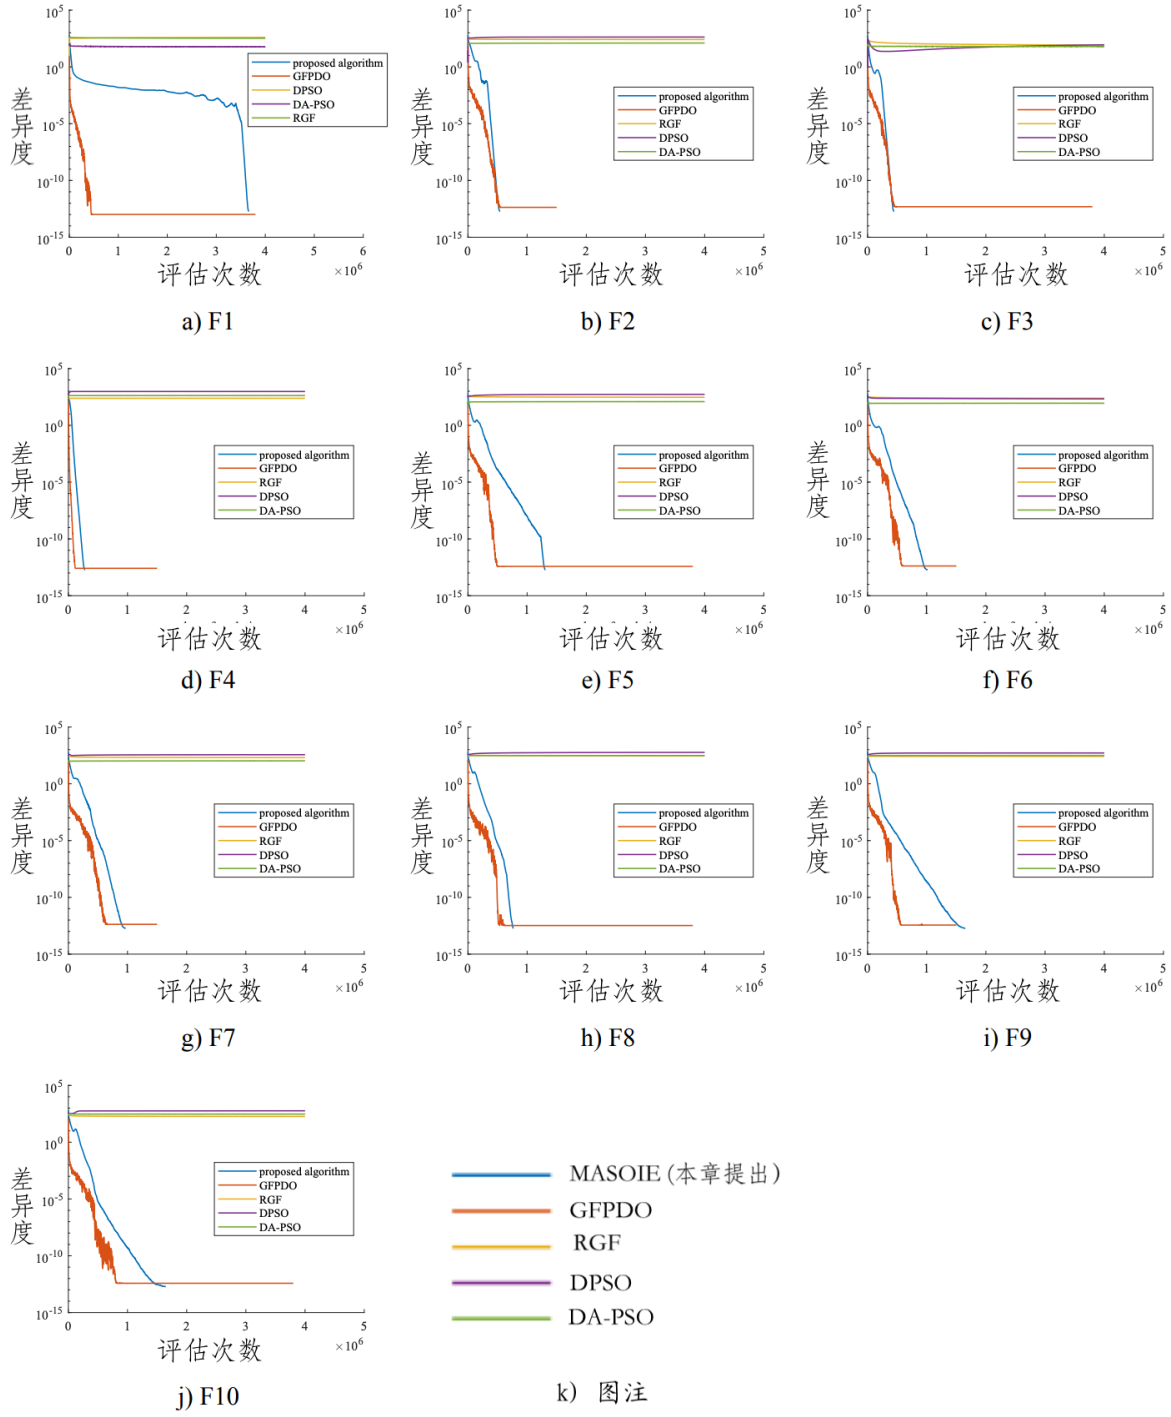
该符号代表在 Wilcoxon rank sum test（0.05）下自适应间隔显著优于静态间隔

* 该符号代表在 Wilcoxon rank sum test（0.05）下自适应间隔显著劣于静态间隔

3.4.3 与现有算法的比较与分析

在本实验中，我们将 MASOIE 与四种现有算法进行比较。GFPDO（A general framework for population-based distributed optimization）[70] 属于第一类分布式进化计算算法。DPSO（Distributed particle swarm optimization using an average consensus algorithm）[72] 与 DA-PSO（Distributed particle swarm optimization algorithm using the strategies of diffusion adaptation）[71] 属于第二类分布式进化计算算法。RGF (Randomized Gradient-Free Methods)[27] 是一种用于分布式优化的随机无梯度方法。由于 GFPDO 与 DPSO 为通用框架，为保证公平比较，我们均采用 LLSO 作为其嵌入算法。

解质量结果见表 3-2。MASOIE 在 15 个函数中的 12 个上优于其他算法，仅在 F4、F8 和 F10 上例外。这三个函数均包含基础函数 Griewank，该函数为多峰函数。面对该函数时，MASOIE 的搜索不够充分，出现提前收敛。GFPDO 本质上模拟集中式优化过程，因此在复杂问题 F4 上表现更优。根据图 3-6，由于 DPSO 未收敛，其消耗了更多评



a) F1　b) F2　c) F3

d) F4　e) F5　f) F6

g) F7　h) F8　i) F9

j) F10　k) 图注

图 3-6 MASOIE 与四种现有算法 GFPDO、RGF、DPSO 和 DA-PSO 的比较。纵轴“disagreement”表示不同智能体（agents）之间解的距离。当 disagreement 降至 1E-13 时，认为算法已收敛并终止。该实验重复进行 25 次。根据实验结果，仅 MASOIE 和 GFPDO 能够使分布式系统收敛到同一解，而另外三种算法则不能。

表 3-2 MASOIE 与对比算法的比较结果

		MASOIE	GFPDO	RGF	DPSO	DA-PSO		MASOIE	GFPDO	RGF	DPSO	DA-PSO
mean	F1	**6.23E+04**	2.44E+06	4.58E+08	1.42E+07	1.10E+07	F9	**2.02E+05**	3.64E+07	4.46E+07	5.39E+07	3.31E+08
median		6.12E+04	2.34E+06	4.50E+08	1.40E+07	9.52E+06		2.00E+05	3.50E+07	2.71E+07	5.15E+07	1.93E+08
std		7.78E+03	6.97E+05	1.96E+07	4.55E+06	4.39E+06		1.93E+04	1.20E+07	5.71E+07	1.15E+07	3.70E+08
p-value		-	7.08e-10#	7.08e-10#	7.08e-10#	7.08e-10#		-	7.08e-10#	7.08e-10#	7.08e-10#	7.08e-10#
mean	F2	**6.49E+04**	1.57E+07	1.45E+08	1.02E+08	7.02E+07	F10	1.02E+07	2.30E+09	2.46E+09	**2.27E+04**	5.52E+09
median		6.18E+04	1.46E+07	1.45E+08	1.04E+08	6.94E+07		9.27E+06	2.30E+09	2.42E+09	2.27E+04	5.26E+09
std		8.48E+03	7.22E+06	0.00E+00	2.53E+07	8.22E+06		3.02E+06	9.69E+07	5.15E+08	1.25E+02	9.95E+08
p-value		-	7.08e-10#	4.86e-11#	7.08e-10#	7.08e-10#		-	7.08e-10#	7.08e-10#	7.08e-10*	7.08e-10#
mean	F3	**9.70E+03**	2.60E+09	3.57E+07	4.53E+04	4.02E+08	F11	**7.14E+05**	9.28E+12	4.85E+07	6.66E+07	1.30E+08
median		9.58E+03	2.53E+09	3.54E+07	4.53E+04	4.06E+08		7.06E+05	9.20E+12	4.85E+07	6.50E+07	1.23E+08
std		2.36E+03	2.23E+08	7.68E+05	3.64E+02	7.01E+07		3.01E+04	1.31E+12	0.00E+00	1.80E+07	4.83E+07
p-value		-	7.08e-10#	6.83e-10#	7.08e-10#	7.08e-10#		-	1.42e-09#	9.73e-11#	1.42e-09#	1.42e-09#
mean	F4	2.42E+01	**1.56E+01**	2.80E+01	2.93E+02	3.46E+01	F12	**2.00E+04**	4.89E+11	5.05E+08	3.08E+04	3.39E+09
median		2.41E+01	1.56E+01	2.79E+01	2.93E+02	3.52E+01		1.98E+04	4.89E+11	5.05E+08	3.05E+04	3.49E+09
std		1.06E+00	3.50E-01	1.88E+00	0.00E+00	3.15E+00		3.25E+03	1.24E+10	2.92E+06	3.08E+02	8.85E+08
p-value		-	7.08e-10*	8.20e-09#	4.86e-11#	7.08e-10#		-	1.42e-09#	8.34e-10#	1.41e-09#	1.42e-09#
mean	F5	**1.98E+07**	5.39E+08	1.81E+09	3.56E+10	6.52E+08	F13	**2.36E+04**	8.67E+04	1.98E+05	8.25E+05	1.90E+07
median		1.97E+07	5.32E+08	1.81E+09	8.52E+09	6.73E+08		2.48E+04	8.60E+04	1.96E+05	8.03E+05	1.85E+07
std		1.56E+06	3.78E+07	9.19E+06	6.64E+10	1.07E+08		4.49E+03	1.17E+04	2.37E+04	7.65E+04	2.25E+06
p-value		-	7.08e-10#	7.08e-10#	7.08e-10#	7.08e-10#		-	1.42e-09#	1.42e-09#	1.42e-09#	1.42e-09#
mean	F6	**2.09E+06**	2.77E+09	2.98E+09	9.19E+10	1.82E+09	F14	**3.69E+04**	8.54E+07	1.45E+08	3.98E+04	6.69E+06
median		1.99E+06	2.84E+09	2.99E+09	7.88E+10	1.80E+09		3.69E+04	8.42E+07	1.43E+08	4.00E+04	6.45E+06
std		6.27E+05	2.17E+08	2.71E+07	5.54E+10	3.18E+08		2.93E+03	6.34E+06	8.47E+06	7.01E+02	1.34E+06
p-value		-	7.08e-10#	7.08e-10#	7.08e-10#	7.08e-10#		-	1.42e-09#	1.42e-09#	3.88e-06#	1.42e-09#
mean	F7	**1.83E+05**	2.31E+09	2.82E+09	1.83E+11	2.05E+09	F15	**4.21E+04**	1.98E+05	6.16E+05	2.29E+05	2.01E+05
median		1.94E+05	2.32E+09	2.82E+09	1.55E+11	1.89E+09		4.15E+04	1.97E+05	6.06E+05	2.31E+05	1.98E+05
std		7.53E+04	1.75E+08	0.00E+00	6.54E+10	4.62E+08		3.87E+03	4.18E+03	6.99E+04	2.70E+04	1.49E+04
p-value		-	7.08e-10#	4.86e-11#	7.08e-10#	7.08e-10#		-	1.42e-09#	1.42e-09#	1.42e-09#	1.42e-09#
mean	F8	4.50E+07	4.41E+08	1.52E+09	**4.16E+06**	1.51E+09						
median		4.49E+07	4.42E+08	1.54E+09	3.92E+06	1.42E+09						
std		3.84E+06	2.09E+07	2.55E+08	1.32E+06	5.19E+08						
p-value		-	7.08e-10#	7.08e-10#	7.08e-10*	7.08e-10#						

估次数，因此在 F8 与 F10 上的解质量优于 MASOIE。

综上，与上述四种算法相比，MASOIE 在基准函数上表现出稳定的共识性能、具有竞争力的解质量以及更低的通信成本。

3.4.4 算法在不同网络规模与结构上的性能验证

3.4.4.1 MASOIE 在不同规模网络上的性能

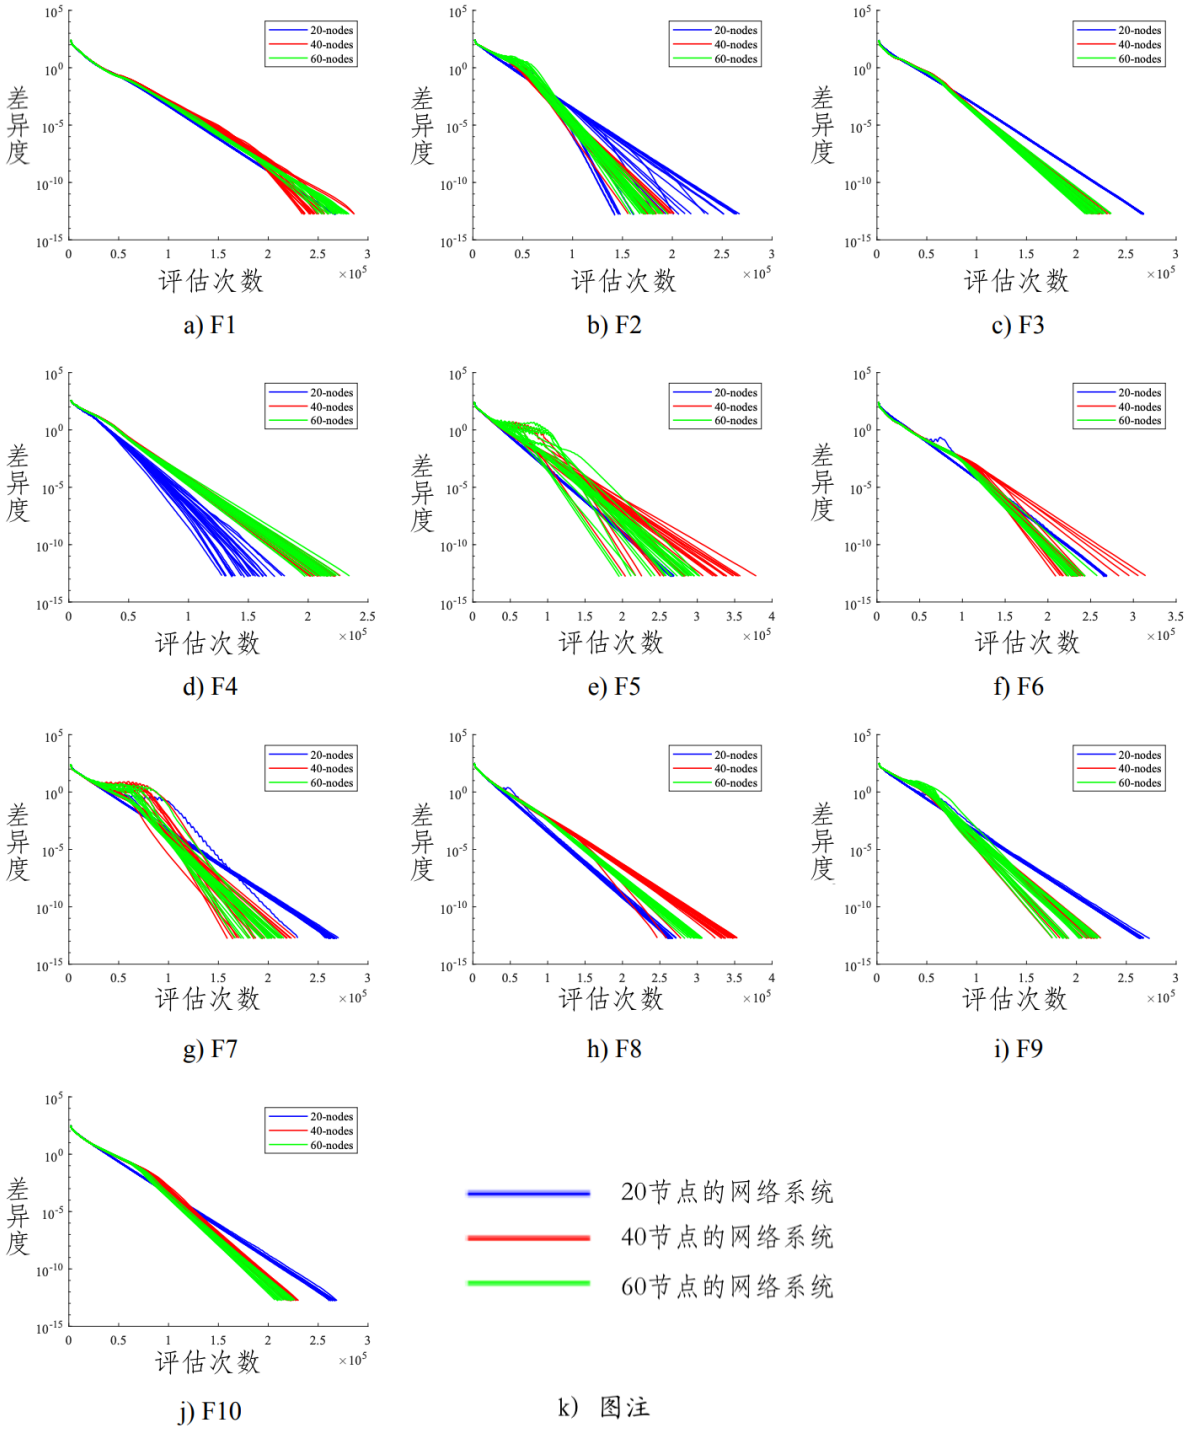


图 3-7 确定性-MASOIE 在 20、40、60 节点的系统下的收敛表现

在本实验中，我们测试 MASOIE 在不同规模网络上的性能。基于原基准函数，我们设计了 40 节点网络和 60 节点网络。首先，我们测试 MASOIE 确定性实现的共识能

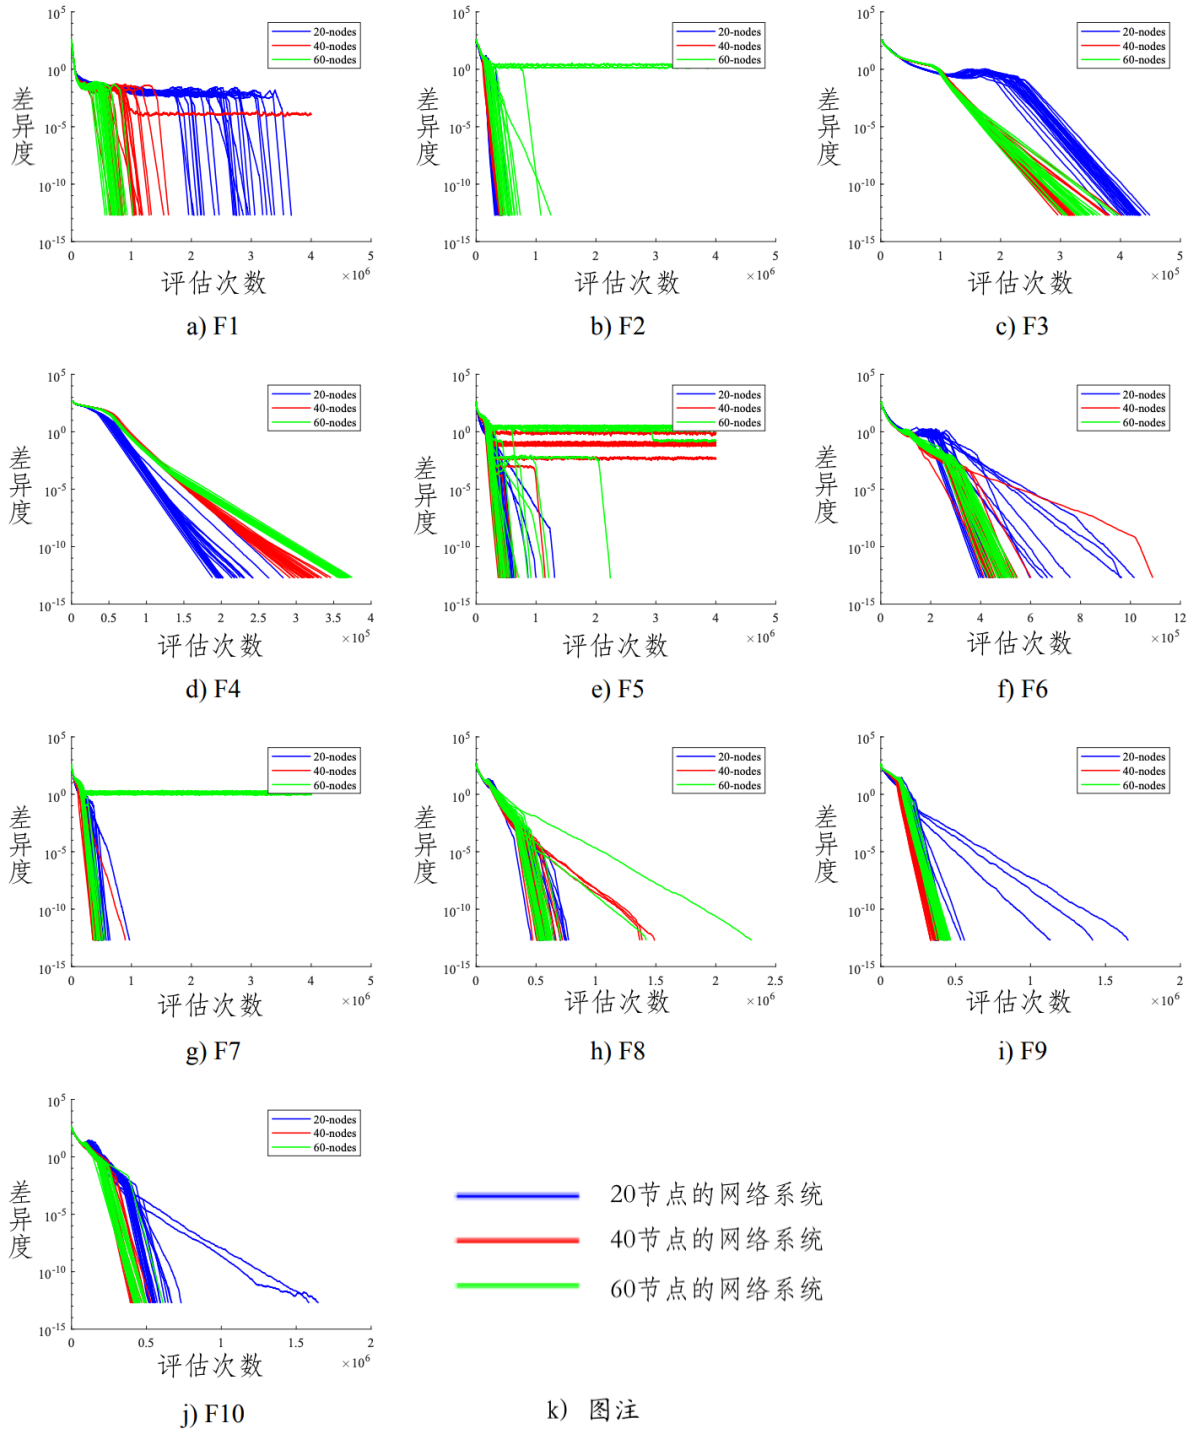


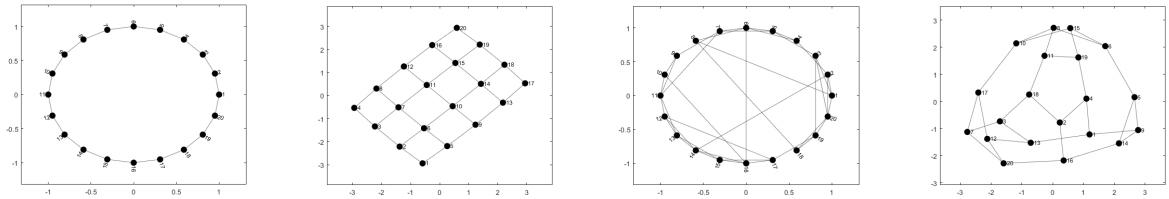
图 3-8 MASOIE 在 20、40、60 节点的系统下的收敛表现

力，结果见图3-7。根据结果，当节点数为 20、40 和 60 时，deterministic-MASOIE 均能够良好收敛。

随后，我们测试引入随机学习权重 r_1-r_4 的 MASOIE 的共识能力，结果见图3-8。根据结果，当节点数为 20 时，MASOIE 能够良好收敛。当网络中有 40 或 60 个节点时，在 F1、F2、F5 和 F7 上存在少量实验在最大评估次数内未能收敛。MASOIE 的收敛性能劣

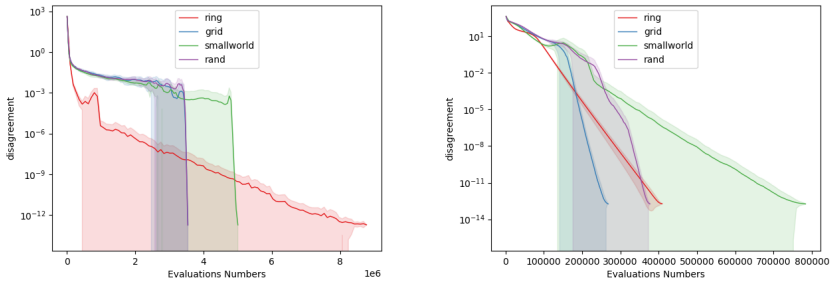
于 deterministic-MASOIE 的原因在于随机参数 r_1-r_4 增大了种群多样性。

3.4.4.2 MASOIE 在不同网络拓扑上的性能

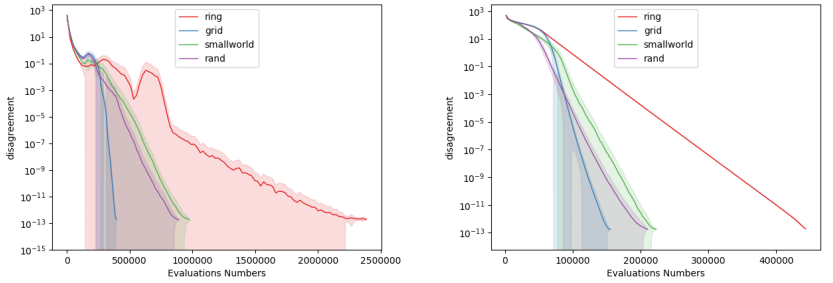


a) 环形网络　　b) 网格网络　　c) 小世界网络　　d) 随机网络

图 3-9 实验测试的四类网络拓扑



a) F1　　b) F2



c) F3　　d) F4

图 3-10 MASOIE 在不同网络拓扑下的共识表现

为验证所提出更新规则是否适用于不同网络拓扑，我们构建了四种拓扑结构并进行实验。如图3-9 所示，我们构建了环形网络、网格网络、小世界网络和随机网络。我们在四个同质基准函数 F1-F4 上测试 MASOIE 的性能。共识结果见图3-10。在函数 F1-F4 上，所有网络中的系统差异度度均下降至 1E−13，表明 MASOIE 在所测试的四种网络拓扑下均可实现共识。

3.5 本章小结

本章针对黑盒与非凸分布式优化问题，提出了一种具有自适应内部与外部学习机制的多智能体群体优化算法（MASOIE）。每个智能体通过内部学习与外部学习两个交替阶段演化一组粒子。在内部学习阶段，同一智能体内的粒子相互学习，从而优化本地目标；在外部学习阶段，不同智能体间的粒子相互学习，以优化全局目标。为提升系统共识性能与通信效率，本章提出了外部学习中的特殊速度设置以及自适应通信机制。

我们构建了一个黑盒分布式优化基准集，包括 14 个合成函数和 1 个真实应用问题，并将 MASOIE 与四种现有黑盒分布式优化算法（GFPDO、RGF、DPSO 和 DA-PSO）进行比较。通过共识性能与解适应值对算法进行评估，以反映系统各节点最终解是否共识以及是否符合全局目标。首先，实验表明 MASOIE 与 GFPDO 的共识性能优于 RGF、DPSO 和 DA-PSO。其次，在 15 个函数中，MASOIE 在 12 个函数上获得最佳解适应值；在其余三个以 Griewank 为基础函数的多峰函数（即 F4、F8 和 F10）上排名第二。

未来研究中，我们将尝试根据邻居智能体的贡献自适应调整外部学习权重，以期提升算法在高度异质问题上的性能。此外，在 60 节点网络上的基准函数实验中，MASOIE 的共识收敛速度慢于 20 节点网络。如何改进通信与协作机制，使算法能够扩展至更大规模网络，是今后的另一重要研究方向。

第四章　基于协同步长自适应机制的多智能体共识优化算法

4.1　引言

在许多复杂场景中，梯度信息难以获得或计算不可行。首先，当解的质量通过仿真评估时，目标函数往往不存在显式数学表达。例如，网络影响力评估依赖蒙特卡洛仿真[29]，交通效率评估需要真实道路网络仿真[30]，车辆性能评估依赖物理测试[33-34]。其次，在超参数优化问题中梯度信息同样不可获得。例如神经网络结构搜索[32]、机器学习特征选择[31]、智能电网潮流计算[75] 等场景。因此，不依赖梯度信息的黑盒分布式优化具有重要研究意义。为解决黑盒分布式优化问题，已有大量无梯度或零阶方法被提出[27,76-80]。这些方法的核心思想是在当前解附近进行随机采样以估计梯度。采样步长在此类方法中起关键作用。多数现有方法采用固定步长[27] 或递减步长[81-83]，且初始步长通常通过针对测试问题的参数调优获得。然而，在实际应用中，优化问题可能随环境变化而改变，例如智能电网中的电力需求[84-85]。在这种情况下，固定的步长设置难以在不同环境下保持较高优化效率。此外，这类优化方法往往频繁调用，无法依赖人工重复调参。

针对上述步长自适应问题，进化策略（Evolution Strategies, ES）作为一类进化计算方法具有巨大潜力**li2020**,[86-87]。这是因为 ES 中的变异步长自适应机制已被广泛研究，包括累积步长自适应（Cumulative Step Adaptation, CSA）[66,88]、基于成功率的规则[89-90]、自适应机制[91-92] 以及元进化策略[93-94]。例如，CSA 是一种代表性的自适应方法，通过分析 ES 的进化路径来调整步长。其直观目标是在陡峭区域增大步长以加速优化，在最优区域减小步长以逐步收敛。尽管上述方法在集中式优化问题中已被证明有效，但在分布式优化问题中面临挑战，因为它们仅根据单个智能体的进化路径进行步长调整。在分布式优化中，本地目标通常存在冲突，因此全局目标的最优区域不同于各本地目标的最优区域。当各智能体分别采用独立步长自适应方法时，它们会选择有利于自身本地目标的步长，而非全局目标，从而相互冲突，无法有效优化全局目标。总之，在缺乏协作的情况下独立采用现有步长自适应方法并不利于分布式优化。因此，有必要进一步研究在分布式优化过程中多个智能体如何协作实现步长自适应。现有分布式或并行进化策略中，对协作步长自适应的研究较少[76,95-96]。He 等[76] 在分布式进化策略中预设递减步长，并

未采用步长自适应机制。Duan 等[96] 在集中式问题下验证了并行进化策略，未考虑当本地目标冲突时的协作挑战。

针对上述研究空白，本章提出一种具有协作与累积步长自适应机制的多智能体进化策略（Dencentralized Evolution Strategies with Cooperative and Cumulative Step Adaptation, CCSA-DES），用于解决黑盒分布式优化问题。CCSA-DES 采用分布式方式运行，每个智能体执行相同算法，并通过点对点通信与邻居协作。CCSA-DES 在局部优化与邻域协作两个阶段之间交替运行。在第一阶段，各智能体独立运行进化策略若干代以优化本地目标函数；在第二阶段，智能体与邻居通信，并根据邻居信息更新本地解与步长。本章的主要贡献如下：

1) 为提高算法采样自适应能力，提出协作与累积步长自适应方法（Cooperative and Cumulative Step Adaptation, CCSA）。CCSA 包括内部自适应与外部自适应，前者在局部优化阶段执行，后者在邻域协作阶段执行。CCSA 的核心思想在于识别某智能体的进化方向是否与邻居一致或冲突。根据识别结果，当进化方向一致时增大步长，当进化方向冲突时减小步长。本章对 CCSA 的工作原理进行了理论分析，并通过实验验证其有效性。
2) 基于 CCSA，提出多智能体进化策略 CCSA-DES。首先，在共识能力方面，基于 CCSA 机制对 CCSA-DES 进行理论共识分析，并通过实验表明其共识优于现有算法。其次，在解质量方面，CCSA-DES 在黑盒分布式优化基准函数上取得具有竞争力的性能。

本章其余部分结构如下。第4.2节介绍步长自适应方法的相关基础。第4.2.2节通过分布式优化中的进化路径案例分析，说明现有方法的局限性。第4.3节详细介绍所提出的 CCSA-DES。第4.4节给出一系列实验结果。最后，第4.5节对本章进行总结。

4.2 分布式优化中演化路径的案例研究

4.2.1 现有的步长自适应方法

累积步长自适应（Cumulative Step Adaptation, CSA）是进化策略中具有代表性的步长控制方法。对于一个 N 维优化问题，CSA 构造一个累积进化路径 $p \in \mathbb{R}^N$。初始路径 p^0 设为零向量。随着优化过程进行，进化路径按如下方式更新：

$$p^{t+1} = (1 - c_s)p^t + \sqrt{c_s(2 - c_s)\mu_{\text{eff}}}\Delta x^t / \sigma^t \tag{4-1}$$

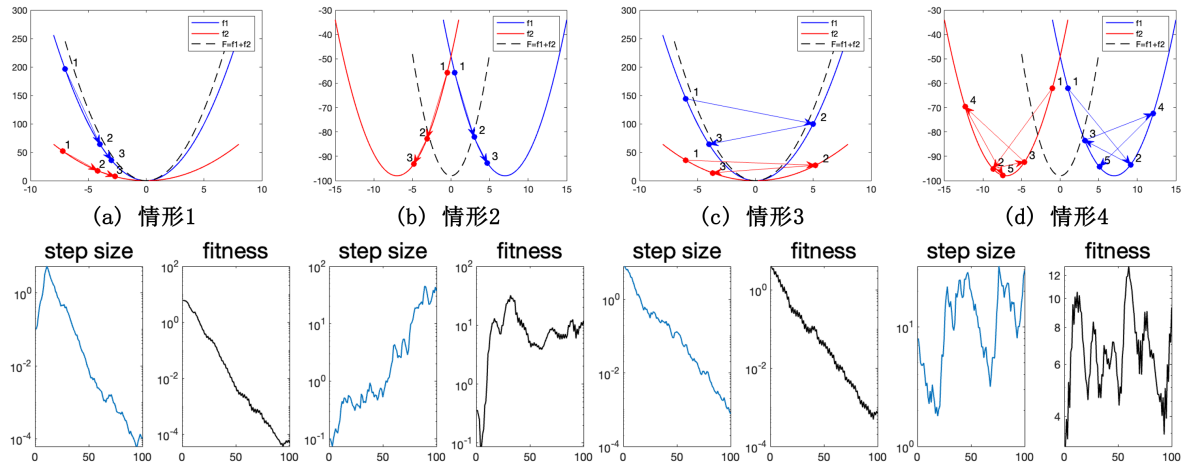
其中，t 为迭代次数，σ^t 为步长，Δx^t 为当前代的移动向量。当问题维度 $N < 1000$ 时，参数 c_s 通常取值范围为 $[0, 0.5]$，μ_{eff} 取值范围为 $[1, 10]$。

向量 p 的长度反映进化路径的一致性。当 $\|p\|$ 较短时，表示过去若干步之间相互抵消、呈负相关，此时应减小步长。当 $\|p\|$ 较长时，表示过去若干步方向一致、呈正相关，进化路径在相似方向上累积，此时应增大步长。基于该思想，步长 σ 的更新方式如下：

$$\sigma^{t+1} = \sigma^t \exp[r(\frac{\|p^t\|}{\mathbb{E}(\|p\|)} - 1)] \tag{4-2}$$

其中，t 为迭代次数，r 为自适应速率，通常取值范围为 $[0, 0.5]$。这里将当前进化路径长度 $\|p^t\|$ 与其期望长度进行比较，该期望值假设路径为随机生成且互不相关。当 $\|p^t\|$ 大于期望值时，步长增大；否则步长减小。

4.2.2 现有方法在分布式优化中的表现与分析



(a) 情形1　(b) 情形2　(c) 情形3　(d) 情形4

(e) CSA优化情形1　(f) CSA优化情形2　(g) CSA优化情形3　(h) CSA优化情形4

图 4-1 分布式优化中演化路径的案例研究。(1) 图 (a)-(d) 展示了一个由两个智能体组成的一维分布式优化问题的四个示例。两个智能体的目标函数分别以蓝色和红色表示，记为 f_1 和 f_2。全局目标函数 $F = f_1 + f_2$ 以黑色虚线表示。图中以数字标注了演化路径。(2) 图 (e)-(h) 记录了采用 CSA[66] 进行步长自适应时智能体的步长与适应值变化，横坐标为迭代次数。

演化路径，即多个连续步长的累积，是 CSA 及其变体方法进行步长调节的关键。然而，与集中式优化相比，分布式优化中的演化路径分析更加复杂，因为每个智能体都拥有各自的演化路径。以一个双智能体系统为例，我们在图4-1中展示了分布式优化中演化路径的四种典型情形：

1) 如图4-1(a) 所示，当前智能体的演化方向与其自身历史演化路径一致，同时也与其邻居智能体的演化路径一致。

2) 如图4-1(b) 所示，当前智能体的演化方向与其自身历史演化路径一致，但与其邻居智能体的演化路径相反。
3) 如图4-1(c) 所示，当前智能体的演化方向与其自身历史演化路径相反，但与其邻居智能体的演化路径一致。
4) 如图4-1(d) 所示，当前智能体的演化方向与其自身历史演化路径相反，同时也与其邻居智能体的演化路径相反。

需要指出的是，可能的演化路径情况并不限于上述四种情形。本节的目的在于讨论这四种典型情形，以说明其中的困难并引出本章提出的算法。

现有步长自适应方法（如 CSA）的直观思想是：当演化路径方向一致时增大步长，当方向相反时减小步长。图4-1(e)-(h) 展示了 CSA 在四种情形下的表现，包括步长与适应值。适应值定义为当前评估解与全局最优解之间的差异。记当前解为 $\bar{x}$，全局最优解为 x^*，则适应值计算为 $f = \|\bar{x} - x^*\|$。因此，这四种情形的最优适应值均为零。下面我们分析 CSA 的行为：

1) 对于图4-1(e) 所示的第一种情形，由于智能体 1 的当前演化方向与其自身演化路径一致，CSA 在早期阶段增大步长；当其接近最优区域时减小步长。最终适应值趋近于零，表明 CSA 在该情形下表现良好。
2) 对于图4-1(f) 所示的第二种情形，由于智能体 1 的当前演化方向与其自身历史演化路径一致，CSA 整体上会增大步长。然而，在该情形下步长的增大不利于算法收敛至全局最优。结果是适应值出现波动并维持在较高水平。
3) 对于图4-1(g) 所示的第三种情形，由于智能体 1 的当前演化方向与其自身历史演化路径相反，CSA 会减小步长。在该情形下 CSA 同样有效，因为适应值最终趋近于零。
4) 对于图4-1(h) 所示的第四种情形，由于智能体 1 的当前演化方向与其自身历史演化路径相反，CSA 在早期阶段减小步长。然而在后期阶段步长出现波动，适应值无法收敛至全局最优。

综上，在第一种和第三种情形下，由于两个智能体的局部目标函数具有相同的最优解，CSA 能够有效工作。然而，在第二种和第四种情形下，由于两个局部目标函数的最优解不同，CSA 无法正确调节步长。除 CSA 外，其他传统自适应方法（如基于成功率的规则和自适应机制）也面临类似挑战。其根本原因在于智能体仅关注自身的演化路径，而忽略了邻居之间的协同信息。

针对现有步长自适应方法在分布式优化场景中的上述挑战，我们设计了一种协同累积步长自适应方法，利用邻居信息辅助步长调节。CCSA 的详细流程与原理将在下一节中阐述。

表 4-1 CCSA-DES 中的符号说明

符号	含义	符号	含义
T	迭代次数	M	通信间隔
λ	子代数量	μ	精英子代数量
w	子代重组权重	β	历史演化方向权重
γ	当前演化方向权重	θ	冲突角阈值
r_1	内部步长自适应速率	r_2	外部步长自适应速率
$\boldsymbol{x}_i$	智能体 i 的局部解	α_i	智能体 i 的采样步长
$\mathcal{N}_i$	智能体 i 的邻居集合	$\mathcal{G}_i$	智能体 i 的邻居演化路径
$\boldsymbol{p}_i$	智能体 i 的局部演化路径	$\vec{\boldsymbol{v}}_i$	智能体 i 周围的当前邻域演化方向
$\hat{\nabla g_i}$	估计梯度		

4.3 基于协同步长自适应机制的多智能体共识优化算法

本章提出了一种基于协同累积步长自适应的多智能体演化策略。下文将依次介绍算法框架、CCSA 的具体过程、CCSA 的工作原理以及共识分析。

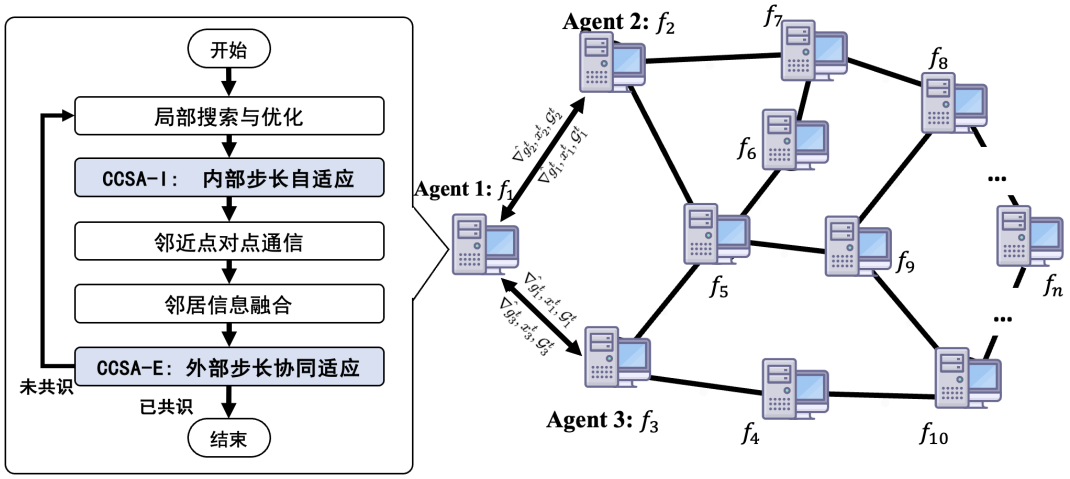


图 4-2 CCSA-DES 的系统结构与流程。CCSA-DES 运行于多智能体系统中，每个智能体执行相同的过程。智能体可以表示无线传感器网络中的传感器节点，或分布式电网系统中的发电站等。

4.3.1 算法框架

CCSA-DES 旨在解决黑盒与非凸分布式优化问题。该框架运行于多智能体系统中，例如智能电网和无线传感器网络。在多智能体系统中，每个智能体代表一个物理实体，例如传感器或发电站。由于数据的局部性和感知范围的限制，每个智能体 i 只能访问其自身的局部目标函数 f_i。为了优化式 (2-2) 中的全局目标 F，智能体之间必须进行通信与协作。

图 4-2 展示了系统结构以及每个智能体的流程图。智能体具备计算与通信能力。在计算方面，每个智能体执行相同的算法与流程；在通信方面，每个智能体只能与其邻居进行通信。所有智能体通过一个固定且连通的通信网络连接。该通信网络通常为非全连接图，其结构由物理环境决定。以无线传感器网络为例，只有当两个传感器之间的距离小于最大通信范围时，它们才可直接连接。

如算法 4-2 所示，CCSA-DES 在每个智能体中包含以下步骤：

1) *初始化*（第 2 行）：在开始阶段，每个智能体初始化如下变量。第一，局部解 $\boldsymbol{x}_i \in \mathbb{R}^D$，其中 D 为分布式优化问题的维度。第二，步长 $\sigma_i \in \mathbb{R}$，用于控制局部采样尺度。每个智能体独立维护并调整 σ_i。第三，历史邻域演化方向 $\mathcal{G}_i \in \mathbb{R}^D$ 以及历史局部演化方向 $\boldsymbol{p}_i \in \mathbb{R}^D$，二者均用于协同累积步长自适应。需要注意的是，$\boldsymbol{p}_i$ 在每次迭代开始时重新初始化，因为其用于跟踪最近的局部演化路径（第 5 行）。
2) *局部优化*（第 6–16 行）：该阶段包括演化策略的基本过程，即变异、选择与重组。首先，智能体以尺度 σ_i 的标准高斯分布采样 λ 个向量用于变异。然后，利用局部目标函数 f_i 对这 λ 个子代进行评估。根据适应值对其排序后，选择 μ 个精英子代并进行重组，得到新的解 $\boldsymbol{x}_i^t$。每个智能体在局部优化阶段演化 M 代。
3) *通信与协作*（第 18–20 行）：在局部优化完成后，每个智能体 i 与其邻居集合 $\mathcal{N}_i$ 中的智能体进行通信。在通信信息中，将邻居的局部解进行重组，得到新的解 $\boldsymbol{x}_i^{t+1}$，作为下一轮迭代的起点。此外，估计梯度 $\hat{\nabla g_i^t}$ 与邻域演化方向 $\mathcal{G}_k^t$ 用于更新 $\mathcal{G}_k^{t+1}$。
4) *步长自适应*（第 15 行与第 23 行）：所提出的协同累积步长自适应方法包括两部分，即内部步长自适应与外部步长自适应。内部步长自适应用于智能体未与邻居通信时的局部优化阶段；外部步长自适应用于通信阶段，利用邻域信息协同控制步长。

当达到最大迭代次数或满足共识条件时，算法终止。分布式演化策略的共识条件定

义如下：

$$\frac{1}{n}\sum_{i=1}^{n}\|\boldsymbol{x}_i-\overline{\boldsymbol{x}}\|_2^2<\epsilon, \text{其中 } \overline{\boldsymbol{x}}=\frac{1}{n}\sum_{i=1}^{n}\boldsymbol{x}_i \tag{4-3}$$

其中，ϵ 为接近零的小阈值，$\overline{\boldsymbol{x}}$ 为所有局部解的均值向量。当上述条件满足时，认为分布式系统达到共识，算法可以终止。

Algorithm 4-2 每个智能体中的 CCSA-DES

输入： 局部目标函数 f_i

/* 初始化 */

令 $\boldsymbol{x}_i^0=\mathbf{0},\sigma_i=\sigma_0,\mathcal{G}_i=\mathbf{0},t=0$

while $t<T$ 且未满足共识条件 **do**

  /* 局部优化 */

  令 $\boldsymbol{p}_i=\mathbf{0}$

  for $m=0,...,M-1$ **do**

    for $j=1,...,\lambda$ **do**

      采样 $\boldsymbol{z}_j\sim\mathcal{N}(\mathbf{0},I)$, 并计算 $y_j=f_i(\boldsymbol{x}_i+\sigma_i\boldsymbol{z}_j)$

    end for

    根据 $\{y_j\}_{j=1}^{\lambda}$ 对 $\{z_j\}_{j=1}^{\lambda}$ 进行排序

    $\boldsymbol{x}_i^t=\boldsymbol{x}_i^t+\sum_{j=1}^{\mu}w_j\cdot\sigma_i\boldsymbol{z}_j$

    /* CCSA 内部步长自适应 */

    根据式 (4-1) 更新 $\boldsymbol{p}_i$

    $\sigma_i=\sigma_i\cdot\exp\left(\tau\cdot r_1\left(\frac{\|\boldsymbol{p}_i\|}{\mathbb{E}(\|\boldsymbol{p}_i\|)}-1\right)\right)$

  end for

  /* 通信与协作 */

  向邻居 $k\in\mathcal{N}_i$ 发送 $\boldsymbol{x}_i^t,\hat{\nabla g_i^t},\mathcal{G}_i^t$，并从邻居 $k\in\mathcal{N}_i$ 接收 $\boldsymbol{x}_k^t,\hat{\nabla g_k^t},\mathcal{G}_k^t$

  $\boldsymbol{x}_i^{t+1}=\sum_{k\in\mathcal{N}_i\cup\{i\}}W_{i,k}\boldsymbol{x}_k^t$

  /* CCSA 外部步长自适应 */

  根据式 (4-4)–(4-6) 更新 $\mathcal{G}_i^{t+1}$

  $\sigma_i=\sigma_i\cdot\exp(r_2(\|\mathcal{G}_i\|-1))$

  $t=t+1$

end while

输出： x

4.3.2 协同累积步长自适应

针对第 4.2.2 节案例研究中 CSA 的局限性，CCSA 的直观思想是在智能体的演化方向与其邻居一致时增大步长，否则减小步长。为实现这一设计目标，CCSA 主要解决以下两个问题：一是如何构造分布式优化中的演化路径，二是如何基于演化路径进行步长自适应。

4.3.2.1 如何构造邻域演化路径

演化路径由多个连续步长累积而成。因此，我们将分布式优化中的单步定义为当前迭代的邻域方向向量 $\vec{v_i}$，其定义如下：

$$\vec{v_i} = \frac{\sum_{k\in\mathcal{N}_i\cup\{i\}} \hat{\nabla g_k}(t)}{\|\sum_{k\in\mathcal{N}_i\cup\{i\}} \hat{\nabla g_k}(t)\|} \text{ s.t. } \hat{\nabla g_k}(t) = \frac{[f_k(\boldsymbol{x}_k^{t+1}) - f_k(\boldsymbol{x}_k^t)]\Delta\boldsymbol{x}_k}{\|\Delta\boldsymbol{x}_k\|_2^2} \tag{4-4}$$

其中，$\Delta\boldsymbol{x}_i$ 为第 t 次迭代中智能体 i 的移动向量，定义为 $\Delta\boldsymbol{x}_i = \boldsymbol{x}_i^{t+1} - \boldsymbol{x}_i^t$。由于 CCSA-DES 面向黑盒优化问题，我们根据适应值与位置变化来构造 $\hat{\nabla g_i}$ 以估计局部目标函数的梯度。邻域方向向量 $\vec{v_i}$ 反映了邻居智能体的综合移动方向，为后续路径分析提供基础。

为了使步长能够合理自适应，演化路径的长度应反映邻居之间方向的一致性。因此，我们设计邻域演化路径 $\mathcal{G}_i$ 的累积方式如下：

$$\begin{aligned} &\mathcal{G}_i^{t+1} = \beta\mathcal{G}_i^t + \gamma\vec{v_i} \\ &\text{s.t. } \beta^2 + \gamma^2 + 2\beta\gamma cos(\theta) = 1 \\ &\beta, \gamma > 0 \text{ 且 } \theta = (1 - \frac{t}{T})90^\circ \end{aligned} \tag{4-5}$$

其中，β 与 γ 分别为历史路径与当前演化方向的权重。θ 为冲突角阈值，用于判断当前方向与历史方向之间的冲突是否在可接受范围内。在初始阶段，θ 设为正交角 90°；随着迭代次数增加，θ 逐渐衰减至零，表明 CCSA 的冲突检测机制逐渐趋于严格。其工作原理将在第 4.3.3 节中说明。

由于邻域方向向量 $\vec{v_i}$ 仅能整合一跳邻居的信息，我们通过在多智能体系统中扩散路径信息以促进全局协同：

$$\mathcal{G}_i^t = \sum_{k\in\mathcal{N}_i\cup\{i\}} W_{i,k}\mathcal{G}_k^t \tag{4-6}$$

其中，W 为随机矩阵，表示多智能体系统的邻接矩阵。

4.3.2.2 如何进行步长自适应

根据式 (4-5)，当邻居智能体的演化方向一致时，演化路径较长；否则较短。因此，我们基于演化路径长度对步长进行调节。CCSA 包括两部分：用于邻域协作阶段的外部自适应，以及用于局部优化阶段的内部自适应。

首先，在邻域协作阶段，根据邻域演化路径 $\mathcal{G}_i$ 调整步长。外部自适应形式如下：

$$\sigma_i = \sigma_i \cdot \exp(r_2(\|\mathcal{G}_i^t\| - 1)) \tag{4-7}$$

其中，r_2 为外部自适应速率。当 $\mathcal{G}_i$ 的长度大于 1 时步长增大，小于 1 时步长减小。

其次，在局部优化阶段，每个智能体只能获得其自身的局部演化方向。因此，基于式 (4-1) 为每个智能体 i 构造局部演化路径 $\boldsymbol{p}_i$。然而，如第 4.2.2 节所讨论，仅关注局部演化路径不利于全局目标函数的优化。因此，我们利用上一迭代的邻域演化路径 $\mathcal{G}_i^{t-1}$ 辅助内部自适应：

$$\begin{aligned} \sigma_i &= \sigma_i \cdot \exp[\tau \cdot r_1(\frac{\|\boldsymbol{p}_i\|}{\mathbb{E}(\|\boldsymbol{p}_i\|)} - 1)] \\ \text{其中 } \tau &= \begin{cases} 1 & (\frac{\|\boldsymbol{p}_i\|}{\mathbb{E}(\|\boldsymbol{p}_i\|)} - 1)(\|\mathcal{G}_i^{t-1}\| - 1) > 0 \\ 0 & \end{cases} \end{aligned} \tag{4-8}$$

其中，r_1 为内部自适应速率，τ 为控制是否调整步长的二值变量。当局部演化路径与邻域演化路径在步长调节趋势上保持一致（例如第 4.2.2 节中的第一种或第四种情形）时，τ 被激活；否则 τ 关闭，不进行步长调整。

4.3.3 CCSA 的工作原理分析

在本小节中，我们基于以下四种情形对 CCSA 的工作原理进行分析：

	$\|\mathcal{G}_i^t\| \geq 1$	$\|\mathcal{G}_i^t\| < 1$
$\angle(\mathcal{G}_i^t, \vec{v_i}) > \theta$	情形 1	情形 4
$\angle(\mathcal{G}_i^t, \vec{v_i}) \leq \theta$	情形 2	情形 3

(1) 当 $\|\mathcal{G}_i^t\| \geq 1$ 时，步长原本处于增长趋势。若 $\angle(\mathcal{G}_i^t, \vec{v_i}) > \theta$，则有如下推导：

$$\begin{aligned}
&\|\mathcal{G}_i^{t+1}\|^2 - \|\mathcal{G}_i^t\|^2 \\
=&\beta^2\|\mathcal{G}_i^t\|^2 + \gamma^2 + 2\beta\gamma\|\mathcal{G}_i^t\|cos(\angle(\mathcal{G}_i^t, \vec{v_i})) - \|\mathcal{G}_i^t\|^2 \\
<&(\beta^2-1)\|\mathcal{G}_i^t\|^2 + \gamma^2 + 2\beta\gamma\|\mathcal{G}_i^t\|cos(\theta) \\
=&(\beta^2-1)\|\mathcal{G}_i^t\|^2 + \gamma^2 + (1-\beta^2-\gamma^2)\|\mathcal{G}_i^t\| \\
=&(\beta^2-1)(\|\mathcal{G}_i^t\|^2 - \|\mathcal{G}_i^t\|) - \gamma^2(\|\mathcal{G}_i^t\| - 1) \\
=&(\|\mathcal{G}_i^t\| - 1)(\|\mathcal{G}_i^t\|(\beta^2-1) - \gamma^2) \leq 0
\end{aligned} \tag{4-9}$$

其中，第一个不等号由 $cos(\angle(\mathcal{G}_i^t, \vec{v_i})) < cos(\theta)$ 得到，第二个不等号由 $\|\mathcal{G}_i^t\| \geq 1$ 且 $\beta < 1$ 得到。根据式 (4-9)，在所提出的策略下，$\mathcal{G}_i$ 的长度将减小。这表明，当当前方向与历史邻居演化路径不一致时，步长的增长趋势将会放缓。

(2) 当 $\|\mathcal{G}_i^t\| \geq 1$ 时，步长原本处于增长趋势。若 $\angle(\mathcal{G}_i^t, \vec{v_i}) \leq \theta$，则有如下推导：

$$\begin{aligned}
\|\mathcal{G}_i^{t+1}\|^2 =&\beta^2\|\mathcal{G}_i^t\|^2 + \gamma^2 + 2\beta\gamma\|\mathcal{G}_i^t\|cos(\angle(\mathcal{G}_i^t, \vec{v_i})) \\
\geq&\beta^2 + \gamma^2 + 2\beta\gamma cos(\angle(\mathcal{G}_i^t, \vec{v_i})) \\
\geq&\beta^2 + \gamma^2 + 2\beta\gamma cos(\theta) = 1
\end{aligned} \tag{4-10}$$

其中，第一个不等号由 $\|\mathcal{G}_i^t\| \geq 1$ 得到，第二个不等号由 $cos(\angle(\mathcal{G}_i^t, \vec{v_i})) \geq cos(\theta)$ 得到。根据式 (4-10)，在所提出的策略下，$\mathcal{G}_i$ 的长度将保持大于 1。这表明，当当前方向与历史邻居演化路径一致时，步长将持续增长。

(3) 当 $\|\mathcal{G}_i^t\| < 1$ 时，步长原本处于减小趋势。类似于上述情形的推导，根据式 (4-11)，当 $\angle(\mathcal{G}_i^t, \vec{v_i}) \leq \theta$ 时，$\mathcal{G}_i$ 的长度将增大。这表明，当当前方向与历史邻居演化路径一致时，步长的减小趋势将会放缓。

$$\begin{aligned}
&\|\mathcal{G}_i^{t+1}\|^2 - \|\mathcal{G}_i^t\|^2 \\
=&\beta^2\|\mathcal{G}_i^t\|^2 + \gamma^2 + 2\beta\gamma\|\mathcal{G}_i^t\|cos(\angle(\mathcal{G}_i^t, \vec{v_i})) - \|\mathcal{G}_i^t\|^2 \\
\geq&(\beta^2-1)\|\mathcal{G}_i^t\|^2 + \gamma^2 + 2\beta\gamma\|\mathcal{G}_i^t\|cos(\theta) \\
=&(\beta^2-1)\|\mathcal{G}_i^t\|^2 + \gamma^2 + (1-\beta^2-\gamma^2)\|\mathcal{G}_i^t\| \\
=&(\beta^2-1)(\|\mathcal{G}_i^t\|^2 - \|\mathcal{G}_i^t\|) - \gamma^2(\|\mathcal{G}_i^t\| - 1) \\
=&(\|\mathcal{G}_i^t\| - 1)(\|\mathcal{G}_i^t\|(\beta^2-1) - \gamma^2) > 0
\end{aligned} \tag{4-11}$$

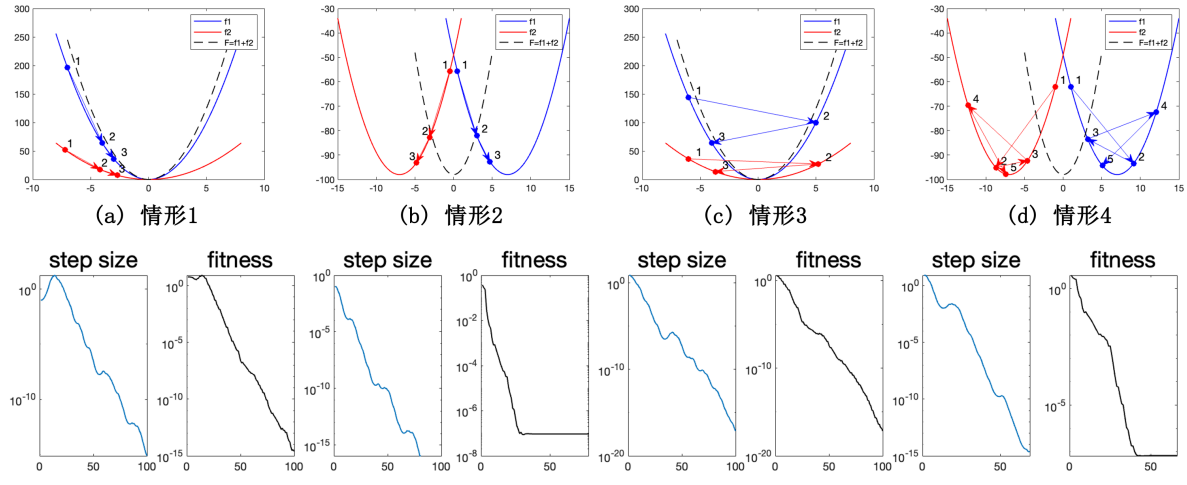
(4) 当 $\|\mathcal{G}_i^t\| < 1$ 时，步长原本处于减小趋势。类似于上述情形的推导，根据式 (4-12)，

当 $\angle(\mathcal{G}_i^t, \vec{v_i}) > \theta$ 时，$\mathcal{G}_i$ 的长度将保持小于 1。这表明，当当前方向与历史邻居演化路径不一致时，步长将持续减小。

$$\begin{aligned} \|\mathcal{G}_i^{t+1}\|^2 =& \beta^2\|\mathcal{G}_i^t\|^2 + \gamma^2 + 2\beta\gamma\|\mathcal{G}_i^t\|cos(\angle(\mathcal{G}_i^t, \vec{v_i})) \\ <& \beta^2 + \gamma^2 + 2\beta\gamma cos(\angle(\mathcal{G}_i^t, \vec{v_i})) \\ <& \beta^2 + \gamma^2 + 2\beta\gamma cos(\theta) = 1 \end{aligned} \tag{4-12}$$

因此，CCSA 的工作原理可总结如下：

$$\|\mathcal{G}_i^{t+1}\| \begin{cases} < \|\mathcal{G}_i^t\| & \text{if } \|\mathcal{G}_i^t\| \geq 1 \text{ and } \angle(\mathcal{G}_i^t, \vec{v_i}) > \theta \\ \geq 1 & \text{if } \|\mathcal{G}_i^t\| \geq 1 \text{ and } \angle(\mathcal{G}_i^t, \vec{v_i}) \leq \theta \\ > \|\mathcal{G}_i^t\| & \text{if } \|\mathcal{G}_i^t\| < 1 \text{ and } \angle(\mathcal{G}_i^t, \vec{v_i}) \leq \theta \\ < 1 & \text{if } \|\mathcal{G}_i^t\| < 1 \text{ and } \angle(\mathcal{G}_i^t, \vec{v_i}) > \theta \end{cases} \tag{4-13}$$



(a) 情形1　(b) 情形2　(c) 情形3　(d) 情形4

(e) CCSA（本文提出的）优化情形1　(f) CCSA优化情形2　(g) CCSA优化情形3　(h) CCSA优化情形4

图 4-3 提出的 CCSA 在代表案例中的表现。(1) 图 (a)-(d) 展示了一个由两个智能体组成的一维分布式优化问题的四个示例。两个智能体的目标函数分别以蓝色和红色表示，记为 f_1 和 f_2。全局目标函数 $F = f_1 + f_2$ 以黑色虚线表示。图中以数字标注了演化路径。(2) 图 (e)-(h) 记录了采用 CCSA（本章提出）进行步长自适应时智能体的步长与适应值变化，横坐标为迭代次数。

我们还在分布式优化的四种典型情形下测试了引入 CCSA 的演化策略行为。图4-3(e)-(h) 记录了使用 CCSA 时的步长和适应度变化情况。

1) 在第一和第三种情形下，CCSA 具有与 CSA 相似的步长自适应行为。两者在这两种情形下均表现良好。这是因为在这两种情形中，两个局部目标函数具有相同的最优解，而集中式优化技术 CSA 可以很好地处理这种情况。

2) 第二种情形展示了 CCSA 相对于 CSA 在分布式优化中的优势。尽管智能体 1 的演化方向与其自身的演化路径一致，但两个智能体的演化方向存在冲突。在这种情况下，CCSA 能够检测到冲突，并减小步长。因此，最终适应度低于 10^{-6}，显著优于 CSA。
3) 第四种情形同样体现了 CCSA 的效果。尽管 CSA 和 CCSA 在初期都会减小步长，但由于 CSA 无法检测两个智能体之间的冲突，其步长在后期出现波动。相比之下，CCSA 持续减小步长，最终适应度低于 10^{-5}。

综上所述，CCSA 通过对邻居演化路径的分析，能够更好地处理分布式优化中的典型情形。在第 V 节中，将验证 CCSA 在更复杂问题上的有效性。

4.3.4 CCSA 的共识分析

本部分讨论 CCSA-DES 的系统共识性。在所提出的算法中，冲突角阈值 θ 按照式 (4-5) 从初始值递减至零。下面我们分析 θ 变为零后的系统，此时有 $\beta+\gamma=1$。为避免时间符号 t 与指数运算混淆，以下将 $\mathcal{G}_i^t$ 记为 $\mathcal{G}_i(t)$，其他变量同理。

首先，根据第 IV.B 节中的式 (4-5) 和 (4-6)，用如下动力学方程描述所有智能体的邻居演化路径：

$$\begin{aligned}&\mathbb{G}(t+1)=\beta W\mathbb{G}(t)+\gamma\boldsymbol{V}(t)\\&\text{where }\mathbb{G}(t)=\begin{pmatrix}\mathcal{G}_1(t)\\\mathcal{G}_2(t)\\\cdots\\\mathcal{G}_n(t)\end{pmatrix}\text{ and }\boldsymbol{V}(t)=\begin{pmatrix}\vec{v_1}(t)\\\vec{v_2}(t)\\\cdots\\\vec{v_n}(t)\end{pmatrix}\end{aligned}\tag{4-14}$$

然后，第 t 次迭代时系统状态可表示为：

$$\begin{aligned}\mathbb{G}(t)&=\beta W\mathbb{G}(t-1)+\gamma\boldsymbol{V}(t-1)\\&=\beta W(\beta W\mathbb{G}(t-2)+\gamma\boldsymbol{V}(t-2))+\gamma\boldsymbol{V}(t-1)\\&=\beta^2W^2\mathbb{G}(t-2)+\beta\gamma W\boldsymbol{V}(t-2)+\gamma\boldsymbol{V}(t-1)\\&=\cdots\\&=\beta^tW^t\mathbb{G}^0+\gamma\sum_{k=0}^{t-1}\beta^kW^k\boldsymbol{V}(t-k-1)\end{aligned}\tag{4-15}$$

当迭代次数 $t\to\infty$ 时，由于 $0<\beta<1$，第一项趋于零。此时考虑矩阵中第 i 行对

应的 $\mathcal{G}_i(t)$ 的长度，有：

$$\|\mathcal{G}_i(t)\|_{t\to\infty} = \|\gamma \sum_{k=0}^{t} \beta^k [W^k]_{i*} \boldsymbol{V}(t-k-1)\| \tag{4-16}$$

其中 $[W^k]_{i*}$ 表示矩阵 W^k 的第 i 行。下面在两种情形下讨论演化路径 $\mathcal{G}_i(t)$ 的长度。

1) 首先，假设各智能体的演化方向始终不一致，即 $\vec{v_i}(t) \neq \vec{v_j}(t)(\exists 1 \leq i,j \leq n,\ \exists t = 1,2,...,\infty)$。在这种情况下，有如下推导：

$$\|\mathcal{G}_i(t)\|_{t\to\infty} = \|\gamma \sum_{k=0}^{\infty} \beta^k [W^k]_{i*} \boldsymbol{V}(t-k)\| \tag{4-17}$$

$$\leq \gamma \sum_{k=0}^{\infty} \beta^k \|[W^k]_{i*} \boldsymbol{V}(t-k)\| \tag{4-18}$$

$$= \gamma \sum_{k=0}^{\infty} \beta^k \| \sum_{j=1}^{n} [W^k]_{i,j} \vec{v_j}(t-k)\| \tag{4-19}$$

$$< \gamma \sum_{k=0}^{\infty} \beta^k \sum_{j=1}^{n} [W^k]_{i,j} \|\vec{v_j}(t-k)\| \tag{4-20}$$

$$= \gamma \sum_{k=0}^{\infty} \beta^k \sum_{j=1}^{n} [W^k]_{i,j} \tag{4-21}$$

$$= \gamma \sum_{k=0}^{\infty} \beta^k \tag{4-22}$$

其中，不等式 (4-18) 和 (4-20) 由三角不等式得到，而在 (4-20) 中等号不成立。等号仅当所有智能体的演化方向一致时成立，即 $\vec{v_i}(t) = \vec{v_j}(t)\ \forall 1 \leq i,j \leq n$ and $t = 1,2,...,\infty$，这不满足上述假设条件。对于左侧推导，式 (4-21) 成立是因为 $\vec{v_j}$ 为单位向量，其长度为 1。式 (4-22) 成立是由于随机矩阵的性质，即随机矩阵每一行元素之和为 1。由于 W 为随机矩阵，因此对任意 $k \in \mathbb{N}$，W^k 仍为随机矩阵。

2) 其次，假设所有智能体的演化方向始终一致且不存在冲突，即 $\vec{v_1}(t) = \vec{v_2}(t) = \cdots = \vec{v_n}(t) = \vec{v_*}(t), \forall t = 1,2,...,\infty$。在这种情况下，有：

$$\|\mathcal{G}_i(t)\|_{t\to\infty} = \|\gamma \sum_{k=0}^{\infty} \beta^k [W^k]_{i*} \boldsymbol{V}(t-k)\| \tag{4-23}$$

$$= \|\gamma \sum_{k=0}^{\infty} \beta^k \sum_{j=1}^{n} [W^k]_{i,j} \vec{v_*}(t-k)\| \tag{4-24}$$

$$= \|\gamma \sum_{k=0}^{\infty} \beta^k \vec{v_*}(t-k)\| \tag{4-25}$$

$$< \gamma \sum_{k=0}^{\infty} \beta^k \|\vec{v_*}(t-k)\| \tag{4-26}$$

$$= \gamma \sum_{k=0}^{\infty} \beta^k \tag{4-27}$$

其中，不等式 (4-26) 由三角不等式得到。假设优化问题存在最小化解，则等号不成立。等号仅当所有迭代中的演化方向完全一致时成立，即 $\vec{v_*}(t_1) = \vec{v_*}(t_2)\ \forall t_1, t_2 \in \{1, 2, ..., \infty\}$。在这种情况下，根据 CCSA 的工作原理，步长将持续增大，从而解趋于无穷。然而，在具有最小化解的问题中不会出现这种情况，因为优化算法会沿着适应度下降的方向移动。对于其余推导，式 (4-25) 成立是由于随机矩阵每一行元素之和为 1 的性质。式 (4-27) 成立是因为单位向量 $\vec{v_*}(t-k)$ 的长度为 1。

对于上述两种情形，我们得到相同的结果，即 $\|\mathcal{G}_i(t)\|_{t\to\infty} < \gamma \sum_{k=0}^{\infty} \beta^k$。考虑到当 $|\beta| < 1$ 时，β 的幂级数和为 $\frac{1}{1-\beta}$，因此有：

$$\|\mathcal{G}_i(t)\|_{t\to\infty} < \gamma \sum_{k=0}^{\infty} \beta^k = \frac{\gamma}{1-\beta} = 1 \tag{4-28}$$

根据第 4.3.2.2 节，当 $\|\mathcal{G}_i(t)\| < 1$ 时，外部自适应阶段将减小步长，内部自适应阶段将减小或保持步长不变。综合来看，当迭代次数 $t \to \infty$ 时，步长将持续减小并趋于零。在这种情况下，由于采样步长趋于零（见算法 4-2 第 9 行），局部优化阶段不会改变各智能体的解。因此，可用如下动力学方程描述所有智能体的解：

$$\begin{aligned} &\mathbb{X}(t+1) = W\mathbb{X}(t) \\ &\text{其中}\ \ \mathbb{X}(t) = \big(\boldsymbol{x}_1(t), \boldsymbol{x}_2(t), \cdots, \boldsymbol{x}_n(t)\big)^T \end{aligned} \tag{4-29}$$

根据共识理论[21]，当 $t \to \infty$ 时，有：

$$\boldsymbol{x}_i^* = \boldsymbol{x}_j^*\ \ \forall 1 \le i, j \le n \tag{4-30}$$

因此，多智能体系统最终能够达到共识。

4.4 实验

在本节中，我们开展以下实验，即参数分析实验、消融实验以及与最新先进算法的对比实验。

4.4.1 实验设置与基准函数

为验证所提算法的性能，我们采用文献[97]中提出的黑箱、非凸分布式优化基准函数。该基准函数的一般定义如下：

$$F(\boldsymbol{x}) = \sum_{i=1}^{n} f_i(\boldsymbol{x}) \tag{4-31}$$

$$\text{其中}\quad f_i(\boldsymbol{x}) = f^i_{elementary}(\boldsymbol{z}) + c\sum_{j=1}^{D}[A]_{ij}\boldsymbol{z}_j \tag{4-32}$$

$$\text{且}\quad \boldsymbol{z} = T^{0.2}_{asy}(T_{osz}(R(\boldsymbol{x} - \boldsymbol{x}'))) \tag{4-33}$$

其中，$f_i(*)$ 表示第 i 个智能体的局部目标函数，$F(*)$ 表示全局目标函数。由式 (4-32) 可见，局部目标函数由一个非凸基础函数和一个线性项组成。在式 (4-33) 中，解 $\boldsymbol{x}$ 经过四种操作处理：（1）平移：$\boldsymbol{x}$ 被一个随机生成的向量 $\boldsymbol{x}'$ 平移；（2）旋转：解通过随机生成的正交矩阵 R 进行旋转；（3）非光滑变换：将解输入变换函数 T_{osz} 以构造局部平滑不规则性；（4）非对称变换：将向量输入变换函数 T_{asy} 以打破对称函数的对称性。

表 4-2 给出了基准函数集的配置。基础函数包括 Elliptic、Schwefel、Rosenbrock 和 Griewank。在 F1-F3 中，各智能体的基础函数 $f^i_{elementary}(*)$ 相同；而在 F4-F9 中，各智能体的基础函数不同。参照文献[97]的设置，智能体数量设为 20，问题维度设为 100，每个智能体的最大目标函数评估次数设为 1.5E+6。

表 4-2 基准函数配置

基准函数	基础函数	基准函数	基础函数
F1	Elliptic	F2	Schwefel
F3	Rosenbrock	F4	Elliptic & Schwefel
F5	Elliptic & Rosenbrock	F6	Schwefel & Rosenbrock
F7	Elliptic & Griewank	F8	Schwefel & Griewank
F9	Rosenbrock & Griewank		

CCSA-DES 的参数部分依据已有研究设定，部分通过参数分析实验确定。根据[66]，后代数量 λ 设为 34，精英个体数量 μ 设为 17。重组权重设为 $w_j = \log(\mu + 0.5) - \log(j)$，其中 $j = 1, 2, ..., \mu$。自适应权重 r_1 与 r_2 分别设为 0.01 和 0.001。初始步长 σ_0 设为 1E-6。其他参数，包括历史权重 β 与通信间隔 M，通过实验进行分析，具体见 Sec. 4.4.2。

以下实验在由 Intel(R) Xeon(R) CPU E5-2699 v3@2.30GHz 36 核处理器与 CentOS 7.5 x64 系统组成的集群上进行。每组实验独立重复 25 次。

4.4.2 参数调研

本小节对 CCSA-DES 中三个重要参数进行分析。简而言之，历史权重影响 CCSA 的敏感性，通信间隔影响 CCSA 的触发频率，冲突角阈值影响 CCSA 的判定倾向。具体实验与分析如下。

4.4.2.1 历史权重

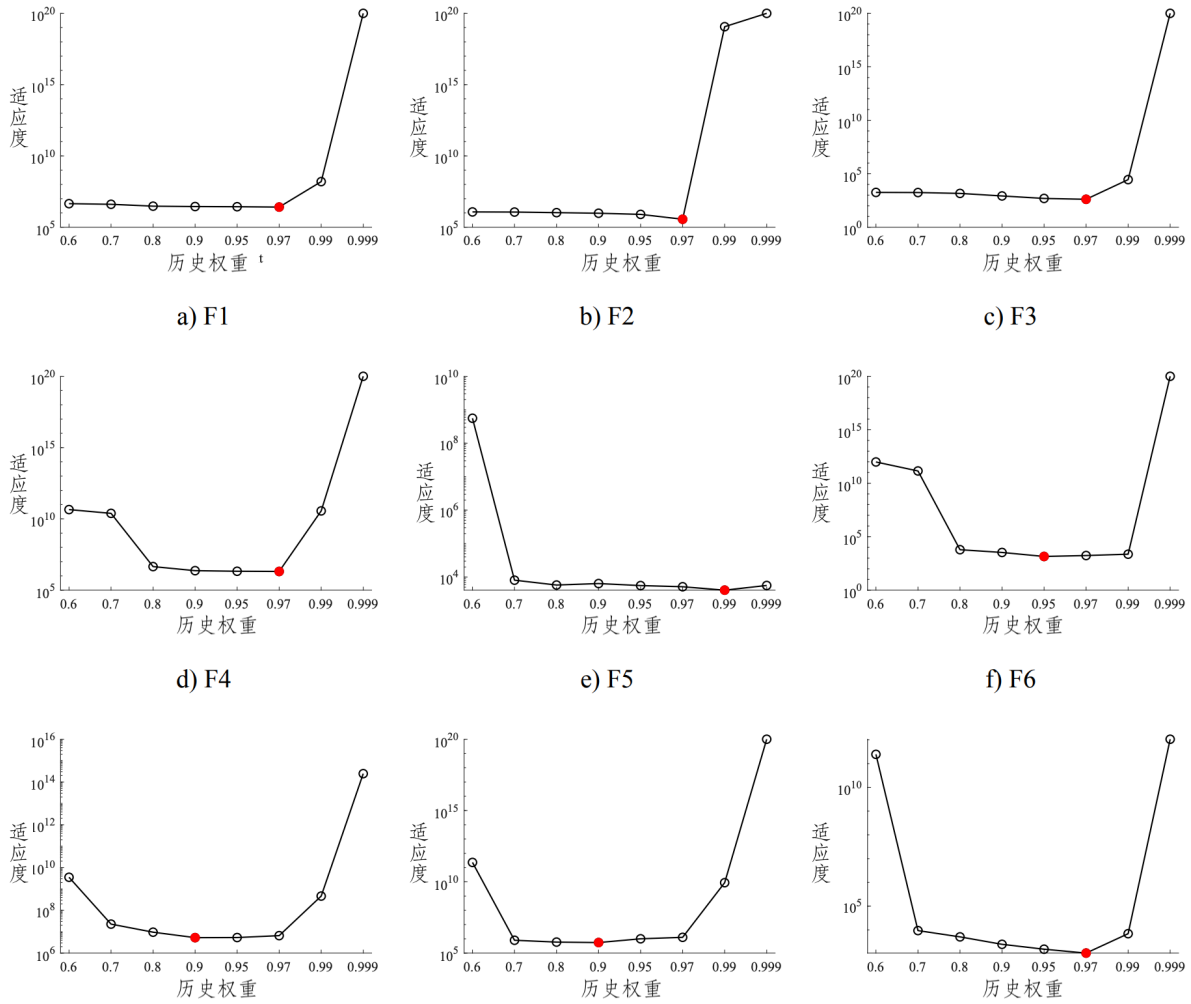


图 4-4 针对历史权重 β 的参数调研

历史权重决定了在进化路径累积过程中历史路径的重要性，如式 (4-5) 所示。为研究历史权重对算法的影响，我们分别将历史权重 β 设为 0.6、0.7、0.8、0.9、0.95、0.97、0.99 和 0.999，并测试 CCSA-DES 的性能。根据图4-4 的结果，在大多数测试函数中，适应度值随历史权重变化呈现“V”形曲线。这表明历史权重过大或过小都不合适。

当历史权重过大，尤其是设为 0.999 时，图4-4 中的适应度明显大于其他情况。这是因为步长自适应变得迟缓，无法及时捕捉不同智能体进化路径之间的冲突。考虑如下情形：若过去一段时间内进化方向始终一致，则根据 Sec. 4.3.3 中的工作原理，进化路径 $\mathcal{G}_i$ 的长度较大。在此状态下，当优化区域从一致区域进入冲突区域时，步长应当减小。然而由于进化路径较长且历史权重较大，步长仍将维持增长趋势。结果是算法无法稳定在全局最优区域，从而导致优化性能较差。

当历史权重过小，尤其是设为 0.6 时，在函数 F4-F9 上的性能明显劣于其他设置。根据式 (4-5)，当 $\beta = 0.6$ 且 $\theta = 90$ 时，当前方向权重 γ 为 0.8。在此情况下，步长自适应变得短视，仅关注近期进化路径，导致步长变化趋势频繁波动，使优化过程不稳定。

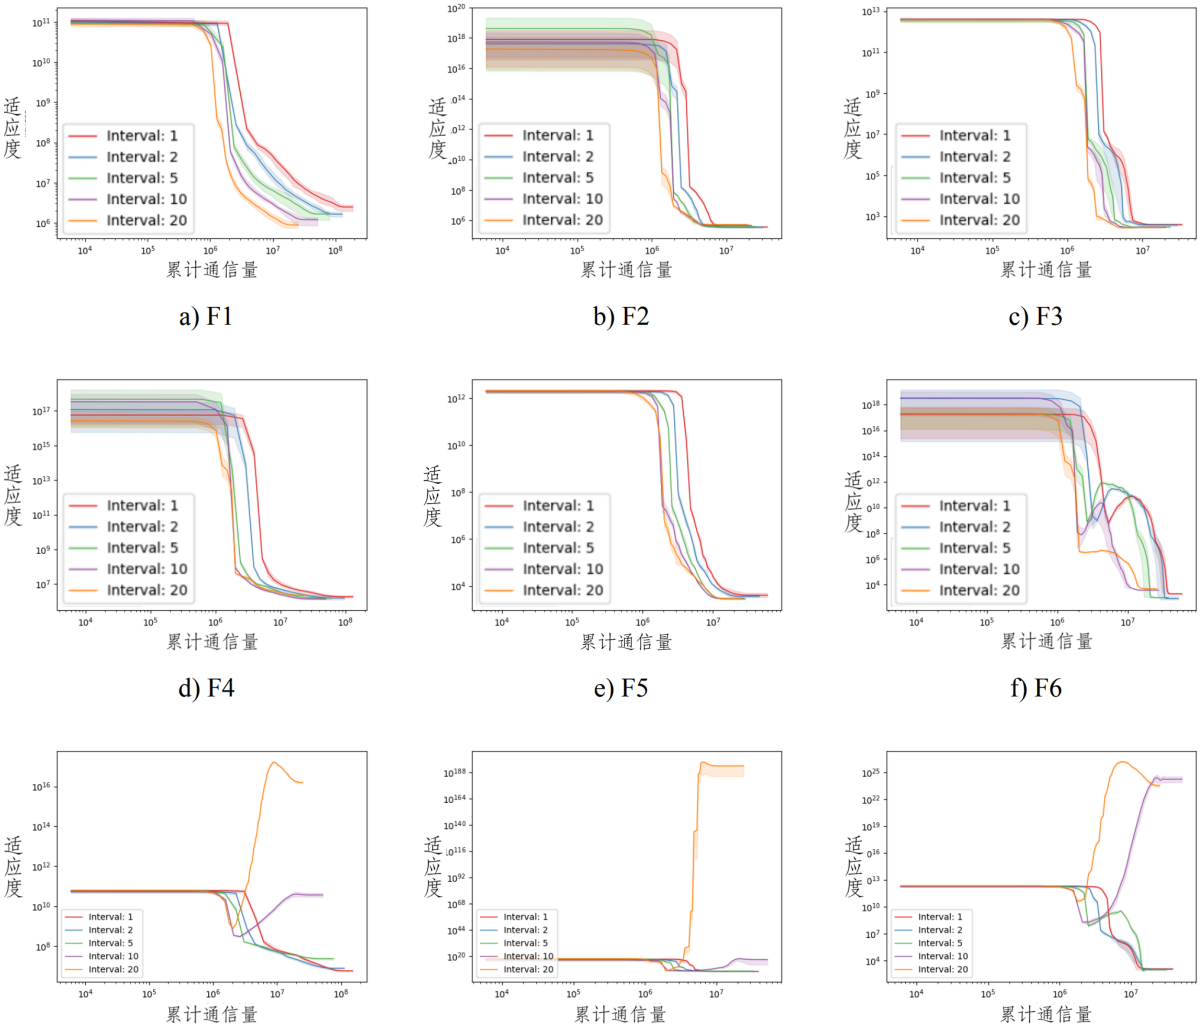
综合整体性能考虑，0.97 是较为合适的历史权重设置。当 $\beta = 0.97$ 时，算法在 9 个函数中的 5 个上取得最佳性能。此外，在 F5 和 F6 上，0.97 与最佳适应度之间的差异在 Wilcoxon 秩和检验下不显著。具体而言，仅当 p 值小于 0.05 时，认为两算法性能存在显著差异。F5 上 0.97 与 0.99 的 p 值为 0.202，F6 上 0.97 与 0.95 的 p 值为 0.148。因此，在后续实验中将历史权重设为 0.97。

4.4.2.2 通信间隔

CCSA-DES 的通信间隔决定了局部优化阶段的代数。在本部分，我们研究通信间隔对算法性能的影响，并寻找合适的参数设置。我们分别将通信间隔设为 1、2、5、10 和 20，并测试算法性能。图4-5 展示了适应度曲线随通信次数变化的情况，实验结果如下。

在函数 F1-F5 中，在相同通信次数下，通信间隔越大，适应度曲线下降越快。这是因为通信间隔较大时，智能体在局部优化阶段的探索更加充分。然而，该现象并不适用于所有基准函数。在函数 F7-F9 中，当通信间隔设为 20 或 10 时，适应度曲线出现明显反弹。这是由于智能体之间缺乏必要的协作。具体而言，在局部优化阶段，智能体仅依据自身的局部进化路径调整步长。一般而言，局部目标函数的最优区域与全局目标函数的最优区域并不一致。当通信间隔较大时，智能体倾向于增大步长并搜索各自的局部最优区域。结果是智能体跳出全局最优区域，导致全局适应度值反弹。

综上所述，通信间隔过大会削弱智能体之间的协作，而通信间隔过小则会带来较大的通信开销。为在两者之间取得平衡，后续实验中将默认通信间隔设为 5。当间隔为 5 时，CCSA-DES 在九个测试函数上均表现良好。



a) F1　b) F2　c) F3

d) F4　e) F5　f) F6

g) F7　h) F8　i) F9

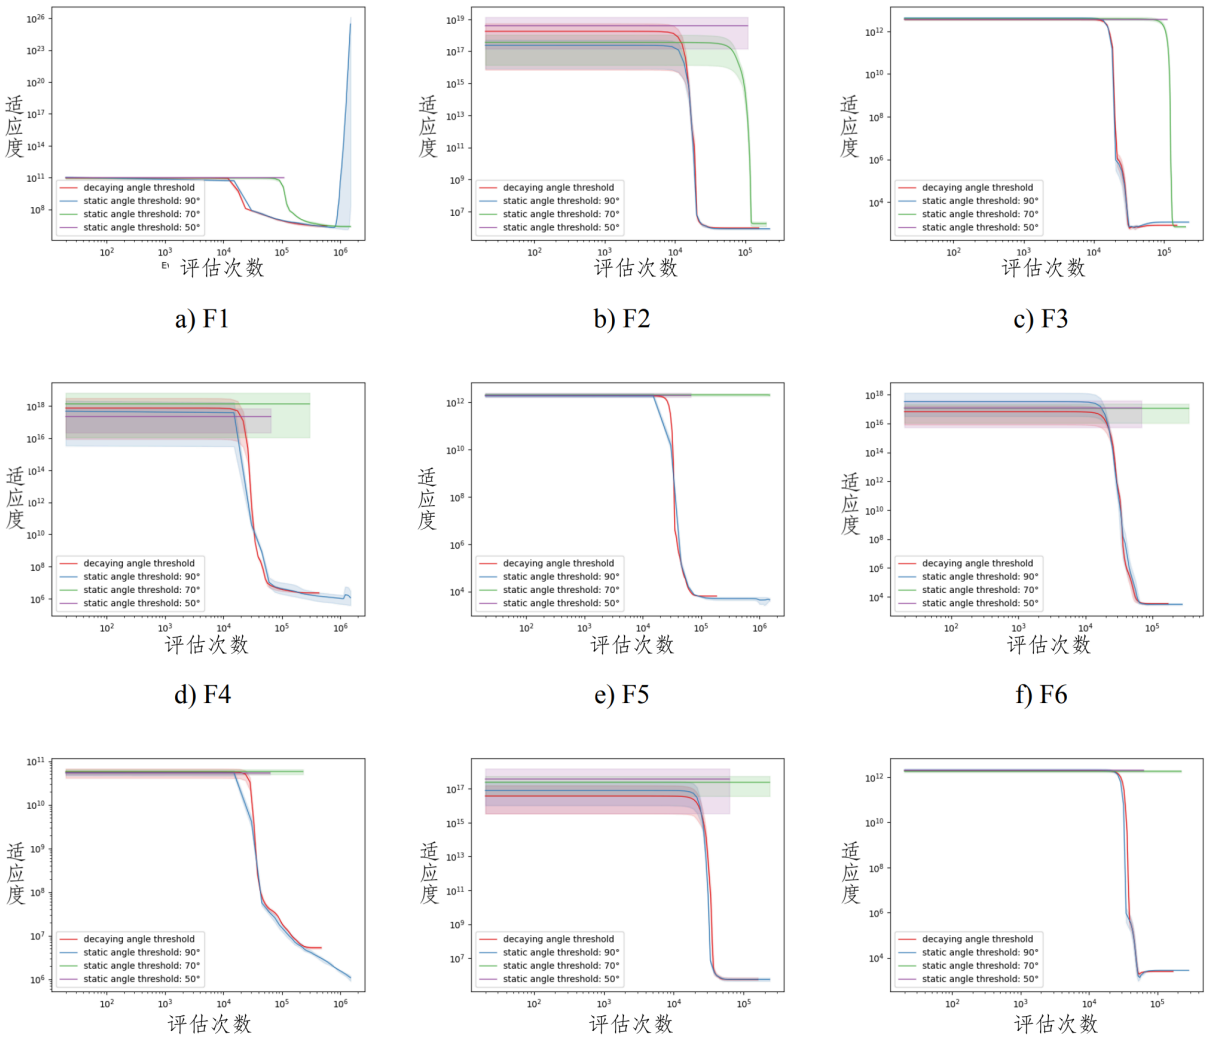
图 4-5 针对通信间隔的参数调研。该图展示了适应值随着通信传输比特的变化。

4.4.2.3 冲突角阈值

冲突角阈值影响进化路径，从而影响步长自适应。在 CCSA-DES 中，冲突角阈值随优化过程逐渐衰减，如式 (4-5) 所示。本部分通过实验验证衰减角阈值相较于固定角阈值的优势。在实验中，固定角阈值分别设为 90°、70° 和 50°。根据图4-6 的实验结果，可得如下现象。

首先，当固定角阈值设为 90° 时，F1 的适应度曲线出现明显反弹。根据 Sec. 4.3.3 中 CCSA 的工作原理，较大的固定角度会使冲突判定较为宽松，从而使算法倾向于增大步长。结果是采样步长可能过大，使解跳出原有收敛区域，从而导致适应度反弹。尽管在其他八个函数上表现良好，但该设置仍不理想，因为其无法适应不同问题。

其次，当固定角阈值设为 50° 时，所有函数的适应度曲线从一开始几乎停滞。这是



a) F1　b) F2　c) F3

d) F4　e) F5　f) F6

g) F7　h) F8　i) F9

图 4-6 算法采用衰减角阈值与固定角阈值时的表现。当系统达成共识时，算法会提前终止。

因为较小的固定角度使冲突判定过于严格。根据 CCSA 的工作原理，采样步长在算法初期即趋于减小。在此情况下，智能体的局部优化被限制在初始位置附近的小区域内，算法无法充分探索优化空间。

再次，当固定角阈值设为 70° 时，在 F1-F3 上的性能与衰减角阈值相当，但在 F4-F9 上适应度曲线出现停滞。

上述三种情况表明，固定角阈值难以良好适应不同优化问题。相比之下，采用衰减角阈值的 CCSA-DES 在九个函数上均表现良好。这是因为衰减角阈值同时兼顾了算法早期的探索能力与后期的开发能力。综上，本实验验证了衰减角阈值的有效性。

4.4.3 消融实验

在黑箱分布式优化领域，步长控制方法包括固定步长[27]、递减步长[76,78-82] 以及自适应步长[66,98]。因此，我们开展消融实验，以验证所提出 CCSA 相对于现有方法的优势。我们选择 CSA[66] 作为自适应步长方法的代表，因为其是进化策略中的典型方法。递减步长方法依据近期提出的分布式进化策略[76] 实现。为测试步长控制方法的适应性，我们基于原有九个基准函数设计了九组“孪生函数”。具体而言，每组包含两个函数 Fi-L 和 Fi-S，其中 i 表示基准函数编号。Fi-S 由 Fi-L 在定义域上缩放 10000 倍得到。例如，F1-L 与 F1-S 定义如下：

$$\begin{aligned} \text{F1-L}(\boldsymbol{x}) &= \text{F1}(\boldsymbol{x}) \\ \text{F1-S}(\boldsymbol{x}) &= \text{F1}(10000 * \boldsymbol{x}) \end{aligned} \tag{4-34}$$

表 4-3 给出了在孪生函数上的适应度结果。总体适应度为两者适应度的平均值，p 值基于总体适应度并通过 Wilcoxon 秩和检验计算。实验结果如下。

首先，从自适应步长方法来看，CSA 在 F1 上优于 CCSA，在 F3 和 F5 上略逊于 CCSA，但在其他函数上与 CCSA 存在较大差距。这是因为 CSA 仅根据智能体自身的进化路径进行步长自适应，缺乏智能体之间的协作。当局部目标函数的最优区域接近全局目标函数最优区域时（如 F1 和 F3），CSA 表现良好。相反，当局部目标函数最优区域与全局目标函数最优区域不一致时，CSA 可能在全局最优区域增大步长，导致算法跳出最优区域，全局适应度显著上升。

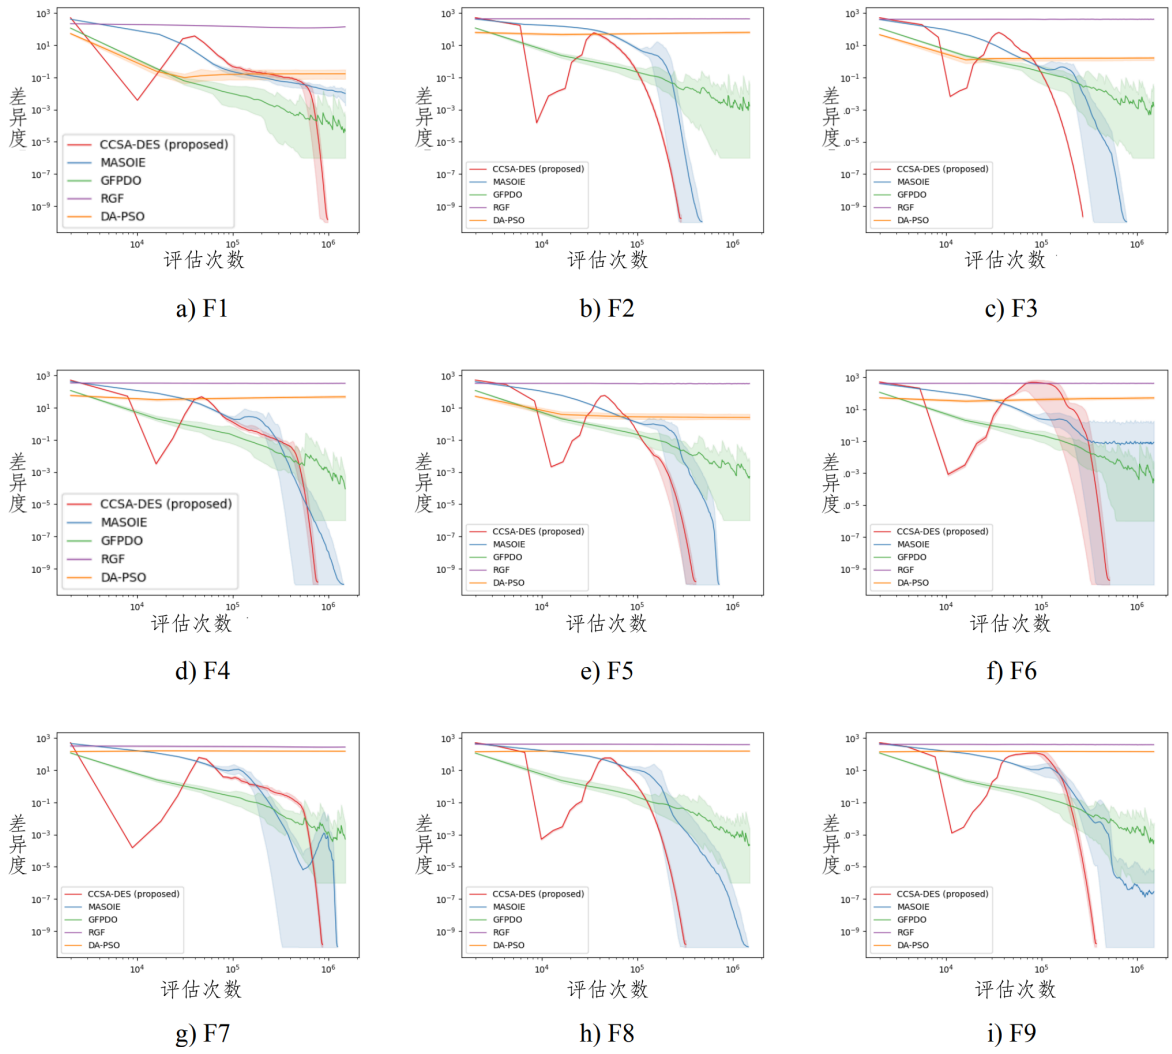
其次，从固定步长方法来看，不存在一个固定步长能够同时在孪生函数上取得良好性能。在消融实验前，我们分别通过参数调优为孪生函数选择最佳步长。Fi-L 的最佳步长为 1E-1，Fi-S 的最佳步长为 1E-5。表 4-3 给出了使用这两种步长时的性能。当固定步长设为较大值 1E-1 时，在 F1-L 至 F9-L 上表现良好，但在 F1-S 至 F9-S 上表现较差，因为较大的步长无法有效开发 Fi-S 的最优区域。类似地，当固定步长设为较小值 1E-5 时，在 F1-S 至 F9-S 上表现良好，但在 F1-L 至 F9-L 上表现较差，因为较小步长无法充分探索 Fi-L，解仅停留在初始位置附近。

再次，从递减步长方法来看，实验结果与固定步长类似，不存在一个初始步长能够同时在孪生函数上取得良好性能。在消融实验前，我们同样通过参数调优选取最佳初始步长。Fi-L 的最佳初始步长为 1.0，Fi-S 的最佳初始步长为 1E-3。当初始步长设为较大值 1 时，在 F1-S 至 F9-S 上表现较差；当初始步长设为较小值 1E-3 时，在 F1-L 至 F9-L

上表现较差。

综上所述，所提出的 CCSA 在总体性能上优于上述三类现有步长控制方法。

4.4.4 与现有算法的对比分析



a) F1　b) F2　c) F3

d) F4　e) F5　f) F6

g) F7　h) F8　i) F9

图 4-7 所提出算法与当前先进算法（state-of-the-art algorithms）的共识性能比较。纵轴表示分布式系统的 disagreement，即各局部解之间的差异。disagreement 按照公式 (4-35) 计算。

在本实验中，我们将 CCSA-DES 与四种现有的黑箱、非凸分布式优化算法进行比较。MASOIE (Multi-Agent Swarm Optimization With Adaptive Internal and External Learning) 是一种具有自适应内外学习机制的多智能体群体优化算法[97]。RGF (Randomized Gradient-Free Methods) 是经典的随机无梯度方法[27]。GFPDO (General Framework for Population-based Distributed Optimization) 是一种基于种群的分布式优化通用框架[70]。DA-PSO (Distributed particle swarm optimization algorithm using the strategies of diffusion adaptation) 是一种采用扩散自适应策略的分布式粒子群优化算法[71]。所有算法在相同的目标函数

表 4-3 提出的步长自适应方法 CCSA 的消融实验

benchmark		CCSA（本章）	自适应步长: CSA	固定步长: 取较大值	固定步长: 取较小值	衰减步长: 初始值大	衰减步长: 初始值小
F1	fitness on F1-L	1.51E+06	5.21E+05	5.21E+05	9.87E+10	4.06E+06	1.89E+11
	fitness on F1-S	1.36E+06	6.18E+05	3.74E+11	4.31E+05	1.53E+10	2.38E+07
	overall fitness	1.44E+06	**5.70E+05**	1.87E+11	4.93E+10	7.66E+09	9.46E+10
	p-value	-	2.80e-04*	2.80e-04#	2.80e-04#	8.74e-08#	8.74e-08#
F2	fitness on F2-L	5.92E+05	1.76E+287	5.82E+05	2.60E+17	1.02E+06	4.09E+23
	fitness on F2-S	4.25E+05	9.89E+16	3.33E+11	6.21E+05	9.53E+10	3.64E+05
	overall fitness	**5.08E+05**	8.79E+286	1.66E+11	1.30E+17	4.77E+10	2.05E+23
	p-value	-	2.80e-04#	2.80e-04#	2.80e-04#	8.74e-08#	8.74e-08#
F3	fitness on F3-L	2.80E+02	1.22E+03	3.62E+02	3.56E+12	5.23E+02	1.74E+13
	fitness on F3-S	3.12E+02	1.22E+03	4.18E+13	4.02E+02	3.06E+12	8.04E+02
	overall fitness	**2.96E+02**	1.22E+03	2.09E+13	1.78E+12	1.53E+12	8.68E+12
	p-value	-	2.80e-04#	2.80e-04#	2.80e-04#	8.74e-08#	8.74e-08#
F4	fitness on F4-L	1.35E+06	1.01E+305	9.50E+05	2.40E+17	1.22E+06	5.68E+23
	fitness on F4-S	1.21E+06	6.77E+305	2.61E+25	9.79E+05	2.72E+10	6.75E+06
	overall fitness	**1.28E+06**	3.89E+305	1.31E+25	1.20E+17	1.36E+10	2.84E+23
	p-value	-	2.80e-04#	2.80e-04#	2.80e-04#	8.74e-08#	8.74e-08#
F5	fitness on F5-L	2.97E+03	1.29E+05	1.52E+04	2.13E+12	1.73E+04	8.15E+12
	fitness on F5-S	2.99E+03	1.37E+05	7.80E+13	1.52E+04	1.27E+12	1.27E+05
	overall fitness	**2.98E+03**	1.33E+05	3.90E+13	1.06E+12	6.36E+11	4.07E+12
	p-value	-	2.80e-04#	2.80e-04#	2.80e-04#	8.74e-08#	8.74e-08#
F6	fitness on F6-L	1.49E+03	6.67E+294	3.38E+02	1.69E+17	4.71E+02	3.45E+21
	fitness on F6-S	1.28E+03	2.62E+304	7.32E+17	3.66E+02	1.43E+14	5.49E+03
	overall fitness	**1.39E+03**	1.31E+304	3.66E+17	8.47E+16	7.13E+13	1.72E+21
	p-value	-	2.80e-04#	2.80e-04#	2.80e-04#	8.74e-08#	8.74e-08#
F7	fitness on F7-L	8.18E+06	1.73E+18	4.54E+06	5.79E+10	6.26E+06	9.44E+10
	fitness on F7-S	2.05E+07	1.68E+18	4.48E+13	4.48E+06	7.01E+13	1.81E+08
	overall fitness	**1.44E+07**	1.70E+18	2.24E+13	2.89E+10	3.51E+13	4.73E+10
	p-value	-	2.80e-04#	2.80e-04#	2.80e-04#	8.74e-08#	8.74e-08#
F8	fitness on F8-L	1.77E+06	9.48E+217	1.41E+06	3.41E+16	2.59E+06	1.38E+24
	fitness on F8-S	2.58E+06	2.91E+124	1.58E+15	1.46E+06	1.29E+37	7.94E+07
	overall fitness	**2.18E+06**	4.74E+217	7.89E+14	1.71E+16	6.47E+36	6.89E+23
	p-value	-	2.80e-04#	2.80e-04#	2.80e-04#	8.74e-08#	8.74e-08#
F9	fitness on F9-L	1.53E+03	9.63E+27	3.73E+02	1.90E+12	1.11E+03	8.40E+12
	fitness on F9-S	1.49E+03	1.05E+28	2.33E+14	4.05E+02	5.23E+15	2.85E+03
	overall fitness	**1.51E+03**	1.00E+28	1.16E+14	9.51E+11	2.62E+15	4.20E+12
	p-value	-	2.80e-04#	2.80e-04#	2.80e-04#	8.74e-08#	8.74e-08#

* 该符号代表在 Wilcoxon rank sum test（0.05）下对比算法显著优于 CCSA

该符号代表在 Wilcoxon rank sum test（0.05）下对比算法显著劣于 CCSA

表 4-4 CCSA-DES 与 SOTA 算法的比较结果

		CCSA-DES	MASOIE[97]	GFPDO[70]	RGF[27]	DA-PSO[71]
F1	fitness	1.51E+06	7.69E+04	5.85E+06	**5.02E+03**	4.23E+05
	comm. amount	6.35E+07	6.01E+08	4.85E+09	1.50E+09	9.96E+06
F2	fitness	5.92E+05	**6.43E+04**	8.87E+08	1.03E+11	7.80E+07
	comm. amount	1.98E+07	2.11E+08	1.48E+10	1.50E+09	9.96E+06
F3	fitness	**2.80E+02**	1.09E+04	9.58E+09	3.72E+10	1.86E+04
	comm. amount	1.92E+07	2.56E+08	1.53E+10	1.50E+09	9.96E+06
F4	fitness	**1.35E+06**	2.06E+07	1.82E+09	2.52E+09	4.23E+08
	comm. amount	5.08E+07	3.25E+08	1.29E+10	1.50E+09	9.96E+06
F5	fitness	**2.97E+03**	2.41E+06	6.95E+09	3.84E+09	6.62E+06
	comm. amount	2.67E+07	2.59E+08	1.46E+10	1.50E+09	9.96E+06
F6	fitness	**1.49E+03**	1.50E+05	6.66E+09	4.50E+10	1.12E+09
	comm. amount	2.87E+07	3.28E+08	1.46E+10	1.50E+09	9.96E+06
F7	fitness	**8.18E+06**	4.54E+07	8.99E+08	1.32E+09	1.43E+09
	comm. amount	5.93E+07	3.35E+08	1.44E+10	1.50E+09	9.96E+06
F8	fitness	1.77E+06	**1.98E+05**	5.44E+08	3.43E+10	8.58E+07
	comm. amount	2.21E+07	2.55E+08	1.46E+10	1.50E+09	9.96E+06
F9	fitness	**1.53E+03**	1.08E+07	5.69E+09	2.31E+10	2.67E+09
	comm. amount	2.57E+07	3.93E+08	1.41E+10	1.50E+09	9.96E+06

* 该符号代表在 Wilcoxon rank sum test（0.05）下对比算法显著优于提出的 CCSA-DES

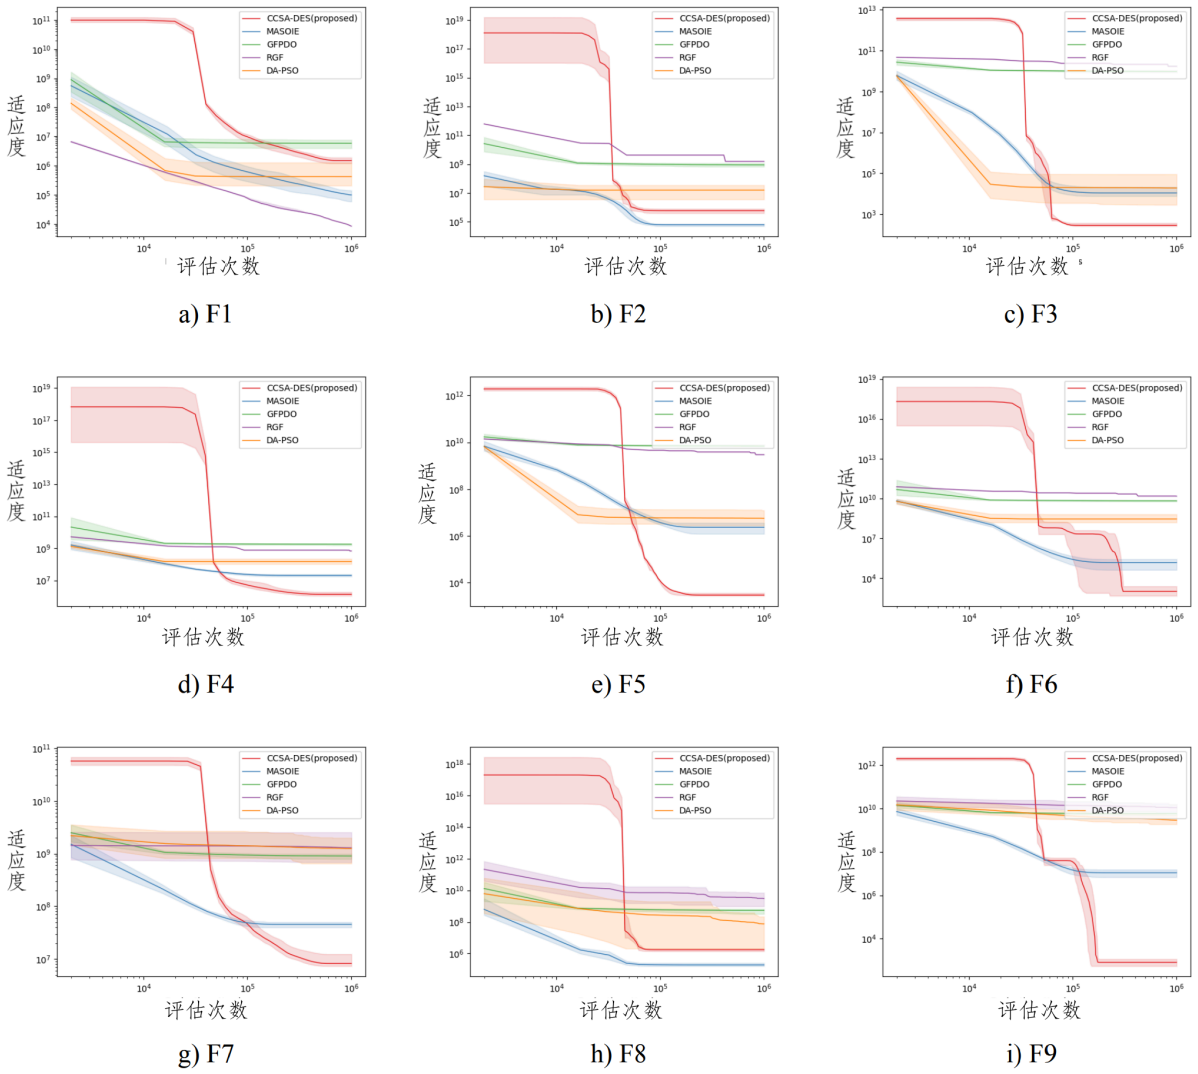
该符号代表在 Wilcoxon rank sum test（0.05）下对比算法显著劣于提出的 CCSA-DES

最大评估次数下进行比较。

对比算法的控制参数设置如下。首先，基于种群的算法（包括 MASOIE、GFPDO 和 DA-PSO）的种群规模均设为 300[97]。此外，MASOIE 的初始通信间隔设为 4[97]。对于 RGF，初始步长设为 1E-5，高斯扰动幅度设为 1E-3。对于 DA-PSO，惯性权重设为 0.5。最后，GFPDO 的共识精度水平设为 1E-3[70]。

图4-8 展示了 CCSA-DES 与对比算法的解质量。根据图中的适应度曲线，算法的优化过程可划分为三个阶段：初期、中期和后期。在初期阶段，由于初始步长较小，CCSA-DES 的适应度值高于其他算法。MASOIE、GFPDO 和 DA-PSO 均为基于种群的算法，不包含采样步骤，其初始种群随机分布于搜索空间，因此在初期具有较小的适应度值。在中期阶段，CCSA-DES 在九个函数上的曲线均呈现快速下降趋势。这是因为 CCSA-DES 自适应地增大步长，从而加快了探索速度。在该阶段，CCSA-DES 在六个函数上优于其他算法。在后期阶段，各算法的适应度曲线逐渐趋于平缓并收敛。

我们还在图4-7 中展示了 CCSA-DES 与对比算法的共识性能。图中的纵轴为分布式



a) F1　b) F2　c) F3

d) F4　e) F5　f) F6

g) F7　h) F8　i) F9

图 4-8 提出的算法与 SOTA 算法在求解质量上的对比

系统的差异度，该指标通常用于评估分布式算法的共识性能。差异度定义为局部解与平均解之间距离的平方和：

$$\mathcal{D} = \frac{1}{n}\sum_{i=1}^{n} \|\boldsymbol{x}_i - \overline{\boldsymbol{x}}\|_2^2 \tag{4-35}$$

其中 $\boldsymbol{x}_i$ 为第 i 个智能体的局部解，$\overline{\boldsymbol{x}} = \frac{1}{n}\sum_{i=1}^{n} \boldsymbol{x}_i$ 为所有局部解的平均值。当各局部解一致时，差异度趋近于零，表明系统达到共识。

根据图4-7 中的差异度曲线，CCSA-DES 在优化过程中同样呈现三个阶段。在初期阶段，由于初始步长较小，局部探索较少，差异度下降。在中期阶段，由于 CCSA-DES 自适应增大步长，探索增强，差异度上升。在后期阶段，CCSA-DES 逐渐减小步长，差异度收敛至 1E-10。多智能体系统在九个函数上最终均达到共识。根据图示，CCSA-DES 在所有算法中具有最佳共识性能。MASOIE 与 GFPDO 的共识性能次之。具体而言，

MASOIE 在六个函数上差异度收敛至 1E-10。GFPDO 的差异度曲线下降较慢，未达到 1E-10。不同于上述算法，RGF 与 DA-PSO 的差异度未表现出明显下降趋势。RGF 的共识仅在凸函数上得到理论保证，因此在非凸基准函数上表现不佳。DA-PSO 的差异度曲线基本保持在初始值附近，这是因为其算法设计未考虑系统共识问题。

表格 4-4 给出了各算法的解质量与通信量。通信量记录了在整个优化过程中，每个智能体与其邻居进行通信的次数。此外，p 值为 Wilcoxon 秩和检验结果，用于判断两种算法性能是否存在显著差异。根据表中结果，CCSA-DES 在九个函数中的六个上，其解质量显著优于其他算法。此外，RGF 在 F1 上优于 CCSA-DES，MASOIE 在 F2 和 F8 上优于 CCSA-DES。然而，RGF 与 MASOIE 的通信量比 CCSA-DES 高 1 至 2 个数量级。在通信受限场景下，CCSA-DES 相较于 MASOIE、GFPDO 与 RGF 具有优势。

综上所述，与当前先进的黑箱分布式优化算法相比，所提出的 CCSA-DES 具有更优的共识性能和具有竞争力的解质量。

4.4.5 现实应用问题验证

在本小节中，我们在一个真实问题——无线传感器网络中的多目标定位问题上验证所提出算法的性能。考虑一个包含 n 个传感器的无线传感器网络，其位置记为 $y_1, y_2, ..., y_n$。假设检测区域内同时存在 N_t 个目标。每个传感器可以接收来自多个目标的信号强度。对于传感器 i，其测量数据记为 $\phi_{i,1}, \phi_{i,2}, ..., \phi_{i,N_t}$。

$$\phi_{i,t} = P_0 - 10n_p \log_{10}(\frac{\|p_t - y_i\|}{d_0}) + \epsilon \tag{4-36}$$

其中 $\epsilon \sim \mathcal{N}(0, v)$ 为测量噪声。P_0 为在参考距离 d_0 处的已知参考功率值（单位为分贝）。本实验中，v 设为 0.1，P_0 设为 100，d_0 设为 1，n_p 设为 2[99]。

传感器可以根据信号强度估计目标到自身的距离。然而，由于缺乏方向信息，单个传感器难以准确定位目标。因此，需要多个传感器协作完成目标定位。由此，多目标定位问题定义如下：

$$\begin{aligned} F(p_1, p_2, ..., p_{N_t}) &= \frac{1}{n}\sum_{i=1}^{n} f_i(p_1, p_2, ..., p_{N_t}) \\ \text{s.t. } f_i(*) &= \sum_{t=1}^{N_t}[\phi_{it} - (P_0 - 10n_p \log_{10}(\frac{\|p_t - y_i\|}{d_0}))]^2 \end{aligned} \tag{4-37}$$

其中，$p_1, p_2, ..., p_{N_t}$ 为优化变量，$p_t \in \mathbb{R}^3$ 表示第 t 个目标的估计位置。$f_i(*)$ 为传感器 i 的局部目标函数，表示基于其测量数据的估计误差。$F(*)$ 为全局目标函数，即所有传

感器的总估计误差。

我们在不同目标数量下测试 CCSA-DES 与对比算法在该问题上的性能。根据图4-9的实验结果，可以发现 CCSA-DES 的整体性能优于对比算法。尽管在 10 个目标的情况下，MASOIE 的性能接近 CCSA-DES，但随着目标数量的增加，MASOIE 的估计误差迅速上升。这是因为问题维度随目标数量增加而升高。相比之下，所提出的 CCSA-DES 受目标数量增加的影响较小，即使在 50 个目标的情况下仍能保持良好性能。

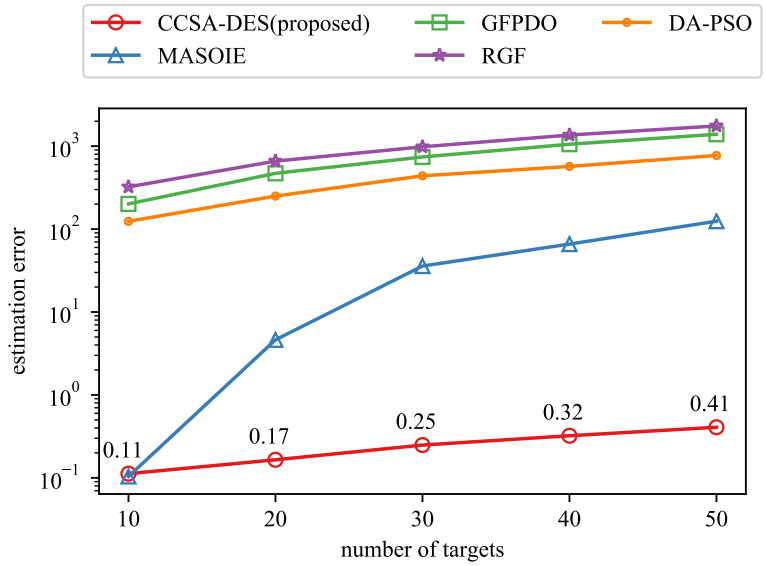


图 4-9 CCSA-DES 与对比算法在多目标定位问题上的性能

4.5 本章小结

在本章中，我们提出了一种用于黑箱分布式优化的多智能体进化策略——协作与累积步长自适应算法（CCSA-DES）。我们设计了一种用于分布式优化中邻域进化路径的累积方法。基于邻域进化路径，分别为局部优化阶段与通信阶段设计了内部自适应方法与外部自适应方法。在理论分析方面，我们首先讨论了所提出步长自适应方法的工作原理，然后分析了所提出分布式优化算法的系统共识性。在实验验证方面，与当前先进的黑箱分布式优化算法相比，CCSA-DES 取得了具有竞争力的解质量与更优的共识性能。

未来，我们将研究黑箱分布式优化问题在复杂多智能体系统中的鲁棒性与动态特性，例如时变网络、节点失效等。此外，多智能体进化策略在无线传感器网络与分布式机器学习系统中的应用也值得进一步研究。

第五章　基于适应性目标激励的多智能体共识优化算法

5.1　引言

进化计算（Evolutionary Computation, EC）是另一类受生物进化和群体行为启发的无梯度方法。与基于梯度方法和 RGF 相比，EC 不依赖于问题的数学性质或梯度计算[100]。EC 具有较强的全局搜索能力，常用于黑箱和非凸优化问题[101-102]。由于 EC 具有内在并行性，许多并行与分布式进化算法被提出，包括种群分布式模型和维度分布式模型[45]。顾名思义，种群分布式模型将种群划分为多个子种群，并在不同计算节点上协同进化[47-48]；维度分布式模型则将全局问题的决策变量划分为若干子组件，并通过协同优化器求解[52,103-105]。这些算法主要研究变量划分方式、通信协议及多子种群之间的协作机制，使多个计算节点能够高效协同求解复杂问题。

尽管现有并行进化算法为多种群协同进化提供了丰富的协作机制，但它们主要面向加速集中式优化设计，在此类问题中，全局信息通常可在每个计算节点直接获得。而在网络化系统的分布式优化问题中，每个智能体只能访问全局目标函数的一部分，即其局部目标函数。局部目标函数的去中心化特性与潜在冲突性对进化算法设计提出了两大挑战：如何引导子种群协同优化全局目标，以及如何在合理通信成本下通过协商使分布式智能体达成共识。目前针对分布式优化的分布式进化算法仍较少。例如，在应对第一个挑战方面，DPSO（distributed particle swarm optimization）[72] 通过引入辅助变量来估计子种群进化过程中的全局适应度；在应对第二个挑战方面，文献[70] 中每个智能体在每一代计算自身子种群与邻居子种群的加权平均。然而，大多数方法针对特定应用[5,42,71] 或低维问题[70,72] 设计。

综上所述，针对具有冲突局部目标的黑箱和非凸分布式优化问题，现有研究仍然有限。尽管分布式进化算法在理论上具有潜力，但现有算法尚未在更一般和大规模问题上充分解决上述两个挑战。本章关注一种常见的分布式优化类型——具有部分重叠变量的分布式共识优化问题（Distributed Consensus Optimization with Overlapping Variables, DOOV），其存在于交通网络中的交通分配问题[106]、电力系统中的电力调度问题[107]、分布式电力系统状态估计[108] 等场景。在这些场景中，数据通常分散于不同节点，因此设计分布式优化方法尤为重要。DOOV 中每个智能体对应网络图中的一个顶点，并拥有私有局部目标函数。局部目标函数的决策变量包括顶点上的私有变量以及边上的共享变量，边上的变量由两端顶点对应的两个智能体共享，具体定义见章节2.1.3。针对上述挑战，本

章提出一种多智能体协同进化算法与基于惩罚的目标函数（Multiagent Co-Evolutionary Algorithm With Penalty-Based Objective, MACPO）来求解 DOOV。在 MACPO 中，网络系统中的每个智能体控制一个子种群，其中个体由该智能体的私有变量以及其边上的共享变量编码。在优化过程中，智能体在局部优化阶段进化其子种群，并在协商阶段通过通信与邻居交替协商共享变量的取值。主要贡献体现在以下两个方面：

1) 为了在每个智能体只能访问其局部目标函数的情况下实现对全局目标的协同优化，我们设计了一种基于惩罚的目标函数用于适应度评估以引导子种群进化。具体而言，在原始局部目标函数中加入惩罚项。该惩罚目标将子种群约束在接近共识解的一个小且可控的范围内，从而使邻居智能体在共享变量上的解更加接近，有利于达成共识。此外，为使惩罚更具针对性，我们提出一种冲突检测方法，用于检测两个智能体是否在某个决策变量上存在冲突。仅当某变量存在冲突时，才在惩罚目标函数中加入关于该变量的惩罚项。
2) 为帮助智能体在仅能访问局部目标函数的情况下就全局解达成共识，我们对共享变量的协商过程进行了重构，包括评估、竞争与共享三个步骤。这三个步骤使网络系统中的相邻智能体能够协商解并在共享变量上达成共识。

大多数基于种群的进化算法均可嵌入该框架中。MACPO 在一组 DOOV 基准函数上进行了测试。实证研究表明，与现有分而治之算法相比，所提出的基于惩罚的目标函数在引导子种群进化方面是有效的。与现有整体式算法相比，本章算法在解质量方面具有竞争力，同时具有更高的计算效率和更好的可扩展性。

在可计算梯度的测试问题上，MACPO 的解质量接近基于梯度的分布式算法，但基于梯度算法更加稳定。在不可计算梯度的真实世界与基准问题上，与无梯度分布式算法相比，MACPO 具有更优的解质量且计算开销相近。

本章其余部分安排如下。第 5.2 节介绍所提出的算法 MACPO。第 5.3 节开展一系列实验。最后，第 5.4 节给出总结。

5.2 基于适应性目标激励的多智能体共识优化算法

本节首先介绍所提出的多智能体协同进化算法框架。随后，按照局部优化、协商机制与冲突检测的顺序，依次对框架中的三个关键组成部分进行详细说明。

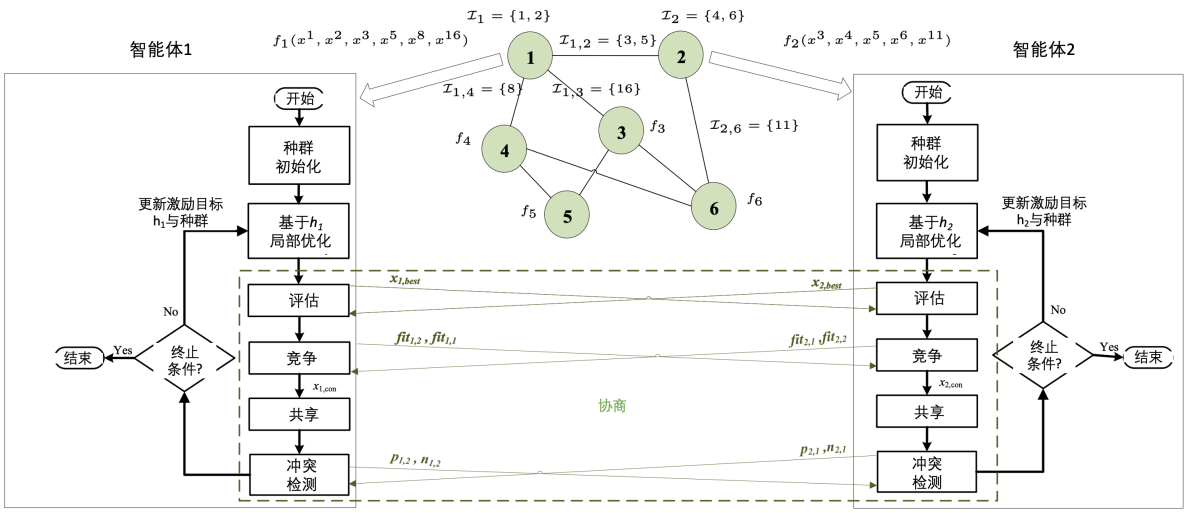


图 5-1 MACPO 的框架示意图。该图展示了一个包含六个智能体的网络化系统示例。每个绿色圆圈代表一个智能体。由于智能体 1 与智能体 2 相连，因此展示了这两个相连智能体的流程图，以说明它们在 MACPO 中如何进行通信与协商。两个流程图之间的绿色连线表示智能体 1 与智能体 2 之间的通信。符号说明：x^i 表示 DOOV 全局变量中的第 i 个变量。$\mathcal{I}_i$ 表示顶点 i 上私有变量的索引集合，$\mathcal{I}_{i,j}$ 表示边 (i,j) 上共享变量的索引集合。详细定义见第 2.1.3 节。h_i 表示第 5.2.2 节中提出的惩罚型目标函数。

5.2.1 算法框架

在本研究中，我们提出了一种多智能体协同进化算法框架。在该框架中，每个智能体对应网络系统中的一个节点，从而能够访问该节点的局部目标函数。每个智能体维护一个种群，并与其邻居进行协同进化。每个智能体的流程以及智能体之间的通信关系如图 5-1 所示。多智能体系统的通信拓扑由所求解问题决定。当两个不同的智能体 i 与 j 在网络 G 中相连时，它们之间即可建立通信关系。智能体 i 的邻居集合定义如下：

$$\mathcal{N}_i := \{j \in V \backslash \{i\} : (i,j) \in E\} \tag{5-1}$$

在每次迭代中，智能体的操作包含两个阶段：局部优化阶段与协商阶段。顾名思义，局部优化是指每个智能体的内部计算过程；协商则是指相邻智能体在共享变量上达成共识，并利用该共识解引导种群进化的过程。

在局部优化阶段，每个智能体围绕惩罚型目标函数 h_i 对其决策变量 X_i 进行优化。对于智能体 i，其优化目标 h_i 初始时等于原始局部目标函数 f_i，并在每次协商之后发生更新。需要强调的是，局部优化阶段所采用的优化算法可以是任意基于种群的进化算法。这是因为该框架仅对目标函数进行修改，并在协商阶段对种群赋值。

在协商阶段，智能体与邻居之间通过四个步骤完成协商：评估、竞争、共享与冲突检测。每一轮迭代中，智能体 i 与邻居 j 在共享变量集合 $\mathcal{I}_{i,j}$ 上进行协商时，需要进行三次通信。第一次通信发生在评估步骤，智能体向邻居发送其最优解（候选解）。第二次通信发生在竞争步骤，智能体向邻居发送两个评估结果。第三次通信发生在冲突检测步骤，智能体向邻居发送梯度估计结果。

5.2.2 基于目标激励的局部优化机制

如前所述，算法在局部优化阶段与协商阶段之间交替进行。根据图 5-1，惩罚型目标函数 h_i 在初始化时等于原始局部目标函数 f_i。在每次迭代中，当获得共识解 $\boldsymbol{x}_{i,con}$ 后，h_i 将被更新。本小节将介绍与 $\boldsymbol{x}_{i,con}$ 相关的惩罚型目标函数设计方法。

惩罚型目标函数通过在原始局部目标函数上添加惩罚项构造，其形式如下：

$$h_i(x) = f_i(x) + w * \sum_{j\in\mathcal{N}_i}\sum_{d\in\mathcal{I}_{i,j}} (t_{j,d}|\boldsymbol{x}^d - \boldsymbol{x}^d_{i,con}|) \tag{5-2}$$

其中，$w \in \mathbb{R}$ 为惩罚权重，$t_{j,d} \in \{0,1\}$ 为惩罚开关，$\boldsymbol{x}_{i,con}$ 为每次迭代更新的共识解。惩罚项反映了当前评估个体 x 与共识解 $\boldsymbol{x}_{i,con}$ 在共享变量上的距离。

惩罚型目标函数能够将种群约束在共识解附近的一个小范围内，从而在下一轮协商中减小不同智能体候选解之间的冲突，有利于邻居之间的协作。一方面，共享变量的取值更加接近，使得相邻智能体更容易达成共识；另一方面，当共享变量被替换为共识解时，私有变量也能更好地与共享变量匹配。

惩罚型目标函数包含两个重要参数：惩罚权重 w 与惩罚开关 $t_{j,d}$。这两个参数的作用及设置如下所述：

5.2.2.1 惩罚权重

惩罚权重对 MACPO 的性能具有重要影响。若惩罚权重过大，则适应度将被惩罚项主导，原始目标函数被忽略；若惩罚权重过小，则惩罚项失去作用。由于问题的原始适应度会随着优化过程不断下降，采用固定惩罚权重并不合适。因此，本工作采用自适应惩罚权重，其随问题原始适应度变化而调整：

$$w = \lambda \sum_{i=1}^{n} f_i(\boldsymbol{x}_{i,con}) \tag{5-3}$$

其中，λ 为静态参数，其取值将在参数实验中分析。$\sum_{i=1}^{n} f_i(\boldsymbol{x}_{i,con})$ 表示当前共识解在所有智能体上的局部适应度之和。随着优化过程推进，共识解的适应度下降，惩罚权

重 w 也相应减小。该自适应策略能够平衡惩罚项与原始目标值之间的相对尺度，从而更有效地引导种群搜索。惩罚权重通过广播机制周期性更新。

5.2.2.2 惩罚开关

在式 (5-2) 中，$t_{j,d}$ 为惩罚开关，其取值为 0 或 1。它用于决定在当前种群中是否对与邻居 j 相关的第 d 个共享变量施加约束。当惩罚开关为 1 时，惩罚型目标函数将考虑个体 x 与共识解 $\boldsymbol{x}_{i,con}$ 在该变量上的距离。因此，在该变量上远离共识解的个体将因适应度增大而不被优先选择，从而限制该变量的进化。该变量在优化过程中动态调整，其机制将在第 5.2.3.3 节介绍。

5.2.3 多智能体协商机制

在所提出的框架中，通过协商阶段的前三个步骤——评估、竞争与共享，实现不同智能体之间在共享变量上的共识。该协商机制适用于分布式场景，在该场景中，每个智能体仅能进行局部适应度评估。

5.2.3.1 评估

在评估步骤开始时，每个智能体将其候选解（子种群中的最优解）发送给邻居，如图 5-1 所示。接收邻居的候选解后，智能体对其进行评估。评估的核心思想是在当前解的某一维度被邻居解替换时，计算局部适应度。算法 5-3 返回两个向量 $fit_{i,i}$ 与 $fit_{i,j}$。向量 $fit_{i,i}$ 中的元素 $fit_{i,i}^{d}$ 表示当共识解在第 d 个共享变量上采用 $\boldsymbol{x}_i$ 的取值时子问题 f_i 的适应度；同理，$fit_{i,j}^{d}$ 表示当共识解在该变量上采用 $\boldsymbol{x}_{j,best}$ 的取值时子问题 f_i 的适应度。

考虑到共享变量之间的相互影响，共识解 $\boldsymbol{x}_{i,test}$ 中共享变量的初始取值设为编号较小智能体的候选解（第 3–4 行）。该操作保证 $fit_{i,j}$ 与 $fit_{j,j}$ 在评估共享变量时基于相同解。随后，对于每个共享变量，将其取值替换为编号较大智能体的解（a1），并计算 $\boldsymbol{x}_{i,test}$ 的适应度作为 $fit_{i,b}^{d}$（a2）。之后，将该变量恢复为原取值（a3）。由于 $fit_{i,a}^{d}$ 等于初始适应度 fit_0，因此无需重复计算（a4）。

5.2.3.2 竞争

在竞争步骤中，相邻智能体首先通过通信交换评估结果，然后执行算法 5-4 中的竞争操作。对于共享变量集合 $\mathcal{I}_{i,j}$，智能体 i 与智能体 j 基于四个向量 $fit_{i,i}$、$fit_{i,j}$、$fit_{j,i}$ 与 $fit_{j,j}$ 进行比较。竞争的思想是依据全局适应度确定共识解。由于共享变量仅存在于两个智能体中，其全局适应度可表示为 f_i 与 f_j 之和。因此，在第 d 个共享变量上，

Algorithm 5-3 MACPO 中的评价阶段

输入: 局部最优解 $\boldsymbol{x}_{i,best}$，决策变量索引 Θ_i，共享变量索引 $\mathcal{I}_{i,j}$

向每个邻居智能体 $j \in \mathcal{N}_i$ 发送 $\boldsymbol{x}_{i,best}$，并从每个邻居智能体 $j \in \mathcal{N}_i$ 接收 $\boldsymbol{x}_{j,best}$

令 $a = \min(i,j),\ b = \max(i,j)$

令 $\boldsymbol{x}_{i,test} = \boldsymbol{x}_{i,best}^{\Theta_i \setminus \mathcal{I}_{i,j}} \cup \boldsymbol{x}_{a,best}^{\mathcal{I}_{i,j}}$

令 $fit_0 = f_i(\boldsymbol{x}_{i,test}),\ fit_{i,i} = fit_{i,j} = 0^{1\times\|\mathcal{I}_{i,j}\|}$

for 每个 $d \in \mathcal{I}_{i,j}$ **do**

$$\boldsymbol{x}_{i,test}^d = \boldsymbol{x}_{b,best}^d \tag{a1}$$

$$fit_{i,b}^d = f_i(\boldsymbol{x}_{i,test}) \tag{a2}$$

$$\boldsymbol{x}_{i,test}^d = \boldsymbol{x}_{a,best}^d \tag{a3}$$

$$fit_{i,a}^d = fit_0 \tag{a4}$$

end for

输出: $fit_{i,i},\ fit_{i,j}$

$\boldsymbol{x}_{i,best}$ 的全局适应度为 $fit_{i,i}^d + fit_{j,i}^d$，而 $\boldsymbol{x}_{j,best}$ 的全局适应度为 $fit_{i,j}^d + fit_{j,j}^d$。除了共识解的选择（a5）外，竞争结果还记录在 res_j 中（a6，a7），用于后续共享步骤。

Algorithm 5-4 MACPO 中的竞争阶段

输入: 局部最优解 $\boldsymbol{x}_{i,best}$，邻居 j 的最优解 $\boldsymbol{x}_{j,best}$，共享变量索引 $\mathcal{I}_{i,j}$

向每个邻居 $j \in \mathcal{N}_i$ 发送 $fit_{i,i}, fit_{i,j}$，并从每个邻居 $j \in \mathcal{N}_i$ 接收 $fit_{j,j}, fit_{j,i}$

令 $res_j = 0^{1\times\|\mathcal{I}_{i,j}\|}$，且 $\boldsymbol{x}_{i,con} = \boldsymbol{x}_{i,best}$

for 每个 $d \in \mathcal{I}_{i,j}$ **do**

  if $fit_{i,i}^d + fit_{j,i}^d > fit_{i,j}^d + fit_{j,j}^d$ **then**

$$\boldsymbol{x}_{i,con}^d = \boldsymbol{x}_{j,best}^d \tag{a5}$$

$$res_j^d = 0 \tag{a6}$$

  else

$$res_j^d = 1 \tag{a7}$$

  end if

end for

输出: $\boldsymbol{x}_{i,con},\ res_j$

5.2.3.3 共享

在竞争步骤之后，新的共识解将用于引导下一轮种群进化。算法 5-5 中的引导包括两个方面：更新种群与更新目标函数。一般而言，我们期望在竞争中获胜的一方引导共享变量的进化。因此，在本算法中，竞争获胜方在下一轮局部优化阶段不受约束，其惩

罚开关 $t_{j,d}$ 设为 0（a8）。相反，竞争失败方将受到约束，其惩罚开关设为 1（a9）。此外，当当前智能体在该变量上失败时，其种群中所有个体在该变量上的取值将被替换为共识解（a10）。

Algorithm 5-5 MACPO 中的共享阶段

输入: 共识解 $\boldsymbol{x}_{i,con}$，种群 $\mathcal{P}_i$，竞争结果 res

for 每个 $j \in \mathcal{N}_i$ **do**
  for 每个 $d \in \mathcal{I}_{i,j}$ **do**
    if $res_j^d == 1$ **then**
      $t_{j,d} = 0$ (a8)
    else
      $t_{j,d} = 1$ (a9)
      for 种群 $\mathcal{P}_i$ 中的每个个体 $\boldsymbol{x}$ **do**
        $\boldsymbol{x}^d = \boldsymbol{x}_{i,con}^d$ (a10)
      end for
    end if
  end for
end for
更新 h_i

输出: $\mathcal{P}_i$, h_i

*备注 1：（共识性讨论）*上述协商阶段的三个步骤保证了邻居智能体在共享决策变量上能够达成共识，即：

$$\boldsymbol{x}_{i,con}^d = \boldsymbol{x}_{j,con}^d,\ \forall d \in \mathcal{I}_{i,j}\ \forall (i,j) \in E$$

在 DOOV 中，共享决策变量定义在两个智能体之间的边上，由这两个智能体共同拥有。在每次迭代中，每个共享变量存在两个候选解。这两个智能体需要选择较优者以达成共识。在所提出算法中，相邻智能体通过交换评估结果，在竞争步骤中作出相同决策。根据算法 5-4，智能体依据 $fit_{i,i}^d + fit_{j,i}^d$ 与 $fit_{i,j}^d + fit_{j,j}^d$ 的大小关系选择共享变量取值。因此，MACPO 能够在分布式环境下实现共识。

5.2.4 多智能体冲突检测机制

一般而言，惩罚型目标函数中的惩罚项旨在帮助相邻智能体朝相同方向优化，从而减少由于原始局部目标函数冲突导致的共享变量差异。然而，在解空间的不同位置，两

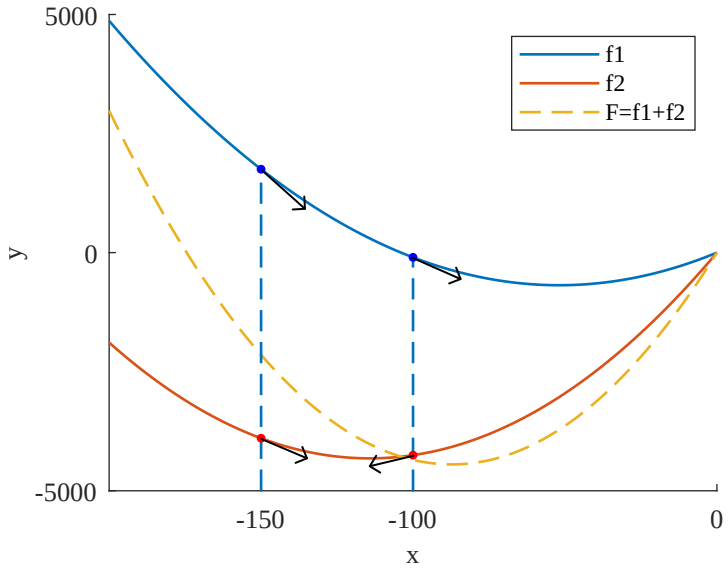


图 5-2 冲突检测示例图

个子问题并非始终冲突或始终一致，其冲突状态是动态变化的。

因此，当某一时刻两个相邻智能体之间几乎不存在冲突时，可以移除惩罚项。

为此，我们在协商阶段设计了额外步骤——冲突检测，通过梯度估计自适应调整惩罚开关。具体而言，当两个智能体在某共享变量上的梯度估计方向一致时，认为它们将自主朝相同方向优化，因此可以移除该变量上的惩罚项。

图 5-2 给出了一个一维分布式问题的示例。根据图示，f_1 与 f_2 是全局问题 F 中两个相互冲突的子问题。当共识解位于 $x=-150$ 时，f_1 与 f_2 的梯度方向相同，因此移除惩罚项；而当共识解位于 $x=-100$ 时，其梯度方向相反，此时保留惩罚项。

针对黑盒函数的梯度估计定义为：

$$\triangle_{\delta,\boldsymbol{x}_d}[f_i](\boldsymbol{x}) = f_i(\boldsymbol{x}_1,...,\boldsymbol{x}_d+\delta,...,\boldsymbol{x}_D) - f_i(\boldsymbol{x}_1,...,\boldsymbol{x}_d,...\boldsymbol{x}_D) \tag{5-4}$$

其中，δ 为变量扰动量，根据变量取值范围设定。对于取值范围为 $[a,b]$ 的变量，δ 设为 $\theta(b-a)$，其中 θ 为权重参数。

根据算法 5-6，每个智能体首先对每个共享变量进行梯度估计（a11，a12），并将估计结果发送给对应邻居。接收邻居估计结果后，与自身估计结果进行比较；若方向一致，则移除惩罚项（a13）。

Algorithm 5-6 MACPO 中的冲突检测

输入： $\boldsymbol{x}_{i,con}$，共享变量索引集合 $\mathcal{I}_{i,j}$

for 每个 $j \in \mathcal{N}_i$ **do**
  for 每个 $d \in \mathcal{I}_{i,j}$ **do**
    $p_{i,j}^d = \triangle_{\delta,\boldsymbol{x}_d}[f_i](\boldsymbol{x}_{i,con})$ (a11)
    $n_{i,j}^d = \triangle_{-\delta,\boldsymbol{x}_d}[f_i](\boldsymbol{x}_{i,con})$ (a12)
  end for
  将 $p_{i,j}$、$n_{i,j}$ 发送给智能体 j
end for
for 每个 $j \in \mathcal{N}_i$ **do**
  从智能体 j 接收 $p_{j,i}$、$n_{j,i}$
  for 每个 $d \in \mathcal{I}_{i,j}$ **do**
    if $p_{j,i}^d * p_{i,j}^d > 0$ 且 $n_{j,i}^d * n_{i,j}^d > 0$ **then**
      $t_{j,d} = 0$ (a13)
    end if
  end for
end for
更新 h_i

输出： h_i

5.3 实验

本节中，我们在第 5.3.3 节将所提出的算法与两种流行的分而治之算法 CCEA 和 FEA 进行比较。在第 5.3.4 节中，我们将基于主从模型实现的整体式优化算法与本章算法进行对比。为保证公平性，每组实验均重复 25 次。

5.3.1 实验设置

一般而言，问题维度越大，种群在维度空间中搜索所需的代数越多。因此，迭代代数设置为 $0.4D$，其中 D 为智能体的维度规模。我们对式 (5-3) 中的参数 λ 以及式 (5-4) 中的参数 θ 进行了参数敏感性实验，详见章节5.3.5。根据实验结果，惩罚权重参数 λ 设置为 $1/512$，θ 设置为 0.05%。

在后续实验中，我们从问题规模、同质性与异质性、基本函数类型以及网络拓扑结构等角度设计了 18 个基准函数 F1-F18。MACPO 及对比算法均为通用算法框架，可嵌入不同的基于种群的进化算法。在实验中，我们选用分层学习粒子群优化算法

（Level-Based Learning Swarm Optimizer, LLSO）[65] 和竞争粒子群优化算法（Competitive Swarm Optimizer, CSO）[64] 作为统一优化器，因为它们在大规模优化问题上表现优良。

所有算法均采用 C++ 语言并基于消息传递接口（Message Passing Interface, MPI）实现。实验运行于由 Intel(R) Xeon(R) CPU E5-2699 v3@2.30GHz 36 核处理器和 CentOS 7.5 x64 系统组成的集群环境。

5.3.2 冲突检测机制的效果验证

为验证冲突检测机制的有效性，我们将 MACPO 与其变体——不含冲突检测的 MACPO（MACPO-NC）进行比较。F1−F6 上的实验结果如表 5-1 所示。

MACPO-NC 与 MACPO 的唯一区别在于前者不包含“冲突检测”步骤。根据实验结果，当嵌入优化器为 LLSO 时，MACPO 在 6 个函数中的 4 个上优于 MACPO-NC，在 2 个函数上表现相当。当嵌入优化器为 CSO 时，结果亦相同。实验结果表明冲突检测机制是有效的。

MACPO 表现更优的原因在于：当共享变量未引起冲突时，其惩罚项将被移除。正如前文所述，两个子问题之间的冲突状态在优化过程中是动态变化的。因此，MACPO 通过冲突检测机制对每个变量进行检测，从而更有效地促进智能体协作。根据实验结果，冲突检测能够在子问题之间不存在冲突时放松惩罚项的约束，使智能体能够更加自由地优化，因此更有可能找到优良解。

图5-3 展示了优化过程中由所提方法检测得到的共享变量冲突概率。具体地，概率 p 定义为 $p = n_c/n_s$，其中 n_c 是被判定为冲突的变量的数量，n_s 是所有共享变量的数量总和。根据图示，所有函数中的冲突概率总体呈上升趋势。这表明局部目标函数在定义域不同位置的冲突程度不同。在优化初期，冲突概率相对较低；随着种群在后期逐渐接近最优区域，冲突概率逐步上升。

在 MACPO 中，由于早期许多共享变量不存在冲突，其惩罚项被移除；而在 MACPO-NC 中，每个共享变量始终带有惩罚项。这是两者之间的唯一区别。

5.3.3 与分而治之算法的比较与分析

本节将 MACPO 与两种流行的分而治之算法——协同进化算法（Cooperative Co-Evolutionary Algorithm,CCEA）和分解进化算法（Factorized Evolutionary Algorithm, FEA）进行比较。这类算法将问题的决策变量划分为多个子组件分别求解，主要面向集中式优化。以 CCEA 和 FEA 为代表的大多数分而治之算法并未考虑原始局部目标之间的冲突，

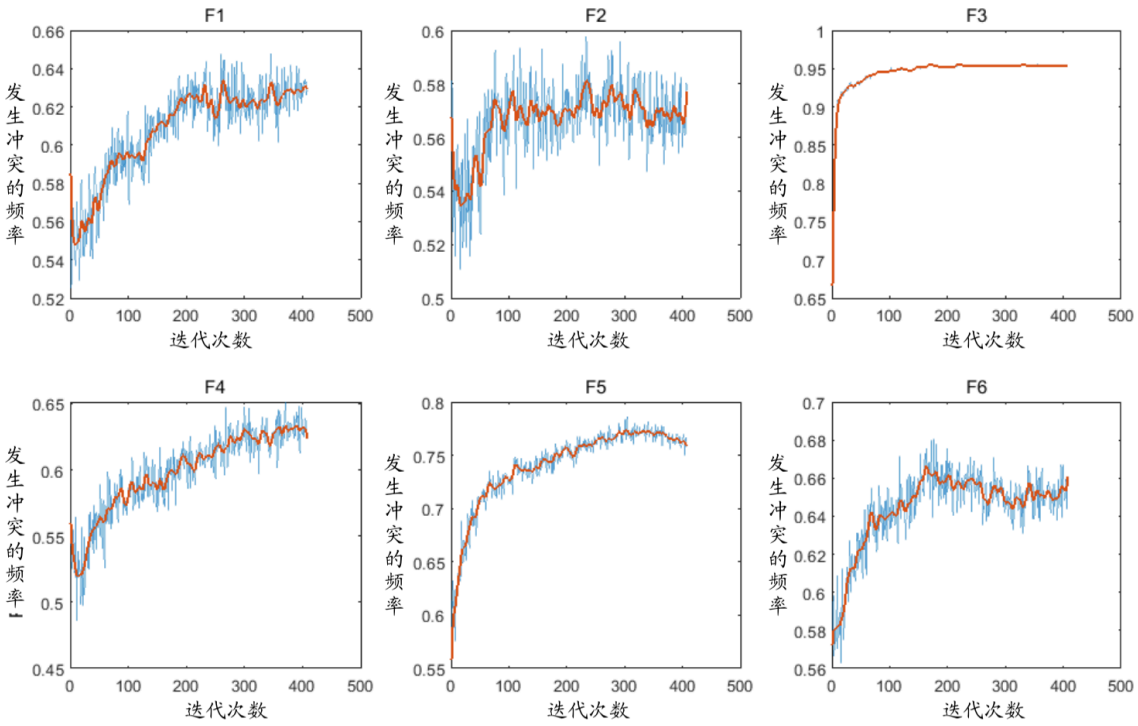


图 5-3 MACPO 在优化过程中检测到的共享变量冲突概率

因此在局部优化阶段缺乏有效引导。为此，我们提出基于惩罚的目标函数以引导局部优化，使智能体具备更强的全局意识。与分而治之算法比较的目的在于验证所提惩罚型目标函数的有效性。

由于 CCEA 和 FEA 无法直接处理 DOOV，我们将其思想嵌入所提算法框架中，分别命名为 MAC-CC 和 MAC-FEA。

在 MAC-CC 中，每次迭代中一个共享变量仅由一个智能体优化，另一个智能体固定该共享变量的取值。共享变量的分配由竞争结果决定，即竞争获胜者在下一次迭代中负责优化该共享变量。智能体仍在每次迭代中进行协商，但失败方提供的候选解为上一轮的共识解。除共享变量分配方式外，MAC-CC 的其他实现与 MACPO 相同。

在 MAC-FEA 中，两个智能体均依据各自原始局部目标优化共享变量，即在 MAC-FEA 中惩罚权重 w 被设为 0。除目标函数不同外，MAC-FEA 的其他实现与 MACPO 相同。

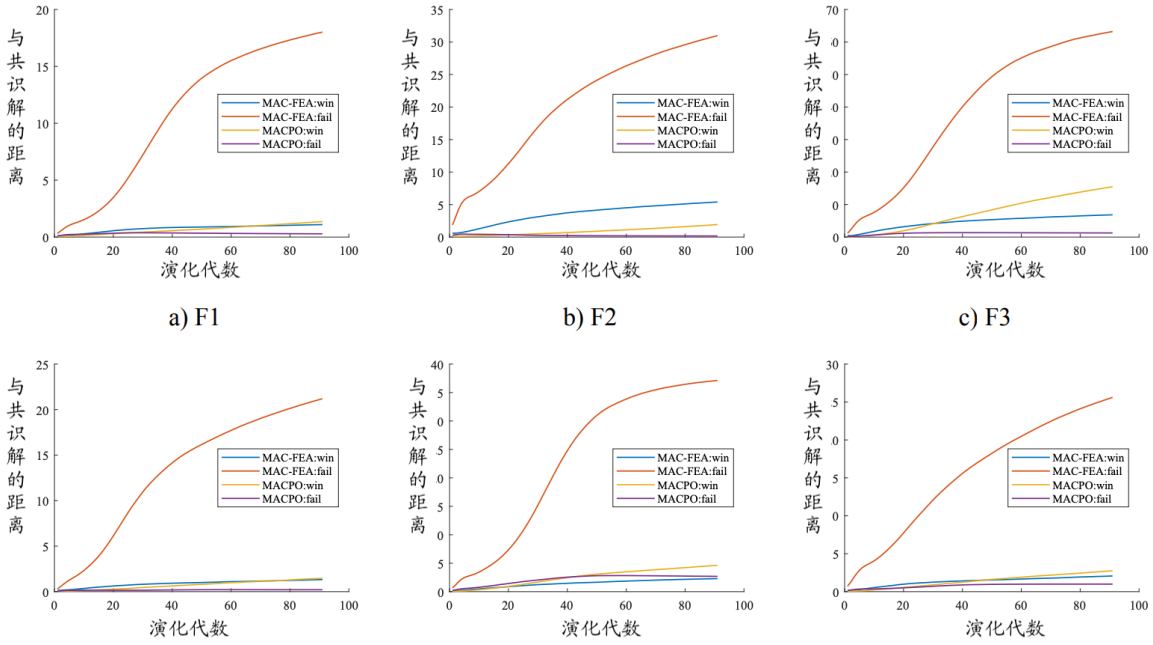
根据表 5-1，在 F1−F6 上 MACPO 的表现优于 MAC-CC 和 MAC-FEA。下文进一步分析三种算法的性能差异，并解释 MACPO 中惩罚型目标函数的优势。

5.3.3.1 与 MAC-FEA 的比较分析

为探究 MAC-FEA 与 MACPO 性能差异的原因，我们计算了优化过程中局部种群与共识解之间的平均距离。距离定义如下：

$$D(X)=\frac{1}{\mathrm{NP}}\sum_{i=1}^{\mathrm{NP}}\sqrt{\sum_{d\in\Theta_i\setminus\mathcal{I}_i}\left(\boldsymbol{x}_i^d-\boldsymbol{x}_{i,con}^d\right)} \tag{5-5}$$

其中，$\boldsymbol{x}_{i,con}$ 为共识解，NP 为智能体的种群规模。



a) F1　b) F2　c) F3

d) F4　e) F5　f) F6

图 5-4 该图展示在局部优化阶段中，局部种群与共识解之间的平均距离。横坐标代表局部优化阶段的进化代数，纵坐标代表种群与共识解之间的平均距离。“MACPO: win”和“MAC-FEA: win”显示了在前一竞争阶段中获胜智能体的种群距离，而“MACPO: fail”和“MAC-FEA: fail”则显示了在前一竞争阶段中失败智能体的种群距离。平均距离的计算公式为 $D(X)=\frac{1}{\mathrm{NP}}\sum_{i=1}^{\mathrm{NP}}\sqrt{\sum_{d\in\Theta_i\setminus\mathcal{I}_i}(\boldsymbol{x}_i^d-\boldsymbol{x}_{i,con}^d)}$.

图5-4 展示了 F1−F6 中局部优化阶段 90 代内距离变化趋势。具体而言，“MACPO: win”与“MAC-FEA: win”表示上一轮竞争获胜智能体的距离，“MACPO: fail”与“MAC-FEA: fail”表示失败智能体的距离。根据图示，当智能体在竞争中获胜时，MACPO 与 MAC-FEA 的距离变化趋势相似；而当智能体失败时，两者差异显著。MAC-FEA 中种群与共识解的距离迅速增大，而 MACPO 中距离保持较低水平。

当智能体在竞争中获胜时，两种算法的优化目标均为原始局部目标，因此距离趋势相似。相较失败方，获胜方在局部优化过程中种群与共识解之间的距离始终维持在较小

范围内，说明其对共识解具有较高接受度。

当智能体在竞争中失败时，两种算法的距离趋势显著不同，体现了 MACPO 中惩罚函数的有效性。MAC-FEA 中距离迅速增大，说明失败智能体对共识解的接受度较低。这是因为当失败智能体种群中的共享变量被共识解替换后，其私有变量与新的共享变量匹配性较差。

在 MAC-FEA 中，当仍以原始目标作为优化目标时，种群会迅速远离共识解，导致成功与失败智能体的候选解差异较大。候选解之间的巨大冲突不利于邻居之间的协商与合作，因此 MAC-FEA 在实验中表现较差。

而在 MACPO 中，基于惩罚的目标函数能够将种群约束在共识解附近的小范围内。在局部优化过程中，私有变量与共享变量逐渐匹配，从而在下一轮协商阶段成功与失败智能体的候选解之间冲突较小，有利于邻居协作。表 5-1 的实验结果也表明该机制有助于提升优化性能。

5.3.3.2 与 MAC-CC 的比较分析

在前述分析中，我们强调了将种群约束在共识解附近的重要性。本部分讨论约束强度对优化性能的影响。MAC-CC 对种群的约束强于 MACPO。在上一轮竞争失败的智能体中，共享变量被固定为共识解，仅私有变量参与进化。

根据实验结果，MAC-CC 在 F1−F6 上优于 MAC-FEA，说明约束机制对种群具有积极作用。然而另一方面，MAC-CC 又劣于 MACPO，表明约束强度同样会影响算法性能。当共享变量仅由一个智能体优化时，进化结果具有偏向性，倾向于该智能体，不利于多智能体之间的协同协同进化。

综上所述，在优化 DOOV 时，MACPO 中提出的惩罚型目标函数能够将种群约束在共识解附近。实验结果表明，适度约束有利于多个子种群协同进化以优化全局目标；缺乏约束会导致种群间冲突，而过强约束则会导致结果偏向单方。

5.3.4 与整体式算法的比较分析

整体式算法在大规模黑盒优化中同样广受关注。这类算法将问题整体优化，通常具有较强的优化性能。然而在 DOOV 这类分布式优化问题中，其计算代价较高且可扩展性受限。本节通过与整体式算法对比，说明 MACPO 在计算成本显著较低的情况下仍具备竞争性的解质量。

在以下实验中，我们将 MACPO 与基于主从模型实现的 LLSO（记为 MS-LLSO）进

行比较。同时，MACPO 也嵌入 LLSO 作为底层优化器，以保证比较公平。之所以将 LLSO 嵌入主从模型，是因为整体式算法无法直接处理 DOOV。在该模型中，整体算法运行于主节点。进行全局适应度评估时，主节点将解发送至各从节点，并等待其返回局部适应度，然后求和得到全局适应度。对于含 n 个智能体的 DOOV，MS-LLSO 使用 $(n+1)$ 个计算节点。

DOOV 的冲突程度会影响 MACPO 的性能，因为其采用分布式方式求解。因此，我们设计冲突指标以量化问题中的冲突程度，从而辅助分析算法性能。对于智能体 i 与其邻居 j，若共享变量为 $\{d1, d2, ..., dm\} \in \mathcal{I}_{i,j}$，则冲突指标 CI 定义为：

$$CI = -< \frac{\widetilde{\nabla f_i}}{\| \widetilde{\nabla f_i} \|}, \frac{\widetilde{\nabla f_j}}{\| \widetilde{\nabla f_j} \|} > \tag{5-6}$$

该指标为归一化梯度估计向量的负内积，可反映两个梯度方向之间的夹角。冲突指标取值范围为 $[-1, 1]$，CI 越大表示冲突越强。当 $CI = 1$ 时两个梯度方向完全相反；当 $CI = -1$ 时方向完全一致。

表 5-1 与变种算法及现有算法的比较结果

embedded EC		LLSO						CSO					
Functions		MACPO	MACPO-NC	MAC-CC	MAC-FEA	DPSO	GFPDO	MACPO	MACPO-NC	MAC-CC	MAC-FEA	DPSO	GFPDO
F1	mean	**1.75E+08**	2.14E+08	4.41E+08	1.16E+09	2.25E+10	8.46E+08	**3.42E+08**	3.87E+08	1.11E+09	1.83E+09	3.65E+10	2.06E+10
	median	1.77E+08	2.05E+08	4.01E+08	1.02E+09	2.23E+10	8.29E+08	3.27E+08	3.76E+08	1.05E+09	1.70E+09	3.72E+10	2.06E+10
	std	1.62E+07	3.62E+07	1.74E+08	3.10E+08	2.66E+09	8.46E+07	6.52E+07	9.29E+07	2.53E+08	6.81E+08	4.15E+09	3.15E+09
	p-value	-	5.66e-03#	1.24e-05#	2.73e-06#	9.13e-05#	5.46e-06#	-	2.60E-01	9.13e-05#	9.13e-05#	9.13e-05#	5.46e-06#
F2	mean	**7.65E+05**	9.00E+05	1.25E+07	8.07E+07	5.61E+10	9.43E+06	**1.41E+06**	1.46E+06	1.91E+07	1.43E+08	2.69E+10	2.37E+09
	median	7.64E+05	9.01E+05	1.65E+06	3.88E+07	1.34E+10	9.26E+06	1.46E+06	1.47E+06	2.17E+06	6.63E+07	5.56E+09	7.07E+08
	std	6.64E+04	4.72E+04	1.68E+07	1.15E+08	9.39E+10	4.13E+06	1.11E+05	1.41E+05	4.99E+07	2.13E+08	6.51E+10	4.34E+09
	p-value	-	3.84e-04#	2.73e-06#	2.73e-06#	9.13e-05#	5.46e-06#	-	2.10E-01	6.57e-04#	9.13e-05#	9.13e-05#	5.46e-06#
F3	mean	**2.13E+10**	2.31E+10	7.11E+10	1.18E+11	3.86E+10	5.86E+10	**2.08E+10**	2.22E+10	6.60E+10	1.55E+11	3.99E+10	1.04E+11
	median	2.13E+10	2.26E+10	7.21E+10	1.14E+11	3.87E+10	5.83E+10	2.07E+10	2.22E+10	6.54E+10	1.53E+11	3.97E+10	1.03E+11
	std	8.53E+08	1.52E+09	4.29E+09	1.36E+10	5.62E+08	4.22E+09	6.64E+08	1.07E+09	8.87E+09	2.88E+10	1.12E+09	3.92E+09
	p-value	-	2.29e-03#	2.73e-06#	2.73e-06#	9.13e-05#	5.46e-06#	-	8.53e-04#	9.13e-05#	9.13e-05#	9.13e-05#	5.46e-06#
F4	mean	**2.70E+07**	4.01E+07	8.91E+07	8.43E+09	1.68E+10	4.53E+08	**1.02E+08**	1.24E+08	4.98E+08	1.45E+09	1.89E+10	8.62E+09
	median	2.54E+07	3.62E+07	8.78E+07	2.93E+09	1.67E+10	4.67E+08	8.95E+07	1.35E+08	4.46E+08	1.49E+09	1.82E+10	7.43E+09
	std	5.78E+06	1.34E+07	2.58E+07	1.94E+10	2.33E+09	6.74E+07	2.42E+07	2.37E+07	2.80E+08	4.29E+08	4.13E+09	3.16E+09
	p-value	-	7.01e-03#	2.73e-06#	2.73e-06#	9.13e-05#	5.46e-06#	-	3.20e-02#	9.13e-05#	9.13e-05#	9.13e-05#	5.46e-06#
F5	mean	6.58E+08	**5.42E+08**	2.17E+09	1.02E+10	2.65E+10	2.11E+10	**3.31E+08**	3.97E+08	5.45E+09	2.53E+10	4.30E+10	5.60E+10
	median	5.34E+08	4.86E+08	1.99E+09	9.83E+09	2.68E+10	2.05E+10	3.27E+08	3.85E+08	5.81E+09	2.41E+10	4.31E+10	5.57E+10
	std	3.20E+08	2.15E+08	7.41E+08	1.90E+09	1.87E+09	2.24E+09	3.51E+07	6.25E+07	1.30E+09	6.79E+09	4.11E+09	3.77E+09
	p-value	-	2.40E-01	3.86e-06#	2.73e-06#	9.13e-05#	5.46e-06#	-	4.55e-03#	9.13e-05#	9.13e-05#	9.13e-05#	5.46e-06#
F6	mean	2.39E+08	**2.12E+08**	5.91E+09	7.82E+09	2.72E+10	4.00E+10	**1.61E+08**	2.69E+08	4.82E+10	1.23E+11	4.00E+10	5.23E+10
	median	2.17E+08	2.04E+08	4.17E+09	5.42E+09	2.71E+10	3.93E+10	1.52E+08	2.41E+08	4.31E+10	1.20E+11	3.27E+10	5.22E+10
	std	7.20E+07	4.75E+07	4.21E+09	7.01E+09	2.87E+09	4.31E+09	3.04E+07	1.06E+08	2.35E+10	3.93E+10	2.24E+10	4.16E+09
	p-value	-	1.90E-01	2.73e-06#	2.73e-06#	9.13e-05#	5.46e-06#	-	5.66e-03#	9.13e-05#	9.13e-05#	9.13e-05#	5.46e-06#
w/t/l		-	4/2/0	6/0/0	6/0/0	6/0/0	6/0/0	-	4/2/0	6/0/0	6/0/0	6/0/0	6/0/0

[#] 该符号代表在 Wilcoxon rank sum test（0.05）下对比算法显著劣于提出的 MACPO

[*] 该符号代表在 Wilcoxon rank sum test（0.05）下对比算法显著劣于提出的 MACPO

接下来, MACPO 和 MS-LLSO 将从两个方面进行比较：解的质量和计算代价。

表 5-2 MACPO 与整体式算法的在不同评估预算下的效果

E_{max}		$3000 \times D$		$30000 \times D$	
Func.	CI	MACPO	MS-LLSO	MACPO	MS-LLSO
F1	0.228	**3.66E+08**	5.22E+09	**1.75E+08**	4.55E+08
F2	0.049	**1.47E+06**	5.59E+07	**7.65E+05**	1.81E+07
F3	0.846	2.29E+10	**2.25E+10**	2.13E+10	**1.84E+10**
F4	0.051	**9.77E+07**	1.77E+09	**2.70E+07**	2.21E+08
F5	0.497	**8.19E+08**	3.54E+09	6.58E+08	**3.73E+08**
F6	0.268	2.61E+08	**2.51E+08(=)**	2.39E+08	**1.05E+08**
F7	0.173	**2.23E+09**	3.68E+10	**1.06E+09**	3.89E+09
F8	-0.110	**1.24E+07**	5.66E+08	**6.74E+06**	4.52E+07
F9	0.634	**3.25E+11**	4.15E+11	2.74E+11	**1.70E+11**
F10	0.090	**3.23E+01**	1.99E+10	**3.64E+08**	2.12E+09
F11	0.381	**5.47E+10**	9.95E+10	4.26E+10	**3.27E+10**
F12	0.169	**6.23E+10**	1.23E+11	4.97E+10	**3.06E+10**
F13	0.280	**6.75E+09**	1.59E+11	**2.54E+09**	2.17E+10
F14	-0.180	**6.19E+07**	7.92E+10	**2.29E+07**	1.99E+08
F15	0.590	**1.24E+12**	3.48E+12	8.47E+11	**5.85E+11**
F16	0.105	**2.92E+09**	1.45E+11	**5.84E+08**	1.30E+10
F17	0.471	**2.15E+11**	6.71E+11	1.21E+11	**1.10E+11**
F18	0.192	**2.15E+11**	2.50E+12	8.15E+10	**6.57E+10**
w/t/l		16/1/1		9/0/9	

5.3.4.1 求解质量比较

F1-F18 上的实验结果如表 5-2 所示，其中记录了两种算法在 $3000 \times D$ 次评估和 $30000 \times D$ 次评估下的适应度值。实验结果可总结如下。

a) MACPO 在早期阶段比 MS-LLSO 具有更强的探索能力。当适应度评估次数为 $3000 \times D$ 时，除 F3 和 F6 外，MACPO 在 18 个函数中的 16 个函数上优于 MS-LLSO。这表明 MACPO 在探索方面具有较高效率。

b) 在某些函数上，MACPO 的开发能力弱于 MS-LLSO。当适应度评估次数为 $30000 \times D$ 时，MACPO 在 F3、F5、F6、F9、F11、F12、F15、F17 和 F18 上的表现劣于 MS-LLSO。这些函数的一个共同特征是其基本函数中包含 Rosenbrock 函数。其中，F3、F9 和 F15 是 Rosenbrock 的同构函数，其余则是由 Rosenbrock 与其他基本函数构成的异构函数。

由于共享变量的存在，分布式优化问题（包括 DOOV）中智能体之间的冲突是普遍存在的。这种冲突特性对分布式优化算法提出了巨大挑战。整体式算法（如 LLSO）以

及分治算法（如 DCC 和 FEA）不存在这一困难，因为它们在优化过程中始终进行全局适应度评估。这也是为什么 MS-LLSO 在上述函数上优于 MACPO 的原因。

我们在 MACPO 的优化过程中计算了 F1-F6 上的冲突指数。在每一次协商阶段，计算每一对相邻智能体之间的冲突指数，并将其平均值记录在表 5-2 中。实验结果可总结如下。

a) 存在两类函数具有较高的冲突指数。第一类是 Rosenbrock 的同构函数，包括 F3、F9 和 F15。第二类是由 Rosenbrock 和 Elliptic 构成的异构函数，包括 F5、F11 和 F17。在优化这些函数时，MACPO 会在最优解附近徘徊而难以进一步逼近。因此，其解的质量劣于整体式算法 MS-LLSO。这是分布式优化问题的一个共性挑战，尤其是在非凸和黑盒问题中。

b) 存在两类函数具有较低的冲突指数。第一类是 Schwefel 的同构函数，包括 F2、F8 和 F14。第二类是由 Schwefel 和 Elliptic 构成的异构函数，包括 F4、F10 和 F16。尽管这些问题中的智能体之间也存在冲突，但程度较轻，使得所提出算法的协作策略能够有效优化问题。在这些函数上，MACPO 的表现优于 MS-LLSO。

综上所述，问题的冲突指数越高，对分布式优化算法 MACPO 的挑战越大。整体式算法 MS-LLSO 不受冲突程度影响，因为它将 DOOV 视为一个集中式问题进行处理。

5.3.4.2 计算开销比较

在本部分中，我们将证明 MACPO 中的多智能体协同进化模型相比 MS-LLSO 具有更低的计算代价和更好的可扩展性。计算代价由两部分组成：问题的评估代价 T_e 和分布式模型的通信代价 T_c。

我们在相同评估次数下比较 MACPO 和 MS-LLSO 的计算代价。假设每个智能体的最大适应度评估次数相同，记为 E_{max}。此外，我们假设每次通信的时间代价相同，每次子问题适应度评估的时间代价也相同，分别记为 t_c 和 t_e。

对于 MACPO，第 i 个智能体的计算代价为：

$$\begin{aligned} T^i_{\text{MACPO}} = T^i_c + T^i_e &= 3I\|\mathcal{N}_i\|t_c + It_e(k\|\mathcal{P}_i\| + \sum_{j\in\mathcal{N}_i}(\|\mathcal{I}_{i,j}\|+1)) \\ &= \frac{3\|\mathcal{N}_i\|E_{max}}{k\|\mathcal{P}_i\| + \sum_{j\in\mathcal{N}_i}(\|\mathcal{I}_{i,j}\|+1)}t_c + E_{max}t_e \\ \text{where } I &= \frac{E_{max}}{k\|\mathcal{P}_i\| + \sum_{j\in\mathcal{N}_i}(\|\mathcal{I}_{i,j}\|+1)} \end{aligned} \tag{5-7}$$

其中 n 为问题中的智能体数量，I 为迭代次数，k 为每次迭代中的代数。在每次迭代中，

每个智能体与每个邻居通信三次，因此通信代价为 $3\|\mathcal{N}_i\|t_c$。每次迭代中的适应度评估用于种群进化和与邻居协商，分别为 $k\|\mathcal{P}_i\|$ 和 $\sum_{j\in\mathcal{N}_i}(\|\mathcal{I}_{i,j}\|+1)$。

对于 MS-LLSO，每一次局部适应度评估都需要两次通信：主节点向从节点发送解，并从从节点接收适应度。因此，主智能体的计算代价为：

$$T_{master} = E_{max}(2nt_c + t_e) \tag{5-8}$$

在每一次评估中，评估代价记为 t_e，因为从节点可以并行执行局部评估。

MACPO 的计算代价由计算代价最大的智能体决定；MS-LLSO 的计算代价由主节点决定。因此，两种算法的计算代价比为：

$$\frac{T_{\text{MS-LLSO}}}{T_{\text{MACPO}}} = \frac{T_{master}}{max(T^i_{\text{MACPO}})} = \frac{2nt_c + t_e}{qt_c + t_e} = \frac{2n(t_c/t_e)+1}{q(t_c/t_e)+1} \tag{5-9}$$

其中

$$q = \max_{i\in\{1,\dots,n\}} \frac{3\|\mathcal{N}_i\|}{k\|\mathcal{P}_i\| + \sum_{j\in\mathcal{N}_i}(\|\mathcal{I}_{i,j}\|+1)} \tag{5-10}$$

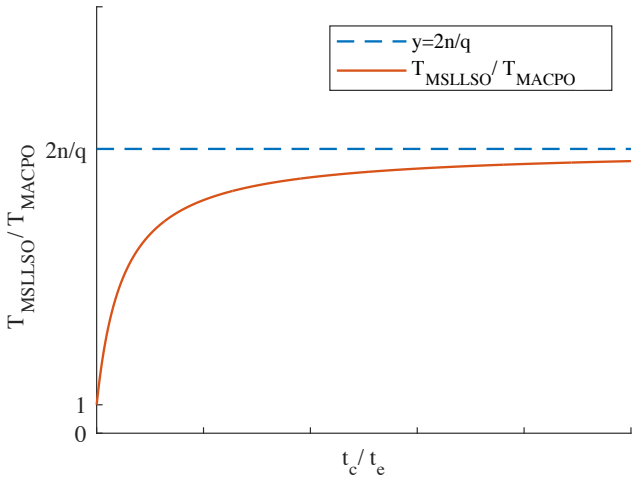


图 5-5 MACPO 与 MS-LLSO 的计算时间比率。其中 t_c 表示每次通信的时间开销，t_e 表示每次局部适应度评价的时间开销。随着比值 t_c/t_e 的增加，MACPO 与 MS-LLSO 的时间比率也将随之增加，并趋近于 $2n/q$。

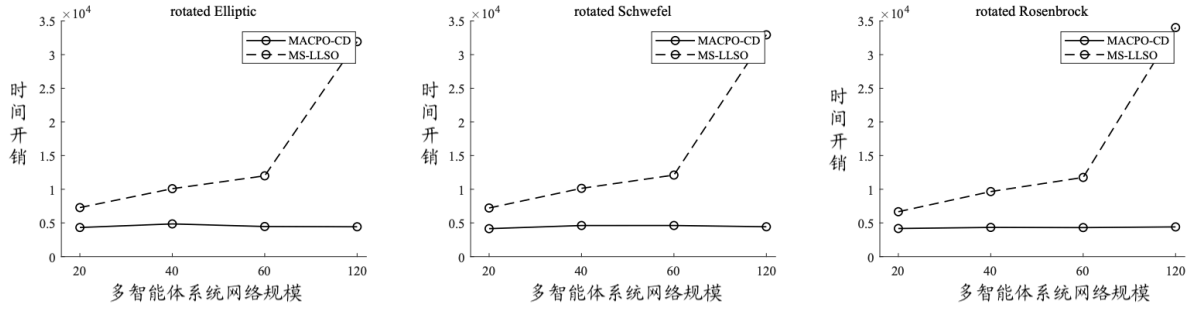
可以看出，算法的时间比与 q、n 以及 (t_c/t_e) 有关。因此，可以得到如下结论。

a) 参数 q 由基准函数以及 MACPO 的参数设置决定。在大多数情况下，q 小于 1。例如，在 F1-F6 中，每个智能体有一个或两个邻居，每对邻居之间的共享变量规模 $\|\mathcal{I}_{i,j}\|$ 为 5。MACPO 中的种群规模 $\|\mathcal{P}_i\|$ 为 300，每次迭代的代数 k 为 $0.4\times D$。

因此，在 F1-F6 中 $q = 1/502$。类似地，在 F7-F12 中 $q = 1/1337$，在 F13-F18 中 $q = 1/2005$。

b) t_c/t_e 的取值在不同应用场景中有所不同，取决于通信网络质量、智能体拓扑结构以及问题的评估方式。根据图5-5，当通信代价为 0，即 $t_c/t_e = 0$ 时，两种算法的代价相同。随着 t_c/t_e 的增加，两种算法的代价比将逐渐增大，并趋近于 $2n/q$。最大比值 $2n/q$ 在 F1-F6 中为 20080，在 F7-F12 中为 106960，在 F13-F18 中为 240600。

c) 根据式 (5-7)，MACPO 的计算代价受共享变量数量、种群规模以及每次迭代代数的影响。



a) rotated Elliptic　　b) rotated Schwefel　　c) rotated Rosenbrock

图 5-6 随着网络规模增加，MACPO 与 MS-LLSO 的时间开销。在本实验中，每个智能体的适应度评价次数为 $1000 \times D$，其中智能体的维度 D 为 1000。四种规模网络的总维度分别为 18500、37000、55500 和 111000。

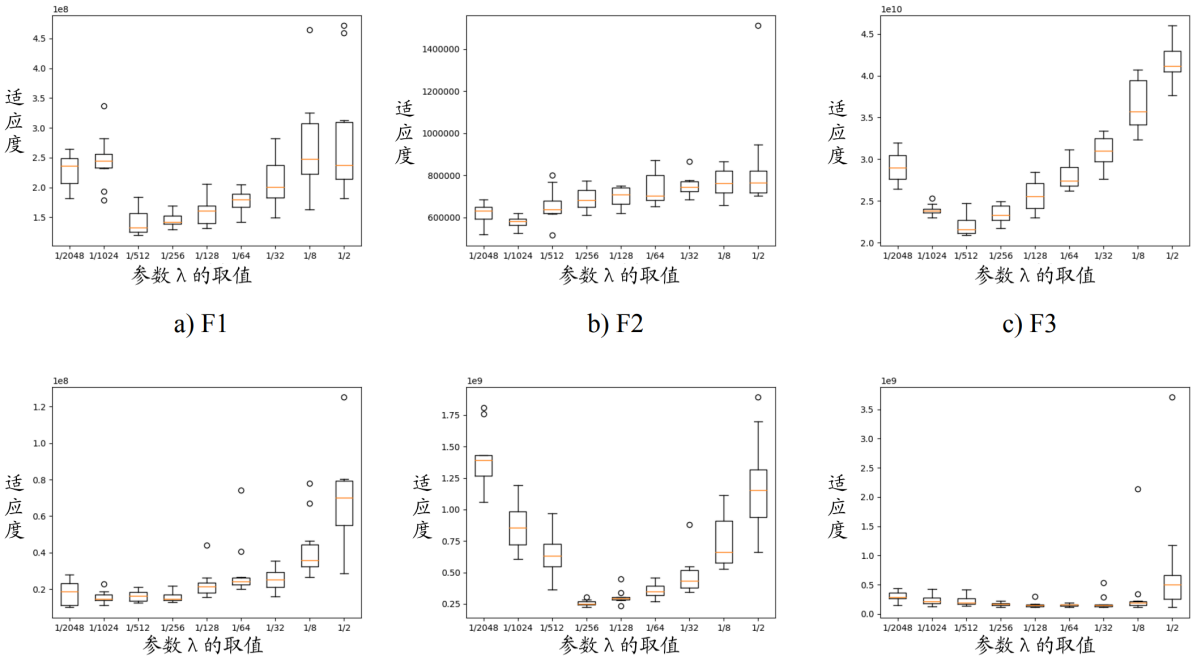
除了理论分析外，我们还通过实验测试了 MACPO 和 MS-LLSO 的时间代价，结果如图5-6所示。根据实验结果，随着网络规模的增加，MACPO 的时间代价变化不大，而 MS-LLSO 的时间代价迅速增加。

综上所述，在优化相同问题时，MACPO 的计算代价低于 MS-LLSO。在通信代价与适应度评估代价之比越低的场景下，两者之间的差距越明显。计算代价比最终趋于一个由问题特性决定的值。

5.3.5 参数调研

5.3.5.1 式 (7) 中的 λ

惩罚权重的设置对于平衡惩罚项与原始目标值之间的相对大小至关重要。当惩罚权重设置得较大时，适应度主要由被评估解与共识解之间的距离决定。在这种情况下，整个种群将紧密围绕共识解进化，算法的探索能力较差。当惩罚权重设置得较小时，适应



a) F1　b) F2　c) F3

d) F4　e) F5　f) F6

图 5-7 当参数 λ 设置为不同值时，MACPO 在 F1-F6 上的性能。在图中，横坐标代表 λ 的值，纵坐标代表 MACPO 经过 25 次重复实验后的平均适应度。参数 λ 决定了第 III-B 节中的惩罚权重 $w = \lambda \sum_{i=1}^{n} f_i(\boldsymbol{x}_{i,con})$。根据结果，$\lambda$ 的值过大或过小都不利于 MACPO 的性能。因此，我们最终选择 1/512 作为 MACPO 的 λ 值。

度主要由被评估解的局部适应度决定。在这种情况下，种群将向原始局部目标进化，而忽略与邻居的合作。这不符合我们的预期。综上所述，在 MACPO 中更倾向于选择中等强度的权重。

下图和表格显示了参数 λ 设置为不同值时 MACPO 在 F1-F6 上的性能。在图中，横坐标代表 λ 的值，纵坐标代表 MACPO 经过 25 次重复实验后的平均适应度。参数 λ 决定了惩罚权重 $w = \lambda \sum_{i=1}^{n} f_i(\boldsymbol{x}_{i,con})$。根据结果，$\lambda$ 的值过大或过小都不利于 MACPO 的性能。对于 F1 和 F3，$\lambda = 1/512$ 的 MACPO 表现最好；对于 F2 和 F4，$\lambda = 1/1024$ 的 MACPO 表现最好。考虑到剩下的两个函数 F5 和 F6，$\lambda = 1/512$ 的 MACPO 表现优于 $\lambda = 1/1024$。因此，我们最终选择 1/512 作为 MACPO 的 λ 取值。

5.3.5.2 正文式 (8) 中的 θ

我们进行了一项实验来调研 θ 的取值。我们将 θ 的值设置为从 0% 到 75%。实验结果如表 5-4 所示。Wilcoxon 秩和检验是基于第一列 $\theta = 0.05\%$ 计算的。根据结果，我们可以得出以下结论：(1) 首先，θ 不能太小或太大。当 $\theta = 0$ 时，其在三个函数上的表现

表 5-3 算法在参数 λ 的不同取值下的表现

Func.	λ	1/2	1/8	1/32	1/64	1/128	1/256	1/512	1/1024	1/2048
F1	mean	2.83E+08	2.66E+08	2.10E+08	1.77E+08	1.59E+08	1.47E+08	**1.44E+08**	2.46E+08	2.27E+08
	median	2.37E+08	2.48E+08	2.01E+08	1.80E+08	1.61E+08	1.42E+08	1.32E+08	2.45E+08	2.36E+08
	std	9.91E+07	8.42E+07	3.76E+07	1.82E+07	2.25E+07	1.21E+07	2.29E+07	4.17E+07	2.67E+07
	p-value	-	4.90E-01	3.78e-02*	2.91e-04*	1.65e-04*	9.13e-05*	1.23e-04*	4.60E-01	2.60E-01
F2	mean	8.47E+05	7.64E+05	7.52E+05	7.34E+05	6.97E+05	6.88E+05	6.57E+05	**5.77E+05**	6.18E+05
	median	7.66E+05	7.62E+05	7.44E+05	7.02E+05	7.08E+05	6.81E+05	6.36E+05	5.80E+05	6.32E+05
	std	2.32E+05	7.11E+04	4.64E+04	7.74E+04	4.59E+04	5.04E+04	7.71E+04	2.53E+04	4.92E+04
	p-value	-	3.70E-01	2.90E-01	3.78e-02*	1.29e-02*	2.90e-03*	1.81e-03*	9.13e-05*	9.13e-05*
F3	mean	4.16E+10	3.65E+10	3.08E+10	2.81E+10	2.56E+10	2.35E+10	**2.20E+10**	2.39E+10	2.91E+10
	median	4.12E+10	3.57E+10	3.10E+10	2.74E+10	2.56E+10	2.33E+10	2.16E+10	2.38E+10	2.90E+10
	std	2.49E+09	3.02E+09	1.95E+09	1.73E+09	1.71E+09	1.05E+09	1.14E+09	6.18E+08	1.74E+09
	p-value	-	1.10e-03*	9.13e-05*	9.13e-05*	9.13e-05*	9.13e-05*	9.13e-05*	9.13e-05*	9.13e-05*
F4	mean	6.91E+07	4.25E+07	2.52E+07	3.01E+07	2.29E+07	1.60E+07	1.63E+07	**1.55E+07**	1.78E+07
	median	7.01E+07	3.57E+07	2.52E+07	2.41E+07	2.16E+07	1.47E+07	1.63E+07	1.47E+07	1.87E+07
	std	2.45E+07	1.59E+07	5.84E+06	1.57E+07	7.78E+06	2.91E+06	2.78E+06	3.33E+06	6.28E+06
	p-value	-	8.63e-03*	2.91e-04*	5.04e-04*	1.23e-04*	9.13e-05*	9.13e-05*	9.13e-05*	9.13e-05*
F5	mean	1.19E+09	7.43E+08	4.78E+08	3.56E+08	3.07E+08	**2.58E+08**	6.53E+08	8.64E+08	1.39E+09
	median	1.15E+09	6.61E+08	4.32E+08	3.47E+08	2.94E+08	2.52E+08	6.35E+08	8.55E+08	1.39E+09
	std	3.58E+08	2.08E+08	1.50E+08	5.42E+07	5.35E+07	2.31E+07	1.65E+08	1.82E+08	2.31E+08
	p-value	-	3.64e-03*	1.65e-04*	9.13e-05*	9.13e-05*	9.13e-05*	6.57e-04*	2.26e-02*	5.00E-02
F6	mean	8.06E+08	3.88E+08	1.95E+08	**1.52E+08**	1.57E+08	1.68E+08	2.34E+08	2.43E+08	3.05E+08
	median	4.98E+08	1.94E+08	1.49E+08	1.57E+08	1.47E+08	1.68E+08	1.97E+08	2.15E+08	2.93E+08
	std	1.01E+09	5.86E+08	1.23E+08	2.35E+07	4.87E+07	2.80E+07	8.94E+07	9.19E+07	7.79E+07
	p-value	-	2.70e-02*	7.01e-03*	2.90e-03*	2.90e-03*	4.55e-03*	2.70e-02*	3.20e-02*	1.10E-01

明显差于 $\theta = 0.05\%$。当 θ 设置为 $25\%, 50\%,$ 或 75% 时，它们在三个函数上的表现均明显差于 $\theta = 0.05\%$。(2) 其次，θ 在区间 $[0.005\%, 2.5\%]$ 内不敏感。在此区间内，大多数性能结果没有显著差异。(3) 第三，0.05% 是 θ 的合适选择，原因如下：$\theta = 0.05\%$ 在两个函数上达到了最佳性能，多于其他设置。对于剩下的四个函数，$\theta = 0.05\%$ 与表现最佳的设置之间没有显著差异。因此，我们选择 $\theta = 0.05\%$ 作为最终的参数设置。

5.4 本章小结

本章提出了一种多智能体协同进化算法，用于求解基于网络的分布式优化问题。根据实验结果与分析，对于冲突指数 CI 较高的基准问题，所提出算法的性能不如整体式算法。因此，在高冲突问题或场景下，该算法仍有较大的研究与改进空间。此外，近年来已提出多种先进优化算法，并在复杂优化问题（如在线学习、调度、多目标优化、交

表 5-4 扰动变量的参数调研

	θ	0.05%	0%	0.005%	0.1%	0.25%	0.5%	2.5%	10%	25%	50%	75%
F1	mean	3.73E+08	3.86E+08	3.67E+08	3.64E+08	3.71E+08	3.75E+08	**3.52E+08**	3.94E+08	4.45E+08	4.79E+08	4.45E+08
	median	3.66E+08	3.79E+08	3.61E+08	3.58E+08	3.7E+08	3.71E+08	3.41E+08	3.99E+08	4.42E+08	4.66E+08	4.51E+08
	std	5.25E+07	4.34E+07	3.97E+07	4.29E+07	2.4E+07	4.95E+07	2.82E+07	5.2E+07	4.13E+07	6.6E+07	4.38E+07
	p-value	-	6.03E-02	3.14E-01	2.61E-01	3.36E-01	4.46E-01	8.4E-02	3.26e-02#	2.78e-07#	4.58e-07#	2.78e-07#
F2	mean	**1.48E+06**	1.6E+06	1.51E+06	3.72E+06	8.13E+06	1.54E+06	1.54E+06	1.5E+06	1.52E+06	1.52E+06	1.49E+06
	median	1.46E+06	1.59E+06	1.5E+06	1.5E+06	1.56E+06	1.52E+06	1.51E+06	1.51E+06	1.53E+06	1.5E+06	1.46E+06
	std	1.34E+05	1.53E+05	1.26E+05	1.1E+07	2.38E+07	1.41E+05	1.26E+05	8.07E+04	1.25E+05	1.24E+05	1.32E+05
	p-value	-	3.50e-03#	1.86E-01	3.56E-01	5.21E-02	3.87e-02#	8.91E-02	1.95E-01	5.16E-02	1.18E-01	3.07E-01
F3	mean	**2.33E+10**	2.57E+10	2.34E+10	2.36E+10	2.35E+10	2.35E+10	2.4E+10	2.44E+10	2.54E+10	2.72E+10	2.71E+10
	median	2.32E+10	2.56E+10	2.29E+10	2.34E+10	2.33E+10	2.33E+10	2.36E+10	2.43E+10	2.53E+10	2.67E+10	2.72E+10
	std	9.47E+08	1.56E+09	1.68E+09	1.53E+09	1.4E+09	1.5E+09	1.58E+09	1.43E+09	1.64E+09	1.97E+09	1.84E+09
	p-value	-	2.05e-07#	2.8E-01	4.15E-01	4.75E-01	3.93E-01	1.32E-01	3.00e-02#	2.13e-06#	1.83e-09#	1.28e-08#
F4	mean	9.78E+07	1.09E+08	9.9E+07	1.05E+08	1.78E+08	9.86E+07	1.06E+08	1E+08	**9.39E+07**	9.74E+07	9.59E+07
	median	9.7E+07	1.1E+08	9.57E+07	1.04E+08	1E+08	9.58E+07	1.04E+08	1.02E+08	9.37E+07	9.69E+07	9.62E+07
	std	1.24E+07	1.45E+07	1.37E+07	2.13E+07	2.55E+08	1.4E+07	1.48E+07	1.2E+07	9.17E+06	1.29E+07	1.11E+07
	p-value	-	3.71e-03#	3.78E-01	8.72E-02	1.32E-01	4.77E-01	5.07E-02	1.67E-01	1.11E-01	3.86E-01	3.63E-01
F5	mean	6.94E+08	6.1E+08	7.86E+08	6.84E+08	7.81E+08	6.51E+08	7.29E+08	**6.39E+08**	8.3E+08	1.02E+09	1.09E+09
	median	6.61E+08	5.7E+08	7.09E+08	5.92E+08	7.04E+08	6.11E+08	6.22E+08	6.45E+08	8.53E+08	1.02E+09	1.08E+09
	std	2.12E+08	1.54E+08	3.45E+08	2.96E+08	2.4E+08	1.73E+08	3.02E+08	1.56E+08	1.59E+08	1.18E+08	1.59E+08
	p-value	-	8.12E-02	2.49E-01	2.19E-01	1.6E-01	3.21E-01	3.92E-01	3.24E-01	6.16e-03#	1.77e-06#	2.05e-07#
F6	mean	3.67E+08	3.05E+08	**2.44E+08**	2.58E+08	2.79E+08	2.61E+08	2.84E+08	2.69E+08	2.79E+08	3.31E+08	3.07E+08
	median	2.36E+08	2.87E+08	2.23E+08	2.46E+08	2.22E+08	2.21E+08	2.53E+08	2.47E+08	2.43E+08	2.58E+08	2.63E+08
	std	3.69E+08	1.26E+08	9.1E+07	5.99E+07	1.46E+08	1.04E+08	8.45E+07	8.8E+07	1.48E+08	3.03E+08	1.7E+08
	p-value	-	2.08E-01	1.11E-01	4.69E-01	3.24E-01	2.67E-01	2.98E-01	4.49E-01	2.8E-01	5E-01	3.93E-01

通、医学以及数据分类等）中展现出卓越性能[109-111]。因此，有必要进一步研究更先进优化算法在基于网络的分布式优化中的效果，例如新型混合启发式算法、元启发式算法、自适应算法、自适应进化算法、岛模型算法、多倍体算法等[112-113]。

第六章　基于多智能体共识优化的多目标协同定位追踪方法

6.1　引言

无线传感器网络（Wireless Sensor Network, WSN）通过通信网络连接多个传感器，每个传感器具备感知、通信与计算能力[99,114-115]。WSNs 的定位技术已被应用于多种场景，例如水下定位[116-117]、工业装置故障检测[118]、交通监控[119] 等。当检测区域内同时存在多个目标时，如何对来自多个传感器的多目标测量数据进行关联成为一个热门研究问题。近年来，针对多目标定位与数据关联问题，已有大量研究工作开展[120-122]。

从多目标定位中的数据关联对象角度来看，现有研究可分为三类，即测量-航迹关联、航迹-航迹关联以及测量-测量关联[120,123]。第一类是指将新获取的测量与某一传感器已记录的航迹进行关联。正确的关联有助于传感器构建精确航迹并预测目标的下一步状态，而错误的关联可能导致目标丢失[124-125]。第二类是指不同传感器所获得航迹之间的关联[126-128]。由于局部观测与测量噪声的影响，单个传感器构建的航迹通常存在一定偏差。对航迹进行正确关联与融合有助于提高跟踪精度。测量-测量关联（Measurement-to-Measurement Association, M2M）是第三类，指不同传感器之间测量数据的关联。该方法常用于噪声干扰[129]、运动轨迹构建[120] 以及测量信息不足[130-133] 等情形。

从定位方法的实现方式来看，现有研究可分为集中式方法与分布式方法两类。集中式方法将所有传感器的测量数据汇总至中心节点进行处理[124,130,134]。在分布式方法中，各传感器保留自身测量数据，运行相同算法，并通过在 WSN 中与其邻居通信实现目标定位[126-127,135-137]。集中式优化通常具有更高精度且实现较为简单，而分布式方法则在鲁棒性、可扩展性与效率方面具有优势[135]。随着通信技术与物联网的发展，终端硬件的通信与计算能力不断增强。因此，分布式定位方法有望提升 WSN 的能力并拓展其应用范围。

在本章中，我们旨在研究带有测量-测量关联的多目标定位问题（DM2M）的分布式算法。该问题在单个传感器的测量不足以完成目标定位的场景中尤为重要。例如，到达角（Angle-of-Arrival Measurement, AOA）测量[138] 仅揭示目标相对于传感器的方向信息，而到达时间差（Time Difference of Arrival Measurement, TDOA）测量[139] 仅提供目

标与传感器之间的距离信息。相比于视觉摄像头等高精度传感器[126]，上述简单传感器硬件成本更低，且在各类场景中部署更为广泛。考虑到每个传感器会同时获取多个目标的测量数据，且不同传感器之间的测量关联事先未知，因此有必要先对各传感器的测量进行关联，再利用其进行目标定位。例如，Kazemi 等人[130] 通过引入辅助变量和一阶泰勒近似，在集中式框架下解决了基于 TDOA 测量的 M2M 问题。Wei 等人[132] 提出一种粗门限策略，在集中式框架下解决了基于 AOA 测量的 M2M 问题。据我们所知，如何以分布式方式解决 DM2M 仍然具有挑战性。

以分布式方式解决 DM2M 面临如下困难。DM2M 同时包含用于表示目标位置的连续变量以及用于数据关联的离散变量，这两类变量相互耦合且需同时优化。没有正确的关联，就无法获得用于定位的正确测量数据；而没有准确的定位结果，也无法评估数据关联的正确性。此外，在缺乏先验测量关联的情况下，DM2M 不能被分解为多个单目标定位问题。因此，随着目标数量的增加，数据关联的可能情况数量呈指数增长。在分布式框架下，传感器需要在指数增长的搜索空间中就离散变量进行协商，这具有较大挑战。

为应对上述挑战，我们提出一种基于贡献度协作的多智能体群体优化方法（Multi-Agent Swarm Optimization with Contribution-Based Cooperation, MASTER），以分布式方式解决 DM2M。我们将 WSN 视为一个多智能体系统，其中每个智能体代表一个传感器，并与其邻居进行计算与通信。每个传感器维护一个粒子群，其中每个粒子表示一个候选的目标位置解。粒子群通过两个交替阶段演化：局部优化阶段与邻域协作阶段。在局部优化阶段，各传感器利用自身测量数据独立优化局部目标函数。我们结合 Kuhn-Munkres 算法[140] 与竞争粒子群优化算法[64] 实现局部优化。在邻域协作阶段，传感器与邻居通信，并利用邻居信息更新自身粒子群。

本章的主要贡献总结如下：

1) 鉴于在指数增长的搜索空间中对离散变量进行协商较为复杂，我们将 DM2M 重构为一个分布式优化问题，其局部目标函数为一个双层优化问题（Distributed Bi-level Multi-target localization problem with measurement-to-measurement association, DBM2M）。局部目标函数的下层为数据关联的线性指派问题，可通过确定性算法求解。对于每一个上层解，都可以找到对应的下层最优解。因此，传感器仅需在与邻居协商时处理上层连续变量，同时由下层保证最优性。该重构有效降低了由于数据关联问题所带来的协商变量搜索空间。

2) 针对双层局部目标函数不可求梯度且非凸的特性，我们利用进化计算在黑盒与非凸优化中的优势来求解 DBM2M。我们提出一种多智能体群体优化方法，包括局部优化、邻域协作以及自适应通信机制。该方法可推广至多种 WSN 测量技术。我们通过往返传播时间（Round Trip Time Measurement, RTT）测量、到达时间差（Time Difference of Arrival Measurement, TDOA）测量、接收信号强度（Received Signal Strength Measurement, RSS）测量以及到达角（Angle-of-Arrival Measurement, AOA）测量对 MASTER 进行了实验验证。
3) 为促进在每个传感器仅能获取局部测量数据的情况下优化全局目标，我们设计了一种基于贡献度的协作机制，引导传感器向邻居学习。在通信之前，每个传感器根据局部优化过程中粒子运动情况与适应度值变化计算其贡献度。随后，粒子群连同其贡献度一并传输给邻居。通信之后，我们设计了一种新的速度更新规则，使粒子群根据邻居贡献度进行学习。消融实验表明，该基于贡献度的协作机制有助于传感器优化全局目标并获得更高的定位精度。
4) 为验证所提算法的有效性，我们在二维与三维场景下，针对不同目标数量的多目标定位问题进行了实验。实验结果表明，在所测试的实验案例中，MASTER 相比现有算法取得了更小的定位误差。同时，在去中心化通信网络下，MASTER 能够使传感器就目标位置达成共识。

综上所述，本章旨在提升在面临数据关联挑战的多目标场景下分布式协同定位技术的性能。与现有研究相比，本章工作的创新性如表 6-2 所示。简而言之，现有分布式多目标数据关联方法通常要求传感器具备独立定位能力[126-129]，而本章仅要求传感器具备距离或方位测量能力。这有助于将分布式定位技术应用于更为简单的传感器网络，并降低硬件部署成本。

本章其余部分组织如下。第6.2节介绍预备知识与相关工作。第6.3节给出 DM2M 的分布式双层形式化描述。第6.4节和第6.5节详细阐述所提出的算法，并在第6.6节中开展多项实验验证。最后，第6.7节对本章进行总结。

6.2 问题建模与相关工作

6.2.1 系统模型

考虑一个包含 N_s 个传感器的无线传感器网络，其部署在区域 $\mathcal{S}$ 内。每个传感器均具备感知、通信和计算能力。第 i 个传感器（$i = 1, 2, ..., N_s$）能够确定自身位置

表 6-1 MASTER 相关符号说明

符号	含义	符号	含义
N_s	传感器数量	N_t	目标数量
y_i	第 i 个传感器的位置 ($i=1,\ldots,N_s$)	ρ_t^x	解 x 中第 t 个目标的估计位置
d_i	第 i 个传感器的测量数据 ($d_i \in \mathbb{R}^{N_t}$)	$\mathcal{N}_i$	第 i 个传感器的邻居索引集合
x	DBM2M 问题的一个解 ($x \in \mathbb{R}^{3N_t}$)	C	数据关联矩阵 ($C \in \{0,1\}^{N_t \times N_t}$)
m	粒子群规模（粒子数量）	P_i	第 i 个传感器的种群 ($P_i=(X_i,V_i)$)
X_i	粒子位置集合 ($X_i \in \mathbb{R}^{m\times(3N_t)}$)	V_i	粒子速度集合 ($V_i \in \mathbb{R}^{m\times(3N_t)}$)
t_m	局部优化频率（初始值 t_m^0）	t_n	邻域协作频率（最大 $t_n^{\max}$）
t_p	非进展迭代次数容忍阈值	ϕ	局部优化控制参数
φ	邻域协作控制参数		
缩略语	全称	缩略语	全称
DM2M	带测量-测量关联的分布式多目标定位问题	DBM2M	带测量-测量关联的分布式双层多目标定位问题
AOA	到达角测量技术	RTT	往返传播时间测量技术
TDOA	到达时间差测量技术	RSS	接收信号强度测量技术

$y_i=[y_i^1,y_i^2,y_i^3]\in\mathcal{S}$，但无法获知其他传感器的位置。WSN 的通信拓扑记为 $G=<V,E>$。若两个传感器之间的距离小于通信范围 D_c，则可进行通信，因此边集合定义为：

$$E=\{(i,j)|i,j\in V \text{ and } \|y_i-y_j\|<D_c\} \tag{6-1}$$

第 i 个传感器的邻居集合定义为：

$$\mathcal{N}_i=\{j\in[1,N_s]\,|(i,j)\in E\} \tag{6-2}$$

假设在探测区域内同时出现 N_t 个目标，第 j 个目标（$j=1,2,...,N_t$）的位置记为 $p_j=[p_j^1,p_j^2,p_j^3]$，目标位置对传感器未知。假设不存在虚警，当 N_t 个目标同时出现时，第 i 个传感器能够获得一组测量数据 $d_i=\{d_{i,1},d_{i,2},...,d_{i,N_t}\}$。本章考虑测量数据不完备的情形，例如距离测量或角度测量。对于距离测量，目标可能位于以传感器 i 为中心、半径为 $d_{i,j}$ 的球面上任意一点；对于角度测量，目标可能位于经过传感器 i 的射线上。因此，单个传感器的测量数据不足以确定目标位置。

当单个传感器测量信息不完备时，需要对多个传感器的测量数据进行关联。然而，由于传感器在分布式环境下独立探测目标，因此不存在测量之间的先验关联信

息。关联通常表示为 N_s 个置换矩阵 $\{C^1, C^2, ..., C^{N_s}\}$。对于传感器 i，置换矩阵 C^i（$i = 1, 2, ..., N_s$）表示目标与测量数据之间的对应关系。具体而言，$C^i_{n,m} = 1$ 表示第 m 个测量数据 $d_{i,n}$ 来自第 n 个目标。由于关联未知，测量关联的可能情况数为 $(N_s - 1)A^{N_t}_{N_t}$，因此寻找正确的数据关联是多目标定位问题的核心挑战。

6.2.2 多目标协同定位的问题定义

带测量到测量关联的多目标定位问题（DM2M）旨在同时估计多个目标的位置及多个传感器测量之间的关联关系[130,133]，其形式化定义如下：

$$\min_{x, C^1, C^2, ..., C^{N_s}} F_{\text{DM2M}}(x, \{C^i\}_{i=1,2,..,N_s}) = \frac{1}{n}\sum_{i=1}^{N_s} f_i(x, C^i) \tag{6-3}$$

全局目标函数 F 为所有局部目标函数之和，第 i 个传感器的局部目标函数 f_i 基于其本地数据 d_i 和位置 y_i 最小化定位误差。

$$\begin{aligned} & f_i(x, C^i) = \sum_{t=1}^{N_t}(\sum_{k=1}^{N_t} C^i_{t,k} d_{i,k} - \mathcal{M}(\rho^x_t, y_i))^2 \\ s.t.\ & \rho^x_t = [x^{t*3-2}, x^{t*3-1}, x^{t*3}] \\ & C^i \in \{0,1\}^{N_t \times N_t}, \forall i = 1, 2, ..., N_s \\ & \sum_{m=1}^{N_t} C^i_{n,m} = 1, \forall n = 1, 2, ..., N_t \\ & \sum_{n=1}^{N_t} C^i_{n,m} = 1, \forall m = 1, 2, ..., N_t \end{aligned} \tag{6-4}$$

其中，ρ^x_t 为第 t 个目标的位置估计，是一个三维向量；$x \in \mathbb{R}^{3N_t}$ 为包含所有目标位置估计的向量。C^i（$i = 1, 2, ..., N_s$）为置换矩阵，表示估计目标位置与第 i 个传感器测量之间的关联关系。

DM2M 的目标函数为非凸函数，算法容易陷入局部最优。此外，该问题还具有以下两个主要挑战：

1) 混合整数特性：DM2M 同时包含连续变量（目标位置）和离散变量（数据关联），二者相互耦合，无法独立求解。没有正确的关联，就无法获得正确的定位数据；没有准确的定位，也无法评估关联的正确性，因此形成混合整数特性。
2) 不可分性：如上所述，在获得正确位置之前，测量数据的正确关联未知。因此，DM2M 不能分解为多个独立的单目标定位问题。随着目标数量增加，数据关联的可能情况呈指数级增长。对于包含 N_s 个传感器和 N_t 个目标的三维定位任务，目

标位置变量维度为 $3 \times N_t$，测量关联的可能情况数为 $(N_s - 1)A_{N_t}^{N_t}$。

表 6-2 多目标协同定位相关工作的对比

方法	分布式计算	多目标定位	数据关联	单个传感器能力要求
Parmar et al.[124], Chen et al.[125]	x	√	√	具备完整定位能力，例如地平面位置[126]、激光雷达点云[129] 等。此类方法中的数据关联主要用于降低噪声带来的误差。
Kamal et al.[126][127-129]	√	√	√	
Wang et al.[138][135,141]	√	x	x	仅具备方位或距离等基础测量能力，无法独立完成目标定位。此类方法中的数据关联用于融合测量数据以实现目标定位。
Costa et al.[142]	√	√	x	
Kazemi et al.[130][131-133]	x	√	√	
MASTER（本章方法）	√	√	√	

6.2.3 多目标协同定位的相关工作

如表 6-2 所示，相关研究从三个维度进行分类，即传感器能力、数据关联以及计算环境。首先，从传感器能力要求的角度看，现有研究可分为两类。第一类要求每个传感器具备完整的定位能力[124-125,127-128]。例如，[126] 采用视觉传感器获取目标在地平面上的位置，[129] 使用激光雷达生成行人的点云数据。第二类仅要求每个传感器具备方位或距离等基础测量能力[135,138,141]。其次，从数据关联角度看，尽管[142] 研究了具备基础能力传感器的分布式目标定位问题，但其假设多目标数据关联已知，而本章不作此类先验假设。第三，从计算环境角度看，针对仅具备基础能力传感器的多目标数据关联问题，现有研究大多采用集中式优化[130-133]。本章将其扩展到无需中心节点的分布式计算环境。

综上，本章在问题设定层面的贡献在于：在传感器仅具备方位或距离等基础测量能力的情况下，研究带有数据关联的分布式多目标定位问题。该设定不依赖数据关联先验信息、中心节点或高性能传感器设备，因而具有更广泛的应用前景。

6.2.4 Kuhn-Munkres 算法

匈牙利算法最初用于求解无权二分图的完美匹配问题。对于二分图 $G =< V, E >$，若其子图 $M =< V, E' >$ 满足每个顶点均恰好连接一条边，则称 M 为完美匹配。匈牙利算法的基本思想是通过寻找增广路径构造匹配。增广路径从一个未匹配顶点出发，交替经过未匹配边和已匹配边，最终到达另一个未匹配顶点。

Kuhn-Munkres 算法[140] 基于匈牙利算法发展而来，用于求解带权二分图的最大匹配

问题，即线性指派问题。最大匹配不仅是完美匹配，而且其包含边的权重之和最大。对于一个两侧各含 n 个顶点的带权二分图 G，设 $W \in \mathbb{R}^{n\times n}$ 为加权邻接矩阵，Kuhn-Munkres 算法的基本步骤如下：

1) 构造无权子图 G'，仅保留 W 每一行中权重最大的边。
2) 采用匈牙利算法在 G' 中寻找完美匹配。若找到完美匹配，则算法结束；否则更新 W 的权重并返回步骤 1。

6.3 多目标协同定位问题的等价转换与复杂度简化

本节将 DM2M 重构为如下形式的分布式双层优化问题（DBM2M）：

$$\min_{x} F_{\text{DBM2M}}(x) = \frac{1}{n}\sum_{i=1}^{N_s} f_i^{\text{bi-level}}(x) \tag{6-5}$$

第 i 个传感器的局部目标函数 f_i 定义如下：

$$\begin{aligned}
&f_i^{\text{bi-level}}(x) = f_i(x, g_i(x)) \\
s.t.\ \ &g_i(x) \in \min_{C^i} \sum_{k=1}^{N_t}\sum_{t=1}^{N_t} C_{t,k}^i (d_{i,k} - \mathcal{M}(\rho_t^x, y_i))^2 \\
&\rho_t^x = [x^{t*3-2}, x^{t*3-1}, x^{t*3}] \\
&C^i \in \{0,1\}^{N_t\times N_t}, \forall i = 1,2,...,N_s \\
&\sum_{m=1}^{N_t} C_{n,m}^i = 1, \forall n = 1,2,...,N_t \\
&\sum_{n=1}^{N_t} C_{n,m}^i = 1, \forall m = 1,2,...,N_t
\end{aligned} \tag{6-6}$$

该局部目标函数为一个双层优化问题，其上层为目标定位的连续变量最小化问题，下层为数据关联的离散变量最小化问题。

1) 在上层中，数据关联的离散变量 C^i 被固定。此时可得到每个传感器的测量数据序列 $D_i = [\phi_{i,1}, \phi_{i,2}, ..., \phi_{i,N_t}]$，其中 $\phi_{i,t} = \sum_{k=1}^{N_t} C_{t,k}^i d_{i,k}$。因此，上层优化目标是寻找目标位置 x，以最小化目标位置的估计误差。
2) 在下层中，目标位置的连续变量 x 被固定。传感器可以根据当前估计目标位置计算其到自身位置的测量结果 $\{u_{i,1}, u_{i,2}, ..., u_{i,N_t}\}$，其中 $u_{i,k} = \mathcal{M}(\rho_k^x, y_i)$。因此，下层优化目标是对序列 $\{u_{i,1}, u_{i,2}, ..., u_{i,N_t}\}$ 与 $\{d_{i,1}, d_{i,2}, ..., d_{i,N_t}\}$ 进行一一匹配，并最小化二者之间的差异。

与式 (6-3) 中的 DM2M 相比，式 (6-5) 中全局目标函数 F_{DBM2M} 的决策变量仅包含 x，而不再显式包含 C。

DBM2M 的优势在于，它避免了在分布式环境下对离散变量进行协商所带来的困难。其原因在于，下层问题本质上是一个线性和指派问题，可通过 Kuhn-Munkres 算法等确定性算法求解。在下层问题具有最优性保证的前提下，各传感器仅需对连续变量进行协商。重构后，传感器之间需要协商的变量搜索空间由 $(N_s-1)A_{N_t}^{N_t}\times\mathbb{R}^{3N_t}$ 降至 $\mathbb{R}^{3N_t}$。

使用 DBM2M 解决 DM2M 的前提是：DBM2M 的最优解能够导出 DM2M 的最优解。

对于 DBM2M 的最优解 x^*，有：

$$\begin{aligned} &F_{\text{DBM2M}}(x^*)\le F_{\text{DBM2M}}(x')\ \forall x'\in\mathbb{R}^{3N_t}\\ \Rightarrow&\frac{1}{n}\sum_{i=1}^{N_s}f_i(x^*,g_i(x^*))\le\frac{1}{n}\sum_{i=1}^{N_s}f_i(x',g_i(x')) \end{aligned} \tag{6-7}$$

由于 $g_i(x')$ 是下层问题的最小化结果，对于任意 $C^{i'}\in\{0,1\}^{N_t\times N_t}$，有：

$$\sum_{k=1}^{N_t}\sum_{t=1}^{N_t}g_i(x')_{t,k}(d_{i,k}-\mathcal{M}(\rho_t^{x'},y_i))^2\le\sum_{k=1}^{N_t}\sum_{t=1}^{N_t}C_{t,k}^{i'}(d_{i,k}-\mathcal{M}(\rho_t^{x'},y_i))^2 \tag{6-8}$$

考虑到式 (6-6) 中 C^i 为置换矩阵，有：

$$\begin{aligned} &\sum_{k=1}^{N_t}(\sum_{t=1}^{N_t}g_i(x')_{t,k}d_{i,k}-\mathcal{M}(\rho_t^{x'},y_i))^2\le\sum_{k=1}^{N_t}(\sum_{t=1}^{N_t}C_{t,k}^{i'}d_{i,k}-\mathcal{M}(\rho_t^{x'},y_i))^2\\ \Rightarrow&f_i(x',g_i(x'))\le f_i(x',C^{i'}) \end{aligned} \tag{6-9}$$

因此，对于任意 $x'\in\mathbb{R}^{3N_t}$ 和 $C^{i'}\in\{0,1\}^{N_t\times N_t}$，有：

$$\frac{1}{n}\sum_{i=1}^{N_s}f_i(x^*,g_i(x^*))\le\frac{1}{n}\sum_{i=1}^{N_s}f_i(x',g_i(x'))\le\frac{1}{n}\sum_{i=1}^{N_s}f_i(x',C^{i'}) \tag{6-10}$$

即：

$$F_{\text{DM2M}}(x^*,\{g_i(x^*)\}_{i=1,2,\dots,N_s})\le F_{\text{DM2M}}(x',\{C^{i'}\}_{i=1,2,\dots,N_s}) \tag{6-11}$$

这表明 x^* 同样是 DM2M 的最优解。

6.4 单一时刻的分布式多目标协同定位方法

为应对 DBM2M 的挑战，本章提出一种基于贡献度协作的多智能体群体优化方法。

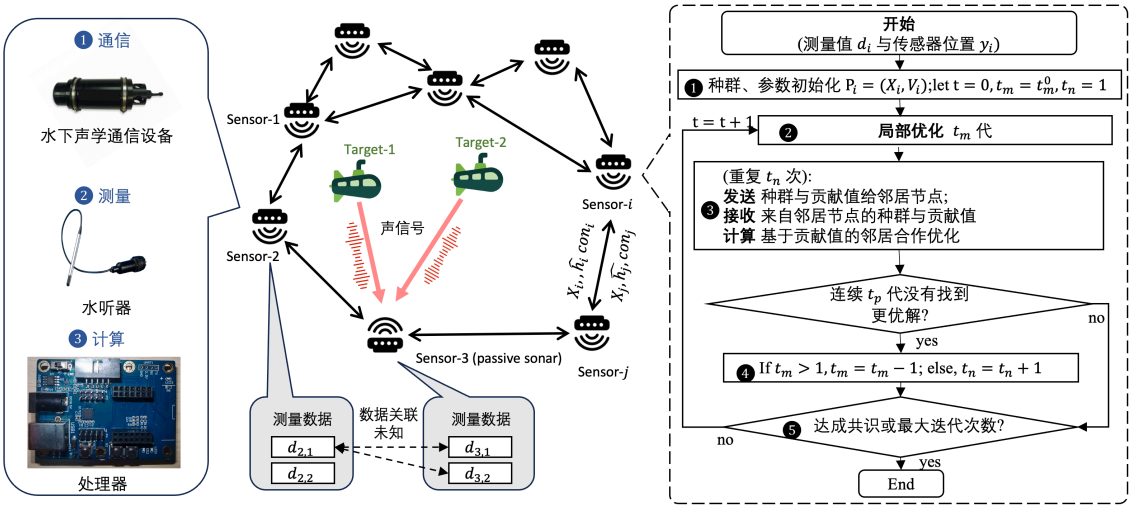


图 6-1 问题场景与算法框架。左侧展示了本文所研究的问题场景。在该场景中，传感器通过去中心化网络进行连接，并同时探测多个目标，而各传感器测量数据之间的关联关系是未知的。图中给出了一个水下场景示例，其中使用声呐对声信号的方位角进行测量。该算法同样可以应用于其他场景，例如智能交通场景中的协同激光雷达感知。右侧展示了算法流程图。

6.4.1 算法框架

在所提出的多智能体优化框架中，每个智能体对应一个具备计算与通信能力的传感器。传感器之间通过点对点方式进行通信。每个传感器维护一个粒子群，其中每个个体表示问题的一个候选解。在优化过程中，粒子群在局部优化阶段与协作阶段之间交替演化。

MASTER 中每个传感器的流程如图 6-1 所示，主要包括以下步骤：

1) *初始化*: 在三维定位场景中，一个候选解由向量 $[x^1, x^2, ..., x^{N_t*3}]$ 表示，其中 $(x^{t*3-2}, x^{t*3-1}, x^{t*3})$ 表示第 t 个目标的估计位置。在二维定位场景中，个体编码为向量 $[x^1, x^2, ..., x^{N_t*2}]$。每个传感器初始化一个粒子群 $P_i = (X_i, V_i)$，其中 $X_i = \{x_{i,1}, x_{i,2}, ..., x_{i,m}\}$ 表示粒子位置，$V_i = \{v_{i,1}, v_{i,2}, ..., v_{i,m}\}$ 表示粒子速度。
2) *局部优化*: 在该阶段，传感器利用自身本地数据搜索目标位置。针对第 6.3 节中的双层优化模型，下层离散优化问题（数据关联）采用 Kuhn-Munkres 算法求解，上层连续优化问题（目标定位）采用竞争粒子群优化（CSO）求解。
3) *通信与协作*: 在该阶段，传感器通过协作优化全局目标函数。首先，每个传感器向邻居节点发送信息。本章假设通信拓扑为固定连通图。随后，在接收所有邻居信息后，传感器根据邻居种群及其贡献度更新自身粒子群。本章提出一种基于贡献度的协作方法。

4) *通信间隔调整*: 通过调整局部优化与协作的执行频率来调节通信间隔。局部优化有助于智能体探索局部目标，而协作有助于达成共识。因此，框架在早期分配更多资源于局部优化，在后期分配更多资源于协作。初始时，局部优化频率 t_m 设为大于 1 的值，协作频率 t_n 设为 1。在优化过程中，当某智能体连续 t_p 次迭代无改进时，将调整频率。具体而言，当局部优化频率大于 1 时，将降低其频率；否则增加协作频率。协作频率的最大值为 $t_n^{\max}$。改进的判断基于延迟全局适应值更新机制。每个传感器 i 维护一个全局适应值估计 $\hat{h}_i$。在第 t 次迭代时，其更新方式如下：

$$\begin{aligned} \hat{h}_i &= \sum_{j \in \mathcal{N}_i \cup \{i\}} \hat{h}_j - \overline{h_i}(t) + \overline{h_i}(t+1) \\ \text{其中 } \overline{h_i}(t) &= \frac{1}{\|P\|} \sum_{a=1}^{\|P\|} f_i^{bi-level}(x_{i,a}(t)) \end{aligned} \tag{6-12}$$

其中，$\hat{h}_j, j \in \mathcal{N}_i$ 在通信阶段由邻居节点发送获得。

5) *终止*: 当多智能体系统达成共识或达到最大迭代次数时，算法终止。共识性表示无线传感器网络中所有传感器对目标位置的估计一致。具体而言，当传感器之间的差异度低于某一阈值时，认为系统达成共识。由于本框架在每个传感器中维护一个候选解种群，系统的差异度定义如下：

$$disagreement = \sum_{a=1}^{\|P\|} \sum_{i=1}^{N_s} \|x_{i,a} - \frac{1}{n} \sum_{i=1}^{N_s} x_{i,a}\| \tag{6-13}$$

其中 $x_{i,a}$ 表示第 i 个智能体的第 a 个个体，$\|P\|$ 表示种群规模。在实验中，该阈值设为 10^{-8}。

6.4.2 单传感器局部优化阶段

局部优化阶段中，各传感器优化其自身局部目标函数。根据第 6.3 节的建模，局部目标函数为双层优化问题。

对于下层问题，在目标位置估计 x 固定的情况下，最小化估计误差。为此，我们构建一个包含 $2 * N_t$ 个顶点的二分图，其中一侧 N_t 个顶点表示估计目标位置，另一侧 N_t 个顶点表示该传感器的测量值。二分图两侧顶点完全连接。对于任意估计目标位置 $\rho_k^x = [x^{k*3}, x^{k*3+1}, x^{k*3+2}]$ 与测量值 $d_{i,t}$，其对应顶点之间的边权定义为：

$$W_{k,t} = -(d_{i,t} - \mathcal{M}(\rho_k^x, y_i))^2 \tag{6-14}$$

因此，数据关联问题被建模为带权二分图的最大匹配问题。本章采用 Kuhn-Munkres 算

法求解。

对于上层问题，在数据关联固定的情况下最小化估计误差。正如第 6.3 节所述，上层问题具有梯度不可计算和不可分性特征。因此，本章采用竞争粒子群优化（CSO）求解，该方法在大规模与黑箱优化问题中表现良好。

算法 6-7 给出了 MASTER 中的局部优化过程。初始时，粒子索引集合 S 包含所有粒子。在每次循环中，从 S 中无放回随机选取两个粒子索引 a 和 b（第 5 行与第 14 行）。采用 Kuhn-Munkres 算法分别优化其数据关联结果 $C^{i,a}$ 与 $C^{i,b}$（第 6 行）。随后计算估计误差 $f_i(x, C^i)$ 作为粒子的适应值。两个粒子根据适应值进行竞争，败者根据式 (2-13) 更新（第 7-13 行）。上述过程重复进行直至 S 为空。

Algorithm 6-7 每个传感器 i 的局部优化

输入: 当前种群 $P_i(t) = (X_i, V_i)$

1: **for** $p = 1, 2, ..., t_m$ **do**
2: 粒子索引集合 $S = \{1, 2, ..., m\}$
3: $\overline{X_i} = \frac{1}{m}\sum_{a=1}^{m} x_{i,a}$
4: **while** $S \neq \emptyset$ **do**
5: 从 S 中随机选择两个粒子索引 a, b
/* 下层优化 */
6: 分别利用 Kuhn-Munkres 算法为 $x_{i,a}$ 和 $x_{i,b}$ 求解关联矩阵 $C^{i,a}$ 和 $C^{i,b}$
/* 上层优化 */
7: **if** $f_i(x_{i,a}, C^{i,a}) < f_i(x_{i,b}, C^{i,b})$ **then**
8: $v_{i,b} = r_1 v_{i,b} + r_2(x_{i,a} - x_{i,b}) + \phi r_3(\overline{X_i} - x_{i,b})$
9: $x_{i,b} = x_{i,b} + v_{i,b}$
10: **else**
11: $v_{i,a} = r_1 v_{i,a} + r_2(x_{i,b} - x_{i,a}) + \phi r_3(\overline{X_i} - x_{i,a})$
12: $x_{i,a} = x_{i,a} + v_{i,a}$
13: **end if**
14: 从 S 中移除 a, b
15: **end while**
16: **end for**

输出: 新种群 $P_i(t + \frac{1}{2}) = (X_i, V_i)$

6.4.3 多传感器协作阶段

邻域协作阶段中，传感器通过协作优化全局目标函数。根据第 6.3 节的建模，全局目标函数仅与连续变量 x 有关。由于每个传感器仅能访问本地数据并计算局部目标函数，协同优化全局目标函数具有挑战性。此外，由于目标函数梯度不可计算，传统基于梯度的协作方法（如次梯度下降）不适用于该问题。

针对上述挑战，本章提出一种基于贡献度的多智能体群体优化协作策略。在该阶段，传感器向邻居发送当前种群信息。随后，各传感器根据邻居种群更新自身种群。其基本思想是：在上一局部优化阶段中贡献更大的粒子，在协作阶段应具有更大的影响力与吸引力。

为此，定义第 i 个智能体第 a 个粒子的贡献度为：

$$con_{i,a} = \begin{cases} 0, & f_i(x_{i,a}(t+\frac{1}{2})) \geq f_i(x_{i,a}(t)) \\ \frac{f_i(x_{i,a}(t)) - f_i(x_{i,a}(t+\frac{1}{2}))}{\|x_{i,a}(t) - x_{i,a}(t+\frac{1}{2})\|^2}, & \text{otherwise} \end{cases} \tag{6-15}$$

其中 $x_{i,a}(t)$ 为局部优化前的位置，$x_{i,a}(t+\frac{1}{2})$ 为局部优化后的位置。当当前位置的适应值未优于原位置时，贡献度设为 0。显然，单位移动距离内适应值提升越大，其贡献度越高。

随后，协作权重定义为：

$$\mathcal{W}_{j,a} = \frac{con_{j,a}}{\sum_{j \in \mathcal{N}_i \cup \{i\}} con_{j,a}} \tag{6-16}$$

该权重基于各粒子的贡献度计算，且保证权重之和为 1。

因此，每个粒子的速度与位置按照如下基于贡献度的协作策略更新：

$$\begin{aligned} v_{i,a} =& r_4 v_{i,a} + \varphi(\overline{x}_a - x_{i,a}) + (1-\varphi) \sum_{j \in \mathcal{N}_i} \mathcal{W}_{i,j}(x_{j,a} - x_{i,a}) \\ x_{i,a} =& x_{i,a} + v_{i,a} \end{aligned} \tag{6-17}$$

其中 $x_{i,a}$ 与 $v_{i,a}$ 分别表示第 i 个传感器中第 a 个粒子的当前位置与速度。

速度更新规则包括三部分。第一部分为惯性项，其中 r_4 为 $[0,1]$ 区间内的随机数，$v_{i,a}$ 为上一协作阶段的速度。第二部分为均值吸引项，粒子被邻居粒子的平均位置吸引，其中 $\overline{x}_a = \frac{1}{\|\mathcal{N}_i\|+1} \sum_{j \in \mathcal{N}_i \cup \{i\}} x_{j,a}$。第三部分为贡献项，粒子受到贡献度更高粒子的吸引。参数 φ 用于调节后两部分的相对影响。

算法 6-8 给出了通信与协作过程。在通信前，每个智能体基于上一局部优化阶段计

算贡献度（第 2-5 行）。随后向邻居发送种群及对应贡献度（第 6-8 行）。在接收所有邻居信息后，执行基于贡献度的协作并更新种群（第 9-13 行）。

Algorithm 6-8 每个传感器 i 的通信与协作

输入: 当前种群 $P_i(t+\frac{1}{2})=(X_i,V_i)$

1: **for** $p=1,2,...,t_n$ **do**

2: /* 贡献度计算 */

3: **for** $a=1,2,...,\|P_i\|$ **do**

4: $$con_{i,a}=\begin{cases}0, & f_i(x_{i,a}(t+\frac{1}{2}))\geq f_i(x_{i,a}(t))\\ \dfrac{f_i(x_{i,a}(t))-f_i(x_{i,a}(t+\frac{1}{2}))}{\|x_{i,a}(t)-x_{i,a}(t+\frac{1}{2})\|^2}, & \text{否则}\end{cases}$$

5: **end for**

6: /* 通信 */

7: 向邻居发送种群 X_i 及对应贡献度 $[con_{i,a}]_{a=1,2,...,\|P\|}$

8: 从邻居 $j\in\mathcal{N}_i$ 接收种群 X_j 及贡献度 $[con_{j,a}]_{1\times\|P\|}$

9: /* 自适应加权协作 */

10: **for** $a=1,2,...,\|P_i\|$ **do**

11: **for** $j\in\mathcal{N}_i$ **do**

12: $$\mathcal{W}_{j,a}=\frac{con_{j,a}}{\sum_{j\in\mathcal{N}_i\cup\{i\}}con_{j,a}}$$

13: **end for**

14: $v_{i,a}=r_4v_{i,a}+\varphi(\overline{x}_a-x_{i,a})$

15: $+(1-\varphi)\sum_{j\in\mathcal{N}_i}\mathcal{W}_{i,j}(x_{j,a}-x_{i,a})$

16: $x_{i,a}=x_{i,a}+v_{i,a}$

17: **end for**

18: **end for**

输出: 新种群 $P_i(t+1)=(X_i,V_i)$

6.4.4 计算复杂度分析

在所提出算法中，各传感器并行执行算法。因此，我们分析单个传感器的计算复杂度。MASTER 包含三部分计算：CSO、Kuhn-Munkres 算法以及邻域协作。首先，根据[64]，CSO 的计算复杂度为 $\mathcal{O}(D\|P\|)$，其中 $\|P\|$ 为种群规模，D 为问题维度。其次，Kuhn-Munkres 算法的计算复杂度为 $\mathcal{O}[(N_t)^3]$[140]，该算法对每个粒子执行一次，因此复杂度为 $\|P\|$ 倍。第三，邻域协作的计算复杂度为 $\mathcal{O}(D\|P\|)$。根据第 V-A-(4) 节，局部优化阶段每次迭代最多执行 t_m^0 次，邻域协作阶段最多执行 $t_n^{\max}$ 次。设最大迭代次数为 L，则每个传感器的总体计算复杂度为 $\mathcal{O}[Lt_m^0D\|P\|+Lt_m^0(N_t)^3\|P\|+Lt_n^{\max}D\|P\|]$。

具体而言，在三维目标定位中问题维度为 $D=3*N_t$，在二维定位中为 $D=2*N_t$。本章中参数 t_m^0 设为 6，$t_n^{\max}$ 设为 5。因此，在二维与三维环境下，上述表达式均可简化为 $\mathcal{O}[L(N_t)^3\|P\|]$。

为更清晰地说明复杂度，我们将 MASTER 与现有算法进行比较。根据[130]，其方法复杂度为 $\mathcal{O}((N_t)^7(N_s)^{3.5})$，相较于 MASTER，其随目标数量 N_t 增长的阶数高出 4 个数量级。

表 6-3 MASTER 计算复杂度

项目	复杂度
CSO (式 (2-13))	$\mathcal{O}(Lt_m^0 D\|P\|)$
Kuhn-Munkres 算法（算法 6-7 第 6 行）	$\mathcal{O}(Lt_m^0 (N_t)^3\|P\|)$
邻域协作（式 (6-15)-(6-17)）	$\mathcal{O}(Lt_n^{\max} D\|P\|)$

6.5 连续运动环境下的分布式多目标协同追踪方法

基于上一节所描述的多目标定位方法，本节进一步研究多目标追踪问题。图 6-2 展示了多目标追踪的基本流程，该流程通过三个步骤循环执行。首先，利用上一节提出的多目标定位方法获得目标的位置。其次，通过测量与轨迹之间的关联构建目标轨迹。最后，各传感器对目标位置进行预测，以辅助下一时隙的目标定位。

算法 6-9 给出了每个传感器 S_i 的多目标追踪过程，主要包括以下步骤：

6.5.1 数据关联

多目标追踪同样面临数据关联问题，即测量与轨迹之间的关联（measurement-to-track association）。假设传感器 i 在时间隙 t 之前已经记录了 $N_{\mathcal{L}}$ 条目标轨迹

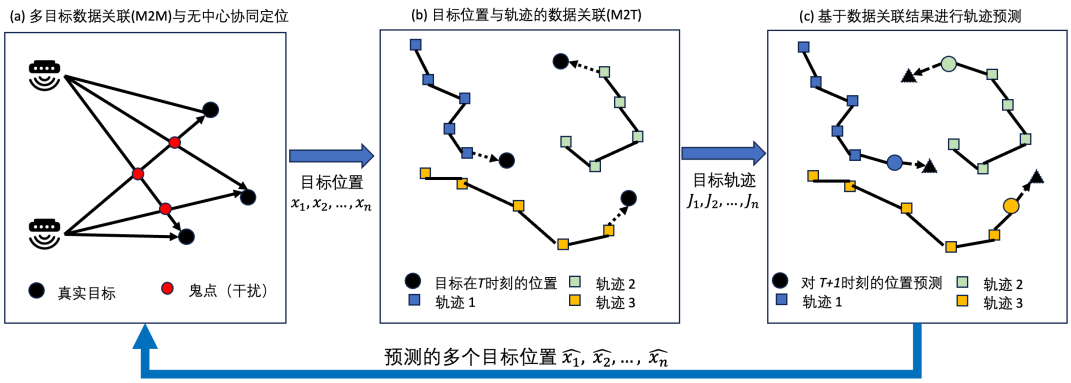


图 6-2 多目标协同追踪的基本流程

Algorithm 6-9 用于连续时刻目标跟踪（每个传感器 S_i 的执行流程）

轨迹集合 $\mathcal{L}(0)=\emptyset$
for $t=1,2,...,T$ **do**
  $\mathbf{z}_i(t) \leftarrow$ 方位角测量
  根据式 (6-25) 初始化种群 $\mathbf{X}_i$
  计算当前目标位置：
  $Q_{U_1}(t), Q_{U_2}(t), ..., Q_{U_{N_u^t}}(t) \leftarrow$ Algorithm 6-8 $(\mathbf{z}_i(t), \mathbf{X}_i)$
  根据式 (6-19)-(6-21) 构建权重矩阵 W
  数据关联矩阵 $\hat{C} \leftarrow KuhnMunkres(W)$
  for 每条已存在的目标轨迹 $\mathcal{L}_k$ **do**
    根据式 (6-22) 更新轨迹
  end for
  for 每个新目标 U_j **do**
    根据式 (6-23) 添加新轨迹
  end for
  for 每条离开的目标轨迹 $\mathcal{L}_k$ **do**
    根据式 (6-24) 删除轨迹 $\mathcal{L}_k$
  end for
  使用卡尔曼滤波预测 $\{\hat{Q}_{U_k}(t+1|\mathcal{L}_k(t))\}_{k\in[1,N_\mathcal{L}]}$
end for
输出： $\mathcal{L}_1(T), \mathcal{L}_2(T), ..., \mathcal{L}_{N_\mathcal{L}}(T)$

$\{\mathcal{L}_1(t-1), \mathcal{L}_2(t-1), ..., \mathcal{L}_{N_\mathcal{L}}(t-1)\}$。在第 t 个时间隙，传感器检测目标并测量其方位角，然后与其他传感器协作确定 N_u^t 个目标的位置 $\{Q_{U_1}(t), Q_{U_2}(t), ..., Q_{U_{N_u^t}}(t)\}$。为了构建新的目标轨迹，传感器需要将新的目标位置与已有轨迹进行关联。

记关联矩阵为 $C \in \{0,1\}^{N_u^t \times N_\mathcal{L}}$，测量到轨迹关联问题的最小化目标函数可以表示为：

$$f_{\text{M2T}}(C) = \sum_{k=1}^{N_\mathcal{L}} \| \sum_{j=1}^{N_u^t} C_{j,k} \hat{Q}_{U_k}(t|\mathcal{L}_k(t-1)) - Q_{U_j}(t) \|^2 \tag{6-18}$$

其中，$\mathcal{L}_k(t-1)$ 表示目标 U_k 的已有轨迹，$\hat{Q}_{U_k}(t|\mathcal{L}_k(t-1))$ 表示根据已有轨迹预测得到

的第 k 个目标在时刻 t 的预测位置。

我们还将式 (6-18) 中的测量到轨迹关联问题建模为一个加权二分图匹配问题。具体而言，我们构建一个二分图，其中包含两组节点，每组节点数量为 N_u^t。第一组节点表示当前检测到的目标位置，第二组节点表示预测得到的目标位置。权重矩阵 $W \in \mathbb{R}^{N_u^t \times N_{\mathcal{L}}}$ 定义如下：

$$W_{j,k} = \|\hat{Q}_{U_k}(t|\mathcal{L}_k(t-1)) - Q_{U_j}(t)\|^2 \tag{6-19}$$

当轨迹数量与目标数量相等时，可以采用 Kuhn-Munkres 算法求解最优关联矩阵，记为 $\hat{C}$。

6.5.2 目标数量动态变化的处理

在实际追踪任务中，目标数量可能会在过程中发生变化。例如，目标可能突然离开检测范围，也可能进入检测范围。因此，已有轨迹的数量可能与当前目标数量不同，即 $N_{\mathcal{L}} \neq N_u^t$。在这种情况下，二分图是不平衡的，无法直接使用 Kuhn-Munkres 算法求解。

针对上述问题，我们在二分图中加入虚拟节点以使其变为平衡图。具体而言，当轨迹数量少于目标数量时，在轨迹节点组中添加 $(N_u^t - N_{\mathcal{L}})$ 个虚拟轨迹节点。此时权重矩阵 $W \in \mathbb{R}^{N_u^t \times N_u^t}$ 定义如下：

$$W_{j,k} = \begin{cases} \|\hat{Q}_{U_k}(t|\mathcal{L}_k(t-1)) - Q_{U_j}(t)\|^2 & k \leq N_{\mathcal{L}} \\ 0 & k > N_{\mathcal{L}} \end{cases} \tag{6-20}$$

这里，与虚拟节点相连的边的权重统一设置为 0，因为虚拟节点不会增加关联误差。

类似地，当轨迹数量多于目标数量时，在目标节点组中添加 $(N_{\mathcal{L}} - N_u^t)$ 个虚拟目标节点。此时权重矩阵 $W \in \mathbb{R}^{N_{\mathcal{L}} \times N_{\mathcal{L}}}$ 定义如下：

$$W_{j,k} = \begin{cases} \|\hat{Q}_{U_k}(t|\mathcal{L}_k(t-1)) - Q_{U_j}(t)\|^2 & j \leq N_u^t \\ 0 & j > N_u^t \end{cases} \tag{6-21}$$

在构建完成带权的平衡二分图之后，采用 Kuhn-Munkres 算法求解关联矩阵 $\hat{C}$。如果某个目标与虚拟轨迹相连，则该目标被视为一个新目标；如果某条已有轨迹与虚拟目标相连，则表示该轨迹对应的目标已经离开检测范围。

6.5.3 轨迹预测与种群注入

在获得最优关联矩阵 $\hat{C}$ 之后，可以根据以下三种情况构建目标轨迹。首先，如果某条已有轨迹 $\mathcal{L}_k(t-1)$ 与真实目标 U_j 关联，则轨迹更新如下：

$$\mathcal{L}_k(t) = \mathcal{L}_k(t-1) \cup \{Q_{U_j}(t) | \hat{C}_{j,k} = 1 \; \exists j \in [1, N_u^t]\} \tag{6-22}$$

其次，如果某个目标与虚拟轨迹相连，则创建一条新的轨迹并加入轨迹集合：

$$\mathcal{L}(t) = \mathcal{L}(t-1) \cup \{Q_{U_j}(t) | \hat{C}_{j,k} = 0 \; \forall k \in [1, N_{\mathcal{L}}]\} \tag{6-23}$$

第三，如果某条已有轨迹与虚拟目标相连，则将该轨迹从轨迹集合中移除：

$$\mathcal{L}(t) = \mathcal{L}(t-1) - \{\mathcal{L}_k | \hat{C}_{j,k} = 0 \; \forall j \in [1, N_u^t]\} \tag{6-24}$$

在完成轨迹构建之后，采用 Kalman 滤波器对下一时间隙的目标位置进行预测，从而为下一时隙的目标定位提供辅助信息。由于本文提出的算法是一种基于种群的进化算法，我们将预测得到的目标位置注入到初始化种群中以提供搜索引导。具体而言，在第 $t+1$ 个时间隙，种群初始化如下：

$$\mathbf{X}_i = \begin{bmatrix} X_{i,0} \leftarrow & [\hat{Q}_{U_k}(t+1|\mathcal{L}_k(t))]_{k \in [1, N_{\mathcal{L}}]} \\ X_{i,1} \leftarrow & \text{Uniform}(lb, ub)^{1 \times D} \\ \cdots & \cdots \\ X_{i,N_p} \leftarrow & \text{Uniform}(lb, ub)^{1 \times D} \end{bmatrix} \tag{6-25}$$

其中，lb 和 ub 表示追踪空间的边界。种群中的第一个个体初始化为预测位置，其余个体按照均匀分布随机初始化。

6.6 实验

6.6.1 实验设置

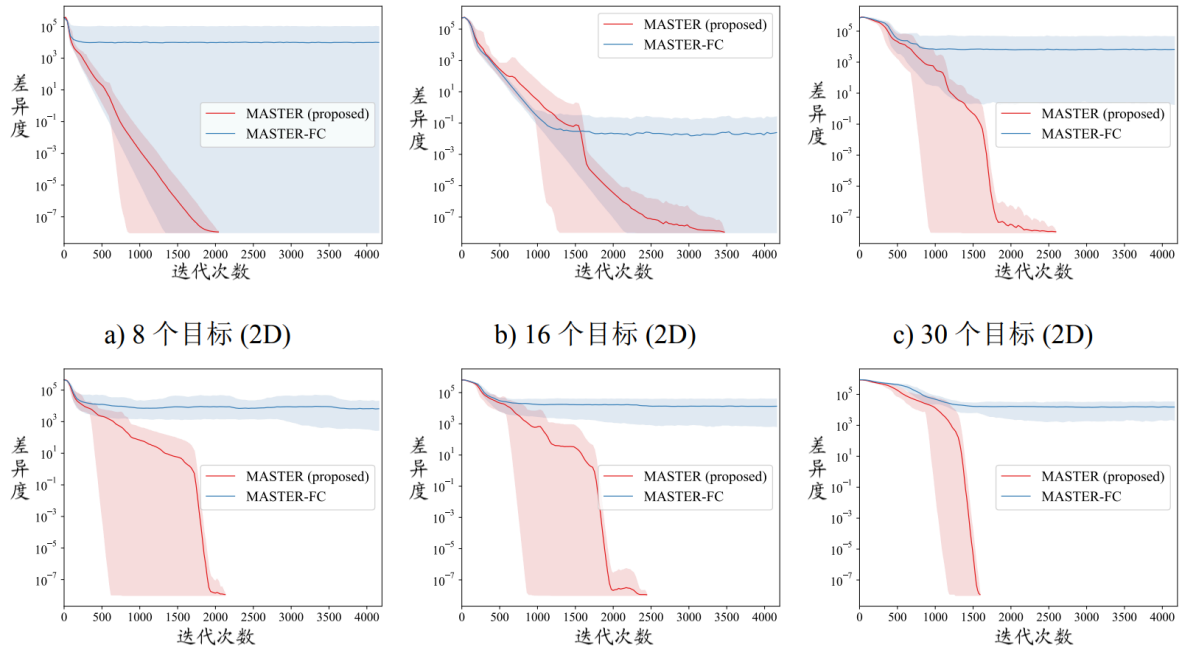
在以下实验中，我们同时考虑二维（2D）和三维（3D）定位场景。对于 2D 场景，目标和传感器随机分布在大小为 100×100 的连续空间中。对于 3D 场景，目标和传感器随机分布在大小为 $100 \times 100 \times 100$ 的连续空间中。传感器通过一个连通图进行连接，其中每个传感器平均拥有三个邻居传感器。在以下实验中，我们对测量数据的顺序进行扰动，以确保传感器无法获知其对应关系。

参数 t_p 决定了非进展迭代的容忍阈值，在本章中设置为 20。最大协作频率 $t_n^{\max}$ 设

置为 5。根据 CSO[64]，式 (2-13) 中的社会因子 ϕ 在问题维度小于 100 时设置为 0，在维度为 100~500 时设置为 0.05，否则设置为 0.1。每个传感器的种群规模设置为 300。

算法采用 C++ 语言基于消息传递接口（Message Passing Interface, MPI）实现。每个计算节点代表一个传感器。实验在由 Intel(R) Xeon(R) CPU E5-2699 v3@2.30GHz 36 核处理器和 CentOS 7.5 x64 系统组成的集群上进行。每组实验重复 25 次。

6.6.2 自适应通信的效果验证



a) 8 个目标 (2D)　b) 16 个目标 (2D)　c) 30 个目标 (2D)

d) 8 个目标 (3D)　e) 16 个目标 (3D)　f) 30 个目标 (3D)

图 6-3 采用固定或自适应通信间隔时 MASTER 的分歧度曲线。MASTER-FC 表示采用固定通信间隔的 MASTER。当分歧度低于 $1 * 10^{-8}$ 时，系统被认为达成共识，算法终止。

通信间隔同样会影响 MASTER 的性能。当通信间隔较大时，传感器将更多资源分配给局部优化，从而获得更好的探索能力。相反，较小的通信间隔有助于更快达成共识，因为传感器之间的协作更加频繁。因此，我们开展实验以寻找合适的初始通信间隔 t_m^0。

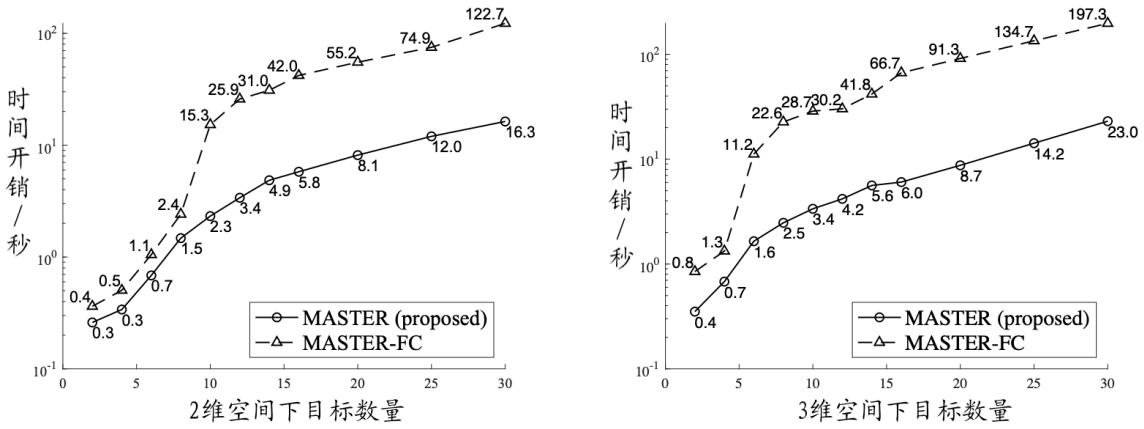
与上一节相同，我们在八个定位任务中测试 MASTER 的性能。初始通信间隔分别设置为 {2, 4, 6, 8, 10}，实验结果如表 6-4 所示。需要注意的是，p 值是通过与当前任务中的最佳结果进行比较得到的。因此，具有最小估计误差的单元格，其 p 值记为 “-”。从表中可以得出以下结论：（1）当 t_m^0 设置为 6 时，MASTER 在八个任务中的三个任务上取得了最低的估计误差，其性能优于其他 t_m^0 设置。（2）在第二、第三和第七个任务中，$t_m^0 = 6$ 时的 MASTER 与最佳结果相比无显著差异，因为 p 值大于 0.05。（3）在第一个

表 6-4 MASTER 在不同的通信间隔 t_m^0 下的表现

Targets \ t_m^0		2	4	6	8	10
4 targets (2D)	mean	9.57E-23	2.42E+01	7.22E-23	1.18E+01	**6.30E-23**
	median	9.22E-23	1.90E-22	7.07E-23	6.64E-23	6.47E-23
	std	3.72E-23	8.25E+01	8.59E-24	5.80E+01	3.09E-24
	p-value	4.95e-02#	1.60e-08#	6.15e-07#	9.53e-04#	-
8 targets (2D)	mean	9.66E+00	**2.45E-05**	3.72E-05	3.48E-05	3.23E-05
	median	1.10E-22	9.71E-23	6.19E-05	6.19E-05	6.20E-05
	std	4.73E+01	3.00E-05	3.04E-05	3.08E-05	3.10E-05
	p-value	4.04e-02#	-	1.07E-01	2.30E-01	3.28E-01
16 targets (2D)	mean	3.20E+02	2.12E+00	2.44E-05	**2.23E-05**	3.96E-05
	median	2.01E+02	6.06E-05	2.15E-22	2.16E-22	6.18E-05
	std	6.74E+02	1.04E+01	2.99E-05	2.97E-05	2.97E-05
	p-value	5.84e-09#	1.56E-01	3.49E-01	-	1.89e-02#
30 targets (2D)	mean	6.60E+03	3.00E+01	**1.91E+01**	4.23E+01	2.54E+01
	median	6.75E+03	1.25E+01	1.78E+00	5.19E+00	8.54E+00
	std	1.88E+03	3.32E+01	3.35E+01	4.77E+01	3.40E+01
	p-value	7.08e-10#	4.57e-02#	-	5.37E-02	1.39E-01
4 targets (3D)	mean	**1.26E+00**	1.39E+01	5.03E+00	3.61E+00	8.02E+00
	median	4.40E-22	1.72E-19	8.16E-15	3.16E-10	2.58E-06
	std	6.18E+00	2.83E+01	1.40E+01	1.23E+01	1.61E+01
	p-value	-	5.80E-02	2.76e-03#	1.61e-06#	4.27e-08#
8 targets (3D)	mean	2.91E+01	1.94E+01	**1.72E+01**	2.05E+01	2.35E+01
	median	9.81E+00	3.83E+00	3.71E+00	2.08E+01	2.50E+01
	std	3.52E+01	2.63E+01	2.72E+01	1.88E+01	2.30E+01
	p-value	3.41e-02#	4.08E-01	-	1.66E-01	1.86E-01
16 targets (3D)	mean	5.62E+02	7.60E+01	4.56E+01	**3.82E+01**	4.88E+01
	median	4.64E+02	8.17E+01	4.39E+01	2.88E+01	4.33E+01
	std	2.41E+02	2.63E+01	2.84E+01	2.62E+01	2.89E+01
	p-value	7.08e-10#	2.72e-05#	1.71E-01	-	7.83E-02
30 targets (3D)	mean	1.54E+03	7.44E+01	**5.25E+01**	5.77E+01	6.12E+01
	median	1.43E+03	7.16E+01	4.91E+01	5.38E+01	6.44E+01
	std	6.56E+02	1.26E+01	1.46E+01	1.16E+01	1.93E+01
	p-value	7.08e-10#	9.83e-06#	-	5.37E-02	2.99e-02#

任务中，尽管 $t_m^0 = 6$ 时的 p 值小于 0.05，但其估计误差接近于 0，因此认为该定位任务已被准确完成。综上所述，$t_m^0 = 6$ 是最佳的初始通信间隔设置，并在后续实验中采用。

为验证自适应通信机制的有效性，我们从共识性能和时间开销两个方面，对 MASTER 与其固定通信间隔变体 MASTER-FC 进行对比实验。MASTER-FC 的通信间隔固定为初始通信间隔 $t_m = 6$。在共识性能方面，根据图 6-3 中的分歧度曲线，除第一



a) 不同 2D 目标数量下的时间开销　　b) 不同 3D 目标数量下的时间开销

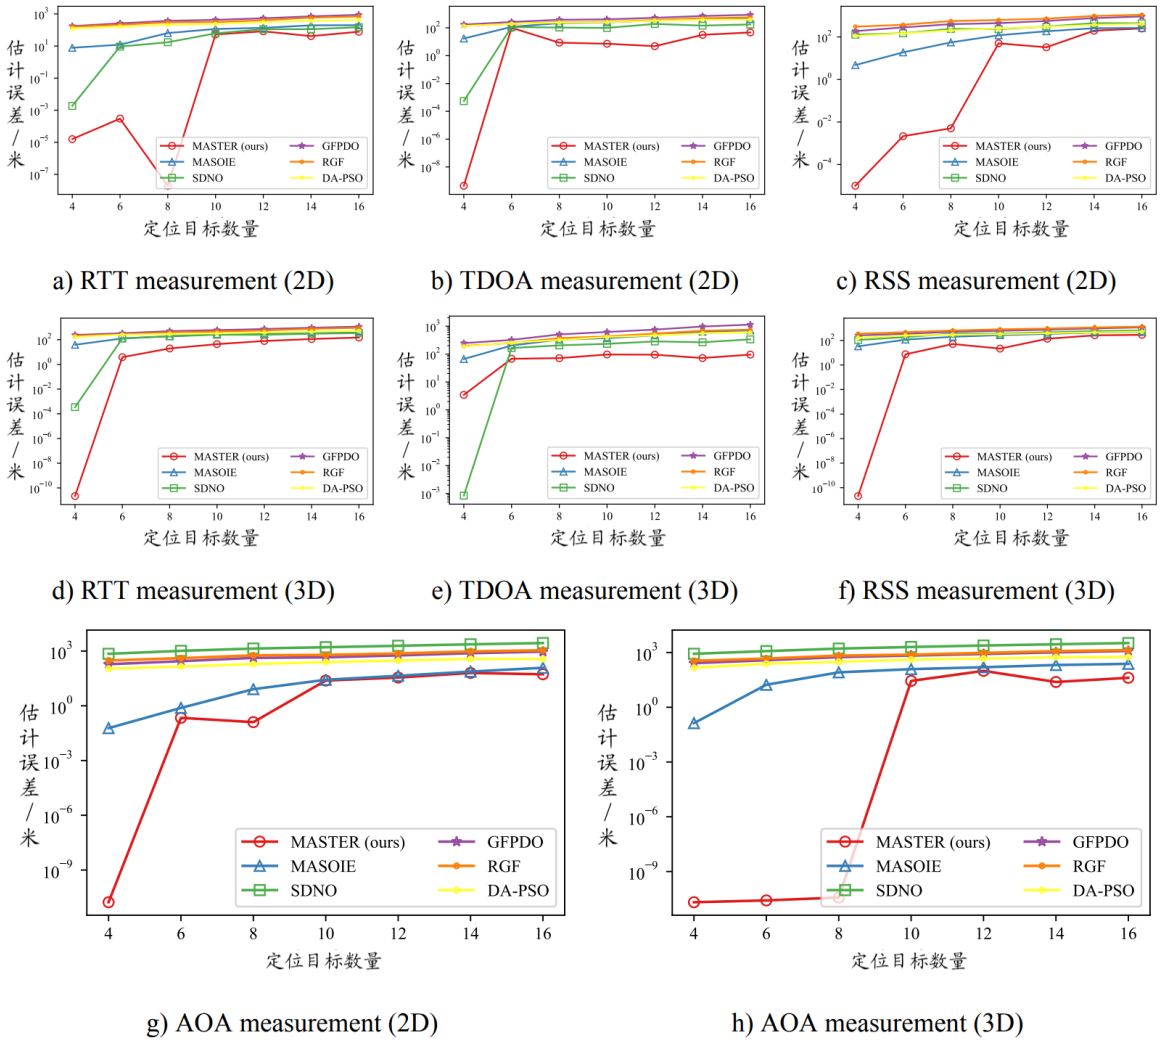
图 6-4 MASTER 及其固定通信间隔变体 MASTER-FC 的时间开销对比

个任务外，MASTER-FC 的分歧度值较高，且未呈现明显下降趋势。这是因为第一个任务相对简单且维度较低。相反，采用自适应通信机制的 MASTER 在八个任务中均表现出明显的下降趋势。在时间开销方面，图 6-4 展示了在不同目标数量场景下 MASTER 与 MASTER-FC 的时间开销。MASTER 的时间开销小于 MASTER-FC，且随着目标数量的增加，其优势更加明显。这是因为 MASTER 中的自适应通信机制有助于系统更快达成共识。综上，自适应通信机制有利于提升系统的共识性能与效率。

6.6.3　与现有算法的比较与分析

在本实验中，我们将 MASTER 与五种现有算法进行比较。MASOIE (Multi-Agent Swarm Optimization With Adaptive Internal and External Learning)[97] 通过自适应内部学习与外部学习来解决基于共识的分布式优化问题，并已应用于无线传感器网络的分布式多目标定位。GFPDO (General Framework for Population-based Distributed Optimization) 是一种基于种群的分布式优化通用框架[70]，采用平均共识理论促进节点之间的分布式协作。DA-PSO (Distributed particle swarm optimization algorithm using the strategies of diffusion adaptation) 是一种分布式粒子群优化算法[71]，提出了一种扩散自适应策略以帮助节点实时协作与信息扩散。最后两种算法分别为用于分布式凸优化的随机无梯度方法（Randomized Gradient-Free Methods, RGF）[27] 和用于随机分布式非凸优化的零阶算法（Zeroth-order algorithms for stochastic distributed nonconvex optimization, SDNO）[143]，它们通过随机采样估计梯度，从而确定分布式优化的搜索方向。

由于目前尚无相关工作研究在传感器仅具备基本方位或距离测量能力时带数据关联的分布式多目标定位问题，同时考虑到 DBM2M 具有梯度不可计算和非凸特性，我们



a) RTT measurement (2D)　b) TDOA measurement (2D)　c) RSS measurement (2D)

d) RTT measurement (3D)　e) TDOA measurement (3D)　f) RSS measurement (3D)

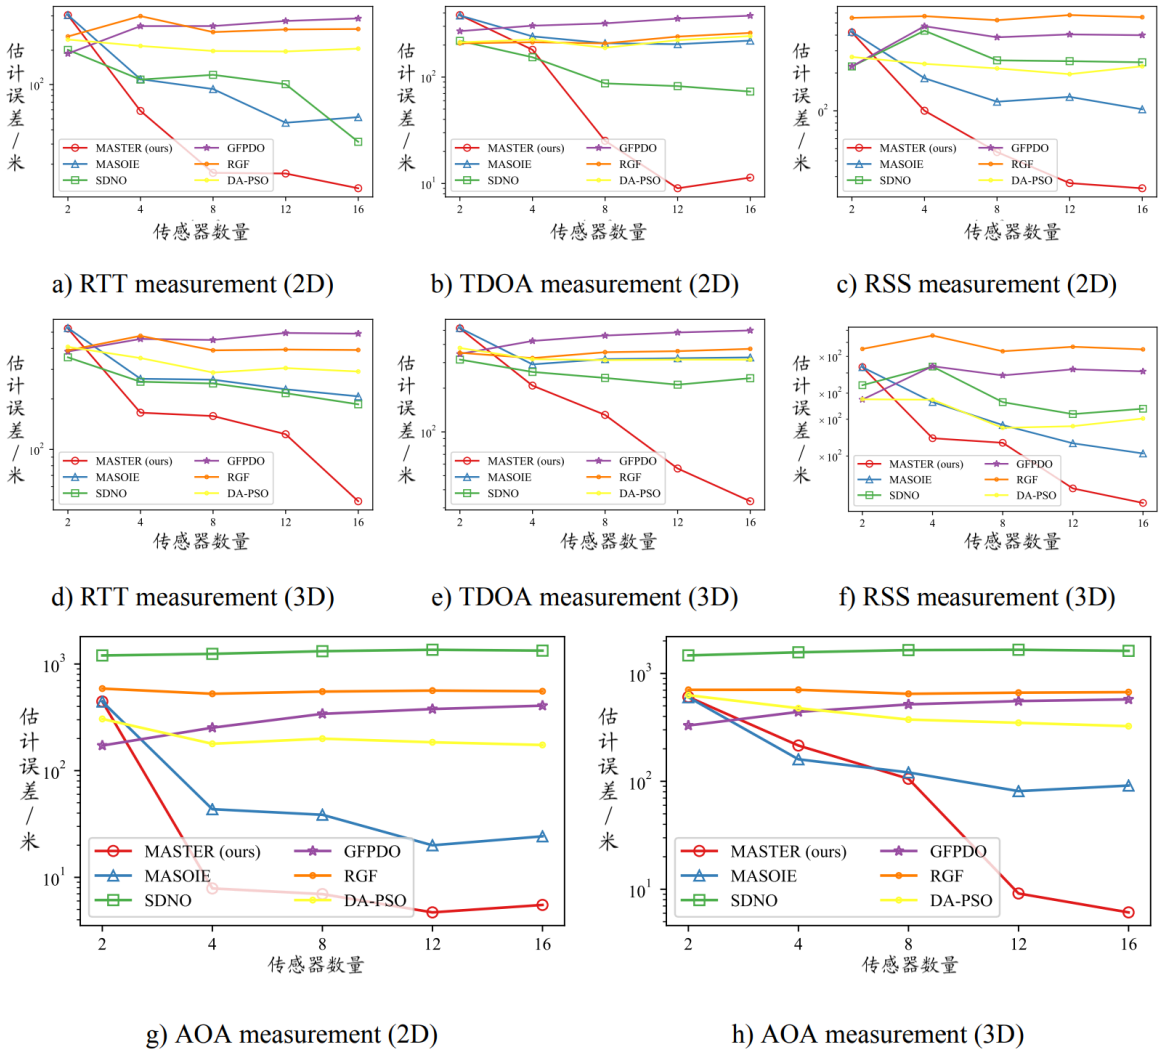
g) AOA measurement (2D)　h) AOA measurement (3D)

图 6-5 MASTER 与对比算法在不同数量的目标和不同的测量技术下的表现

选择上述五种用于分布式连续优化的黑盒优化算法进行比较。由于这些算法并非专门为 DBM2M 设计，我们在其优化过程中嵌入 Kuhn-Munkres 算法。具体而言，我们使用这些算法优化式 (6-6) 中的连续变量 x。在每次计算局部目标函数时，利用 Kuhn-Munkres 算法确定目标与测量之间的数据关联关系。

由于 MASOIE、GFPDO 和 DA-PSO 均为基于种群的算法，其种群规模均设置为与 MASTER 相同，即 300。MASOIE 和 GFPDO 的嵌入算法采用 CSO，与 MASTER 保持一致。DA-PSO 的嵌入算法则与原论文一致，因为其并非通用框架。对于 RGF，初始步长设置为 10，高斯扰动幅值设置为 0.001。SDNO 的步长设置为 $1 * 10^{-3}$。

我们在不同传感器数量和不同目标数量条件下，对 MASTER 及对比算法在 DBM2M 上的性能进行比较。估计误差如图 6-5 和图 6-6 所示，分歧度曲线如图 6-7 所示。实验结果总结如下：（1）根据图 6-5，平均估计误差总体上随着目标数量的增加而增大，尽



a) RTT measurement (2D)　b) TDOA measurement (2D)　c) RSS measurement (2D)

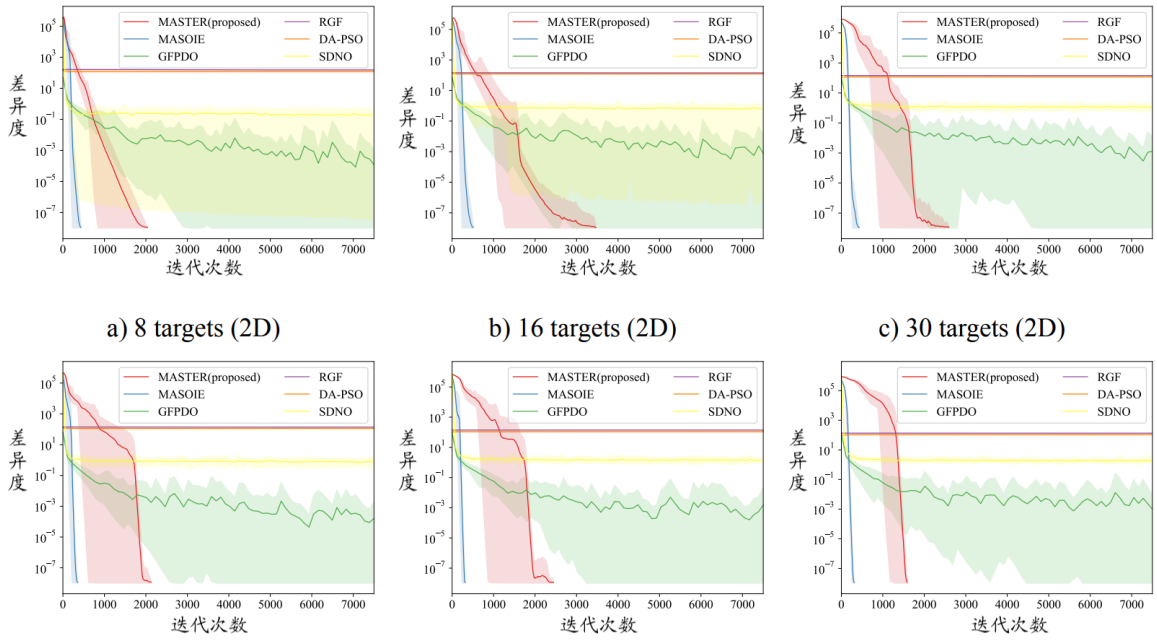
d) RTT measurement (3D)　e) TDOA measurement (3D)　f) RSS measurement (3D)

g) AOA measurement (2D)　h) AOA measurement (3D)

图 6-6 MASTER 与对比算法在不同数量的传感器和不同的测量技术下的表现

管存在少量局部波动。该现象对所有算法均成立。这是因为随着目标数量增加，可能的测量关联数量迅速增长，详见第 6.2.2 节。

（2）根据图 6-6，平均估计误差总体上随着传感器数量增加而降低。这表明更多的协作传感器有助于提升定位效果和抗噪能力。当使用两个传感器时，MASTER 的性能与对比算法接近。然而，随着传感器数量增加，MASTER 的性能显著提升，并明显优于对比算法。这体现了 MASTER 在多传感器协作与共识方面的优势。（3）根据图 6-5 和图 6-6，MASTER 在不同场景下均取得了低于对比算法的估计误差。这说明 MASTER 的优势在于能够在不同测量技术与定位场景下保持较高精度。（4）尽管 MASOIE 在图 6-7 中表现出稳定的共识性能，但即便在仅有四个目标的简单任务中，其估计误差仍高于 MASTER。这是因为系统收敛过快，未能充分探索解空间。（5）当目标数量较少时，SDNO 的性能接近 MASTER，但随着目标数量增加，两者差距逐渐扩大。相应地，根据



a) 8 targets (2D)　b) 16 targets (2D)　c) 30 targets (2D)

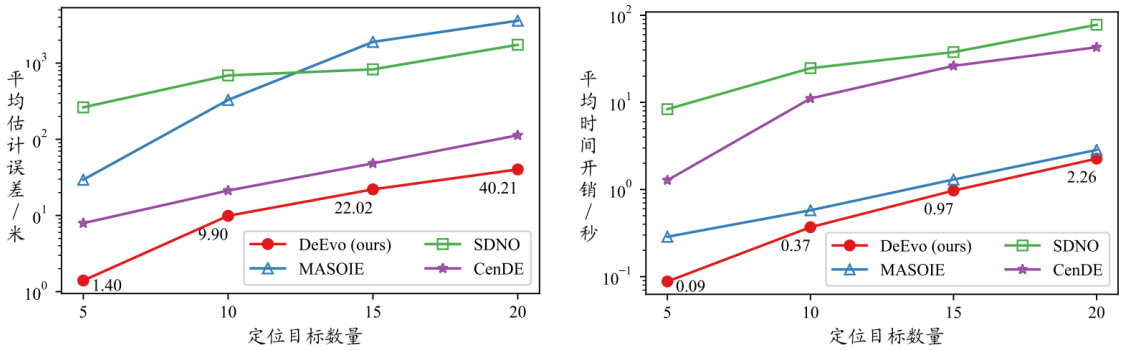
d) 8 targets (3D)　e) 16 targets (3D)　f) 30 targets (3D)

图 6-7 MASTER 与对比算法的 disagreement 曲线。当 disagreement 低于 1×10^{-8} 时，认为系统达到共识（consensus），算法终止。

图 6-7，SDNO 在简单任务中的共识性能优于复杂任务。这表明 SDNO 更适用于少目标定位场景。（6）在图 6-7 中，DA-PSO 和 RGF 的分歧度曲线未呈现明显下降趋势，这是其性能较差的原因之一。

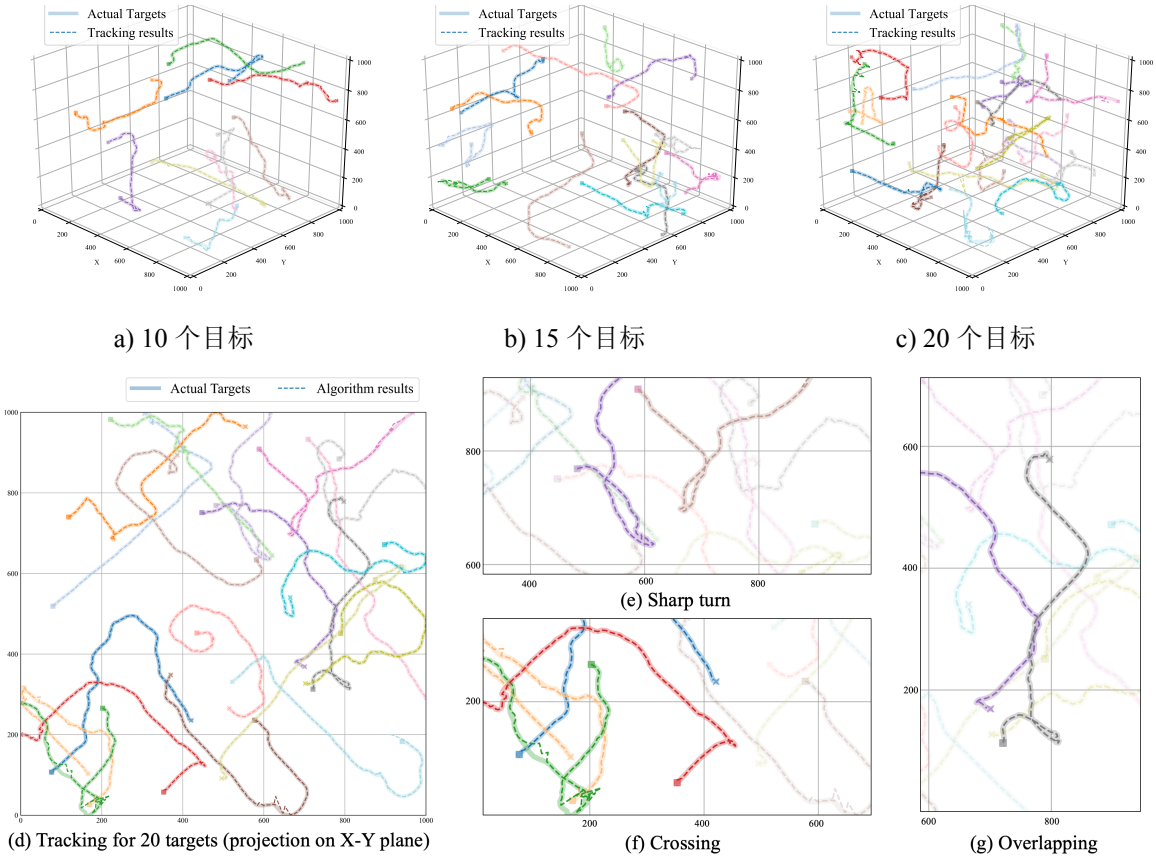
6.6.4　多目标协同追踪效果验证

我们在三维多目标追踪任务上，将 MASTER-T 与三种已有算法进行比较。



a) 估计误差　b) 时间开销

图 6-8 MASTER-T 与现有算法在估计精度和效率方面的性能比较，其中时间开销表示一次定位所需的计算时间。



a) 10 个目标　　b) 15 个目标　　c) 20 个目标

图 6-9 多目标协同追踪方法的连续追踪效果。(a)-(c) 为 MASTER-T 在不同目标数量下的追踪结果。(d) 为 X-Y 平面上的投影，而 (e)-(g) 为从 (d) 中提取的局部细节。粗线表示目标的真实轨迹，细虚线表示 MASTER-T 所跟踪得到的轨迹。每种颜色代表一个目标。

6.6.4.1 追踪精度

图 6-8(a) 的实验结果表明，随着目标数量的增加，所有测试算法的估计误差都会增大。这是因为测量之间的关联搜索空间会随着目标数量的增加呈指数级增长。

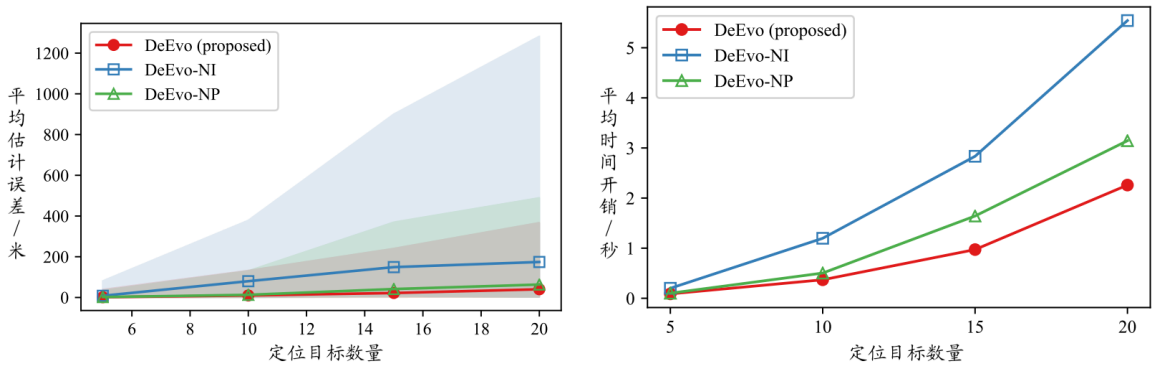
在四个不同目标数量的任务中，MASTER-T 的估计误差均低于对比算法。集中式算法 CenDE 的精度与 MASTER-T 接近，这是因为它不受局部信息和局部通信的限制。然而，由于所有计算负担都集中在单个节点上，CenDE 的时间开销明显高于 MASTER-T。

MASTER-T 的追踪结果如图 6-9(a)-(c) 所示。为了更清晰地展示结果，图 6-9(d) 给出了其在 X-Y 平面上的投影。从图 6-9(d) 可以看出，当目标靠近边界运动时，追踪路径更容易偏离真实轨迹。然而，在短暂偏离之后，追踪路径能够重新回到正确的目标轨迹。因此，所有目标都能够从起点到终点被成功追踪，并且其轨迹关联也能够被正确识别。图 6-9(e)-(g) 展示了三种典型的目标运动行为，包括急转弯、多目标交叉以及两个目标重叠。可以发现，在这三种情况下 MASTER-T 仍然能够有效地完成目标追踪。

6.6.4.2 效率与实时性能

图 6-8(b) 的实验结果展示了一次定位的平均时间开销。与其他算法相比，MASTER-T 具有最低的时间开销。MASOIE 与 MASTER-T 的时间开销较为接近，而 SDNO 的时间开销则明显更大。MASOIE 和 MASTER-T 均基于种群进化算法构建，其搜索过程不依赖固定步长，因此搜索更加灵活且速度更快。

定位时间开销反映了算法的追踪频率。具体而言，在 15 个目标的定位任务中，MASTER-T 的时间开销为 0.97，因此其追踪频率约为每分钟 61 次。在 20 个目标的定位任务中，MASTER-T 的时间开销为 2.26，对应的追踪频率约为每分钟 26 次。总体而言，MASTER-T 相比现有算法具有更好的实时性能。在 20 个并发目标的情况下，MASTER-T 仍然能够保证每分钟超过 26 次的追踪频率。



a) 消融实验：估计误差　　b) 消融实验：时间开销

图 6-10 多目标协同追踪方法的消融实验

6.6.4.3 消融实验

为了验证 MASTER-T 中种群注入策略的有效性，我们设计了两个变体算法：MASTER-T-NI 和 MASTER-T-NP。首先，MASTER-T-NI 不将预测结果注入初始种群。具体而言，将式 (6-25) 中的初始化方式替换为随机初始化。其次，MASTER-T-NP 不使用 Kalman 滤波器预测目标的下一位置。具体而言，在式 (6-25) 中，将当前目标位置 $Q_{U_k}(t)$ 注入种群，而不是预测位置 $\hat{Q}_{U_k}(t+1|\mathcal{L}_k(t))$。

估计误差如图 6-10(a) 所示，时间开销如图 6-10(d) 所示。图 (a) 中的背景填充表示对应颜色曲线的误差范围。实验结果表明：

(1) 在估计误差方面，种群注入策略能够有效降低估计误差。对于 MASTER-T-NI，虽然其估计误差的下界与 MASTER-T 接近，但其上界明显更大。这是因为 MASTER-T-NI

在每个时间隙都会重新开始优化，没有利用目标轨迹的历史信息。对于 MASTER-T-NR，其仅注入当前目标位置，而未考虑目标的运动特性。虽然其性能优于 MASTER-T-NI，但与 MASTER-T 仍存在一定差距。

(2) 在效率方面，种群注入策略能够有效降低时间开销。这是因为注入的信息为种群搜索提供了引导，从而帮助种群更快收敛。由于 MASTER-T 的终止条件是各传感器之间达到一致，因此 MASTER-T 相比 MASTER-T-NI 可以通过更少的迭代完成优化。

6.7 本章小结

本章针对 DM2M 提出了一种基于贡献度协作的多智能体群体优化方法。首先，我们将 DM2M 转化为一个分布式双层优化问题，从而使传感器仅需对连续变量进行协商。随后，采用多智能体群体优化方法对其进行求解。在局部优化阶段，我们结合 Kuhn-Munkres 算法与竞争群体优化算法，对双层局部目标函数进行优化。在邻居协作阶段，我们设计了一种基于贡献度的协作机制，以促进传感器对全局目标进行优化。目前的研究结果表明，在分布式多目标定位测试中，所提出的 MASTER 相比现有算法获得了更小的定位误差和更稳定的共识性能。MASTER 还可推广至不同测量技术，包括 RTT、TDOA、AOA 和 RSS。

随着技术的发展与需求的提升，现实应用问题的建模日益复杂，通常伴随非凸性、混合整数、高维等特征。在这种情况下，问题转化的成本与难度不断增加，传统数值优化方法也越来越难以应对。黑盒分布式优化逐渐成为解决此类问题的潜在有效方法。因此，本研究有望激发更多学者关注黑盒分布式优化技术，以解决更加复杂的实际问题。所提出的算法不依赖数据关联信息、中心节点或高性能设备，因而具有集成到现有系统中的潜力。尽管 MASTER 相比现有算法取得了更优性能，但在面对大规模目标时仍存在一定估计误差。这是因为数据关联的复杂度随着目标数量呈指数增长。因此，在后续研究中，有必要探索如何将问题划分为多个子问题并协同求解，从而提升定位能力的上限。此外，未来研究还将考虑更多实际因素，如虚警和跟踪安全问题[144-145]。

第七章　基于多智能体共识优化的分布式能源博弈与管理方法

7.1　引言

去中心化能源管理（Distributed Energy Resource, DER）是指在没有中央控制器的情况下，在由去中心化实体（如发电站、储能单元和终端用户）组成的网络中协调能源分配[146-149]。具体而言，每个智能体可以基于自身的隐私信息计算其局部目标函数，这些信息包括设备参数、电力存储容量等。DER 的全局目标是最大化电网的整体收益，该收益被定义为所有局部收益之和。与集中式能源管理相比，DER 具有更好的可扩展性、鲁棒性以及抗故障能力，因此吸引了研究者的广泛关注[150-154]。近年来，电池技术的进步推动了电动汽车（Electric Vehicle, EV）数量的快速增长。大量充电站已在城市区域部署，EV 充电所消耗的电网电力比例持续上升。由于 EV 的充电行为会显著影响电网运行，研究考虑 EV 充电行为的去中心化能源管理（Distributed Energy Resource Management considering Electric Vehicles,DER-EV）具有重要的研究意义[155-158]。

分布式进化计算近年来受到研究者的广泛关注，在解决黑盒、非凸分布式共识优化问题方面展现出巨大潜力[159-160]。现有算法的一般框架是在每个智能体中维护一个子种群，并通过多智能体之间的协同进化实现优化[70-72,97,161]。例如，Chen 等[97] 提出了一种多智能体群体优化方法，通过自适应的内部与外部学习机制实现智能体之间的协作。在[161] 中，在多智能体优化框架下为进化策略设计了协作与累计步长自适应机制。

然而，考虑 EV 的自主决策行为将为去中心化电力分配带来巨大挑战。首先，EV 的自主决策行为会对电网的供需平衡构成挑战。不同于工业或居民用电，EV 的充电行为无法提前调度，也无法由电网系统直接控制。EV 车主在决策时会考虑充电价格、出行规划、电池老化等因素以最大化自身收益[162-164]。因此，在电动汽车参与的情况下，确保电力系统供需平衡具有较大难度。其次，电网智能体之间的信息不完全性以及局部通信范围给去中心化优化带来了显著困难[165-166]。在去中心化系统中，每个智能体只能获取自身的局部信息和局部目标函数。此外，智能体通过无中心节点的通信网络连接，只能与邻居进行通信。因此，如何设计一种算法使智能体在有限数据与通信范围下协作优化全局目标，是一个具有挑战性的问题。

针对上述挑战，本章提出了一种改进的多智能体粒子群优化方法（Multi-Agent

Swarm Optimization With Adaptive Internal and External Learning considering game behaviors MASOIE-G）以解决 DER-EV 问题。基于具有内部与外部学习机制的多智能体群体优化框架[97]，每个智能体维护一个粒子群，每个粒子表示一个候选的能源管理方案。各智能体通过协同进化各自的粒子群以优化全局目标函数。本章的主要贡献如下：

1) 为了在 EV 参与的电网系统中实现供需平衡，我们在内部学习阶段设计了一种用于自适应定价的演化博弈策略。实验结果表明，该定价策略能够有效响应供需变化：当供给压力较大时提高价格，当供给过剩时降低价格。
2) 为了在有限数据与通信范围下实现智能体协同优化全局目标，我们设计了一种具有可变邻居权重的外部学习方法，使智能体能够从多个邻居中学习有效信息。该方法根据邻居适应度提升情况动态调整其重要性权重。消融实验表明，该方法在所有测试场景下均取得更优性能。

本章其余结构安排如下。第 7.2 节介绍问题模型与数学表述。第 7.3 节详细阐述所提出的多智能体粒子群优化方法。第 7.4 节进行多组实验验证。最后，第 7.5 节对本章进行总结。

7.2 分布式能源博弈与管理问题定义

本节首先将电网系统建模为一个多智能体系统，其次介绍系统中各类智能体的损失函数。

表 7-1 MASOIE-G 相关符号说明

符号	含义	符号	含义
n_{CG}, n_{ESS}, n_{EVS}	三类智能体的数量	n	智能体总数
$\mathcal{N}_i$	智能体 i 的邻居集合	$\mathcal{V}$	智能体集合
$\mathcal{E}$	通信边集合	$P_{i,G}$	第 (i,G) 个 CG 的发电功率
$P_{i,S}$	第 (i,S) 个 ESS 的输出功率	$P_{i,B}$	第 (i,B) 个 BL 的用电功率
$P_{i,E}$	第 (i,E) 个 EVS 的用电功率	$w_{i,E}$	第 (i,E) 个 EVS 的电价
$N_{i,E}$	第 (i,E) 个 EVS 所在区域的车辆数量		
缩写	全称	缩写	全称
EV	电动汽车	CG	常规发电机组
ESS	储能系统	EVS	电动汽车充电站
BL	基础负载		

7.2.1 分布式能源系统

如图 7-1 所示，考虑一个包含四类单元的电网系统，分别为常规发电机组（Conventional Generator, CG）、储能系统（Energy Storage System, ESS）、电动汽车充电站（Electric Vehicle Charging Station, EVS）以及基础负载（Base Load, BL）。电网中的基础负载指用于照明、供暖或关键工业运行等用途的用电需求。这类电力需求相对稳定且不可调节。因此，在本问题模型中，基础负载的用电功率 $P_{i,B}$ 被视为常数，而非优化变量。

因此，我们将电网系统建模为一个多智能体系统，其中每个智能体对应电网中的前三类单元（不包括基础负载）。智能体具备计算与通信能力。在该系统中，智能体通过通信网络 $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ 相互连接。节点集合为 $\mathcal{V} = \{v_1, v_2, ..., v_n\}$，其中 $n = n_{CG} + n_{ESS} + n_{EVS} + n_{BL}$。边集合 $\mathcal{E}$ 表示智能体之间的连接关系。当 $(i, j) \in \mathcal{E}$ 时，表示智能体 i 与智能体 j 相连。

7.2.2 电力节点的损失函数

下文分别介绍四类智能体的损失函数。

7.2.2.1 传统发电站 (CG)

常规发电机组可以按照计划方式发电。记第 (i, G) 个 CG 的发电功率为 $P_{i,G}$，其生产成本随发电量变化如下：

$$\begin{aligned} f_{i,G}(P_{i,G}) &= \frac{1}{2} a_{i,G} P_{i,G}^2 + b_{i,G} P_{i,G} + c_{i,G} \\ \text{s. t. } & P_{i,G}^{\min} \leq P_{i,G} \leq P_{i,G}^{\max} \end{aligned} \tag{7-1}$$

其中，成本系数 $a_{i,G}, b_{i,G}$, 和 $c_{i,G}$ 为正常数。$P_{i,G}^{\min}$ 和 $P_{i,G}^{\max}$ 分别表示发电量的下界与上界。

7.2.2.2 能源存储系统 (ESS)

在电网中，ESS 可以储存来自电网的多余电能，并在电网需求超过发电量时补充电力。因此，第 (i, S) 个 ESS 的输出功率 $P_{i,S}$ 可以为正或为负。当 $P_{i,S}$ 为正时，储能站向电网供电；当 $P_{i,S}$ 为负时，其从常规发电机组吸收电能。ESS 的损失函数包括充放电效率成本 $C_{i,S}(P_{i,S})$ 以及电池老化成本 $B_{i,S}(P_{i,S})$：

$$\begin{aligned} f_{i,S}(P_{i,S}) &= C_{i,S}(P_{i,S}) + B_{i,S}(P_{i,S}) \\ \text{其中 } C_{i,S}(P_{i,S}) &= \frac{1}{2} a_{i,S} P_{i,S}^2 + b_{i,S} P_{i,S} \\ B_{i,S}(P_{i,S}) &= \rho \times |P_{i,S}|, \text{ 且} P_{i,S}^{\min} \leq P_{i,S} \leq P_{i,S}^{\max} \end{aligned} \tag{7-2}$$

其中，ρ 为单位充放电功率对应的电池成本。成本系数 $a_{i,S}$ 和 $b_{i,S}$ 为正常数。$P_{i,S}^{\min}$ 为最大充电功率的相反数，$P_{i,S}^{\max}$ 为最大放电功率。

7.2.2.3 电动车充电站

在本问题中，每个电动汽车充电站负责满足其指定区域内电动汽车的充电需求，该区域内包含多个充电桩。每个充电站可以通过调整其内部定价策略来影响用户的充电偏好。

给定单位电价 $w_{i,E}$ 和充电量 v_j，电动汽车的收益函数定义如下：

$$\begin{aligned} &\text{profit}(v_j, w_{i,E}) = w_{i,E} v_j + R(v_j + v_j^0) - R(v_j^0) \\ &\text{where} \quad R(v) = v^2 - (\gamma+1)v + \gamma, \ \ \gamma > 1 \\ &\text{and} \quad v^{\min} \le v_j + v_j^0 \le v^{\max} \end{aligned} \tag{7-3}$$

其中，v_j^0 表示车辆的剩余电量。$R(v)$ 表示当车辆电量为 v 时所产生的经济损失。剩余电量 v 越低，出行需求越容易受到影响，从而增加经济活动延误的可能性，并导致更高的经济损失 $R(v)$。

基于电动汽车的收益函数，售电收益可表示为：

$$\begin{aligned} &\text{Revenue} = -w_{i,E} Q_{i,E} \\ &\text{where} \quad Q_{i,E} = \sum_{j \in [1, N_{i,E}]} \arg\max_{v_j} \text{profit}(v_j, w_{i,E}) \end{aligned} \tag{7-4}$$

其中，$w_{i,E}$ 为第 (i,E) 个充电站的充电价格，$N_{i,E}$ 为对应区域内的电动汽车数量。EVS 的用电功率 $Q_{i,E}$ 取决于电动汽车的个体决策。具体而言，每辆电动汽车将根据电价选择使自身收益最大的充电量。

然而，电网的电力供应通常需要提前规划。如果系统完全依赖电动汽车的自主决策，可能会导致供需失衡。当 EV 需求较高时，电网可能出现电力短缺，严重情况下甚至导致过载或停电。相反，当 EV 需求较低时，则会造成电力资源闲置和经济效率下降。因此，有必要通过定价机制调节 EV 需求，以确保电网内部的供需平衡。

给定计划分配的功率 $P_{i,E}$，第 (i,E) 个 EVS 的损失函数定义如下：

$$f_{i,E}(P_{i,E}) = -w_{i,E} P_{i,E} \tag{7-5a}$$

$$\text{s. t.} \ \ w_{i,E} \in \arg\min_{w} |P_{i,E} - Q_{i,E}| \tag{7-5b}$$

$$\text{and} \quad Q_{i,E} = \sum_{j\in[1,N_{i,E}]} \arg\max_{v_j} \text{profit}(v_j, w_{i,E}) \tag{7-5c}$$

其中，$w_{i,E}$ 表示用于平衡供需的最优价格。

7.2.3 全局优化问题定义

基于各类智能体的损失函数，DER-EV 问题的全局目标函数定义如下：

$$\min \sum_{i=1}^{n_{CG}} f_{i,G}(P_{i,G}) + \sum_{i=1}^{n_{ESS}} f_{i,S}(P_{i,S}) + \sum_{i=1}^{n_{EVS}} f_{i,E}(P_{i,E}) \tag{7-6a}$$

$$\text{s. t.} \sum_{(i,G)\in\mathcal{V}} (1-\eta)P_{i,G} + \sum_{(i,S)\in\mathcal{V}} (1-\eta)P_{i,S} = \sum_{(i,E)\in\mathcal{V}} (1+\eta)P_{i,E} + (1+\eta)P_{i,B} \tag{7-6b}$$

其中，η 为输电过程中的功率损耗系数。式 (7-6b) 中的约束要求电网系统在供给与需求之间保持平衡。

为使问题表述更加简洁，我们统一用 f_i 表示智能体的损失函数。若第 i 个智能体为 CG，则 $f_i(*)$ 表示式 (7-1) 中的 $f_{i,G}(*)$；若第 i 个智能体为 ESS，则 $f_i(*)$ 表示式 (7-2) 中的 $f_{i,S}(*)$；否则，若第 i 个智能体为 EVS，则 $f_i(*)$ 表示式 (7-5) 中的 $f_{i,E}(*)$。同时，我们用向量 $\mathbf{x} = [x_1, x_2, ..., x_n]$ 表示能源管理方案，其中 x_i 表示第 i 个智能体的发电或用电功率。最终，DER-EV 问题可定义如下：

$$\min F(\mathbf{x}) = \sum_{i=1}^{n} f_i(x_i) \ \text{ s. t. } \ \sum_{i=1}^{n} \theta_i x_i = (1+\eta)P_{i,B} \tag{7-7}$$

其中，对于 CG 和 ESS 智能体，$\theta_i = 1-\eta$；对于 EVS 智能体，$\theta_i = -(1+\eta)$。

需要指出的是，在 DER-EV 问题中，每个智能体 i 只能访问其局部目标函数 f_i。由于无法获取其他智能体的信息和参数，全局目标函数 F 对各智能体而言是不可访问的。

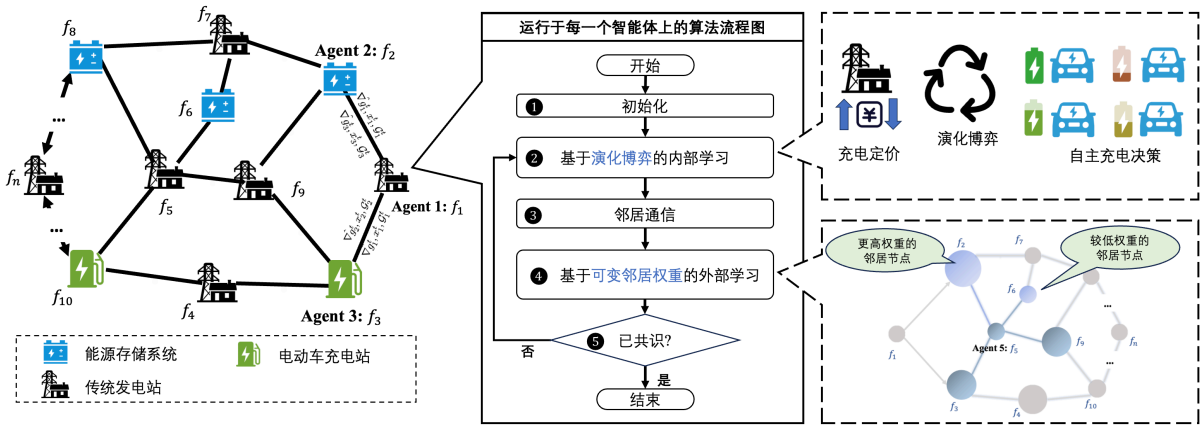


图 7-1 MASOIE-G 算法框架

因此，DER-EV 问题面临以下三个主要挑战：

(1) 信息不完全: 如上所述，每个智能体只能访问其局部目标函数。然而，如果每个节点仅优化自身局部目标，则难以实现系统全局收益的最大化。因此，在仅有局部信息可用的情况下，如何实现节点协同以优化全局目标，是一个重大挑战。

(2) 去中心化通信: 如第 2.1 节所述，智能体通过去中心化通信网络相连。因此，智能体只能与邻居进行通信。在不存在中心节点的情况下，优化全局问题具有较高难度。

(3) 梯度不可计算: 式 (7-5) 中的目标函数梯度涉及双层优化问题，其中式 (7-5a) 的计算依赖于式 (7-5b) 与式 (7-5c) 的最优解。因此，局部目标函数 $f_{i,E}(*)$ 的梯度无法显式求得。

7.3 基于多智能体共识优化的分布式能源博弈与管理方法

DER-EV 问题是一个典型的分布式共识优化问题，同时存在梯度不可计算的挑战。面对这一挑战，分布式进化算法具有潜在优势，因为其不依赖于梯度信息或问题的数学特性。

在现有算法中，具有内部与外部学习机制的多智能体群体优化方法（Multi-Agent Swarm Optimization With Adaptive Internal and External Learning, MASOIE）[97] 是一种适合扩展的分布式进化计算框架。在该框架中，每个智能体维护一个粒子群，每个粒子代表一个候选解。MASOIE 的基本思想是在内部学习与外部学习之间交替进行，直至多智能体系统达成共识。

基于 MASOIE 框架，本章提出了一种结合演化博弈的多智能体粒子群优化算法（MASOIE-G），用于求解 DER-EV 问题。在 MASOIE-G 中，我们进行了如下两点改进。首先，针对 DER-EV 问题中的供需平衡挑战，在内部学习阶段设计了一种融合演化博弈的全新方法。其次，考虑到局部目标函数之间可能存在冲突，我们设计了一种具有可变邻居权重的外部学习方法。

7.3.1 算法框架

图 7-1 展示了 MASOIE-G 的整体框架，包括以下五个主要步骤：

1) **初始化**: 算法开始时，每个智能体 i 创建一个包含 m 个粒子的粒子群 $S_i = (X_i, V_i)$，其中每个粒子代表一个能源管理候选方案。这里，$X_i = (x_{i,1}, x_{i,2}, ..., x_{i,m})$ 和 $V_i = (v_{i,1}, v_{i,2}, ..., v_{i,m})$ 分别表示粒子群的位置和速度。

2) **内部学习**: 在该阶段，每个智能体 i 基于其局部目标函数 $f_i(*)$ 演化自身的粒子群。为使 EVS 智能体能够找到合理价格以平衡供需，我们在内部学习阶段引入了一种用于定价的演化博弈策略，详见第 7.3.2 节。
3) **邻居通信**: 在该阶段，智能体通过通信网络向邻居发送其候选解。当一个智能体接收到所有邻居的消息后，进入下一阶段。
4) **外部学习**: 在该阶段，智能体协作以优化全局目标函数。为帮助智能体从多个邻居中学习有效信息，我们设计了一种具有可变邻居权重的外部学习方法，详见第 7.3.3 节。
5) **终止判定**: 当所有智能体在能源管理方案上达成共识时，算法终止。共识性判定如下：

$$\sum_{a=1}^{m}\sum_{j\in\mathcal{N}_i}\|x_{i,a}-x_{j,a}\|<\kappa \tag{7-8}$$

其中，κ 为接近零的一个小常数。

MASOIE-G 的整体流程如算法 7-10 所示。通信间隔调整方法与 MASOIE 相同。

7.3.2 基于演化博弈的内部学习

内部学习是指智能体独立改进自身粒子群的过程。在该阶段，粒子从当前种群中的精英粒子进行学习。在 MASOIE 中，第 i 个智能体中第 a 个粒子的更新规则如下：

$$\begin{aligned} v_{i,a}^{t+1} &= r_1 v_{i,a}^{t} + r_2(x_{i,b}^{t}-x_{i,a}^{t}) + \phi r_3(x_{i,c}^{t}-x_{i,a}^{t}) \\ x_{i,a}^{t+1} &= x_{i,a}^{t} + v_{i,a}^{t+1} \end{aligned} \tag{7-9}$$

其中，r_1, r_2, and r_3 为 $(0,1)$ 区间内的随机权重，ϕ 为常数参数。此外，$x_{i,b}$ 与 $x_{i,c}$ 为种群中选取的两个精英粒子。

在 DER-EV 问题中，供需平衡对于保障电网系统的正常运行至关重要。因此，MASOIE 中的内部学习机制无法直接应用于 DER-EV 问题，因为其设计面向一般优化问题，并未考虑供需平衡约束。

为帮助 EVS 智能体实现供需平衡，我们在内部学习中设计了一种合理的定价机制。考虑到车辆始终自主进行充电决策，我们基于演化博弈设计该定价机制。

在所设计的演化博弈中，参与者包括一个充电站和多个电动汽车。充电站的博弈变量为价格 $w_{i,E}$，第 j 个（$j=1,2,...,N_{i,E}$）电动汽车的博弈变量为充电量 v_j。当 $v_j<0$ 时，表示电动汽车向电网反向售电。在博弈过程中，电动汽车与充电站不断进行决策直

至电价稳定，此时可视为博弈结束。演化博弈过程如算法 7-11 所示。

7.3.3 基于可变邻居权重的外部学习

外部学习是指粒子向邻居智能体中的粒子学习的过程。在 MASOIE 中，第 i 个智能体第 a 个粒子在外部学习阶段的更新规则为：

$$\begin{aligned} v_{i,a}^{t+1} &= \varphi r_4 v_{i,a}^{t} + \sum_{j \in \mathcal{N}_i} \omega_{i,j}(x_{j,a}^{t} - x_{i,a}^{t}) \\ x_{i,a}^{t+1} &= x_{i,a}^{t} + v_{i,a}^{t+1} \end{aligned} \tag{7-10}$$

其中，r_4 为 $(0,1)$ 区间内的随机权重，φ 为常数参数。

Algorithm 7-10 MASOIE-G（每个智能体的执行过程）

输入:

/* 初始化 */
初始化粒子群 $X_i \in \mathbb{R}^{m \times D}$ 和 $V_i \in \mathbb{R}^{m \times D}$
while 未满足共识条件 **do**
    /* 内部学习 */
    for $a = 1, 2, ..., m$ **do**
        基于[97] 中的分层学习机制选择两个精英粒子, 并根据式 (7-9) 更新第 a 个粒子的位置与速度
        if 智能体 i 为 EVS **then**
            基于能源管理解 $x_{i,a}$ 进行定价，并根据式 (7-5) 的局部目标函数评估粒子 $x_{i,a}$
        else
            根据式 (7-1)、(7-2) 的局部目标函数评估粒子 $x_{i,a}$
        end if
    end for
    /* 邻居通信 */
    向邻居发送种群 X_i 及适应度改进量 $[\xi_{i,a}]_{a=1,2,...,\|P\|}$
    从邻居 $j \in \mathcal{N}_i$ 接收种群 X_j 及贡献度 $[\xi_{j,a}]_{1 \times \|P\|}$
    /* 外部学习 */
    for $a = 1, 2, ..., m$ **do**
        根据式 (7-10) 与式 (7-11) 更新第 a 个粒子的位置与速度
    end for
end while
计算共识解 $\overline{X_i} = \frac{1}{m}\sum_{a=1}^{m} x_{i,a}$

输出: $\overline{X_i}$

Algorithm 7-11 基于演化博弈的内部学习定价机制

输入: 第 (i,E) 个 EVS 的发电计划 $P_{i,E}$

1: 设定初始价格 $w_{i,E}^0$，迭代次数 $t=0$

2: **while** 价格未稳定 **do**

3: /* 车辆决策 */

4: **for** 车辆 $j=1,2,...,N_{i,E}$ **do**

5: 根据式 (7-3) 更新 $v_j^t = \arg\max_{v_j} \text{profit}(v_j, w_{i,E}^t)$

6: **end for**

7: /* 价格调整 */

8: 更新 $w_{i,E}^{t+1} = \begin{cases} w_{i,E}^t + \epsilon & \sum_{j=1}^{N_{i,E}} v_j^t > P_{i,E} \\ w_{i,E}^t - \epsilon & \sum_{j=1}^{N_{i,E}} v_j^t < P_{i,E} \\ w_{i,E}^t & \sum_{j=1}^{N_{i,E}} v_j^t = P_{i,E} \end{cases}$

9: $t = t+1$

10: **end while**

输出: $w_{i,E}$

在 DER-EV 问题中，各局部目标函数之间存在冲突且不平衡。因此，式 7-10 所示的外部学习规则并不适用于该问题，因为邻居权重 $\omega_{i,j}$ 在不同测试场景中是固定的。

为帮助智能体从多个邻居中选择并学习有效信息，我们设计了一种可变邻居权重机制。在新的权重机制中，考虑邻居的适应度改进程度。邻居取得的适应度改进越大，其权重越高。新的权重 $\mathcal{K}_{i,j}$ 定义如下：

$$\begin{aligned} \mathcal{K}_{i,j} =& \phi\omega_{i,j} + (1-\phi)\frac{\xi_{j,a}}{\sum_{j\in\mathcal{N}_i\cup\{i\}}\xi_{j,a}} \\ \text{where } \xi_{i,a} =& \begin{cases} 0, & f_i(x_{i,a}(t+\frac{1}{2})) >= f_i(x_{i,a}(t)) \\ \frac{f_i(x_{i,a}(t))-f_i(x_{i,a}(t+\frac{1}{2}))}{\|x_{i,a}(t)-x_{i,a}(t+\frac{1}{2})\|^2}, & \text{otherwise} \end{cases} \end{aligned} \tag{7-11}$$

其中，ϕ 为固定参数。在 MASOIE-G 的外部学习阶段，用可变邻居权重 $\mathcal{K}_{i,j}$ 替代式 (7-10) 中的固定权重 $\omega_{i,j}$。

7.4 实验

7.4.1 实验设置

在实验中，我们基于 IEEE-39 节点系统测试算法性能。如图 7-2 所示，系统中共有 28 个智能体，包括 9 个常规发电机、5 个储能节点以及 14 个电动汽车充电站。

电网系统的参数设置如表 7-2 所示，参考文献[167]。为验证算法在不同实际工况下的性能，我们设计了以下四种特殊测试场景：

- Case 1: 常规发电机的单位发电成本不一致。在该场景中，将部分 CG 的参数 $a_{i,G}, b_{i,G}$ 设置为较大值。
- Case 2: 储能节点的单位存储成本不一致。在该场景中，将部分 ESS 的参数 $a_{i,S}, b_{i,S}$ 设置为较大值。
- Case 3: 电力供应紧张且需求较高。在该场景中，将基础负荷 $P_{i,B}$ 设置为较大值。
- Case 4: 电力供应冗余且需求较低。在该场景中，将基础负荷 $P_{i,B}$ 设置为较小值。

以下实验在由 AMD EPYC 64-Core Processor 和 CentOS 7.9 x64 系统组成的计算集群上完成。

表 7-2 MASOIE-G 实验参数设置

问题参数					
符号	含义	设置	符号	含义	设置
$a_{i,G}, b_{i,G}$	第 (i,G) 个 CG 的参数	0.086, 2.482	$P_{i,G}^{\min}, P_{i,G}^{\max}$	发电功率上下界	20, 70
$P_{i,S}^{\min}, P_{i,S}^{\max}$	储能功率上下界	-20, 50	$a_{i,S}, b_{i,S}$	第 (i,S) 个 ESS 的参数	0.2092, 0.072
ρ	第 (i,S) 个 ESS 的参数	0.058	γ	EV 收益函数参数	5.0
η	功率损耗系数	0.005	$N_{i,E}$	车辆数量	$100 \sim 300$
MASOIE-G 参数					
符号	含义	设置	符号	含义	设置
m	粒子群规模	50	ϕ	式 (7-11) 中的参数	0.2
φ	式 (7-9) 中的参数	0.5	κ	终止判定参数	1×10^{-6}

7.4.2 对比算法

我们将所提出的算法与四种现有的分布式优化算法进行比较。第一种是 MASOIE[97]，其通过自适应的内部学习与外部学习机制求解基于共识的分布式优化问题。第二种是基于种群的分布式优化通用框架（General Framework for Population-based Distributed Optimization, GFPDO）[70]，该方法采用平均共识理论进行分布式计算。第三种是 DA-PSO (Distributed particle swarm optimization algorithm using the strategies of diffusion adaptation) 是一种分布式粒子群优化算法[71]，其在分布式环境下提出了扩散自适应的信息融合策略。最后一种是用于分布式凸优化的随机无梯度方法（Randomized Gradient-Free Methods, RGF）[27]，该方法通过随机采样估计梯度以实现分布式优化。

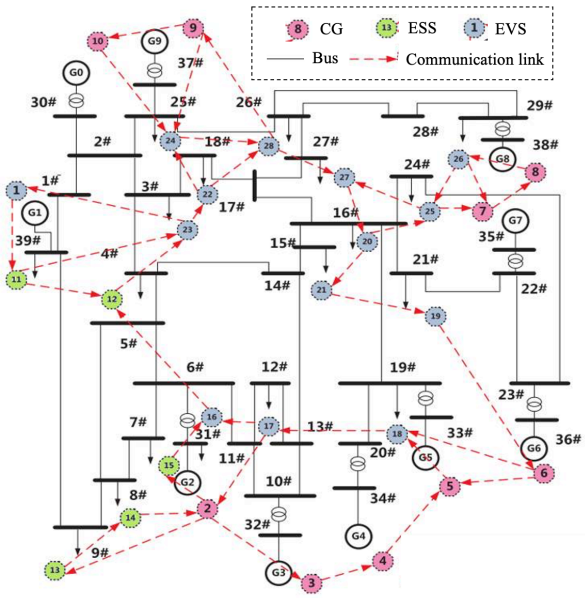


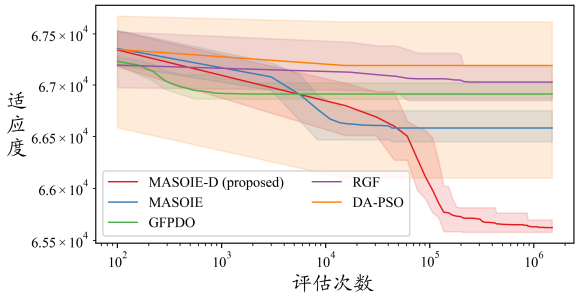
图 7-2 IEEE-39 节点系统示意图

对比算法的参数设置如下。对于基于种群的算法，包括 MASOIE、GFPDO 和 DA-PSO，其种群规模均设置为 50。对于 RGF，初始步长设置为 1E-5，高斯扰动幅值设置为 0.001。此外，所提出算法 MASOIE-G 的详细参数设置见表 7-2。

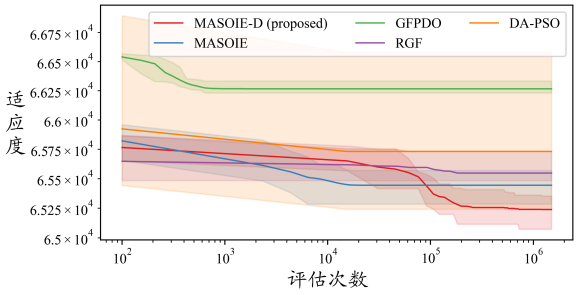
7.4.3 优化性能比较与分析

MASOIE-G 与对比算法的优化性能如图 7-3 所示。根据图 7-3(a)-(d) 中的适应度曲线，可以得到如下结论：(1) MASOIE-G 获得了优于对比算法的适应度值。在早期阶段，MASOIE、RGF 和 DA-PSO 的适应度曲线与 MASOIE-G 接近。然而在后期阶段，MASOIE-G 具有更强的开发能力（exploitation）。GFPDO 的表现不如其他算法，这是因为其在早期阶段即收敛到局部最优。(2) 由于 MASOIE-G 基于 MASOIE 开发，因此 MASOIE-G 与 MASOIE 之间的对比验证了所提出的可变邻居权重外部学习方法的有效性。

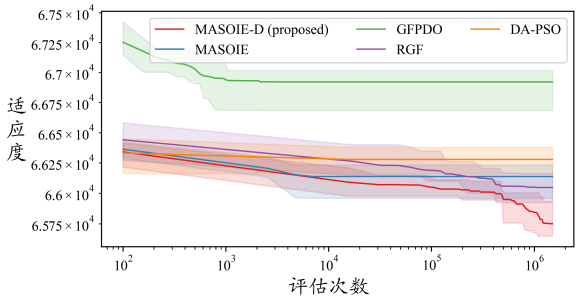
图 7-3(e) 展示了 MASOIE-G 求得的发电方案。在该图中，我们绘制了系统中十台 CG 在四种特殊场景下的发电量。可以得到如下结论：(1) 在 case-1 中，CG-1 的发电量显著低于其他场景。在 case-1 下，CG-1 的发电量几乎达到其发电能力下限。这是因为在第一种场景中，CG-1 的参数 $a_{i,G}, b_{i,G}$ 被设置为较大的数值。该结果表明 MASOIE-G 能够考虑发电成本，并找到发电成本更低的方案。(2) 对于全部十台发电机而言，case-3 下的发电量高于 case-4。这是因为根据第 5.1 节的设置，case-3 的基础负荷高于 case-4。该结果表明 MASOIE-G 能够有效响应负荷变化。



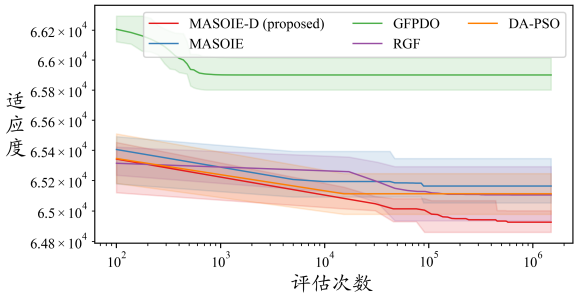
a) Case 1



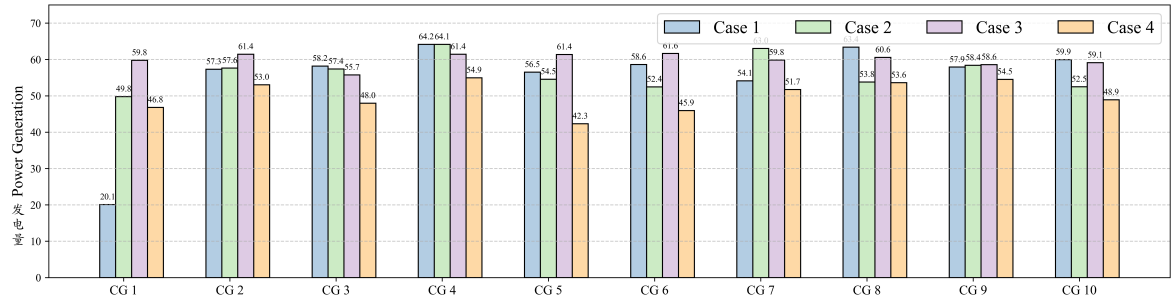
b) Case 2



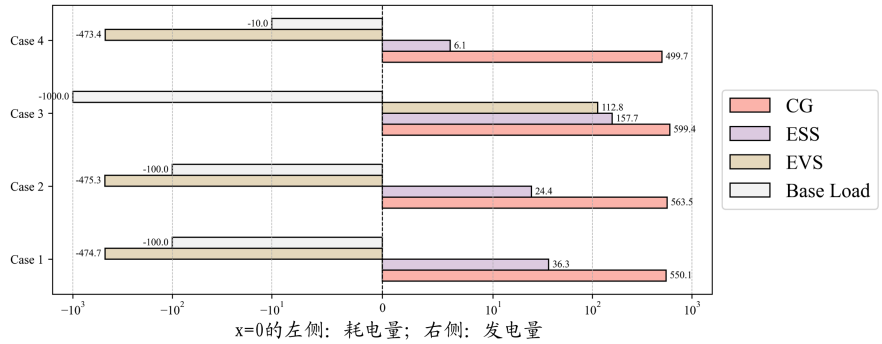
c) Case 3



d) Case 4



e) 由 MASOIE-G 优化得到的十台 CG 的发电方案。



f) 四类智能体的发电或用电情况。

图 7-3 MASOIE-G 与对比算法的整体性能

图 7-3(f) 展示了四类智能体的发电或用电情况。每一类的功率值为所有同类型智能体功率之和。根据该图，可以得到如下结论：(1) 对于 CG 智能体和 ESS 智能体而言，case-3 下的发电量在四种场景中最高，而 case-4 下最低。这是因为 case-3 的基础负荷设置为 1000，而 case-4 为 10。这些结果表明 MASOIE-G 能够响应不同的需求水平。(2) 当第三种场景下电网供给紧张时，可以发现 EVS 智能体也能够作为供给侧发电。这是因为 MASOIE-G 能够自适应提高电价，从而降低充电需求，并激励车辆反向售电。该结果表明 MASOIE-G 所提出的定价策略在不同特殊场景下能够有效平衡供需关系。

7.5 本章小结

本章针对 DER-EV 问题提出了一种改进的多智能体粒子群优化方法（MASOIE-G）。首先，为了在电动汽车参与下实现电网系统的供需平衡，我们在内部学习阶段设计了一种基于演化博弈的自适应定价策略。其次，为了在有限数据与通信范围条件下实现多智能体协同优化全局目标，我们设计了一种可变邻居权重的外部学习方法，以帮助智能体从多个邻居中学习有效信息。实验结果表明，所提出的定价策略能够有效响应供需变化：当供给压力较大时提高电价，当供给过剩时降低电价。未来工作将考虑多日连续决策的能源管理问题，并提升所提算法在不同复杂工况下的鲁棒性。

总结与展望

随着物联网、智能制造与大规模网络化系统的发展，复杂系统呈现出数据分散、目标分散与通信受限等典型特征，使传统集中式优化方法在许多实际应用中难以适用。针对这一问题，本文围绕多智能体黑箱分布式优化展开研究，结合进化计算的全局搜索能力与多智能体共识理论，从群体协同演化机制、采样搜索协同机制以及目标激励协调机制三个层面，系统研究了去中心化环境下多智能体协同优化问题，并在无线传感器网络与智能电网等典型场景中进行了应用验证。围绕上述研究目标，本文取得如下成果：

（1） 提出了一种基于内外学习机制的多智能体群体优化算法（MASOIE），通过内部学习与外部学习相结合的群体协同机制，使各智能体在仅能访问局部目标函数与邻居信息的条件下实现共识优化。通过共识理论与动力系统分析，对算法的稳定性进行了理论分析，并通过大量实验验证了其在解质量与通信效率方面的优势。

（2） 提出了具有协作与累积步长自适应机制的多智能体进化策略（CCSA-DES），通过分析多智能体搜索路径之间的一致性与冲突关系，设计了协作与累积步长自适应机制，使算法能够在保持探索能力的同时提升系统共识性。理论分析与实验结果表明，该方法在黑箱分布式优化问题上具有更好的收敛性能与解质量。

（3） 提出了基于惩罚目标函数的多智能体协同进化框架（MACPO），通过引入冲突检测与自适应惩罚机制，引导各智能体在仅能访问局部目标函数的情况下逐步达成共识解。同时，设计了评估—竞争—共享三阶段协商机制，实现共享变量的协同优化。实验结果表明，该方法在分布式优化问题中具有良好的可扩展性与优化性能。

（4） 在无线传感器网络多目标定位问题中，提出了基于贡献度协作的多智能体群体优化算法（MASTER）。通过将原始问题重构为双层优化问题，实现了连续变量与离散变量耦合问题的分布式求解。实验结果表明，该方法在多目标定位任务中取得了更高的定位精度与更好的系统共识性。

（5） 在智能电网能源管理问题中，提出了改进的多智能体粒子群优化算法（MASOIE-G），通过引入自适应定价的演化博弈机制与可变邻居权重的协同学习策略，实现了在局部信息与有限通信条件下的全局能源管理优化。实验结果表明，该方法能够有效实现供需平衡并提升系统整体收益。

综上所述，本文围绕多智能体黑箱分布式优化问题，提出了一系列协同进化算法与共识机制，从理论分析、算法设计到实际应用验证构建了系统化研究框架，为复杂网络

系统中的去中心化协同优化提供了新的研究思路与方法基础。当前，随着人工智能技术与复杂网络系统的快速发展，仍存在许多值得进一步探索的问题。未来的研究工作可从以下三个方面展开：

（1）多大语言模型智能体协同决策与共识优化

近年来，大语言模型（Large Language Models, LLMs）在复杂推理与决策任务中展现出强大能力[168]。随着多智能体系统与大模型技术的融合，基于多 LLM 智能体的协同决策与合作推理逐渐成为新的研究热点[169-170]。在此类系统中，不同智能体可能拥有不同的知识、能力或任务目标，需要通过通信与协作完成复杂任务[171]。本文提出的多智能体共识优化与协同演化框架为研究多 LLM 智能体之间的协同与共识提供了重要理论基础。未来可进一步探索如何将分布式共识优化机制引入多 LLM 智能体系统，使多个智能体在复杂推理与决策过程中实现稳定协同与共识决策，从而提升多智能体人工智能系统的整体能力。

（2）分布式离散优化问题的共识协同方法

本文主要关注连续变量为主的黑箱分布式优化问题，而在许多实际应用中，如任务调度、组合优化与网络资源分配等问题中，决策变量往往具有离散或组合特性[172-174]。与连续优化问题相比，离散优化问题通常具有更复杂的搜索空间结构，其规模随问题规模呈指数增长。尽管本文在多目标定位问题中通过双层优化方法部分解决了连续—离散耦合问题，但针对一般分布式离散优化问题，如何设计具有良好扩展性的共识优化算法仍然是一个重要研究方向。未来可进一步研究基于群体智能与组合优化方法的分布式协同机制，以实现大规模离散问题的高效求解。

（3）隐私保护与安全约束下的分布式共识优化

随着数据隐私保护与信息安全需求的不断增强，在多智能体系统中直接共享原始数据往往受到严格限制。例如在医疗数据分析、金融系统优化以及跨机构协同学习等场景中，各节点数据具有高度敏感性[175-176]。如何在保证隐私安全的前提下实现协同优化[177]，成为分布式人工智能领域的重要研究问题。未来研究可将差分隐私、安全多方计算或联邦学习等隐私保护技术与分布式进化优化方法相结合，在保证数据安全与隐私保护的同时，实现多智能体系统的高效协同优化。此外，在存在潜在攻击或不可信节点的环境下，如何提升分布式共识算法的鲁棒性与安全性是一个值得研究的重要方向。

参考文献

[1] 李未, 吴文峻, 王怀民, 等. AI2.0 时代的群体智能 [J]. 信息与电子工程前沿（英文）, 2017, 18(1): 15–43. DOI: 10.1631/FITEE.1601859.

[2] Wooldridge M. An introduction to multiagent systems[M]. John wiley & sons, 2009.

[3] Vorotnikov S, Ermishin K, Nazarova A, et al. Multi-Agent Robotic Systems in Collaborative Robotics [C]//Ronzhin A, Rigoll G, Meshcheryakov R. Interactive Collaborative Robotics. Cham: Springer International Publishing, 2018: 270-279.

[4] Bähnemann R, Schindler D, Kamel M, et al. A Decentralized Multi-Agent Unmanned Aerial System to Search, Pick up, and Relocate Objects[C]//2017 IEEE International Symposium on Safety, Security and Rescue Robotics (SSRR). 2017: 123-128. DOI: 10.1109/SSRR.2017.8088150.

[5] Patel R, Rudnick-Cohen E, Azarm S, et al. Decentralized Task Allocation in Multi-Agent Systems Using a Decentralized Genetic Algorithm[C]//2020 IEEE International Conference on Robotics and Automation (ICRA). 2020: 3770-3776. DOI: 10.1109/ICRA40945.2020.9197314.

[6] Zhou L, Liu J, Zheng Y, et al. Game-Based Consensus of Hybrid Multiagent Systems[J]. IEEE Transactions on Cybernetics, 2023, 53(8): 5346-5357. DOI: 10.1109/TCYB.2022.3215619.

[7] Perolat J, Vylder B D, Hennes D, et al. Mastering the game of Stratego with model-free multiagent reinforcement learning[J/OL]. Science, 2022, 378(6623): 990-996. eprint: https://www.science.org/doi/pdf/10.1126/science.add4679. https://www.science.org/doi/abs/10.1126/science.add4679. DOI: 10.1126/science.add4679.

[8] Lanctot M, Zambaldi V, Gruslys A, et al. A Unified Game-Theoretic Approach to Multiagent Reinforcement Learning[C/OL]//Guyon I, Luxburg U V, Bengio S, et al. Advances in Neural Information Processing Systems: vol. 30. Curran Associates, Inc., 2017. https://proceedings.neurips.cc/paper_files/paper/2017/file/3323fe11e9595c09af38fe67567a9394-Paper.pdf.

[9] Molzahn D, Dörfler F, Sandberg H, et al. A Survey of Distributed Optimization and Control Algorithms for Electric Power Systems[J]. IEEE Transactions on Smart Grid, 2017, PP: 1-1. DOI: 10.1109/TSG.2017.2720471.

[10] Van Cutsem O, Ho Dac D, Boudou P, et al. Cooperative Energy Management of a Community of Smart-Buildings: A Blockchain Approach[J]. International Journal of Electrical Power & Energy Systems, 2020, 117: 105643. DOI: 10.1016/j.ijepes.2019.105643.

[11] Patari N, Venkataramanan V, Srivastava A, et al. Distributed Optimization in Distribution Systems: Use Cases, Limitations, and Research Needs[J]. IEEE TRANSACTIONS ON POWER SYSTEMS,

2022, 37(5): 13.

[12] 王毅, 陈启鑫, 张宁, 等.5G 通信与泛在电力物联网的融合: 应用分析与研究展望 [J]. 电网技术,2019,43(05):1575-1585.DOI:10.13335/j.1000-3673.pst.2019.0635.

[13] Kudyba S, Kwatinetz M. Introduction to the big data era[J]. Big data, mining, and analytics, 2014: 1-17.

[14] 张爽, 张晨, 彭淑敏, 等. 面向 6G 的智能物联网通信关键技术综述 [J]. 无线电工程,2025,55(04):699-713.

[15] 王承祥, 高跃, 郭庆, 付雅茹, 陆杨 & 夏文超.6G 跨域通感智算融合物联网. 物联网学报,1-33.

[16] Yang T, Yi X, Wu J, et al. A Survey of Distributed Optimization[J]. Annual Reviews in Control, 2019, 47: 278-305. DOI: 10.1016/j.arcontrol.2019.05.006.

[17] 姜霞, 曾宪琳, 孙健, 等. 多智能体系统分布式优化综述与前瞻 [J]. 中国科学: 信息科学,2025,55(12):2965-2990.

[18] 韩光洁, 朱胜超, 林川, 等. 多智能体强化学习：从基础理论到前沿算法 [J/OL]. 电子学报,1-31[2026-03-15].https://link.cnki.net/urlid/11.2087.TN.20260131.1359.016.

[19] Wong A, Bäck T, Kononova A V, et al. Deep multiagent reinforcement learning: Challenges and directions[J]. Artificial Intelligence Review, 2023, 56(6): 5023-5056.

[20] 郭戈, 康健. 具有复杂动力学的多智能体系统分布式优化综述 [J]. 控制与决策,2024,39(07):2113-2124.DOI:10.13195/j.kzyjc.2023.1788.

[21] Olfati-Saber R, Murray R. Consensus Problems in Networks of Agents with Switching Topology and Time-Delays[J]. IEEE Transactions on Automatic Control, 2004, 49(9): 1520-1533. DOI: 10.1109/TAC.2004.834113.

[22] Nedic A, Olshevsky A, Shi W. Achieving Geometric Convergence for Distributed Optimization Over Time-Varying Graphs[J]. SIAM Journal on Optimization, 2016, 27. DOI: 10.1137/16M1084316.

[23] Varagnolo D, Zanella F, Cenedese A, et al. Newton-Raphson Consensus for Distributed Convex Optimization[J]. IEEE Transactions on Automatic Control, 2016, 61(4): 994-1009. DOI: 10.1109/TAC.2015.2449811.

[24] Shi W, Ling Q, Wu G, et al. Extra: An exact first-order algorithm for decentralized consensus optimization[J]. SIAM Journal on Optimization, 2015, 25(2): 944-966.

[25] Nedic A, Ozdaglar A. Distributed Subgradient Methods for Multi-Agent Optimization[J]. IEEE Transactions on Automatic Control, 2009, 54(1): 48-61. DOI: 10.1109/TAC.2008.2009515.

[26] Lei J, Chen H F, Fang H T. Primal‐Dual Algorithm for Distributed Constrained Optimization[J]. Systems & Control Letters, 2016, 96: 110-117. DOI: 10.1016/j.sysconle.2016.07.009.

[27] Yuan D, Ho D W C. Randomized Gradient-Free Method for Multiagent Optimization Over Time-Varying Networks[J]. IEEE Transactions on Neural Networks and Learning Systems, 2015, 26(6): 1342-1347. DOI: 10.1109/TNNLS.2014.2336806.

[28] Pang Y, Hu G. Randomized Gradient-Free Distributed Optimization Methods for a Multiagent System With Unknown Cost Function[J]. IEEE Transactions on Automatic Control, 2020, 65(1): 333-340. DOI: 10.1109/TAC.2019.2914025.

[29] Li Y, Fan J, Wang Y, et al. Influence maximization on social graphs: A survey[J]. IEEE Transactions on Knowledge and Data Engineering, 2018, 30(10): 1852-1872.

[30] Liao X C, Chen W N, Jia Y H, et al. Towards Scalable Dynamic Traffic Assignment With Streaming Agents: A Decentralized Control Approach Using Genetic Programming[J]. IEEE Transactions on Emerging Topics in Computational Intelligence, 2024, 8(1): 942-955. DOI: 10.1109/TETCI.2023.3296671.

[31] Guo X Q, Wei F F, Zhang J, et al. A Classifier-Ensemble-Based Surrogate-Assisted Evolutionary Algorithm for Distributed Data-Driven Optimization[J]. IEEE Transactions on Evolutionary Computation, 2024.

[32] Zhu H, Jin Y. Real-time federated evolutionary neural architecture search[J]. IEEE Transactions on Evolutionary Computation, 2021, 26(2): 364-378.

[33] Tayarani-N M H, Yao X, Xu H. Meta-heuristic algorithms in car engine design: A literature survey[J]. IEEE Transactions on Evolutionary Computation, 2014, 19(5): 609-629.

[34] Wei F F, Chen W N, Li Q, et al. Distributed and expensive evolutionary constrained optimization with on-demand evaluation[J]. IEEE Transactions on Evolutionary Computation, 2022.

[35] Yi X, Zhang S, Yang T, et al. A primal-dual SGD algorithm for distributed nonconvex optimization [J]. IEEE/CAA Journal of Automatica Sinica, 2022, 9(5): 812-833.

[36] Danilova M, Dvurechensky P, Gasnikov A, et al. Recent theoretical advances in non-convex optimization[G]//High-Dimensional Optimization and Probability: With a View Towards Data Science. Springer, 2022: 79-163.

[37] Kennedy J, Eberhart R. Particle Swarm Optimization[C]//Proceedings of ICNN'95 - International Conference on Neural Networks: vol. 4. 1995: 1942-1948 vol.4. DOI: 10.1109/ICNN.1995.488968.

[38] Mirjalili S. Genetic Algorithm[G]//. Evolutionary Algorithms and Neural Networks: Theory and Applications. Cham: Springer International Publishing, 2019: 43-55. DOI: 10.1007/978-3-319-93025-1_4.

[39] Dorigo M, Birattari M, Stutzle T. Ant Colony Optimization[J]. IEEE Computational Intelligence Mag-

azine, 2006, 1(4): 28-39. DOI: 10.1109/MCI.2006.329691.

[40] Wang B, He Z. Distributed Optimization Over Wireless Sensor Networks Using Swarm Intelligence [C]//2007 IEEE International Symposium on Circuits and Systems. 2007: 2502-2505. DOI: 10.1109/ISCAS.2007.378747.

[41] Wang X, Ma J J, Wang S, et al. Distributed Particle Swarm Optimization and Simulated Annealing for Energy-efficient Coverage in Wireless Sensor Networks[J]. Sensors, 2007, 7(5): 628-648. DOI: 10.3390/s7050628.

[42] Utkarsh K, Trivedi A, Srinivasan D, et al. A Consensus-Based Distributed Computational Intelligence Technique for Real-Time Optimal Control in Smart Distribution Grids[J]. IEEE Transactions on Emerging Topics in Computational Intelligence, 2017, 1(1): 51-60. DOI: 10.1109/TETCI.2016.2635130.

[43] Gionfra N, Sandou G, Siguerdidjane H, et al. Wind Farm Distributed PSO-based Control for Constrained Power Generation Maximization[J]. Renewable Energy, 2019, 133: 103-117. DOI: 10.1016/j.renene.2018.09.084.

[44] Choi H, Kim Y, Kim H J. Genetic Algorithm Based Decentralized Task Assignment for Multiple Unmanned Aerial Vehicles in Dynamic Environments[J]. International Journal of Aeronautical and Space Sciences, 2011, 12: 163-174. DOI: 10.5139/IJASS.2011.12.2.163.

[45] Gong Y J, Chen W N, Zhan Z H, et al. Distributed evolutionary algorithms and their models: A survey of the state-of-the-art[J]. Applied Soft Computing, 2015, 34: 286-300 [2022-02-25]. DOI: 10.1016/j.asoc.2015.04.061.

[46] Dubreuil M, Gagne C, Parizeau M. Analysis of a master-slave architecture for distributed evolutionary computations[J]. IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics), 2006, 36(1): 229-235. DOI: 10.1109/TSMCB.2005.856724.

[47] Zhan Z H, Wang Z J, Jin H, et al. Adaptive Distributed Differential Evolution[J]. IEEE Transactions on Cybernetics, 2020, 50(11): 4633-4647. DOI: 10.1109/TCYB.2019.2944873.

[48] Yang Q, Chen W N, Gu T, et al. A Distributed Swarm Optimizer With Adaptive Communication for Large-Scale Optimization[J]. IEEE Transactions on Cybernetics, 2020, 50(7): 3393-3408 [2022-02-25]. DOI: 10.1109/TCYB.2019.2904543.

[49] Roy G, Lee H, Welch J L, et al. A distributed pool architecture for genetic algorithms[C]//2009 IEEE Congress on Evolutionary Computation. 2009: 1177-1184. DOI: 10.1109/CEC.2009.4983079.

[50] Herrera F, Lozano M. Gradual distributed real-coded genetic algorithms[J]. IEEE Transactions on Evolutionary Computation, 2000, 4(1): 43-63. DOI: 10.1109/4235.843494.

[51] Giacobini M, Tomassini M, Tettamanzi A, et al. Selection intensity in cellular evolutionary algorithms for regular lattices[J]. IEEE Transactions on Evolutionary Computation, 2005, 9(5): 489-505. DOI: 10.1109/TEVC.2005.850298.

[52] Jia Y H, Chen W N, Gu T, et al. Distributed Cooperative Co-Evolution With Adaptive Computing Resource Allocation for Large Scale Optimization[J]. IEEE Transactions on Evolutionary Computation, 2019, 23(2): 188-202. DOI: 10.1109/TEVC.2018.2817889.

[53] Omidvar M N, Li X, Mei Y, et al. Cooperative Co-Evolution With Differential Grouping for Large Scale Optimization[J]. IEEE Transactions on Evolutionary Computation, 2014, 18(3): 378-393 [2022-02-25]. DOI: 10.1109/TEVC.2013.2281543.

[54] Karim S M, Habbal A, Chaudhry S A, et al. Architecture, protocols, and security in IoV: Taxonomy, analysis, challenges, and solutions[J]. Security and Communication Networks, 2022, 2022(1): 1131479.

[55] Wang Y, Wang S, Wu L. Distributed Optimization Approaches for Emerging Power Systems Operation: A Review[J]. Electric Power Systems Research, 2017, 144: 127-135. DOI: 10.1016/j.epsr.2016.11.025.

[56] Pacitti E, Akbaranian R, El-Dick M. P2P Techniques for Decentralized Applications[M]. Springer Nature, 2022.

[57] Liu A, Huang Z, Li M, et al. A survey on fundamental limits of integrated sensing and communication [J]. IEEE Communications Surveys & Tutorials, 2022, 24(2): 994-1034.

[58] Wang J, Elia N. Control Approach to Distributed Optimization[J]. 48th Annual Allerton Conference on Communication, Control, and Computing, Allerton 2010. 2010 48th Annual Allerton Conference on Communication, Control, and Computing, Allerton 2010 2010: 557-561. DOI: 10.1109/ALLERTON.2010.5706956.

[59] Lu J, Tang C Y. Zero-Gradient-Sum Algorithms for Distributed Convex Optimization: The Continuous-Time Case[J]. IEEE Transactions on Automatic Control, 2012, 57(9): 2348-2354. DOI: 10.1109/TAC.2012.2184199.

[60] Back T, Schwefel H P. Evolutionary computation: An overview[C]//Proceedings of IEEE International Conference on Evolutionary Computation. 1996: 20-29.

[61] Hansen N, Arnold D V, Auger A. Evolution strategies[G]//Springer handbook of computational intelligence. Springer, 2015: 871-898.

[62] Beyer H G. Convergence analysis of evolutionary algorithms that are based on the paradigm of information geometry[J]. Evolutionary Computation, 2014, 22(4): 679-709.

[63] Ping Tian D. A review of convergence analysis of particle swarm optimization[J]. International Journal of Grid and Distributed Computing, 2013, 6(6): 117-128.

[64] Cheng R, Jin Y. A Competitive Swarm Optimizer for Large Scale Optimization[J]. IEEE Transactions on Cybernetics, 2015, 45(2): 191-204. DOI: 10.1109/TCYB.2014.2322602.

[65] Yang Q, Chen W N, Deng J D, et al. A Level-Based Learning Swarm Optimizer for Large-Scale Optimization[J]. IEEE Transactions on Evolutionary Computation, 2018, 22(4): 578-594. DOI: 10.1109/TEVC.2017.2743016.

[66] Hansen N. The CMA Evolution Strategy: A Tutorial[J/OL]. 2016: 1-39. arXiv: 1604.00772. http://arxiv.org/abs/1604.00772.

[67] Cheng S, Liu B, Shi Y, et al. Evolutionary Computation and Big Data: Key Challenges and Future Directions[C]//Tan Y, Shi Y. Lecture Notes in Computer Science: Data Mining and Big Data. Cham: Springer International Publishing, 2016: 3-14. DOI: 10.1007/978-3-319-40973-3_1.

[68] Bouvry P, Arbab F, Seredynski F. Distributed Evolutionary Optimization, in Manifold: Rosenbrock's Function Case Study[J]. Information Sciences, 2000, 122(2-4): 141-159. DOI: 10.1016/S0020-0255(99)00116-4.

[69] Choudhury M, Mahmud S, Khan M M. A particle swarm based algorithm for functional distributed constraint optimization problems[C]//Proceedings of the AAAI Conference on Artificial Intelligence: vol. 34: 05. 2020: 7111-7118.

[70] Ai W, Chen W, Xie J. A General Framework for Population-Based Distributed Optimization over Networks[J]. Information Sciences, 2017, 418–419: 136-152. DOI: 10.1016/j.ins.2017.08.010.

[71] Jalloul M K, Al-Alaoui M A. A Distributed Particle Swarm Optimization Algorithm for Block Motion Estimation Using the Strategies of Diffusion Adaptation[C]//2015 International Symposium on Signals, Circuits and Systems (ISSCS). 2015: 1-4. DOI: 10.1109/ISSCS.2015.7204009.

[72] Wakasa Y, Nakaya S. Distributed Particle Swarm Optimization Using an Average Consensus Algorithm[C]//2015 54th IEEE Conference on Decision and Control (CDC). 2015: 2661-2666. DOI: 10.1109/CDC.2015.7402617.

[73] Trelea I C. The Particle Swarm Optimization Algorithm: Convergence Analysis and Parameter Selection[J]. Information Processing Letters, 2003, 85(6): 317-325. DOI: 10.1016/S0020-0190(02)00447-7.

[74] Clerc M. Standard Particle Swarm Optimisation[J]. hal-00764996, 2012 [2023-07-13].

[75] Kargarian A, Mohammadi J, Guo J, et al. Toward distributed/decentralized DC optimal power flow implementation in future electric power systems[J]. IEEE Transactions on Smart Grid, 2016, 9(4): 2574-2594.

[76] He X, Zheng Z, Chen C, et al. Distributed Evolution Strategies for Black-Box Stochastic Optimization [J]. IEEE Transactions on Parallel and Distributed Systems, 2022, 33(12): 3718-3731. DOI: 10.1109/TPDS.2022.3168873.

[77] Chen T Y, Chen W N, Guo X Q, et al. A Multiagent Co-Evolutionary Algorithm With Penalty-Based Objective for Network-Based Distributed Optimization[J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2024, 54(7): 4358-4370. DOI: 10.1109/TSMC.2024.3380389.

[78] Pang Y, Hu G. Randomized Gradient-Free Distributed Optimization Methods for a Multiagent System with Unknown Cost Function[J]. IEEE Transactions on Automatic Control, 2020, 65(1): 333-340. DOI: 10.1109/TAC.2019.2914025.

[79] Wang D, Yin J, Wang W. Distributed Randomized Gradient-Free Optimization Protocol of Multiagent Systems over Weight-Unbalanced Digraphs[J]. IEEE Transactions on Cybernetics, 2021, 51(1): 473-482. DOI: 10.1109/TCYB.2018.2890140.

[80] Yuan D, Ho D W, Xu S. Zeroth-Order Method for Distributed Optimization with Approximate Projections[J]. IEEE Transactions on Neural Networks and Learning Systems, 2016, 27(2): 284-294. DOI: 10.1109/TNNLS.2015.2480419.

[81] Das A, Lewis F. Cooperative adaptive control for synchronization of second-order systems[J]. International Journal of Robust and Nonlinear Control, 2010, 18(March 2014): 557-569. arXiv: arXiv:1505.02595v1. DOI: 10.1002/rnc.

[82] Li J, Wu C, Wu Z, et al. Gradient-free method for nonsmooth distributed optimization[J]. Journal of Global Optimization, 2015, 61(2): 325-340. DOI: 10.1007/s10898-014-0174-2.

[83] Tang Y, Zhang J, Li N. Distributed Zero-Order Algorithms for Nonconvex Multiagent Optimization [J]. IEEE Transactions on Control of Network Systems, 2021, 8(1): 269-281. DOI: 10.1109/TCNS.2020.3024321.

[84] Ayar M, Obuz S, Trevizan R D, et al. A distributed control approach for enhancing smart grid transient stability and resilience[J]. IEEE Transactions on Smart Grid, 2017, 8(6): 3035-3044.

[85] Mishra D K, Ghadi M J, Azizivahed A, et al. A review on resilience studies in active distribution systems[J]. Renewable and Sustainable Energy Reviews, 2021, 135: 110201.

[86] Jin Y, Olhofer M, Sendhoff B. A framework for evolutionary optimization with approximate fitness functions[J]. IEEE Transactions on evolutionary computation, 2002, 6(5): 481-494.

[87] Loshchilov I, Glasmachers T, Beyer H G. Large scale black-box optimization by limited-memory matrix adaptation[J]. IEEE Transactions on Evolutionary Computation, 2018, 23(2): 353-358.

[88] Beyer H G, Sendhoff B. Simplify your covariance matrix adaptation evolution strategy[J]. IEEE Trans-

actions on Evolutionary Computation, 2017, 21(5): 746-759.

[89] Igel C, Suttorp T, Hansen N. A computational efficient covariance matrix update and a (1+ 1)-CMA for evolution strategies[C]//Proceedings of the 8th annual conference on Genetic and evolutionary computation. 2006: 453-460.

[90] Ait Elhara O, Auger A, Hansen N. A median success rule for non-elitist evolution strategies: Study of feasibility[C]//Proceedings of the 15th annual conference on Genetic and evolutionary computation. 2013: 415-422.

[91] Hansen N, Atamna A, Auger A. How to assess step-size adaptation mechanisms in randomised search [C]//Parallel Problem Solving from Nature–PPSN XIII: 13th International Conference, Ljubljana, Slovenia, September 13-17, 2014. Proceedings 13. 2014: 60-69.

[92] Meyer-Nieberg S, Beyer H G. Self-adaptation in evolutionary algorithms[G]//Parameter setting in evolutionary algorithms. Springer, 2007: 47-75.

[93] Beyer H G, Dobler M, Hämmerle C, et al. On strategy parameter control by Meta-ES[C]//Proceedings of the 11th Annual conference on Genetic and evolutionary computation. 2009: 499-506.

[94] Hellwig M, Beyer H G. Analysis of a meta-ES on a conically constrained problem[C]//Proceedings of the Genetic and Evolutionary Computation Conference. 2019: 673-681.

[95] Wilson D, Veeramachaneni K, O’Reilly U M. Cloud scale distributed evolutionary strategies for high dimensional problems[C]//European Conference on the Applications of Evolutionary Computation. 2013: 519-528.

[96] Duan Q, Zhou G, Shao C, et al. Distributed evolution strategies for large-scale optimization[C]// Proceedings of the Genetic and Evolutionary Computation Conference Companion. 2022: 395-398.

[97] Chen T Y, Chen W N, Wei F F, et al. Multi-Agent Swarm Optimization With Adaptive Internal and External Learning for Complex Consensus-Based Distributed Optimization[J]. IEEE Transactions on Evolutionary Computation, 2024: 1-1. DOI: 10.1109/TEVC.2024.3380436.

[98] Warchulski E, Arabas J. A New Step-Size Adaptation Rule for CMA-ES Based on the Population Midpoint Fitness[J]. 2021 IEEE Congress on Evolutionary Computation, CEC 2021 - Proceedings, 2021: 825-831. DOI: 10.1109/CEC45853.2021.9504829.

[99] Mao G, Fidan B, Anderson B D. Wireless sensor network localization techniques[J]. Computer Networks, 2007, 51(10): 2529-2553. DOI: 10.1016/j.comnet.2006.11.018.

[100] Boussaïd I, Lepagnot J, Siarry P. A survey on optimization metaheuristics[J]. Inf. Sci., 2013, 237: 82-117.

[101] Song A, Chen W N, Gu T, et al. Distributed Virtual Network Embedding System With Historical

Archives and Set-Based Particle Swarm Optimization[J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2021, 51(2): 927-942. DOI: 10.1109/TSMC.2018.2884523.

[102] Hussain K, Salleh M N M, Cheng S, et al. Metaheuristic research: a comprehensive survey[J]. Artificial Intelligence Review, 2019: 1-43.

[103] Omidvar M N, Li X, Yao X. Cooperative Co-evolution with Delta Grouping for Large Scale Non-Separable Function Optimization[C]//IEEE Congress on Evolutionary Computation. Barcelona, Spain: IEEE, 2010: 1-8. DOI: 10.1109/CEC.2010.5585979.

[104] Strasser S, Sheppard J, Fortier N, et al. Factored Evolutionary Algorithms[J]. IEEE Transactions on Evolutionary Computation, 2017, 21(2): 281-293. DOI: 10.1109/TEVC.2016.2601922.

[105] Jia Y H, Mei Y, Zhang M. Contribution-Based Cooperative Co-Evolution for Nonseparable Large-Scale Problems With Overlapping Subcomponents[J/OL]. IEEE Transactions on Cybernetics, 2020: 1-14 [2022-03-01]. https://ieeexplore.ieee.org/document/9244085/. DOI: 10.1109/TCYB.2020.3025577.

[106] Tong L, Zhou X, Miller H J. Transportation Network Design for Maximizing Space–Time Accessibility[J]. Transportation Research Part B: Methodological, 2015, 81: 555-576. DOI: 10.1016/j.trb.2015.08.002.

[107] Molzahn D K, Dörfler F, Sandberg H, et al. A Survey of Distributed Optimization and Control Algorithms for Electric Power Systems[J]. IEEE Transactions on Smart Grid, 2017, 8(6): 2941-2962. DOI: 10.1109/TSG.2017.2720471.

[108] Kekatos V, Giannakis G B. Distributed Robust Power System State Estimation[J]. IEEE Transactions on Power Systems, 2013, 28(2): 1617-1626. DOI: 10.1109/TPWRS.2012.2219629.

[109] Heider M, Pätzel D, Stegherr H, et al. A Metaheuristic Perspective on Learning Classifier Systems[G]//Eddaly M, Jarboui B, Siarry P. Metaheuristics for Machine Learning: New Advances and Tools. Singapore: Springer Nature Singapore, 2023: 73-98. DOI: 10.1007/978-981-19-3888-7_3.

[110] Mejía-de-Dios J A, Rodríguez-Molina A, Mezura-Montes E. Multiobjective Bilevel Optimization: A Survey of the State-of-the-Art[J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2023: 1-. DOI: 10.1109/TSMC.2023.3271125.

[111] Elshaer R, Awad H. A Taxonomic Review of Metaheuristic Algorithms for Solving the Vehicle Routing Problem and Its Variants[J]. Computers & Industrial Engineering, 2020, 140: 106242. DOI: 10.1016/j.cie.2019.106242.

[112] Dökeroglu T, Sevinç E, Kucukyilmaz T, et al. A survey on new generation metaheuristic algorithms [J]. Comput. Ind. Eng., 2019, 137.

[113] Meyer-Nieberg S, Beyer H G. Self-Adaptation in Evolutionary Algorithms[G]//Lobo F G, Lima C F, Michalewicz Z. Parameter Setting in Evolutionary Algorithms: vol. 54. Berlin, Heidelberg: Springer Berlin Heidelberg, 2007: 47-75 [2023-05-15]. DOI: 10.1007/978-3-540-69432-8_3.

[114] Wang S, Chen L, Gu D, et al. Cooperative localization of AUVs using moving horizon estimation[J]. IEEE/CAA Journal of Automatica Sinica, 2014, 1(1): 68-76. DOI: 10.1109/JAS.2014.7004622.

[115] Khalil R A, Saeed N, Babar M I, et al. Bayesian Multidimensional Scaling for Location Awareness in Hybrid-Internet of Underwater Things[J]. IEEE/CAA Journal of Automatica Sinica, 2022, 9(3): 496-509. DOI: 10.1109/JAS.2021.1004356.

[116] Zhao H, Yan J, Luo X, et al. Privacy preserving solution for the asynchronous localization of underwater sensor networks[J]. IEEE/CAA Journal of Automatica Sinica, 2020, 7(6): 1511-1527. DOI: 10.1109/JAS.2020.1003312.

[117] Huang W, Pan Z, Xu Z. Underwater Cable Localization Method Based on Beetle Swarm Optimization Algorithm[J]. IEEE/CAA Journal of Automatica Sinica, 2023, 10(9): 1893-1895. DOI: 10.1109/JAS.2022.106073.

[118] Tabella G, Ciuonzo D, Paltrinieri N, et al. Bayesian Fault Detection and Localization Through Wireless Sensor Networks in Industrial Plants[J]. IEEE Internet of Things Journal, 2024, 11(8): 13231-13246. DOI: 10.1109/JIOT.2024.3359646.

[119] Ahmed I, Din S, Jeon G, et al. Towards Collaborative Robotics in Top View Surveillance: A Framework for Multiple Object Tracking by Detection Using Deep Learning[J]. IEEE/CAA Journal of Automatica Sinica, 2021, 8(7): 1253-1270. DOI: 10.1109/JAS.2020.1003453.

[120] Touska D, Gkountakos K, Tsikrika T, et al. Graph-Based Data Association in Multiple Object Tracking: A Survey[J]. Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics), 2023, 13834 LNCS: 386-398. DOI: 10.1007/978-3-031-27818-1_32.

[121] White J H, Beard R W. An iterative pose estimation algorithm based on epipolar geometry with application to multi-target tracking[J]. IEEE/CAA Journal of Automatica Sinica, 2020, 7(4): 942-953. DOI: 10.1109/JAS.2020.1003222.

[122] Liu H, Chen Y, Huang Y, et al. Study on the Localization Method of Multi-Aperture Acoustic Array Based on TDOA[J]. IEEE Sensors Journal, 2021, 21(12): 13805-13814. DOI: 10.1109/JSEN.2021.3070811.

[123] Rakai L, Song H, Sun S, et al. Data association in multiple object tracking: A survey of recent techniques[J]. Expert Systems with Applications, 2022, 192: 116300 [2023-10-09]. DOI: 10.1016/j.eswa

.2021.116300.

[124] Parmar P, Zaveri M. Multiple Target Tracking and Data Association in Wireless Sensor Network[C]//2012 Fourth International Conference on Computational Intelligence and Communication Networks. 2012: 158-163. DOI: 10.1109/CICN.2012.152.

[125] Chen H, Kirubarajan T, Bar-Shalom Y. Tracking of Spawning Targets with Multiple Finite Resolution Sensors[C]//Proceedings of the Fifth International Conference on Information Fusion. FUSION 2002. (IEEE Cat.No.02EX5997): vol. 2. 2002: 1511-1518 vol.2. DOI: 10.1109/ICIF.2002.1020996.

[126] Kamal A T, Bappy J H, Farrell J A, et al. Distributed Multi-Target Tracking and Data Association in Vision Networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2016, 38(7): 1397-1410. DOI: 10.1109/TPAMI.2015.2484339.

[127] Sandell N F, Olfati-Saber R. Distributed Data Association for Multi-Target Tracking in Sensor Networks[C]//2008 47th IEEE Conference on Decision and Control. Cancun, Mexico: IEEE, 2008: 1085-1090 [2023-07-31]. DOI: 10.1109/CDC.2008.4739066.

[128] Zhu Y, Vikram A, Fu H, et al. On Non-Cooperative Multiple-Target Tracking With Wireless Sensor Networks[J]. IEEE Transactions on Wireless Communications, 2014, 13(11): 6496-6510. DOI: 10.1109/TWC.2014.2329306.

[129] Camajori Tedeschini B, Brambilla M, Barbieri L, et al. Cooperative Lidar Sensing for Pedestrian Detection: Data Association Based on Message Passing Neural Networks[J]. IEEE Transactions on Signal Processing, 2023, 71: 3028-3042 [2023-10-09]. DOI: 10.1109/TSP.2023.3304002.

[130] Kazemi S A R, Amiri R, Behnia F. Data Association for Multi-Target Elliptic Localization in Distributed MIMO Radars[J]. IEEE Communications Letters, 2021, 25(9): 2904-2907. DOI: 10.1109/LCOMM.2021.3087009.

[131] Ge T, Tharmarasa R, Lebel B, et al. A multidimensional TDOA association algorithm for joint multitarget localization and multisensor synchronization[J]. IEEE Transactions on Aerospace and Electronic Systems, 2020, 56(3): 2083-2100. DOI: 10.1109/TAES.2019.2943786.

[132] Wei Z, Duan Z, Mallick M. Measurement-to-Measurement Association for MDA with A Practical Coarse Gating Strategy[J]. 2023 26th International Conference on Information Fusion (FUSION), 2023: 1-8. DOI: 10.23919/fusion52260.2023.10224167.

[133] Dang X, Cheng Q, Zhu H. Indoor Multiple Sound Source Localization via Multi-Dimensional Assignment Data Association[J]. IEEE/ACM Transactions on Audio Speech and Language Processing, 2019, 27(12): 1944-1956. DOI: 10.1109/TASLP.2019.2935837.

[134] Ez-Zaidi A, Rakrak S. A Comparative Study of Target Tracking Approaches in Wireless Sensor Net-

works[J]. Journal of Sensors, 2016, 2016: 1-11 [2023-07-31]. DOI: 10.1155/2016/3270659.

[135] Zhang Y, Lou Y, Hong Y, et al. Distributed Projection-Based Algorithms for Source Localization in Wireless Sensor Networks[J]. IEEE Transactions on Wireless Communications, 2015, 14(6): 3131-3142 [2023-08-15]. DOI: 10.1109/TWC.2015.2402672.

[136] Lv Y, Zhang H, Wang Z, et al. Distributed Localization for Dynamic Multiagent Systems With Randomly Varying Trajectory Lengths[J]. IEEE Transactions on Industrial Electronics, 2022, 69(9): 9298-9308. DOI: 10.1109/TIE.2021.3111571.

[137] Wang Y, Chen X, Shi L, et al. A Trust Assessment-Based Distributed Localization Algorithm for Sensor Networks Under Deception Attacks[J]. IEEE/CAA Journal of Automatica Sinica, 2022, 9(10): 1879-1882. DOI: 10.1109/JAS.2022.105881.

[138] Wang S, Jiang X, Wymeersch H. Cooperative localization in wireless sensor networks with AOA measurements[J]. IEEE Transactions on Wireless Communications, 2022, 21(8): 6760-6773.

[139] Zhao Y, Li Z, Hao B, et al. Sensor Selection for TDOA-Based Localization in Wireless Sensor Networks With Non-Line-of-Sight Condition[J]. IEEE Transactions on Vehicular Technology, 2019, 68(10): 9935-9950. DOI: 10.1109/TVT.2019.2936110.

[140] Dasgupta D, Hernandez G, Garrett D, et al. A comparison of multiobjective evolutionary algorithms with informed initialization and kuhn-munkres algorithm for the sailor assignment problem[C]// GECCO '08: Proceedings of the 10th Annual Conference Companion on Genetic and Evolutionary Computation. Atlanta, GA, USA: Association for Computing Machinery, 2008: 2129-2134. DOI: 10.1145/1388969.1389035.

[141] Wen G, Song H, Gao F, et al. Target Localization in Asynchronous Distributed MIMO Radar Systems with a Cooperative Target[J]. IEEE Transactions on Wireless Communications, 2022, 21(6): 4098-4113. DOI: 10.1109/TWC.2021.3126745.

[142] Costa J A, Patwari N, Hero A O. Distributed weighted-multidimensional scaling for node localization in sensor networks[J]. ACM Transactions on Sensor Networks, 2006, 2(1): 39-64. DOI: 10.1145/1138127.1138129.

[143] Yi X, Zhang S, Yang T, et al. Zeroth-order algorithms for stochastic distributed nonconvex optimization[J]. Automatica, 2022, 142: 110353. arXiv: 2106.02958. DOI: 10.1016/j.automatica.2022.110353.

[144] Krishnamurthy V, Pattanayak K, Gogineni S, et al. Adversarial Radar Inference: Inverse Tracking, Identifying Cognition, and Designing Smart Interference[J]. IEEE Transactions on Aerospace and Electronic Systems, 2021, 57(4): 2067-2081. arXiv: 2008.01559. DOI: 10.1109/TAES.2021.309090

1.

[145] Ciuonzo D, Willett P K, Bar-Shalom Y. Tracking the tracker from its passive sonar ML-PDA estimates [J]. IEEE Transactions on Aerospace and Electronic Systems, 2014, 50(1): 573-590. arXiv: 1304.2707. DOI: 10.1109/TAES.2013.120407.

[146] Liu T, Tan X, Sun B, et al. Energy management of cooperative microgrids: A distributed optimization approach[J/OL]. International Journal of Electrical Power and Energy Systems, 2018, 96: 335-346. https://www.sciencedirect.com/science/article/pii/S0142061517300133. DOI: https://doi.org/10.1016/j.ijepes.2017.10.021.

[147] Molzahn D K, Dörfler F, Sandberg H, et al. A Survey of Distributed Optimization and Control Algorithms for Electric Power Systems[J]. IEEE Transactions on Smart Grid, 2017, 8(6): 2941-2962. DOI: 10.1109/TSG.2017.2720471.

[148] Shi W, Xie X, Chu C C, et al. Distributed Optimal Energy Management in Microgrids[J]. IEEE Transactions on Smart Grid, 2015, 6(3): 1137-1146. DOI: 10.1109/TSG.2014.2373150.

[149] Li Q, Liao Y, Wu K, et al. Parallel and Distributed Optimization Method With Constraint Decomposition for Energy Management of Microgrids[J]. IEEE Transactions on Smart Grid, 2021, 12(6): 4627-4640. DOI: 10.1109/TSG.2021.3097047.

[150] Keshta H, Malik O, Saied E, et al. Energy management system for two islanded interconnected microgrids using advanced evolutionary algorithms[J/OL]. Electric Power Systems Research, 2021, 192: 106958. https://www.sciencedirect.com/science/article/pii/S0378779620307562. DOI: https://doi.org/10.1016/j.epsr.2020.106958.

[151] Ferreira W M, Meneghini I R, Brandao D I, et al. Preference cone based multi-objective evolutionary algorithm applied to optimal management of distributed energy resources in microgrids[J/OL]. Applied Energy, 2020, 274: 115326. https://www.sciencedirect.com/science/article/pii/S0306261920308382. DOI: https://doi.org/10.1016/j.apenergy.2020.115326.

[152] Leonori S, Paschero M, Frattale Mascioli F M, et al. Optimization strategies for Microgrid energy management systems by Genetic Algorithms[J/OL]. Applied Soft Computing, 2020, 86: 105903. https://www.sciencedirect.com/science/article/pii/S1568494619306842. DOI: https://doi.org/10.1016/j.asoc.2019.105903.

[153] Soares A, Gomes A, Antunes C H, et al. A Customized Evolutionary Algorithm for Multiobjective Management of Residential Energy Resources[J]. IEEE Transactions on Industrial Informatics, 2017, 13(2): 492-501. DOI: 10.1109/TII.2016.2628961.

[154] Arabali A, Ghofrani M, Etezadi-Amoli M, et al. Genetic-Algorithm-Based Optimization Approach

for Energy Management[J]. IEEE Transactions on Power Delivery, 2013, 28(1): 162-170. DOI: 10.1109/TPWRD.2012.2219598.

[155] Zhao Z, Lee C K M. Dynamic Pricing for EV Charging Stations: A Deep Reinforcement Learning Approach[J]. IEEE Transactions on Transportation Electrification, 2022, 8(2): 2456-2468. DOI: 10.1109/TTE.2021.3139674.

[156] Chen P, Han L, Xin G, et al. Game Theory Based Optimal Pricing Strategy for V2G Participating in Demand Response[J]. IEEE Transactions on Industry Applications, 2023, 59(4): 4673-4683. DOI: 10.1109/TIA.2023.3273209.

[157] Liu P, Liu Z, Zhang N, et al. Cooperative Game-Based Charging-Discharging Efficiency Optimization of Electric Vehicles in 6G-Enabled V2G[J]. IEEE Transactions on Green Communications and Networking, 2023, 7(2): 1078-1089. DOI: 10.1109/TGCN.2022.3191699.

[158] Kim B, Paik M, Kim Y, et al. Distributed Electric Vehicle Charging Mechanism: A Game-Theoretical Approach[J]. IEEE Transactions on Vehicular Technology, 2022, 71(8): 8309-8317. DOI: 10.1109/TVT.2022.3173962.

[159] Chen T Y, Chen W N, Wei F F, et al. The confluence of evolutionary computation and multi-agent systems: A survey[J/OL]. IEEE/CAA Journal of Automatica Sinica, 2025. https://www.ieee-jas.net/article/doi/10.1109/JAS.2025.125246. DOI: 10.1109/JAS.2025.125246.

[160] Chen T Y, Hu X M, Lin Q, et al. Multi-agent swarm optimization with contribution-based cooperation for distributed multi-target localization and data association[J/OL]. IEEE/CAA Journal of Automatica Sinica, 2025. https://www.ieee-jas.net/en/article/doi/10.1109/JAS.2025.125150. DOI: 10.1109/JAS.2025.125150.

[161] Chen T Y, Chen W N, Hao J K, et al. Multi-Agent Evolution Strategy With Cooperative and Cumulative Step Adaptation for Black-Box Distributed Optimization[J]. IEEE Transactions on Evolutionary Computation, 2025: 1-1. DOI: 10.1109/TEVC.2025.3525713.

[162] Gao S, Chau K T, Liu C, et al. Integrated Energy Management of Plug-in Electric Vehicles in Power Grid With Renewables[J]. IEEE Transactions on Vehicular Technology, 2014, 63(7): 3019-3027. DOI: 10.1109/TVT.2014.2316153.

[163] Tabari M, Yazdani A. An Energy Management Strategy for a DC Distribution System for Power System Integration of Plug-In Electric Vehicles[J]. IEEE Transactions on Smart Grid, 2016, 7(2): 659-668. DOI: 10.1109/TSG.2015.2424323.

[164] He H, Wang Y, Li J, et al. An Improved Energy Management Strategy for Hybrid Electric Vehicles Integrating Multistates of Vehicle-Traffic Information[J]. IEEE Transactions on Transportation

Electrification, 2021, 7(3): 1161-1172. DOI: 10.1109/TTE.2021.3054896.

[165] Lyu C, Jia Y, Xu Z. Fully decentralized peer-to-peer energy sharing framework for smart buildings with local battery system and aggregated electric vehicles[J/OL]. Applied Energy, 2021, 299: 117243. https://www.sciencedirect.com/science/article/pii/S0306261921006644. DOI: https://doi.org/10.1016/j.apenergy.2021.117243.

[166] Adetunji K E, Hofsajer I W, Abu-Mahfouz A M, et al. An optimization planning framework for allocating multiple distributed energy resources and electric vehicle charging stations in distribution networks[J/OL]. Applied Energy, 2022, 322: 119513. https://www.sciencedirect.com/science/article/pii/S0306261922008339. DOI: https://doi.org/10.1016/j.apenergy.2022.119513.

[167] Zhao T, Li Z, Ding Z. Consensus-Based Distributed Optimal Energy Management With Less Communication in a Microgrid[J]. IEEE Transactions on Industrial Informatics, 2019, 15(6): 3356-3367. DOI: 10.1109/TII.2018.2871562.

[168] Chang Y, Wang X, Wang J, et al. A survey on evaluation of large language models[J]. ACM transactions on intelligent systems and technology, 2024, 15(3): 1-45.

[169] Du S, Zhao J, Shi J, et al. A survey on the optimization of large language model-based agents[J]. ACM Computing Surveys, 2026, 58(9): 1-37.

[170] Plaat A, van Duijn M, Van Stein N, et al. Agentic large language models, a survey[J]. Journal of Artificial Intelligence Research, 2025, 84.

[171] Bo X, Zhang Z, Dai Q, et al. Reflective multi-agent collaboration based on large language models[J]. Advances in Neural Information Processing Systems, 2024, 37: 138595-138631.

[172] Hady M A, Hu S, Pratama M, et al. Multi-agent reinforcement learning for resources allocation optimization: a survey[J]. Artificial Intelligence Review, 2025, 58(11): 354.

[173] Ao Q, Li C, Niu B, et al. Distributed practical fixed-time resource allocation algorithm for disturbed multiagent systems: An integrated framework[J]. IEEE Transactions on Cybernetics, 2025.

[174] Lv Y, Lei J, Yi P. A local information aggregation-based multiagent reinforcement learning for robot swarm dynamic task allocation[J]. IEEE Transactions on Neural Networks and Learning Systems, 2025.

[175] Yuan J, Sun W, Sun Y, et al. Mask privacy preservation prescribed-time consensus control for nonlinear multi-agent systems[J]. IEEE Transactions on Automation Science and Engineering, 2025, 22: 11554-11563.

[176] Chu H, Yue D, Zhang W, et al. Comprehensively Privacy-Preserving Consensus of General Linear Multiagent Systems: An Isomorphism Transformation Approach[J]. IEEE Transactions on Automatic

Control, 2025.

[177] Huang J Y, Wei F F, Chen T Y, et al. Differential Privacy-Preserving Multi-Agent Swarm Optimization with Internal and External Learning for Consensus-Based Distributed Optimization[C]// International Conference on Neural Information Processing. 2025: 317-332.

攻读博士学位期间取得的研究成果

一、已发表（包括已接受待发表）的论文，以及已投稿、或已成文打算投稿、或拟成文投稿的论文情况**（只填写与学位论文内容相关的部分）：**

序号	作者（全体作者，按顺序排列）	题目	发表或投稿刊物名称、级别	发表的卷期、年月、页码	与学位论文哪一部分（章、节）相关	被索引收录情况
1	Chen, T.Y.; Chen, W.N.*; Wei, F.F.; Hu, X.M.; Zhang, J.	Multi-agent swarm optimization with adaptive internal and external learning for complex consensus-based distributed optimization	IEEE Transactions on Evolutionary Computation；中科院 SCI 一区 top，JCR 一区，自动化学会 A+，IF=12	Vol.29(4), 2024, pp.906–920	第三章	SCI
2	Chen, T.Y.; Chen, W.N.*; Hao, J.K.; Wang, Y.; Zhang, J.	Multiagent evolution strategy with cooperative and cumulative step adaptation for black-box distributed optimization	IEEE Transactions on Evolutionary Computation；中科院 SCI 一区 top，JCR 一区，自动化学会 A+，IF=12	Vol.29(6), 2025, pp.2819–2833	第四章	SCI

序号	作者（全体作者，按顺序排列）	题目	发表或投稿刊物名称、级别	发表的卷期、年月、页码	与学位论文哪一部分（章、节）相关	被索引收录情况
3	Chen, T.Y.; Chen, W.N.*; Guo, X.Q.; Gong, Y.J.; Zhang, J.	A multiagent co-evolutionary algorithm with penalty-based objective for network-based distributed optimization	IEEE Transactions on Systems, Man, and Cybernetics: Systems；中科院 SCI 一区 top，JCR 一区，自动化学会 A，IF=8.7	Vol.54(7), 2024, pp.4358–4370	第五章	SCI
4	Chen, T.Y.; Hu, X.M.; Lin, Q.; Chen, W.N.*	Multi-agent swarm optimization with contribution-based cooperation for distributed multi-target localization and data association	IEEE/CAA Journal of Automatica Sinica；中科院 SCI 一区 top，JCR 一区，计算机学会 T1，自动化学会 A+，IF=19.2	Vol.12, 2025, pp.1–16	第六章	SCI
5	Chen, T.Y.; Chen, W.N.*; Wei, F.F.; Wang, Y.	Decentralized Evolutionary Optimization for Multi-Target Tracking and Data Association with Bearing-only Measurements	IEEE INFOCOM 2025 - IEEE Conference on Computer Com-munications；CCF-A 类会议	2025, pp.1–10	第六章	EI

序号	作者（全体作者，按顺序排列）	题目	发表或投稿刊物名称、级别	发表的卷期、年月、页码	与学位论文哪一部分（章、节）相关	被索引收录情况
6	Chen, T.Y.; Wei, F.F.; Chen, W.N.*	Multi-Agent Swarm Optimization for Decentralized Energy Management Considering Game Behaviors of Electric Vehicles	GECCO '25: Proceedings of the Genetic and Evolutionary Computation Conference；CCF-C 类会议	2025, pp.1337–1344	第七章	EI
7	Chen, T.Y.; Chen, W.N.*; Wei, F.F.; Guo, X.Q.; Song, W.X.; Zhu, R.; Lin, Q.; Zhang, J.	The confluence of evolutionary computation and multi-agent systems: A survey	IEEE/CAA Journal of Automatica Sinica；中科院 SCI 一区 top，JCR 一区，计算机学会 T1，自动化学会 A+，IF=19.2	Vol.12(11), 2025, pp.2175–2193	第二章	SCI

二、与学位内容相关的其它成果（包括专利、著作、获奖项目等）

1. 授权专利：陈伟能，陈泰佑，龚月姣" 分布式传感器目标定位方法、装置及存储介质", CN115955656B, 2025-07-15
2. 教材：陈伟能，魏凤凤，邱文锦，耿明灿，陈泰佑，史宣莉，刘奕彤，杨果, " 并行分布式进化计算"，机械工业出版社, ISBN：978-7-111-78430-2, 2025-08-12